



2CDC - Hemijske osnove

Projektno usmerena hemija, kristalografija i cheminformatika za dve
2CDC aplikacije

Verzija izvora: **ba7bc0efe2c2**

Generisano: **05.09.2026.**

Objedinjeno izdanje za čitanje i štampu

Sadržaj

Početak

Naslovna	3
Kako se koristi knjiga	6
Šta projekat zapravo traži	8
Plan učenja	12
Dijagnostika i kriterijumi prolaza	15

I. Hemijski jezik

1. Atomi, elementi, joni i formule	17
2. Elektroni i hemijske veze	20
3. Molekulska geometrija i konformacija	24
4. Organska hemija koja nam treba	28

II. Koordinaciona hemija

5. Metali, ligandi i kompleksi	32
6. DAP Schiff-base motiv u ovom skupu	41

III. Od molekula do kristala

7. Intermolekulske interakcije	48
8. Kristal, rešetka i jedinična ćelija	57
9. Simetrija, prostorne grupe i periodičnost	68
10. Difrakcija, refiniranje i kvalitet	80
11. Polimorfi i druge čvrste forme	90
11A. Referentne raspodele, Mogul i HBP	99

IV. Digitalna hemija

12. CIF, MOL, MOL2, SDF i SMILES	105
12A. Anatomija jednog CIF fajla	110
13. Standardizacija bez gubitka značenja	114
14. Molekul kao graf i skup deskriptora	118
15. Sličnost nije jedna veličina	122

V. Prevod u dve aplikacije

16. CSD i ConQuest tok podataka	126
17. Forenzika dostavljenog skupa	130
18. Globalna pretraga	143
19. Precizno poređenje parova	146
20. Evaluacija i naučna validacija	151
21. Licence, FAIR i poreklo podataka	157
22. White paper tokovi i federativno učenje	164

Opcioni praktikum

Nastavne laboratorijske vežbe	169
Završna analiza bez implementacije	175
Rešenja i rubrike	179


Referenca

Brzi podsetnik	183
Rečnik pojmova	187
Opasne zablude	206
Izvori i metod validacije	216

Hemija koju 2CDC zaista traži

Ovo nije skraćeni fakultetski kurs hemije. Ovo je put od **nula predznanja** do sposobnosti da kao glavni ML inženjer donosiš naučno odbranjive odluke o sličnosti malih molekulskih kristalnih struktura.

Na kraju treba da umeš da pogledaš jedan CIF i razdvojiš najmanje pet pitanja koja se u svakodnevnom govoru sva zovu "da li su slični":



Dve strukture mogu imati istu formulu, a različit graf; isti graf, a različitu konformaciju; istu konformaciju, a različito pakovanje; ili gotovo isto pakovanje, ali različit kvalitet eksperimentalnog modela. Zato jedna univerzalna "hemijska udaljenost" ne postoji.

Veza sa dostavljenim projektom

Dostavljena specifikacija zahteva dva različita režima:

Režim	Primarni cilj	Razuman naučni obrazac
CIF protiv veoma velike baze	odziv i skalabilnost uz dobar odziv relevantnih kandidata	jeftini metapodaci i 2D/3D reprezentacije za dohvat, pa skuplje rangiranje
svi parovi u malom ulaznom skupu	maksimalno verodostojno poređenje	višeslojno poravnanje molekula, geometrije, pakovanja i interakcija

Lokalni CSD izvozi fokusirani su na 18-atomske DAP-derived query jezgre sa dve C=N veze i velikim brojem zapisa sa metalima. Zbog toga su koordinaciona hemija, donorni atomi, denticitet i geometrija oko metala obavezne teme za razumevanje dostavljenog materijala. Da li je taj slice i domen finalnog proizvoda ili samo primer ostaje pitanje za fakultet.

Put kroz knjigu

1. **Hemijski jezik** - atom, jon, formula, veza, formalno naelektrisanje, funkcionalna grupa i 3D geometrija.
2. **Koordinaciona hemija** - metal, ligand, donor, helat, koordinacioni broj i moguće geometrije.
3. **Kristalografija** - jedinična ćelija, frakcione koordinate, simetrija, periodičnost, difrakcija i kvalitet modela.
4. **Digitalna hemija** - šta CIF/MOL/MOL2/SDF/SMILES čuvaju, šta gube i zašto konverzija nije neutralna.
5. **Sličnost i aplikacije** - grafovi, otisci, deskriptori, poravnanje, pakovanje, evaluacija i dvofazna pretraga.

Ako želiš prvo da vidiš format nad kojim ćeš raditi, otvori [pun](#), [anotiran](#) i [parsabilan CIF primer](#). Za statistički deo polymorph-risk toka koristi [referentne raspodele](#), [Mogul](#) i [HBP](#). Za granice tvrdnji i teorijske teme dostavljenog dokumenta koristi [pregled obima white paper-a](#).

Svako poglavlje ima isti ritam: intuitivna slika, precizna definicija, primer iz projekta, zamka, mini-vežba i kriterijum prolaza. Linkovi vode ka izvorima samo kada je korisno pročitati standard, videti interaktivnu ilustraciju ili ući u detalj koji bi nepotrebno produžio ovu knjigu.

Brza slika lokalnih dokaza

Artefakt	Šta iz njega znamo
white paper, 22 strane	kvalitet i standardizacija struktura, veze struktura-svojstvo, FAIR, CSD alati, pakovanje, polimorfni rizik i federativno učenje
dve funkcionalnosti.txt	jedan skalabilni globalni pretraživač i jedan precizni poređivač svih parova
cu_n14_a.cif	pun eksperimentalni CIF: monoklinična ćelija, P 21/c, frakcione koordinate, refleksije, refiniranje i struktura kvaliteta pogodnog za vežbu
N14.mol / N14.mol2	ista hemijska jedinka u dve molekulske reprezentacije sa različitom semantikom tipova veza i atoma
search1.*	2.110 CSD zapisa iz lokalnog CSD 5.43/2022 snapshot-a koji zadovoljavaju podstrukturni upit za 18-atomsko DAP-derived jezgro sa dve C=N veze
search2.*	2.038 od tih zapisa uz nepovezani 4M uslov: metal je negde u entry-ju, ali query ne dokazuje metal-DAP koordinaciju
tutorial-minimal.cif	sintetički, redistributabilan CIF 1.1 primer za učenje sintakse; nije eksperiment ni CSD zapis

Bitna granica

Repo ne sadrži CSD izvoze. [CCDC uslovi korišćenja](#) navode da su CSD komponente i izvedeni podskupovi vlasnički i da se ne redistribuiraju bez odgovarajućeg odobrenja. Sam prijem lokalnih fajlova ne dokazuje njihovu licencu ni dozvoljenu namenu: do potvrde vlasnika/controller-a, dozvoljenih operacija i odobrenog data-plane-a tretiraju se kao **restricted**.

Šta je uspeh

Spreman si za projektovanje kada možeš bez nagađanja da:

- objasniš razliku između molekula, kristala i eksperimentalnog zapisa o kristalu;
- rekonstruišeš značenje ključnih CIF polja i prepoznaš problematične vrednosti;
- kažeš zašto 2D otisak ne meri kristalno pakovanje;

- definišeš odvojene relevantnosti za hemijski motiv, koordinaciono okruženje, konformaciju, pakovanje i interakcije;
- predložiš filtere, dohvat kandidata, precizno ponovno rangiranje i test-skup bez curenja skoro dupliranih CSD familija;
- svaku tvrdnju o "sličnosti" vežeš za eksplicitnu naučnu namenu i meru uspeha.

Počni od načina rada →

Kako se koristi ova knjiga

Ne čitaj pasivno

Hemijski pojmovi postaju korisni tek kada ih povežeš sa reprezentacijom podataka. Za svaku lekciju radi sledeći ciklus:

1. pročitaj intuitivni deo bez memorisanja;
2. zatvori stranicu i sopstvenim rečima objasni pojam u dve rečenice;
3. pronadi taj pojam u lokalnom CIF/MOL/MOL2 primeru;
4. uradi proveru bez gledanja rešenja;
5. zapiši jednu posledicu za dizajn aplikacije.

Ako ne možeš da odgovoriš na pitanje "koju grešku bi ovaj pojam sprečio u modelu?", gradivo još nije postalo operativno.

Oznake prioriteta

Oznaka	Značenje
MORAŠ	potrebno pre prve ozbiljne odluke o reprezentaciji ili metrici
TREBA	potrebno pre evaluacije prototipa i razgovora sa hemičarima/kristalografima
KASNIJE	korisno za istraživački rad, ali nije blokator prvog validnog sistema

Knjiga je poređana tako da se preduslovi uvode pre ili uz prvu upotrebu. Nemoj preskakati module 1–3 i 7–10. Celinu skрати ili preskoči samo ako već možeš da demonstriraš njen ishod iz [plana učenja](#); za šire grupe gradiva koristi [kontrolne kapije](#).

Kriterijum za prelazak

Prelazak na sledeću celinu zasniva se na izlaznim sposobnostima, ne na broju pročitanih stranica. Pređi dalje kada možeš samostalno da demonstriraš navedeni ishod, tačno uradiš odgovarajuću proveru ili laboratorijsku vežbu i objasniš ključne zamke. Ako neki ishod nije stabilan, vrati se na njegov preduslov u [planu učenja](#).

Kako se koriste spoljni linkovi

Postoje tri vrste izvora:

- **normativni** - IUCr CIF rečnici i IUPAC terminologija; njima verujemo za definicije;
- **primarni naučni** - originalni radovi za algoritme poput COMPACK-a ili ECFP-a;
- **didaktički** - recenzirani otvoreni udžbenici za dodatne primere i vežbu.

Ne moraš čitati svaki izvor od početka do kraja. Link "produbi" označava deo koji vredi otvoriti samo ako objašnjenje u knjizi nije dovoljno ili kada donosiš produkcionu odluku.

Lokalni fajlovi

Izvorni materijal je u `C:\Users\Korisnik\Desktop\2CDC`, a projekat u zasebnom, susednom folderu `C:\Users\Korisnik\Desktop\crystallography-and-ml-theory`. Unutar izvornog foldera nalaze se:

```
2CDC/
├─ CCDC_white_paper_sharpen.pdf
├─ cu_n14_a.cif
├─ N14.mol
├─ N14.mol2
├─ dve funkcionalnosti.txt
├─ Pretrage CSD/
│   ├─ 1 - Sifove baze DAP.cqs
│   ├─ 2 - Kompleksi sa DAP SB.cqs
│   ├─ search1.cif
│   ├─ search1.mol2
│   ├─ search1.sd
│   ├─ search1.smi
│   ├─ search2.cif
│   ├─ search2.mol2
│   ├─ search2.sd
│   └─ search2.smi
```

Originale tretiraj kao **read-only**. Za eksperimente pravi kopije u sopstvenom privremenom direktorijumu. Ne uploaduj CSD izvoze u javne servise za vizuelizaciju ili validaciju dok se ne proverí licenca i poverljivost.

Pravilo za pojednostavljenja

U uvodnoj hemiji modeli su namerno uprošćeni. Lewisova struktura, hibridizacija, parcijalno naelektrisanje i "tip veze" nisu fotografije elektronske gustine; to su korisne reprezentacije sa granicama. Svako poglavlje zato razdvaja:

- **posmatrano** - eksperimentalni podaci;
- **izvedeno** - vrednost izračunata iz podataka;
- **dodeljeno** - hemijska interpretacija softvera ili kustosa;
- **pretpostavljeno** - radna hipoteza modela.

Ta razlika je jedna od najvažnijih navika za ovaj projekat.

Šta projekat zapravo traži

Jedna reč, pet objekata


Reč "struktura" u projektu može značiti:

Objekat	Minimalna informacija	Primer pitanja
hemijski sastav	elementi i njihov broj	imaju li istu sumarnu formulu?
molekulski graf	atomi, veze, redovi veza, naelektrisanja	sadrže li isti DAP/Schiff-base motiv?
konformer	graf plus 3D raspored unutar molekula	da li se razlikuje torzioni ugao?
kristalna struktura	ćelija, simetrija, frakcione koordinate, periodičnost	pakuju li se molekuli na isti način?
eksperimentalni model	kristalna struktura plus poreklo, neizvesnost i kvalitet	da li je razlika realna ili posledica nereda/merenja?

To nisu zamenljive reprezentacije. SMILES uglavnom opisuje molekulski graf, MOL2 može čuvati 3D koordinate i dodeljene atom-tipove, a CIF može opisati periodični kristal i eksperiment. Konverzija CIF → SMILES odbacuje ćeliju i pakovanje; generisanje 3D koordinata iz SMILES-a stvara predikciju, ne vraća eksperimentalni kristal.

Dokazni lanac iz lokalnih fajlova

U dijagramu strelica iz white paper-a ka aplikacijama znači **relevantan princip ili problemski kontekst**, ne poreklo specifikacije. Dve aplikacije potiču iz lokalnog briefa; DAP/CQS i N14 su lokalni primeri čiju ulogu još potvrđuje fakultet.




White paper nije tehnička specifikacija algoritma. On pouzdano postavlja principe: kustosiranje, standardni atom- i bond-tipovi, dosledne jedinice, metapodaci, veze struktura-svojstvo i kontrola kvaliteta. Tvrdnje o konkretnim indeksima, vektorskoj bazi ili graf-neuronskoj mreži zato su **projektantske hipoteze** koje tek treba eksperimentalno proveriti.

4M je ConQuest grupa „all metals“, čija legacy definicija uključuje i Ge/Sb. To je uslov prisustva elementa u istom zapisu; nepovezani query atom ne dokazuje da je taj element koordinisan DAP motivu.

Dve aplikacije nisu isti sistem sa drugim dugmetom

A. Globalna pretraga

Za bazu reda miliona struktura ne može se za svaki upit odmah raditi najskuplje kristalno poravnanje sa svakim zapisom. Coarse-to-fine kaskada je važan algoritamski koncept, ali ovaj dijagram ne propisuje budući stack ili redosled njegove izrade:



Filter nije samo optimizacija. Pitanje "sličan u kom smislu?" određuje da li smeju da se mešaju organska jedinjenja i metalni kompleksi, soli i neutralne forme, polimerne i diskretne strukture, uređeni i neuređeni modeli ili merenja veoma različitog kvaliteta.

B. Poređenje svih parova

Za n ulaza postoji $n(n - 1)/2$ neuređenih parova. Deset fajlova daje 45, sto daje 4.950, a hiljadu 499.500 parova. "Mali skup" zato nije dozvola za neograničen algoritam.

Primer sa fajlovima pretpostavlja po jedan izabrani strukturni zapis iz svakog fajla. CIF može imati više data blokova: najpre odredi koji se blokovi porede, pa n računaj nad tim ulazima, kako objašnjava [poglavlje o svim parovima](#).

Ovde ipak možemo koristiti bogatiji profil:

- identitet i zajednički podgraf;
- koordinaciono okruženje metala;
- dužine veza, uglove i torzije uz neizvesnost;
- 3D poravnanje konformera;
- lokalna pakovanja i periodični susedi;
- mreže vodoničnih i drugih usmerenih interakcija;
- po potrebi simulirani difrakcioni obrazac.

Rezultat treba da bude **vektor objašnjenja**, ne samo jedan skor. Jedna agregatna vrednost može postojati za rangiranje, ali korisnik mora videti zašto je par visoko rangiran.

Najveći naučni rizici

1. **Pogrešna jedinica poređenja.** CSD entry, CIF data block, komponenta, molekul, formula unit i kristal nisu sinonimi.
2. **Lažna preciznost.** RMSD bez definicije atomskog mapiranja, periodične slike, superpozicije i tretmana vodonika nema stabilno značenje.
3. **Informacioni gubitak.** Format-konverzija može promeniti aromatičnost, red veze, protonaciju, koordinacionu vezu ili stereokemiju.
4. **Loš kvalitet kao signal sličnosti.** Disorder, parcijalna occupancy ili propušteni H atomi mogu dominirati deskriptorom.
5. **Curenje familija.** Različiti CSD refkodovi iz iste publikacije, redeterminations ili polimorfne familije mogu završiti i u treningu i u testu.
6. **Neodređen ground truth.** Dva stručnjaka mogu pod "slično" misliti na isti ligand, isti metalni poliedar ili isto pakovanje.
7. **Licenca.** Tehnički moguć izvoz i indeksiranje nisu automatski pravno dozvoljeni za novu aplikaciju.

Sledeća poglavlja grade znanje potrebno da se rizici razumeju i da se jednog dana mogu pretvoriti u proverljive zahteve, tek nakon odgovora fakulteta.

Plan učenja


Ovo je redosled hemijskog i kristalografskog gradiva. Za paralelni ML/AI tok — sa prioritetima gradiva, hemijskim preduslovima i proverama razumevanja — koristi [plan učenja ML/AI dela za 2CDC](#).

Preporučeni redosled gradiva

Celina	Fokus	Ishod koji moraš demonstrirati
Osnove materije	atomi, elementi, joni, formule, količine i jedinice	čitaš formulu i razlikuješ element, atom, jon, molekul i formula unit
Hemijska povezanost	elektroni, valenca, Lewis, veze, formalni naboj i rezonanca	crtáš jednostavan graf i objašnjavaš zašto bond order može biti dodela
Prostorna građa	3D geometrija, polaritet, stereokemija, konformeri	meriš i tumačiš dužinu, ugao, torziju, RMSD i hiralnost
Organski motivi	funkcionalne grupe, aromatičnost, kiselina/baze, tautomeri	prepoznaješ projektno relevantne grupe i normalizacije rizike
Koordinacio na hemija	koordinaciona hemija i minimalno ligandno polje	određuješ metal, donor, ligand, denticitet, oxidation state/ d^n , spin/Jahn–Teller hipotezu i geometriju bez preteranog zaključka
DAP domen	DAP/Schiff-base domen i lokalni upiti	rekonstruišeš nameru <code>search1</code> i <code>search2</code> bez mešanja motiva i metalnog uslova
Kristalne interakcije	intermolekulske interakcije i pakovanje	razlikuješ intra/intermolekulsko i gradiš lokalni interaction graph
Periodična ćelija	ćelija, 7 sistema/14 Bravaisovih tipova, frakcione koordinate i PBC	normalizuješ system/setting i rekonstruišeš periodične susede bez metričke/simetrijske zabune
Kristalna simetrija	simetrija, space group, ASU, Z/Z'	čitaš P 21/c i razlikuješ ASU, ćeliju i superćeliju
Difrakcija i kvalitet	reciprocal space, hkl , XRD/PXRD, refiniranje, neizvesnost i kvalitet	izvodiš $hkl \rightarrow d \rightarrow 2\theta$, razlikuješ simulated/measured PXRD i tumačiš <code>cu_n14_a.cif</code> bez jednog „quality“ praga
Čvrste forme	čvrste forme, referentne raspodele, Mogul i HBP	formiraš solid-form familije i tumačiš outlier/propensity/grouping bez prevođenja u energiju ili polymorph verovatnoću
Formati podataka	formati, puna CIF anatomija i standardizacija	čitaš ceo sintetički CIF i praviš tabelu očuvane/izgubljene informacije pri svakoj konverziji
Strukturna sličnost	grafovi, deskriptori i hijerarhijska sličnost	biraš reprezentaciju i metriku prema pitanju, ne prema popularnosti modela
Projektni kontekst	obe aplikacije, evaluacija, licenca i FAIR	projektuješ retrieval/rerank i pair-comparison tok sa leakage-safe evaluacijom i dozvoljenim data plane-om
Završna sinteza	svih 22 strana white paper-a, lifecycle/FL granice i završni mini-projekat	braniš state contract, evidence granice i kompletan protokol pred hemičarem, kristalografom i ML recenzentom

Redosled je pedagoški: svaka celina uvodi preduslove za one koje slede. Prelazak se zasniva na demonstriranom ishodu, a sastavni deo putanje ostaju tri obavezne remediation strane: [11A — referentne raspodele/HBP](#), [12A — pun CIF](#) i [22 — potpuna white-paper mapa](#).

Zavisnosti između modula



Šta svesno ne učimo sada

Sledeće oblasti nisu deo obaveznog gradiva na uvodnom nivou ove putanje učenja:

- detaljni mehanizmi organskih reakcija i laboratorijska sinteza;
- kompletna termodinamika gasova i rastvora;
- kvantnohemijske derivacije Hartree-Fock/DFT metoda;
- spektroskopija NMR/IR/MS osim osnovne svesti o izvoru podataka;
- biohemija, enzimska kinetika i makromolekulska kristalografija;
- detaljno rešavanje strukture iz sirovih difrakcionih slika, iako učimo potreban reciprocal/PXRD interpretativni most;
- memorisanje svih 230 prostornih grupa;
- crystal/ligand-field teorija u dubini, multipleti, spektroskopija i magnetizam; obavezni minimum d -cepanja, spin/Jahn–Teller i strukturne posledice ipak ostaje;
- reakcioni SMIRKS i predikcija reakcija;
- generativna kristalna struktura kao primarni cilj.

Ove teme se vraćaju samo ako ih konkretan zahtev, podatak ili hipoteza u projektu učini relevantnim.

Ritual nakon završene celine

Nakon svake završene celine napravi jednu stranicu beležaka sa tačno četiri sekcije:

1. **Znam da objasnim** - najviše pet pojmova.
2. **Znam da izmerim/izvučem** - polja ili deskriptori iz fajla.
3. **Još mogu da pogrešim** - konkretna zamka.
4. **Posledica za arhitekturu** - jedna odluka ili eksperiment.

To postaje projektantski dnevnik i kasnije deo metodologije disertacije.

Dijagnostika i kriterijumi prolaza

Ovo nije test inteligencije nego usmerivač. Odgovori bez pretrage. Ako ne znaš, napiši "ne znam"; upravo tome kurs služi.

Ulazna provera

1. Koja je razlika između atoma N, molekula N₂ i jona N³⁻?
2. Da li ista sumarna formula garantuje isti molekulski graf?
3. Šta linija između dva atoma u hemijskom crtežu predstavlja, a šta ne predstavlja?
4. Zašto su ugao C-A-B i torzija A-B-C-D različiti objekti?
5. Može li isti molekul imati više stabilnih 3D konformacija?
6. Šta je ligand i da li koordinacioni broj mora biti jednak broju liganada?
7. Da li "Cu" u nazivu fajla dokazuje da struktura sadrži bakar?
8. Šta se periodično ponavlja u kristalu?
9. Zašto atom sa frakcionom koordinatom 1.02 nije nužno van kristala?
10. Da li dva CIF-a sa različitim parametrima ćelije moraju opisivati različito pakovanje?
11. Šta vrednost 12.7138(3) govori o neizvesnosti?
12. Da li niz SMILES pouzdano čuva kristalno pakovanje?
13. Zašto se aromatična veza može drugačije zapisati u dva validna formata?
14. Šta Tanimoto sličnost meri ako je ulaz Morgan/ECFP bit-vektor?
15. Zašto nizak R faktor nije dokaz da je hemijski model potpuno tačan?
16. Kako sprečiti da bliski redeterminations iste strukture procure u trening i test?

Početni rezultat od 0 je očekivan. Rezultat se ne koristi za preskakanje kristalografije; koristi se samo da skрати osnovne hemijske vežbe koje već pouzdano radiš.

Kontrolne kapije

Kapija A - hemijski graf

Prolaz kada možeš da:

- iz formule razlikuješ sastav od povezanosti;
- odrediš uobičajenu valencu i formalno naelektrisanje u jednostavnim primerima;
- objasniš rezonancu bez tvrdnje da molekul "skače" između crteža;
- označiš funkcionalne grupe i potencijalne donor/acceptor atome u N14.

Kapija B - 3D i koordinacija

Prolaz kada možeš da:

- izračunaš dužinu, ugao i torziju iz koordinata;
- razlikuješ konformer, konfiguracioni izomer i polimorf;
- za kompleks odrediš donorne atome, denticitet, koordinacioni broj i približnu geometriju;
- objasniš zašto metal-ligand "bond order" nije uvek jednostavan ceo broj.

Kapija C - kristalni model

Prolaz kada možeš da:

- iz $a, b, c, \alpha, \beta, \gamma$ formiraš matricu ćelije;
- pretvoriš frakcione koordinate u kartezijanske i primeniš periodic boundary conditions;
- objasniš asymmetric unit, space group, Z i Z' ;
- protumačiš occupancy, disorder, s.u., R , wR i goodness-of-fit bez rigidnih univerzalnih pragova.

Kapija D - projektovanje sličnosti

Prolaz kada možeš da:

- napišeš najmanje tri različite definicije relevantnosti za isti par CIF-ova;
- navedeš informaciju koju svaki format gubi;
- projektuješ dvofazni retrieval/reranking tok;
- napraviš evaluacione splitove po hemijskim i kristalnim familijama;
- prikažeš korisniku komponente skora i neizvesnost.

Završni usmeni test

Uzmi dva lokalna CIF zapisa i objasni:

1. šta je sigurno zapisano;
2. šta je hemijski dodeljeno;
3. šta treba standardizovati;
4. u kojim su slojevima slični;
5. koje razlike mogu biti artefakti eksperimenta;
6. koja bi mera bila prikladna za globalni dohvat, a koja za precizno poređenje.

Ako odgovor može da prati i hemičar i ML inženjer, cilj kursa je postignut.

1. Atomi, elementi, joni i formule

Prioritet: MORAŠ. Ovo poglavlje postavlja rečnik bez kog se CIF polja, atom-tipovi i filteri lako pogrešno tumače.

1.1 Šta je šta

Element je vrsta atoma određena brojem protona u jezgru, odnosno atomskim brojem Z . Svaki atom sa 6 protona je ugljenik (C); sa 7 je azot (N); sa 8 kiseonik (O). Broj neutrona može da se razlikuje - to su izotopi istog elementa.

Atom je pojedinačna elektroneutralna jedinka kada ima isti broj protona i elektrona. Ako izgubi ili primi elektrone postaje **jon**:

- kation ima pozitivan neto naboj, npr. Na^+ ;
- anion ima negativan neto naboj, npr. Cl^- .

Molekul je elektroneutralna, diskretna jedinka od najmanje dva atoma povezana hemijskim vezama. Analogna diskretna jedinka od više atoma sa neto nabojem je **poliatomski jon**. **Jedinjenje** je supstanca sastavljena od najmanje dva elementa. Nisu sva jedinjenja diskretni molekuli: za beskonačnu jonsku rešetku NaCl korisnije je govoriti o **formula unit**, najjednostavnijem stehiometrijskom odnosu $\text{Na}:\text{Cl} = 1:1$.

Formula nije graf

Formula $\text{C}_2\text{H}_6\text{O}$ govori da jedinka sadrži dva C, šest H i jedan O. Ne govori da li je povezanost etanol $\text{CH}_3\text{CH}_2\text{OH}$ ili dimetil-etar CH_3OCH_3 . To su konstitucioni izomeri. Filter po formuli zato nije zamena za podstrukturu ili graf-sličnost.

Za vizuelan uvod pogledaj [OpenStax: atomska struktura i simboli i hemijske formule](#).

1.2 Periodni sistem kao mapa ponašanja

Ne treba da pamtiš ceo periodni sistem. Za ovaj projekat prvo prepoznaj:

Grupa	Projektno značenje
H	često implicitno izostavljen; određuje protonaciju, H-veze i stereokemiju
C	osnovni skelet organskih liganada
N, O, S, P	česti heteroatom; lone pairs, donor/acceptor uloge, promenljive valence i naboji
F, Cl, Br, I	halogeni; supstituenti, anioni, ligandi i potencijalne halogene interakcije
alkalni/zemnoalkalni metali	jonske soli i koordinacija, često visoki koordinacioni brojevi
prelazni metali	više oksidacionih stanja i koordinacionih geometrija; centralni za <code>search2</code>
lantanoidi/aktinoidi	visoki i promenljivi koordinacioni brojevi; ređi, ali <code>4M</code> ih ne isključuje

Pozicija u tabeli pomaže da proceniš broj valentnih elektrona i tipične naboj, ali kod prelaznih metala to nije pouzdana funkcija same grupe. [OpenStax pregled jonskih i molekulskih jedinjenja](#) eksplicitno pokazuje zašto Cu može imati, na primer, +1 ili +2.

1.3 Tri vrste "naboja" koje ne treba mešati

1. **Neto naboj jedinice** - zbir svih naboja; npr. kompleks može biti 2+.
2. **Formalni naboj atoma** - knjigovodstvena dodela elektrona u Lewisovom modelu.
3. **Parcijalni naboj** - model kontinuirane, nejednake raspodele elektronske gustine; zavisi od metode dodele.

MOL2 kolona `charge` obično sadrži parcijalni naboj samo ako je neka charge metoda zaista primenjena. U lokalnom `N14.mo12` zaglavlje kaže `NO_CHARGES`, a kolona sadrži nule. To ne znači da su svi atomi fizički nepolarni; znači da parcijalni naboji nisu dodeljeni.

1.4 Količina supstance, masa i skale

Jedan mol sadrži Avogadrov broj jedinki:

$$N_A = 6.02214076 \times 10^{23} \text{ mol}^{-1}.$$

Molarna masa izražava se u g mol^{-1} . Lokalni CIF navodi:

```
_chemical_formula_sum      'C25 H20 N3 O2 P'  
_chemical_formula_weight   425.41
```

Vrednost 425,41 g/mol je zbir prosečnih atomskih masa u formuli. Kristalografska gustina povezuje molarnu masu M , broj formula jedinki Z i zapreminu ćelije V ; kompletan N14 račun, konverzija $\text{\AA}^3 \rightarrow \text{cm}^3$ i granice ove provere dati su u [Gustina kao provera konzistentnosti](#).

Jedinice koje moraš trenutno prepoznati

Veličina	Uobičajena jedinica	Napomena
atomsko rastojanje	Å (angstrom)	$1 \text{ Å} = 10^{-10} \text{ m} = 0.1 \text{ nm}$
ugao	stepen	ćelijski i molekulski uglovi
temperatura	K	$T[\text{K}] = t[^\circ\text{C}] + 273.15$
molarna masa	g/mol	nije masa jednog molekula
gustina	g/cm ³	CIF može navesti izmerenu i izračunatu
energija	kJ/mol	poređenje energija po molu

1.5 Primer koji razbija pretpostavku iz naziva fajla

Fajl se zove `cu_n14_a.cif`, ali sumarna formula nema Cu atom. `Cu` se pojavljuje u:

```
_diffrn_radiation_type      CuK\alpha  
_diffrn_radiation_wavelength 1.54178
```

To označava karakteristično **Cu Kα rendgensko zračenje** korišćeno u merenju, ne bakar u uzorku. Ime fajla i slobodan tekst nikada ne smeju imati veći autoritet od semantičkih polja i atomskih zapisa.

1.6 Posledice za aplikacije

Globalna pretraga: element-set, formula, prisustvo metala i neto naboj su jeftini filteri, ali nisu dovoljan dokaz hemijskog identiteta. 4M je ConQuest grupa „bilo koji metal“, ne samo prelazni metal. To je operativna taksonomija alata: uključuje i Ge i Sb, koji se u školskim podelama često svrstavaju u metaloide; [precizna definicija i lokalno brojanje](#) moraju ostati vezani za isti skup elemenata.

Poređenje parova: sastav treba prikazati kao odvojenu komponentu sličnosti. Razlika u H broju može biti eksplicitnost formata, protonacija, disorder ili prava hemijska razlika; ne kažnjava se automatski bez standardizacije.

1.7 Provera znanja

1. Da li su Fe^{2+} i Fe^{3+} isti element? Da li su ista hemijska vrsta?
2. Koliko ukupno atoma navodi formula $\text{C}_{25}\text{H}_{20}\text{N}_3\text{O}_2\text{P}$? Koliko je heavy atoms?
3. Čelija sadrži $Z = 4$, a formula ima tri N. Koliko N atoma odgovara punoj idealnoj ćeliji?
4. Zašto filter "sadrži Cu" ne sme pretraživati ceo tekst CIF-a?
5. Šta `NO_CHARGES` u MOL2 znači, a šta ne znači?

Odgovori

1. Da: oba imaju 26 protona, pa su Fe. Ne: razlikuju se brojem elektrona i nabojem, pa nisu ista hemijska vrsta.
2. Ukupno 51; heavy atoms su svi osim H, dakle 31.
3. $4 \times 3 = 12$.
4. Jer se `Cu` može odnositi na izvor zračenja, autora, softver ili komentar. Elementi se izvode iz hemijskih/atomske polja.
5. Parcijalni naboji nisu dodeljeni/zapisani; ne tvrdi da nema formalnih naboj, polarnih veza ili nejednake elektronske gustine.

Kriterijum prolaza: bez gledanja objasni razliku element - atom - jon - molekul - formula unit - kristal i za lokalni CIF prepozna značenje M , Z i V , navedi jedinice za M i V i objasni da je Z bezdimenzioni broj formulskih jedinki. Kompletan račun pripada [poglavljju 8](#).

2. Elektroni i hemijske veze

Prioritet: MORAŠ. Softver ne vidi "hemiju" direktno. On vidi elemente, koordinate i dodeljene veze; kvalitet tih dodela određuje graf, podstrukturu pretragu i fingerprint.

2.1 Minimalni model elektrona

Za ovaj projekat dovoljno je sledeće:

- elektroni zauzimaju kvantna stanja/orbitale, ne kružne putanje kao planete;
- spoljašnji, valentni elektroni dominantno određuju uobičajene veze;
- atomi dele ili formalno prenose elektrone da bi formirali stabilnije celine;
- elektronska gustina je kontinuirana, dok su red veze i formalni naboj diskretni modeli.

Elektronegativnost opisuje sklonost vezanog atoma da privlači elektronsku gustinu. Razlika može dati nepolarnu/polarnu kovalentnu ili pretežno jonsku vezu, ali granice nisu oštre. U kristalima i koordinacionim kompleksima "jonsko naspram kovalentno" često je spektar, ne binarna etiketa.

2.2 Lewisova struktura

Lewisov crtež prati valentne elektrone kao:

- crte između atoma - deljeni elektronski parovi;
- tačke na atomu - nevezani parovi (lone pairs);
- zagrade i superskript - neto naboj jedinke.

Za elemente druge periode C, N, O i F korisno je pravilo okteta, ali ono ima izuzetke. Metali, elektron-deficitarne i hipervalentne vrste ne treba siliti u jednostavan organski obrazac.

OpenStax Lewisov uvod daje postupak za jednostavne vrste.

2.3 Formalni naboj

Za atom u jednoj Lewisovoj formi:

$$q_{\text{formal}} = V - N - \frac{B}{2},$$

gde je V broj valentnih elektrona slobodnog atoma, N broj nevezanih elektrona, a B broj elektrona u vezama.

Formalni naboj je konzistentno knjigovodstvo, ne direktno izmerena lokalna količina. Zbir formalnih naboja mora dati neto naboj jedinke. Ovo je važno kod protonacije, soli, nitro-grupa i metalnih kompleksa.

2.4 Red veze i rezonanca

U osnovnom modelu:

- single bond deli jedan elektronski par;
- double dva;
- triple tri.

Višestruka veza je obično kraća i jača od odgovarajuće jednostruke, ali "obično" zavisi od istih elemenata i sličnog okruženja.

Zašto se kasnije pojavljuju σ , π i konjugacija

U osnovnom orbitalnom modelu **σ -veza** nastaje preklapanjem orbitala duž ose između jezgara, dok **π -veza** uključuje bočno preklapanje, sa elektronskom gustinom sa obe strane te ose. Obična jednostruka veza ima jedan σ doprinos, dvostruka jedan σ i jedan π , a trostruka jedan σ i dva π doprinosa. To objašnjava zašto je rotacija oko izolovane dvostruke veze ograničena: menja se preklapanje π -orbitala.

Konjugacija znači da susedne odgovarajuće orbitale mogu povezati da se preklapaju preko više atoma, kao u nizu $C=C-C=C$. Elektroni tada nisu opisani samo jednim izolovanim parom atoma. To je most ka rezonanci, aromatičnosti i rigidnosti amida, a ne dodatna vrsta bond koda u fajlu. [OpenStax: višestruke veze](#) ilustruje σ/π preklapanje.

Neke vrste ne može verno opisati jedna Lewisova forma. Kod **rezonance** više crteža ima isti raspored jezgara, a različitu formalnu raspodelu elektrona. Prava vrsta ne skače između crteža; elektronska struktura je rezonantni hibrid. [OpenStax objašnjenje rezonance](#) pokazuje zašto jednake N-O dužine u nitritu ne odgovaraju jednoj fiksnoj single i jednoj double vezi.

Lokalni dokaz

U `N14.mol2` rastojanja od N1 do O1 i O2 su praktično jednaka:

Par	Rastojanje iz koordinata
N1-O1	1,22731 Å
N1-O2	1,22732 Å

Ipak, oba MOL2 bond zapisa imaju tip `1`, dok je N atom tipovan kao `N.3`, a O kao `O.2`. Ti tipovi zajedno nisu valenciono dosledan Lewisov prikaz neutralne nitro-grupe. To je problem eksportovanog atom/bond typing-a koji treba proveriti, a ne alternativna, jednako valjana Lewisova forma.

Za nitro-grupu vezanu za organski ostatak R dve uobičajene rezonantne forme su $R-N^+(=O)-O^-$, uz zamenu uloga dva O atoma u drugoj formi. N ima četiri vezna para i formalni naboj +1, jednostruko vezani O ima -1, a dvostruko vezani O nulu; grupa je ukupno neutralna. Rezonanca objašnjava delokalizaciju i slične N-O dužine, ali sama dužina ne određuje jedinstvenu digitalnu dodelu veza i naboja. Standardizacija treba da sačuva original, proveriti ceo motiv i zabeleži korekciju pre računanja fingerprinta ili donor/acceptor etiketa.

2.5 Aromatičnost

Aromatični sistemi imaju cikličnu delokalizaciju elektrona i karakterističnu geometriju/stabilnost. U klasičnim organskim primerima koristi se Hückelovo $4n + 2$ pravilo za planarni konjugovani ciklus. Za cheminformatiku je još važnije:

aromatičnost u fajlu je rezultat određenog modela i algoritma percepcije.

Isti benzenski prsten može biti zapisan kao tri naizmenične single/double veze (Kekulé forma) ili aromatične veze. [Daylight Theory Manual](#) izričito razlikuje hemijski pojam od pravila aromatičnosti namenjenog digitalnom jeziku.

Posledica: fingerprint ili substructure query može da se promeni samo zato što dva parsera koriste druga pravila aromatičnosti.

2.6 Kovalentna, jonska i koordinaciona veza

- **Kovalentna veza:** atomi dele elektronsku gustinu.
- **Jonska interakcija:** privlačenje suprotnih neto naboja; u kristalu je mreža, ne izolovana crta.
- **Koordinaciona (dativna) veza:** u Lewisovom formalizmu oba elektrona deljenog para potiču od donora/liganda. Kada se formira, nije zasebna fizička "vrsta crte" koju svaki format jednoznačno čuva.

Metal-ligand i metal-metal veze su naročito problematične za jednostavan integer bond order. CCDC dokumentacija preporučuje standardizaciju atom- i bond-tipova pre geometrijske analize; [CSD Python API primer](#) eksplicitno poziva dodelu unknown bond tipova i standardizaciju aromatičnih/delokalizovanih veza.

2.7 Eksplicitni i implicitni vodonici

Vodoničnik može biti:

- poseban atomski čvor sa koordinatama;
- implicitni broj vezan za heavy atom;
- nedostajući atom koji parser pokušava da doda prema valenci;
- eksperimentalno rafiniran, geometrijski postavljen ili delimično određen.

To menja molekulsku formulu, donor/acceptor svojstva, formalni naboj, stereokemiju i mrežu H-veza. "Remove hydrogens" nije bezazlena kozmetička transformacija.

2.8 Veza u fajlu nije nužno posmatrana veličina

Kod rendgenske kristalografije direktno se meri difrakcija, iz nje se modeluje elektronska gustina i položaji atoma, a hemijska povezanost/redovi veza se zatim dodeljuju uz hemijsko znanje. CIF može imati geometrijske bond liste, ali kristalografski minimum nisu nužno eksplicitni integer bond orders. CCDC zato navodi da su MOL2/SDF prikladniji kada je cilj molekulska informacija, dok CIF čuva kristalni kontekst: [Reading and writing molecules and crystals](#).

2.9 Posledice za aplikacije

Pre bilo kog fingerprinta: definiši politiku za formalne naboje, protonaciju, implicitne H, aromatičnost, delokalizovane i metal-ligand veze. Čuvaj i original i standardizovanu reprezentaciju, uz verziju softvera i upozorenja.

Za poređenje: odvoji "ista povezanost pod našom normalizacijom" od "isti zapis bond tipova". Neslaganje parsera mora biti dijagnostika, ne automatski hemijska razlika.

2.10 Provera znanja

1. Izračunaj formalni naboj O sa tri lone pairs i jednom single vezom.
2. Da li dve rezonantne forme predstavljaju dva konformera?
3. Zašto tri alternating single/double veze i šest aromatic bonds mogu opisivati isti prsten?
4. Šta može poći pogrešno ako automatski dodaš H pre određivanja neto naboja?
5. Da li nulta MOL2 parcijalna charge kolona dokazuje da je veza nepolarna?

Odgovori

1. Za O je $V = 6$, $N = 6$, $B = 2$, pa $q = 6 - 6 - 1 = -1$.
2. Ne. Raspored jezgara je isti; razlikuje se formalni elektronski crtež. Konformeri imaju različit 3D raspored usled rotacija/oblikovanja.
3. Prvi je Kekulé reprezentacija, drugi aromatična percepcija iste delokalizovane mreže.
4. Možeš dobiti pogrešnu protonaciju, valencu, formulu, donor/acceptor etikete i graf.
5. Ne; može samo značiti da charges nisu izračunate ili zapisane.

Kriterijum prolaza: uz jedan lokalni zapis jasno označi šta je element, koordinata, dodeljeni atom-tip, dodeljeni bond tip, formalni naboj i parcijalni naboj.

3. Molekulska geometrija i konformacija

Prioritet: MORAŠ. Kristalni podaci su trodimenzionalni. Graf kaže ko je povezan; geometrija kaže kako su atomi raspoređeni.

3.1 Od Lewisovog crteža do 3D

Elektronski parovi se prostorno raspoređuju. Jednostavan VSEPR model predviđa osnovne geometrije glavne grupe:

Broj elektronskih domena	Idealni raspored	Tipičan ugao
2	linearan	180°
3	trigonalno planaran	120°
4	tetraedarski	109,5°

Elektronski domen je jedan pravac vezivanja ili jedan nevezani par oko centralnog atoma; jednostruka, dvostruka i trostruka veza prema jednom susedu računaju se svaka kao jedan domen. Tabela opisuje raspored domena. Oblik molekula opisuje samo položaje atoma: CH₄ ima tetraedarski oblik, NH₃ trigonalno-piramidalni, a H₂O savijeni, iako u sva tri primera centralni atom ima četiri domena. Zato broj domena nije isto što i broj vezanih atoma.

Lone pairs odbijaju drugačije od bonding pairs, pa stvarni uglovi odstupaju. Hibridizacije `sp`, `sp2`, `sp3` su koristan model lokalne geometrije i vezivanja, ali nisu dovoljne za sve metale ili delokalizovane sisteme. [OpenStax: molekulska struktura i polaritet](#) daje vizuelne primere.

3.2 Tri osnovne geometrijske veličine

Za kartezijanske koordinate $\mathbf{r}_i = (x_i, y_i, z_i)$:

Dužina

$$d_{ij} = \|\mathbf{r}_j - \mathbf{r}_i\|_2.$$

U lokalnom N14 primeru C1-C2 je približno 1,386 Å, dok je C1-N1 približno 1,468 Å. Broj sam nema značenje bez elemenata, bond tipa, hemijskog okruženja, temperature i neizvesnosti.

Ugao

Za A-B-C, vrh je B. Ako su $\mathbf{u} = \mathbf{r}_A - \mathbf{r}_B$ i $\mathbf{v} = \mathbf{r}_C - \mathbf{r}_B$:

$$\theta = \arccos\left(\frac{\mathbf{u} \cdot \mathbf{v}}{\|\mathbf{u}\| \|\mathbf{v}\|}\right).$$

Promena redosleda atoma može promeniti koji je atom vrh; naziv ugla zato mora čuvati atom mapping.

Torzioni (dihedral) ugao

Za A-B-C-D poredi se ravni ABC i BCD. Potpisani ugao je tipično u opsegu $(-180^\circ, 180^\circ]$. On opisuje rotaciju oko centralne veze B-C i presudan je za konformaciju. Zbog kružne prirode, prosečna vrednost uglova $+179^\circ$ i -179° nije 0° ; potrebna je circular statistics.

Za račun iz koordinata postavi $\mathbf{b}_1 = \mathbf{r}_B - \mathbf{r}_A$, $\mathbf{b}_2 = \mathbf{r}_C - \mathbf{r}_B$, $\mathbf{b}_3 = \mathbf{r}_D - \mathbf{r}_C$ i normale $\mathbf{n}_1 = \mathbf{b}_1 \times \mathbf{b}_2$, $\mathbf{n}_2 = \mathbf{b}_2 \times \mathbf{b}_3$. Jedna eksplicitna konvencija je:

$$\phi = \text{atan2} \left(\frac{\mathbf{b}_2}{\|\mathbf{b}_2\|} \cdot (\mathbf{n}_1 \times \mathbf{n}_2), \mathbf{n}_1 \cdot \mathbf{n}_2 \right).$$

`atan2(y, x)` čuva kvadrant i znak; rezultat u radijanima pretvara se u stepene množenjem sa $180/\pi$. Ako su A–B–C ili B–C–D kolinearni, odgovarajuća normala je nula i torzija nije definisana. Na primer, za A=(0,1,0), B=(0,0,0), C=(1,0,0), D=(1,0,1) gornja konvencija daje $+90^\circ$. Red atoma i konvenciju znaka treba zabeležiti pre poređenja sa drugim alatom.

3.3 Konstitucija, konfiguracija i konformacija

Pojam	Šta se razlikuje	Da li obična rotacija oko single veze pomaže?
konstitucioni izomer	povezanost atoma	ne
konfiguracioni stereoizomer	prostorni raspored koji se ne menja običnom slobodnom rotacijom; interkonverzija zahteva prolazak kroz dovoljno visoku barijeru	ne
konformer	3D oblik istog grafa/konfiguracije	često da; u prstenu su promene torzija međusobno povezane

„Zahteva kidanje veze“ korisna je intuicija za neke konfiguracione promene, ali nije univerzalna definicija. Na primer, inverzija piramidalnog N može promeniti prostorni raspored bez raskida sigma veze, dok ograničena rotacija može dati izolabilne atropizomere. Razlika konfiguracija–konformacija zato zavisi i od mehanizma, energetske barijere i vremenske skale posmatranja.

Hirnost

Objekat je hiralan ako se ne može poklopiti sa sopstvenom slikom u ogledalu. Par takvih stereoizomera su enantiomeri. Za poređenje je važno da algoritam ne dopusti refleksiju ako apsolutna konfiguracija treba da ostane različita.

E/Z i cis/trans

Ograničena rotacija oko double veze može dati različite konfiguracije. SMILES, MOL/SDF i CIF ne čuvaju stereokemiju na isti način; prazna stereo oznaka ne mora značiti da je molekul ahiralan, već da informacija nije određena ili nije preneti.

Za alken čija oba C atoma nose po dva različita supstituenta, E/Z oznaka se dobija poređenjem prioriteta po Cahn–Ingold–Prelog (CIP) pravilima na svakom kraju dvostruke veze. Viši atomski broj neposredno vezanog atoma daje viši prioritet; izjednačenje zahteva poređenje sledećih suseda po tim pravilima. Dve grupe višeg prioriteta na istoj strani daju **Z**, a na suprotnim stranama **E**. Prioritet nije isto što i prostorna veličina grupe. Cis/trans opisuje odnos izabranih grupa i nije univerzalna zamena za E/Z. [OpenStax: E/Z označavanje](#) daje postupak i primere.

3.4 Konformaciona energija nije kristalna stabilnost

Rotacija menja steričke sudare, konjugaciju, intramolekulske H-veze i energiju izolovanog molekula. U kristalu molekul može prihvatiti više-energy konformer ako time dobija povoljnije intermolekulske kontakte i pakovanje.

Zato:

niža energija konformera $\nRightarrow$ stabilniji kristal bez dodatne analize.

CCDC-ov [Molecular Geometry Analysis](#) poredi bond lengths, valence angles, torsions i ring conformations sa hemijski klasifikovanim CSD distribucijama. "Unusual" geometrija je signal za proveru, ne dokaz greške ili metastabilnosti.

3.5 Poravnanje i RMSD

Za dva već mapirana skupa od N atoma, nakon optimalne rotacije/translacije:

$$\text{RMSD} = \sqrt{\frac{1}{N} \sum_{i=1}^N \|\mathbf{x}_i - \mathbf{y}_i\|^2}.$$

Ali RMSD nije definisan dok ne odgovoriš:

- koji atomi ulaze - svi ili heavy atoms;
- kako je pronađeno atom mapping kod simetričnih atoma;
- da li se dozvoljava refleksija;
- kako se tretiraju nedostajući atomi, disorder i više komponenti;
- da li se poredi jedan molekul ili periodični packing cluster;
- da li su koordinate iz iste jedinice i frame-a.

Ista struktura prevedena/rotirana u prostoru treba da ima RMSD blizu nule posle poravnanja. Bez poravnanja, koordinatni frame dominira i mera je besmislena.

3.6 Invarijantnost koju ML reprezentacija mora imati

Za molekul ili kristal obično želimo:

- **translacionu invarijantnost** skora;
- **rotacionu invarijantnost** skora ili ekvivarijantne interne reprezentacije;
- **permutacionu invarijantnost** na redosled ekvivalentnih atoma;
- za kristal, **periodičnu invarijantnost** na izbor ekvivalentne ćelije/origina.

Međutim, ne želimo nužno invarijantnost na refleksiju, promenu stereokemije, protonaciju ili zamenu elementa. Invarijantnost je naučna odluka, ne samo arhitektonsko svojstvo mreže.

3.7 Posledice za aplikacije

Globalna pretraga: 2D graf je brz i robustan prema koordinatnom frame-u; 3D deskriptori daju oblik/konformaciju, ali zahtevaju definisanu protonaciju, atom mapping i tretman conformer ensemble-a.

Poređenje parova: vrati odvojeno molecular RMSD, torsion differences i packing match. Nikada ne nazivaj jedan RMSD "crystal similarity" ako je izračunat samo na asymmetric-unit molekulu.

3.8 Mini-laboratorija na N14

1. Iz `N14.mo12` uzmi koordinate N1, O1 i O2.
2. Izračunaj obe N-O dužine.
3. Objasni zašto skoro identične dužine nose više informacije nego dva formalna MOL2 `1` bond tipa.

4. Transliraj sve koordinate vektorom (100, -50, 3). Proveri da se dužine ne menjaju.
5. Promeni samo red atoma u fajlu. Objasni zašto se hemijska sličnost ne sme promeniti.

Očekivani zaključak

Obe dužine su približno 1,2273 Å. Translacija ne menja razlike koordinata, pa ni dužine. Red linija nije hemijsko svojstvo; stabilan sistem mora mapirati atome po identitetu/grafu, ne po poziciji u fajlu.

Kriterijum prolaza: iz koordinata ručno ili kodom izračunaj dužinu, ugao i torziju, pa objasni sve izbore potrebne da bi RMSD bio reproduktivan.

4. Organska hemija koja nam treba

Prioritet: MORAŠ, selektivno. Ne učimo katalog reakcija. Učimo da prepoznamo hemijsko okruženje koje određuje graf, koordinaciju, interakcije i standardizaciju.

4.1 Ugljenični skelet i funkcionalne grupe

Funkcionalna grupa je lokalni raspored atoma sa prepoznatljivim hemijskim ponašanjem. Za projekat su najvažnije:

Grupa/motiv	Prepoznavanje	Zašto je važno
alkane/alkyl	pretežno C-C/C-H single veze	fleksibilnost, disperzija, rotatable bonds
alkene/alkyne	C=C / C≡C	rigidnost, geometrija, stereokemija
arene	aromatični karbociklus	planarnost, delokalizacija, π kontakti
heteroarene	aromatični prsten sa N/O/S	donor/acceptor svojstva; npr. pyridine N
alcohol/phenol	O-H	H-bond donor i često acceptor; acid-base kontekst
ether	C-O-C	acceptor, fleksibilnost
carbonyl	C=O	jak dipol; acceptor; osnova aldehida/ketona
carboxylic acid/carboxylate	COOH / COO ⁻	protonacija, soli, rezonanca, snažne mreže
ester/amide	C(=O)O / C(=O)N	rezonanca menja bazičnost i rotacionu rigidnost; neutralni amide N obično nije H-bond acceptor niti tipičan metalni donor, ali N-H može biti H-bond donor; carbonyl O je acceptor
amine	N sa single vezama/lone pair	baza i ligand, osim kada je lone pair delokalizovan/protonovan
imine	C=N	DAP Schiff-base motiv; geometrija i N donor
nitro	vezani NO ₂ rezonantni sistem	formalni naboji, približno jednake N-O veze, jak polarni motiv
halogen	C-F/Cl/Br/I ili halidni jon	veličina, polarizabilnost, anion/ligand, halogen bonding
phosphine/phosphoryl motivi	P sa organskim/O susedima	promenljiva valenca, ligand/dipol; zahteva tačno tipovanje

OpenStax Organic Chemistry: functional groups je dobar vizuelni atlas. Za projekat je dovoljno da grupu prepoznaš i navedeš tip veze, tipičan naboj/protonaciju i moguću donor/acceptor ulogu.

4.2 DAP Schiff-base motiv

Iz prvog lokalnog CSD zapisa, **CAPHAG**, sistematsko ime opisuje pyridine-2,6-diyl jezgro sa dve imine grane. Dostavljeni ConQuest upit kodira 18-atomsku podstrukturu sa:

- centralnim šestočlanim pyridine prstenom;
- jednim prstenskim N donorem;
- dve bočne **C=N** jedinice;

- promenljivim terminalnim supstituentima.

Takav tridentatni N-donor raspored može koordinisati metal, ali prisustvo motiva samo po sebi ne dokazuje koordinaciju. Zato `search1` traži motiv, dok `search2` dodaje odvojeni 4M atom-uslov za prisustvo člana ConQuest grupe „bilo koji metal“, čija taksonomija uključuje i Ge i Sb. Čak i tada treba proveriti da li je taj centar zaista povezan sa tri donor-atoma; "u istom kristalnom zapisu" nije isto što i "koordinisan ovim ligandom".

4.3 Kiselina i baza: dva modela koja nam trebaju

Brønsted-Lowry

- kiselina donira proton H^+ ;
- baza prima proton.

Lewis

- Lewisova baza donira elektronski par;
- Lewisova kiselina prima elektronski par.

Ligandni N sa lone pair može biti Lewisova baza prema metalnom centru. Ako je protonovan, lone pair može postati nedostupan za koordinaciju. Acid-base stanje zato menja graf, charge, donor/acceptor etikete, soli i kristalno pakovanje.

OpenStax: [Brønsted-Lowry](#) i [Lewis acids/bases](#) i [kompleksi](#) su dovoljni izvori za ovaj nivo.

pH nije osobina izolovanog CIF-a

pH opisuje rastvor i zavisi od uslova. CIF solidne forme može pokazati protonovanu vrstu i counterion, ali iz samog 3D modela ne treba izmišljati pH kristalizacije.

4.4 Tautomeri, protonacija i soli

Protonaciona stanja se razlikuju položajem/brojem protona i neto nabojem. **Tautomeri** su konstitucionni izomeri povezani formalnim premeštanjem protona i π -veze, npr. keto/enol. Njihova interkonverzija nije univerzalno brza: brzina i ravnoteža zavise od barijere, rastvarača, pH, katalizatora i temperature. U čvrstom stanju kristalna rešetka može stabilizovati jedan tautomer, ograničiti prenos protona ili zahtevati faznu transformaciju, pa se ne sme automatski pretpostaviti brza tautomerna ravnoteža. U digitalnim bazama dva validna zapisa mogu izgledati kao različiti grafovi iako ih hemičar za određenu namenu grupiše.

Standardizacija mora odvojeno evidentirati:

1. originalnu eksperimentalnu formu;
2. fragmentisane komponente (glavna jedinka, counterion, solvent);
3. odabranu parent reprezentaciju za određenu pretragu;
4. tautomer/protomer policy;
5. sve transformacije i upozorenja.

Ne postoji univerzalno ispravno "neutralize everything" pravilo. Za pretragu ligandskog scaffold-a neutralni parent može pomoći; za solid-form i koordinacionu sličnost uklanjanje naboja/counteriona može uništiti suštinu.

4.5 Aromatičnost i heteroatom

Pyridine N i pyrrole N su oba u aromatičnom prstenu, ali lone pair nema istu ulogu:

- pyridine-tip lone pair ne pripada aromatičnom π sekstetu i tipično može biti baza/metal donor;
- pyrrole-tip lone pair doprinosi aromatičnosti i mnogo je manje raspoloživ na isti način.

Zato atom-label "N.ar" sam bez hemijskog okruženja nije dovoljan za donor/acceptor klasifikaciju. SMARTS/feature definicije moraju biti verzionisane i testirane.

4.6 Konjugacija, planarnost i rotatable bonds

Naivno pravilo "svaka single veza je rotatable" nije tačno. Amide C-N ima parcijalni double-bond karakter zbog rezonance i obično je mnogo rigidniji. Ista delokalizacija čini neutralni amide N slabom Lewisovom bazom: on obično nije H-bond acceptor niti tipičan metalni donor, iako N-H može donirati H-vezu. Deprotonovani amid i posebna koordinaciona okruženja su izuzeci; carbonyl O ostaje uobičajeno acceptorsko/koordinaciono mesto. Veze u prstenu, terminalne veze i veze prema metalima zahtevaju posebne definicije.

Broj rotatable bonds iz white paper-a je koristan deskriptor fleksibilnosti, ali vrednost zavisi od implementacione definicije. U modelu čuvaj naziv alata, verziju i parametre.

4.7 Stereokemija kao podatak, ne ukras

Obavezno razlikuj:

- specifikovanu stereokemiju;
- nepoznatu/neodređenu stereokemiju;
- racemat;
- jednu izolovanu enantiomernu formu;
- stereoinformaciju izgubljenu konverzijom.

Canonical SMILES može grupisati samo ono što je zapisano njegovim stereooznakama i pravilima. U CSD familijama potrebni su struktura, stereokemija, solid-form kontekst i ekspertna kuracija; jedna string-kolona nije ground truth.

4.8 Posledice za aplikacije

Filteri: elementi i formula se dopunjuju functional-group/substructure filterima. DAP motiv je eksplicitni podgraf; "metal complex" zahteva proveru metal-ligand povezanosti/okruženja, ne samo metal u formuli.

Feature-i: broj donora, acceptora, rotatable bonds, aromatic rings i formal charge su korisni samo uz dokumentovanu protonation/aromaticity policy.

Objašnjenje rezultata: prikaži koji se scaffold/funkcionalne grupe poklapaju, a ne samo fingerprint score.

4.9 Provera znanja

1. Zašto imine N može biti relevantan metalni donor?
2. Da li svaki N atom prihvata H-vezu i koordinira metal?
3. Zašto uklanjanje counterion-a može pomoći jednoj, a pokvariti drugu pretragu?

4. Da li su dva tautomera isti graf?
5. Zašto "broj rotatable bonds" mora imati verzionisanu definiciju?

Odgovori

1. Ima lone pair koji može donirati metalnom centru, u zavisnosti od protonacije i okruženja.
2. Ne. Dostupnost lone pair-a, naboj, rezonanca/aromatičnost i geometrija određuju ulogu.
3. Parent-scaffold pretraga želi ignorisati različite soli; solid-form pretraga mora sačuvati sastav i jonske interakcije.
4. Ne nužno: premeštanje H i double veze menja formalni graf, iako ih neka standardizacija grupiše.
5. Različiti alati drugačije tretiraju amide, ring bonds, terminalne i metalne veze.

Kriterijum prolaza: na lokalnom DAP pogotku označi pyridine, dve C=N jedinice, tri potencijalna N donor-atoma, terminalne supstituente, moguće protonacione tačke i veze čija rotacija menja konformaciju.

5. Metali, ligandi i kompleksi

Prioritet: MORAŠ. Ako ovo poglavlje savladaš, moći ćeš da razlikuješ zapis koji samo sadrži metal od stvarnog koordinacionog kompleksa i da pravilno čitaš lokalno okruženje metala. To je osnovna hemijska kontrola za obe 2CDC aplikacije.

5.1 Četiri ideje koje ne smeju da se pomešaju

Koordinaciona hemija proučava **centralni atom ili jon**, najčešće metal, i atome ili grupe koji su za njega neposredno vezani. Ti partneri su **ligandi**, a atom liganda koji se neposredno vezuje za metal je **donor-atom**.

Na početnom nivou koristan je Lewisov model:

```

ligand sa slobodnim elektronskim parom + metalni centar sa dostupnom orbitalom
Lewisova baza + Lewisova kiselina
      ↓
    koordinaciona veza
  
```

Na primer, azot može da donira slobodni elektronski par cinku. Strelica $N \rightarrow Zn$ opisuje poreklo elektronskog para pri nastanku veze. Kada je veza nastala, ona nije neka posebna „slabija vrsta crte“: njena priroda može imati jonski i kovalentni doprinos, a način crtanja je model i konvencija. IUPAC zato naglašava da poreklo elektrona samo po sebi ne određuje karakter konačne veze ([coordination](#)).

Četiri nivoa dokaza su različita:

Tvrđnja	Šta je potrebno da bi bila opravdana
„U entry-ju postoji metal“	metal se javlja u formuli ili među atomima
„Metal ima susede“	postoji eksplicitna ili pouzdano izvedena koordinaciona okolina
„Metal je vezan za neki azot“	konkretna M–N veza ili geometrijski potvrđen kontakt
„DAP Schiff-base ligand koordinira metal preko N3 džepa“	mapirana su baš tri ciljna DAP azota i potvrđena njihova veza sa istim metalom

Projektna posledica: filter „metal prisutan“ ne sme u korisničkom interfejsu da bude nazvan „metal koordinisan ligandu“. To su različite operacije nad različitim slojevima podataka.

5.2 Koordinaciona jedinka nije isto što i ceo kristalni zapis

Kristalni zapis može da sadrži više od jedne hemijske komponente:

- koordinacionu jedinku, na primer neutralni kompleks ili kompleksni jon;
- protivjone potrebne za ravnotežu naelektrisanja;
- molekule rastvarača ili vode;
- koformere i više nezavisnih molekula;
- delove polimernog lanca ili disorder alternative.

Zato su sledeći prikazi povezani, ali nisu sinonimi:

CSD entry

- puna formula i kristalno pakovanje
- koordinaciona jedinka: metal + neposredno vezani ligandi
- odvojeni protivjoni
- solvatisani molekuli / druge komponente

Ako formula sadrži Fe, ne sledi da je Fe vezan za ciljnu organsku komponentu. Ako graf ima dve odvojene komponente, metal može biti u drugoj komponenti. Čak i kada su svi atomi nacrtani u jednom CIF bloku, component assignment i koordinacione veze mogu ostati neizvesni.

5.3 Lokalni dokaz: CAPHAG i CAPHEK

Dva prva zapisa iz dostavljenih pretraga daju dobar par za učenje.

CAPHAG — slobodni organski ligand

Lokalni eksport za **CAPHAG** daje formulu `C25 H27 N3`, 55 atoma i 57 veza kada se računaju eksplicitni vodonici u eksportovanom molekulskom zapisu. Njegov SMILES je:

```
CCc1ccccc1N=C(C)c1cccc(n1)C(C)=Nc1ccccc1CC
```

U strukturi postoje tri relevantna azota: jedan piridinski i dva iminska. Oni grade **potencijalni N3 donorski džep**, ali nema metalnog atoma. Zbog toga CAPHAG jeste DAP-derived bis(imine) ligand, ali nije metalni kompleks.

CAPHEK — N3Cl2 okruženje cinka

Za **CAPHEK** lokalni CIF navodi formulu `C27 H32 Cl2 N4 O Zn`. U koordinacionoj jedinki jedan Zn ima pet neposrednih suseda:

Veza	Lokalno rastojanje / Å
Zn–N	2,081
Zn–N	2,251
Zn–N	2,276
Zn–Cl	2,241
Zn–Cl	2,254

Donor-sastav je zato `N3Cl2`, a koordinacioni broj cinka je 5. Eksport takođe sadrži odvojene molekule acetonitrila i vode. Njihovo prisustvo u istoj kristalnoj formuli ne znači automatski da su koordinisani cinku.

Jedna rečenica, tri nivoa

„CAPHEK sadrži Zn“ je composition tvrdnja. „Zn ima N3Cl2 okolinu“ je coordination tvrdnja. „Sva tri N pripadaju istom DAP bis-iminskom ligandu“ zahteva atom mapping ciljnih N atoma. Lokalni zapis podržava sva tri nivoa za CAPHEK, ali sistem mora da ih proverava zasebnim testovima.

5.4 Koordinacioni broj: broje se donor-atomi, ne molekuli

Koordinacioni broj (CN) centralnog atoma u koordinacionoj jedinki jeste broj njegovih direktno vezanih donor-atoma; IUPAC-ova precizna definicija govori o broju ligand–centralni atom σ -veza (**coordination number**).

Primeri:

- četiri monodentatna liganda, svaki preko jednog atoma, mogu dati $CN = 4$;
- dva bidentatna liganda mogu takođe dati $CN = 4$;
- jedan tridentatni DAP ligand i dva monodentatna hlorido liganda daju $CN = 3 + 1 + 1 = 5$, kao u CAPHEK;
- broj liganada i koordinacioni broj zato nisu ista veličina.

Šta lokalni eksport pokazuje

U `search2` ima 2.038 entry-ja, ali samo 1.954 imaju eksportovane atomske koordinate/graf dovoljan za ovu lokalnu analizu. U njima je nađeno 4.070 centara čiji elementi pripadaju ConQuest grupi `4M`. CCDC-ova legacy taksonomija u `4M` uključuje i Ge i Sb preko grupe `2M`, pa ovu operativnu selekciju ne treba neopaženo zameniti školskom podelom na „metale“ i „metaloide“ ([ConQuest User Guide](#)). Za svaki takav centar CN ispod je samo broj incidentnih bond records u eksportovanom MOL2 grafu:

MOL2 graph degree („CN“)	Broj 4M centara	Udeo
0	8	0,2%
1	221	5,4%
2	32	0,8%
3	9	0,2%
4	390	9,6%
5	831	20,4%
6	1.187	29,2%
7	975	24,0%
8	158	3,9%
9	136	3,3%
10	100	2,5%
11–15	23	0,6%

Ovo nisu apsolutne hemijske istine

Tabela je forenzika jednog eksportovanog grafa, ne referentna raspodela CSD-a. MOL2 može propustiti symmetry-generated veze, pojednostaviti metal–ligand vezivanje ili nezgodno predstaviti hapticitet, disorder i polimere. $CN = 0$ u eksportu znači „nema suseda u ovom grafu“, ne „dokazano izolovan goli metalni jon“.

Najčešći neposredni tipovi suseda u istom grafu bili su N (12.041 metal–N ivica), O (6.307), C (2.647), Cl (1.635), S (461), Br (162), F (122), P (117) i I (58). Jedan metal može doprineti više ivica i više tipova, pa ovo nisu brojevi entry-ja.

5.5 Koordinacioni broj ne određuje sam geometriju

Koordinaciona geometrija opisuje prostorni raspored donor-atoma oko centra. Isti CN može imati različite geometrije:

CN	Česti idealizovani modeli	Šta moraš proveriti
2	linearna, savijena	ugao D–M–D
3	trigonalno-planarna, trigonalno-piramidalna	planarnost i uglovi
4	tetraedarska, kvadratno-planarna	uglovi, dijagonale i elektronska konfiguracija

CN	Česti idealizovani modeli	Šta moraš proveriti
5	kvadratno-piramidalna, trigonalno-bipiramidalna	dva najveća ugla i continuous-shape mera
6	oktaedarska, trigonalno-prizmatična, distorzije	trans/cis uglovi i raspored lica
7+	više mogućih poliedara	puna 3D analiza; naziv iz CN nije dovoljan

Realni kompleksi su skoro uvek distordovani: veze nisu identične, helatni prstenovi ograničavaju uglove, a packing i dodatni ligandi pomeraju idealne pozicije.

CAPHEK i mera τ_5

Za petokoordinisani centar korisna je [Addisonova mera](#):

$$\tau_5 = \frac{\beta - \alpha}{60^\circ},$$

gde su β i α dva najveća ugla oko metala. Idealna kvadratna piramida ima $\tau_5 = 0$, a idealna trigonalna bipiramida $\tau_5 = 1$.

Za lokalni CAPHEK dva najveća ugla su $147,436^\circ$ i $128,705^\circ$:

$$\tau_5 = \frac{147,436 - 128,705}{60} \approx 0,312.$$

To je distordovana/intermedijarna petokoordinaciona geometrija, bliža kvadratno-piramidalnom kraju mere nego trigonalno-bipiramidalnom. Ne treba je proglasiti idealnom geometrijom samo na osnovu **CN = 5**.

Dokazna posledica: zaključak o geometriji treba da se može povezati sa M–D distancama, D–M–D uglovima, mapiranjem atoma, CN-om i definicijom geometrijske mere. Tekstualna etiketa „square pyramidal“ je izvedena i može biti neizvesna; ovo nije propisana record schema.

Minimalni ligand-field most: zašto elektroni utiču na geometriju

VSEPR i sam koordinacioni broj nisu dovoljni za prelazne metale. Pet d -orbitala izolovanog jona imaju isti energetski nivo u idealizovanom sfernom okruženju, ali ligandi dolaze iz određenih pravaca. Njihove elektrostatičke i kovalentne interakcije zato **cepaju** te nivoe. Crystal-field model je korisna elektrostatička aproksimacija; ligand-field opis je širi i uključuje kovalentno mešanje orbitala. Ovde nam ne trebaju multipleti ni spektroskopske derivacije — samo strukturne posledice.

Prvi korak je približan d^n broj. Za uobičajene komplekse d -bloka:

$$n_d \approx \text{broj grupe metala} - \text{oksidaciono stanje}.$$

Zato su Fe(II) približno d^6 , Cu(II) d^9 , a Zn(II) d^{10} . Ovo koristi **nezavisno** određeno oksidaciono stanje; postupak bilansa sledi u §5.7. Oksidaciono stanje se ne čita iz MOL2 charge kolone, a ovo jednostavno pravilo za d^n ne prenosi se mehanički na f -elemente ili složeno organometalno electron counting.

Idealizovana geometrija	Kvalitativno cepanje d -orbitala	Projektno važna posledica
octahedral	$t_{2g} = (d_{xy}, d_{xz}, d_{yz})$ niže; $e_g = (d_{z^2}, d_{x^2-y^2})$ više	za neke d^4 – d^7 konfiguracije odnos splitting-a Δ_o i pairing energije daje high- ili low-spin stanje
tetrahedral	$e = (d_{z^2}, d_{x^2-y^2})$ niže; $t_2 = (d_{xy}, d_{xz}, d_{yz})$ više	splitting je obično manji nego u odgovarajućem octahedral slučaju, pa su mnogi 3d tetrahedral kompleksi high spin
square planar	$d_{x^2-y^2}$, usmeren pravo ka četiri liganda, obično je najviši	česta je jaka stabilizacija square-planar d^8 konfiguracije, naročito kod 4d/5d metala; to nije pravilo iz samog CN=4

High spin znači da se, kada je izbor moguć, više orbitala popunjava nesparenim elektronima pre dodatnog sparivanja; **low spin** daje više sparivanja u nižim orbitalama. Odluku menjaju metal, oxidation state, donor-atomi, geometrija i ligandno polje. Spin može promeniti M–donor distance — na primer, popunjavanje orbitala sa izraženim antibonding karakterom često produžava veze — ali se spin stanje ne sme retroaktivno „dokazati“ samo jednom dužinom.

Jahn–Teller efekat kaže da nelinearan sistem sa orbitalno degenerisanim elektronskim osnovnim stanjem može sniziti energiju distorzijom koja uklanja degeneraciju. Klasičan strukturni obrazac je pseudo-octahedral Cu(II), d^9 , sa četiri kraće približno ekvatorijalne i dve duže aksijalne veze. Međutim:

- nije svaka aksijalna elongacija dokaz Jahn–Teller efekta;
- različiti ligandi, helatni strain, packing, disorder i temperatura mogu dati sličnu distorziju;
- dinamička i statička distorzija ne moraju izgledati isto u jednom prosečnom kristalnom modelu.

CAPHEK sadrži Zn(II), približno d^{10} . Njegovu intermedijarnu petokoordinisanu geometriju zato ne treba automatski nazvati spin- ili first-order Jahn–Teller efektom; ligandna arhitektura, sterika, koordinacione veze i packing ostaju stvarni uzroci koje treba proveriti.

Za similarity model: metal, oxidation state/(d^n), spin kada je eksperimentalno ili pouzdano anotiran, donor set, CN, continuous-shape mera i pojedinačne distance moraju biti odvojeni feature-i. Elektronski očekivana distorzija nije „šum koji treba ispeglati“. Za lanthanide/actinide centre, hapticitet i metalne klastere aktiviraj poseban applicability flag umesto nasilnog primenjivanja ovog jednostavnog (d)-orbitalnog modela.

5.6 Denticitet i helatacija

Denticitet je broj donor-grupa jednog liganda koje su vezane za isti centralni atom (IUPAC).

Denticitet	Naziv	Minimalni primer
1	monodentatan	jedan Cl^- preko jednog Cl atoma
2	bidentatan	ligand sa dva N koja se oba vezuju za isti metal
3	tridentatan	DAP bis-imine preko $N_{imine}-N_{pyridine}-N_{imine}$
4+	tetra-/polidentatan	četiri ili više donor-mesta istog liganda

Kada najmanje dva odvojena donor-mesta **istog** liganda vežu isti centralni atom, nastaje **helat**; proces ili prisustvo takvog vezivanja zove se **helatacija** (IUPAC). DAP-derived N3 vezivanje obično zatvara dva helatna prstena oko istog metala.

Važne nijanse:

- potencijalno tridentatan opisuje raspoloživa donor-mesta u ligandu;
- tridentatno koordinisan opisuje ono što se stvarno vidi u konkretnom kompleksu;
- isti ligand u drugom kristalu može biti mono-, bi-, tridentatan, protonovan, premošćujući ili potpuno nekoordinisan;
- helatni efekat je termodinamička tendencija, ne pravilo da svaki polidentatni ligand u svakoj situaciji mora koristiti sva mesta.

5.7 Formalno naelektrisanje, ukupni naboj i oksidaciono stanje

Ova tri pojma rešavaju različite računovodstvene probleme.

Formalno naelektrisanje atoma

Formalno naelektrisanje pripada atomu u izabranoj Lewisovoj strukturi. Pretpostavlja ravnopravno deljenje veznih elektrona bez obzira na elektronegativnost ([IUPAC formal charge](#)):

$$q_{\text{formal}} = N_{\text{valentnih}} - N_{\text{neveznih}} - \frac{1}{2} N_{\text{veznih elektrona}}.$$

To nije izmereno parcijalno naelektrisanje i može zavistiti od rezonantnog zapisa.

Ukupni naboj komponente ili koordinacione jedinice

Ukupni naboj je zbir formalnih naboja u toj jedinici. Ceo kristal mora zadovoljiti ravnotežu naboja, ali pojedina komponenta može biti jon. Protivjon može biti odvojen tačkom u SMILES-u ili zasebnim fragmentom u grafu.

Oksidaciono stanje

Oksidaciono stanje je formalni model raspodele elektrona posle jonske aproksimacije heteronuklearnih veza, a ne eksperimentalno parcijalno naelektrisanje metala ([IUPAC oxidation state](#)). Na početnom nivou često se određuje iz bilansa:

$$\text{OS}(\text{M}) + \sum q_{\text{liganada}} = q_{\text{koordinacione jedinice}}.$$

Za neutralnu koordinacionu jedinku CAPHEK-a, ako je DAP Schiff-base ligand neutralan, a dva hlorido liganda su svaki -1 , bilans daje:

$$x + 0 + 2(-1) = 0 \Rightarrow x = +2,$$

pa se cink opisuje kao Zn(II). Acetonitril i voda u odvojenim komponentama su neutralni i ne menjaju taj bilans.

Ne čitaj oksidaciono stanje iz MOL2 charge kolone

USER_CHARGES, NO_CHARGES, M CHG ili formalni naboj u eksportovanom SMILES-u opisuju konkretnu reprezentacionu šemu. Oni nisu automatski oksidaciona stanja. U lokalnom APHZUC SMILES-u uranijumski fragment čak nosi reprezentacioni zapis koji se ne sme doslovno prevesti u oksidaciono stanje bez hemijskog bilansa i provere strukture.

5.8 Kontraprimeri: metal je prisutan, ali ciljna koordinacija nije dokazana

Drugi lokalni ConQuest upit zahteva DAP motiv i nepovezan atom grupe 4M — bilo koji metal. Zato prolaze i entry-ji u kojima je metal u odvojenoj komponenti.

Refcode	Šta lokalni eksport pokazuje	Zašto nije dovoljan pozitivan N3 primer
APHZUC	protonovani organski ligand, odvojen U/O/Cl fragment i acetonitril	nema metal–N ivice do ciljnog liganda
FOWLEJ	DAP motiv i zaseban Cd/Cl metalatni fragment	metal presence, ne DAP coordination
GEHCOM	organska komponenta i zaseban Sn/Cl fragment	isto
MINQUV	ligand i odvojena Cu/Cl komponenta	Cu u entry-ju nije isto što i Cu–DAP veza
SUZBAT	Fe je u organometalnom C okruženju	metal je vezan, ali ne za ciljna DAP N mesta
UJIXES	ligand i zaseban [Mn+2] fragment	nepovezan Mn nije koordinisan DAP ligandu

Među 1.954 [search2](#) zapisa sa koordinatama/grafom:

- 6 nema nijednu metal–N ivicu u eksportovanom grafu;
- 35 nema nijedan metal sa najmanje tri N suseda;
- 1.919 ima bar jedan metal sa najmanje tri N suseda, ali ni to samo po sebi ne dokazuje da su baš ta tri N mapirana na ciljani DAP motiv.

Pravi pozitivni kriterijum zato izgleda ovako:

```
nađi DAP podgraf i njegovo mapiranje atoma
→ identifikuj tri ciljna N donor-atoma
→ nađi metal u istoj relevantnoj komponenti
→ potvrdi M–N veze ili validirane distance uz PBC/simetriju
→ proveriti da sva tri N vezuju isti metal
→ prijaviti denticitet, CN, druge donore i confidence
```

5.9 Kako reprezentacija može da promeni odgovor

U organskim molekulima bond order je često dovoljno stabilan za graf. Kod kompleksa postoje dodatne zamke:

- CIF može imati koordinate, ali ne eksplicitne hemijske veze;
- MOL2/SDF eksport može dodeliti veze po pravilima konkretnog alata;
- metal–ligand bond order često nije običan celobrojni fizički red veze;
- veze kroz granicu ćelije zahtevaju symmetry i periodične slike;
- hapticity, na primer vezivanje metala za više atoma π -sistema, ne staje uredno u jednostavno „broj crta“ pravilo;
- disorder i parcijalna okupacija mogu dati alternativne lokalne okoline.

Zato se pouzdano tumačenje izvedenog koordinacionog grafa oslanja na:

1. poznat izvor veze: eksplicitna, CSD-kurirana, symmetry-generated ili distance-inferred;
2. poznatu definiciju pravila, verzije i pragova;
3. vidljivu neizvesnost i upozorenja;
4. mogućnost povezivanja sa originalnim koordinatama i mapiranjem atoma;
5. mogućnost `unknown/ambiguous`, a ne prinudnu etiketu.

To su kategorije evidence-a, ne obavezna polja buduće implementacije.

5.10 Mini-vežbe

1. Brojanje

Kompleks ima jedan tridentatni N3 ligand, jedan bidentatni O2 ligand i jedan monodentatni Cl ligand. Koliko liganada i koliki CN ima metal?

Odgovor

Tri liganda, ali $CN = 3 + 2 + 1 = 6$. Broj molekula/grupa oko metala nije isto što i broj donor-atoma.

2. CAPHEK

Zašto iz formule `C27 H32 Cl2 N4 O Zn` ne možeš samo brojanjem elemenata dobiti $CN = 5$?

Odgovor

Formula ne kodira koje su veze prisutne ni koje komponente su odvojene. CN=5 dolazi iz lokalne okoline Zn: tri neposredno vezana N i dva Cl. Jedan dodatni N pripada odvojenom acetonitrilu, a O vodi; oni nisu automatski koordinisani.

3. Dve petokoordinisane strukture

Dva kompleksa imaju CN = 5. Da li imaju istu geometriju?

Odgovor

Ne nužno. Jedan može biti bliži kvadratnoj piramidi, drugi trigonalnoj bipiramidi, a oba mogu biti snažno distordovana. Potrebni su 3D uglovi/distance i odgovarajuća mera, ne samo CN.

4. Presence naspram coordination

Upit traži ciljani organski podgraf i nepovezan metalni atom. Da li su svi pogoci koordinacioni kompleksi tog liganda?

Odgovor

Ne. Dokazano je samo supostojanje motiva i metala u istom entry-ju. APHZUC, FOWLEJ, GEHCOM, MINQUV, SUZBAT i UJIXES pokazuju različite načine na koje ta pretpostavka može da padne.

5. Naboj

MOL2 kolona za metal ima vrednost +2.0. Da li je to dovoljan dokaz da je oksidaciono stanje M(II)?

Odgovor

Ne. To može biti formalni ili modelom dodeljen atom charge. Oksidaciono stanje se određuje hemijskim electron-counting pravilima i bilansom celog koordinacionog entiteta, uz proveru identiteta liganada i njihovih naboja.

6. Elektronska distorzija

Pseudo-octahedral Cu(II) ima četiri Cu–N/O distance oko 2,0 Å i dve oko 2,35 Å. Šta je opravdan, a šta neopravdan zaključak?

Odgovor

Obrazac je kompatibilan sa Jahn–Teller elongacijom karakterističnom za mnoge d^9 Cu(II) centre i zasluhuje ciljanu proveru. Nije samostalan dokaz mehanizma: prvo proveriti oxidation state, donor identitete, simetriju, disorder, s.u., temperaturu i alternativne steričke/packing uzroke.

5.11 Kriterijum prolaza

Poglavlje si savladao kada za proizvoljan zapis možeš da:

- odvojiš ceo entry, koordinacionu jedinku, protivjone i solvatisane komponente;
- navedeš metal, neposredne donore, CN, denticitet i moguću geometriju;
- pokažeš dokaz za svaku M–donor vezu i prijaviš neizvesnost;
- odvojeno izračunaš formalne naboje, ukupni naboj i oksidaciono stanje;
- iz oxidation state-a izvedeš približan d^n broj i objasniš kako ligandno polje, spin i Jahn–Teller efekat mogu — ali ne moraju — uticati na geometriju;
- objasniš zašto metal presence nije DAP coordination ground truth.

Primarni i autoritativni izvori

- IUPAC Gold Book: coordination
- IUPAC Gold Book: ligand
- IUPAC Gold Book: coordination number
- IUPAC Gold Book: denticity
- IUPAC Gold Book: chelation
- IUPAC Gold Book: formal charge
- IUPAC Gold Book: oxidation state
- IUPAC Gold Book: ligand-field splitting
- IUPAC Gold Book: high-spin i low-spin
- IUPAC Gold Book: Jahn–Teller effect
- CSD pregled strukturnih raspodela i koordinacionih geometrija
- OpenStax Chemistry 2e: Coordination Chemistry of Transition Metals

6. DAP Schiff-base motiv u ovom skupu


Prioritet: MORAŠ. Ovo poglavlje prevodi naziv koji su naučnici koristili — „DAP Schiff bases“ — u proverljiv hemijski graf. Cilj nije da zapamtiš katalog jedinjenja, nego da razumeš šta je motiv, kako nastaje, zašto može da koordinira metal i šta lokalni upit zaista dokazuje.

6.1 Šta „DAP“ znači ovde

Skraćenice u hemiji nisu globalno jedinstvene. U ovom projektu **DAP** treba čitati kao **2,6-diacetilpiridin** (2,6-diacetylpyridine), jer baš taj kostur rekonstruišemo iz dostavljenog ConQuest upita:

- centralni šestoročlani piridinski prsten sa jednim N;
- po jedna acetyl-derived iminska ruka na položajima 2 i 6;
- dva C=N centra;
- po jedna metil-grupa uz svaki iminski C.

Najkraća tekstualna skica bis-iminskog proizvoda je:




potencijalni donorski niz: N_imine - N_pyridine - N_imine

Inference, ne originalno ime u fajlu

Lokalni query graf eksplicitno kodira 18-atomsko 2,6-diacetilpiridinsko jezgro sa dve C=N veze. Sam query ne ograničava neposredni supstituent na svakom terminalnom N, pa klasifikacija pogotka kao bis-imina ili Schiffove baze zahteva proveru kompletne strukture. .cqs ne nosi autoritativnu hemijsku definiciju skraćenice; naučni tim treba pisano da potvrdi nameravani scope, uključujući dozvoljene supstitucije, protone/tautomere i parcijalno kondenzovane proizvode.

6.2 Od karbonila i amina do Schiffove baze

2,6-diacetilpiridin ima dve ketonske karbonilne grupe. Svaka može reagovati sa **primarnim aminom** R-NH₂ i dati iminsku vezu C=N. Idealizovana ukupna reakcija za simetrični bis-iminski proizvod je:



Na nivou jedne karbonilne grupe korisna mentalna slika je:

1. nukleofilni N primarnog amina napada elektrofilni karbonilni C;
2. nastaje tetraedarski intermedijer, često opisan kao karbinolamin nakon proton transfera;
3. proton transferi pripremaju odlazak vode;
4. eliminacija vode i deprotonovanje daju C=N.

Reakcija je ravnotežna. Acid/base uslovi, voda, rastvarač, temperatura i stabilnost proizvoda mogu promeniti ishod. „Pomešali smo keton i amin“ nije dovoljan dokaz da je nastao čist bis-iminski ligand; identitet se potvrđuje analitikom i strukturom.

Imine i Schiffove baze

IUPAC definiše **imine** kao jedinjenja sa motivom $RN=CR_2$; aldehidni i ketonski analozi razlikuju se kao aldimini i ketimini (**imines**). **Schiffove baze** su imini kod kojih N nosi hidrokarbilnu grupu, $R_2C=NR'$, uz $R' \neq H$ (**Schiff bases**).

U našem DAP motivu svaki iminski C potiče od ketona i vezan je za CH_3 i piridinski kostur; zato su to ketiminske Schiff-base ruke kada iminski N nosi hidrokarbilni supstituent, kao arilnu grupu u CAPHAG-u. Samo prisustvo $C=N$ i nekog organskog ostatka nije dovoljno za tu užu klasifikaciju: neposredno vezani N–N ili N–O supstituent traži razlikovanje hidrazonskog odnosno oksimskog tipa i pregled kompletne strukture.

6.3 CAPHAG kao konkretna reakcijska provera

Prvi search1 pogodak, **CAPHAG**, ima formulu $C_{25}H_{27}N_3$ i SMILES:

```
CCc1ccccc1N=C(C)c1cccc(n1)C(C)=Nc1ccccc1CC
```

On je konzistentan sa kondenzacijom 2,6-diacetilpiridina i dva ekvivalenta 2-etilanilina:



Provera atoma radi:

- C: $9 + 2 \times 8 = 25$;
- N: $1 + 2 \times 1 = 3$;
- O: dva karbonilna O odlaze u dve vode, pa ih nema u proizvodu;
- H: $9 + 2 \times 11 - 2 \times 2 = 27$.

Ovo je koristan sanity check, ali formula sama ne dokazuje povezivanje atoma. Graf/SMILES pokazuje dve $C=N$ veze i centralni piridinski N; kristalna struktura ili drugi analitički dokaz potvrđuje konkretan identitet.

6.4 Zašto je N3 motiv dobar ligand

Tri azota imaju slobodne elektronske parove koji mogu biti donori:

Donor	Gde se nalazi	Uloga u tipičnom N3 vezivanju
N_imine,left	leva $C=N-R$ ruka	krajnji donator
N_pyridine	centralni heteroatom prstena	srednji donator
N_imine,right	desna $C=N-R'$ ruka	krajnji donator

Ako sva tri vežu isti metal, ligand je **tridentatno koordinisan**. Raspored 2,6-ruku preorganizuje donator-atome i obično omogućava dva helatna prstena. To često stabilizuje vezivanje, ali „potencijalno tridentatan“ i „u ovoj strukturi tridentatan“ nisu isti iskazi.

Donorska sposobnost može da se promeni kada:

- iminski ili piridinski N bude protonovan;
- dođe do tautomerije ili hemijske transformacije;
- konformacija okrene donator od metala;

- sterički glomazni R supstituenti zaklone džep;
- metal preferira drugi koordinacioni broj/geometriju;
- ligand koristi samo jedan ili dva N, premošćuje više metala ili ostane nekoordinisan;
- konkurentni anjoni/rastvarači zauzmu koordinaciona mesta.

Semantička posledica: potencijalna tri donorska mesta liganda moraju se razlikovati od stvarno opažene dentatnosti i mapiranih M–N odnosa u konkretnom kompleksu. Jedna neobjašnjena etiketa „denticity = 3“ izgubila bi razliku između dizajna liganda i opažene strukture.

6.5 CAPHEK: kada se potencijalni džep zaista koristi

Prvi search2 pogodak, **CAPHEK**, daje jasan pozitivan primer:

- formula celog entry-ja: C27 H32 Cl2 N4 O Zn;
- jedan DAP bis-iminski ligand koristi tri N donora;
- isti Zn vezuje i dva Cl donora;
- lokalni donor-sastav je N3Cl2, pa je $CN = 5$;
- Zn–N rastojanja su 2,081, 2,251 i 2,276 Å;
- Zn–Cl rastojanja su 2,241 i 2,254 Å;
- odvojeni acetonitril i voda objašnjavaju dodatni N i O u punoj formuli.

Zato formula ima četiri N, ali koordinacioni N3 džep čine tri N iz istog liganda. Četvrti N pripada acetonitrilu i nije automatski donor cinku. Ovo je praktičan dokaz zašto se koordinacioni broj ne izvodi iz elementarne formule.

Petokoordinisana geometrija CAPHEK-a nije idealna. Iz dva najveća ugla, 147,436° i 128,705°, dobija se $\tau_5 \approx 0,312$: distordovana/intermedijarna okolina bliža kvadratno-piramidalnom kraju mere. Detaljno računanje je u poglavlju 5.

6.6 Šta tačno kodira prvi ConQuest upit

Forenzičko čitanje fajla 1 - Sifove baze DAP.cqs pokazuje jedan 2D connectivity query sa 18 eksplicitnih atoma:

Deo query-ja	Broj / vrsta
elementi	9 C, 3 N, 6 H
centralni prsten	5 C + 1 N
prstenaste veze	6 veza sa ConQuest kodom 5
dvostruke C=N veze	2, kod 2
ostale query veze	10 Any, kod 99
režim	exhaustive=1, symmchk=1

Dve ruke su na položajima 2 i 6 centralnog piridinskog prstena i svaka sadrži ring-C-C(=N)-CH₃ deo. Eksplicitnih šest H pripada dvema metil-grupama.

Query graf nije hemijsko ime

Naziv fajla kaže „DAP Schiff bases“, ali izvršiva semantika je skup atomskih, veznih i opcionalnih constraints. Naučno tumačenje mora razlikovati ljudsku nameru od mašinskog query-ja. Kada se ne slažu, constraints

opisuju šta je stvarno pretraženo, a nameru treba posebno potvrditi sa stručnim timom.

Prvi upit **ne zabranjuje metal**. On samo nema dodatni metalni uslov. Zato `search1` sadrži i metal-free ligande i entry-je sa metalima.

6.7 Drugi upit menja composition, ne koordinacionu vezu

Fajl `2 - Kompleksi sa DAP SB.cqs` sadrži isti 18-atomski povezani motiv i još jedan atom:

AT19 4M

CCDC ConQuest vodič definiše `4M` kao zbir grupa `1M + 2M + TR + LN + AN`, pod nazivom „bilo koji metal“ ([ConQuest User Guide](#)). Ta legacy taksonomija preko `2M` uključuje i Ge i Sb; nije potpuno ista kao svaka školska podela na metale i metaloide. Atom 19 je u query objektu **nepovezan**: nema vezu, kontakt, distance constraint niti uslov da pripada istoj molekulskoj komponenti kao DAP motiv.

Tačna logika je:

$\text{search2} = \text{DAP motiv} \wedge 4M \text{ element negde u istom CSD entry-ju.}$

Netačna, jača interpretacija bila bi:

$\text{search2} = \text{DAP N3 ligand koordinisan metalu.}$

Lokalni izvozi to potvrđuju broičano:

- `search1`: 2.110 rezultata;
- `search2`: 2.038 rezultata;
- `search2` je tačan podskup `search1` u istom redosledu nakon filtriranja;
- razlika od 72 entry-ja je deo `search1` bez `4M` elemenata, odnosno metal-free pod tom taksonomijom;
- svih 2.038 `search2` formula sadrži bar jedan `4M` element.

6.8 Kontraprimeri su važniji od lakih pozitivnih primera

Šest hemijski obrazloženih kontraprimera — APHZUC, FOWLEJ, GEHCOM, MINQUV, SUZBAT i UJIXES — dato je u §5.8. Ovde je njihova posebna ML uloga da služe kao **hard negatives**: dele scaffold/composition signal sa pozitivima, ali padaju na presudnom M–N atom mapping-u.

SMILES tačka je signal, ne konačna presuda

Tačka u SMILES-u označava odvojene graf komponente u tom eksportu. Kod kristala ipak treba proveriti CIF koordinate, simetriju, periodične slike i provenance percepcije veza. Zaključak `not coordinated` treba da nosi dokaz i confidence, naročito kada je izvor lossy.

6.9 Evidence ladder za DAP i metal

Jedan boolean „jeste/nije kompleks“ skriva više različitih pitanja:

Nivo dokaza	Pitanje
motiv	da li je mapirano 18-atomsko DAP query jezgro sa dve C=N veze prisutno?
sastav entry-ja	da li neki metal postoji bilo gde u entry-ju?

Nivo dokaza	Pitanje
komponenta	da li metal i mapirani motiv pripadaju istoj hemijskoj komponenti?
lokalni kontakt	da li postoji hemijski/geometrijski podržan metal–N odnos?
donor mapping	da li isti metal vezuje baš mapirane DAP N atome i sa kojom dentatnošću?
okruženje	koji su CN, ostali donori, geometrija i neizvesnost?
dovoljnost prikaza	da li dostupni format i kvalitet uopšte dopuštaju odluku?

Ovo je pojmovna lestvica dokaza, ne propisana label schema. Konačne positive/negative/ambiguous klase zahtevaju fakultetski odobrenu operativnu definiciju. APHZUC zato može biti kandidat na nivou scaffold-a, ali ne sme postati lažno pozitivan dokaz N3 koordinacije.

6.10 Varijacije koje model mora da očekuje

Jedan 2D scaffold može dati mnogo struktturnih varijanti:

- $R = R'$ ili nesimetrične ruke $R \neq R'$;
- E/Z konfiguracije iminskih veza;
- različite konformacije i orijentacije aromatičnih supstituenata;
- neutralni ligand, protonovani oblik ili druga tautomerna/protonaciona stanja;
- jedan ili više metalnih centara;
- dodatni monodentatni ili polidentatni ligandi;
- koordinacioni polimeri, bridging i symmetry-generated veze;
- counterion-i, hidrati i solvatisane forme;
- disorder, parcijalna okupacija i zapisi bez punih koordinata.

To objašnjava zašto „isti DAP motiv“ nije isto što i „ista molekulska struktura“, „isti koordinacioni kompleks“ ili „ista kristalna forma“.

6.11 Moguće ose relevantne za dve aplikacije

Aplikacija 1 — globalna pretraga

Potencijalne, međusobno različite search semantike uključuju:

- isti/sličan DAP scaffold;
- DAP scaffold + metal bilo gde u entry-ju;
- DAP ligand i metal u istoj komponenti;
- koordinacija preko najmanje jednog mapiranog N;
- N3 koordinacija istom metalu;
- slična koordinaciona geometrija i donor-okruženje.

One nisu unapred odobreni product modovi; njihov scope nije utvrđen dostupnim izvorima i mora ga potvrditi fakultet. Svaki stroži nivo može biti podskup prethodnog samo ako su podaci dovoljni. Zapis bez 3D ili pouzdane konektivnosti ostavlja nepoznat odgovor na odgovarajuću osu, umesto da postane lažno negativan.

Aplikacija 2 — poređenje parova

Za dva ulazna CIF-a stručna analiza može da razdvoji:

- poklapanje 2D DAP podgrafa i njegov atom mapping;

- identitet/protonaciju/supstitucije liganda;
- koji mapirani N atomi koordiniraju koji metal;
- observed denticity i M–N distance;
- CN, ostale donore i geometriju metala;
- razliku kristalne forme, packing-a, solvata i disorder-a.

Visok ligand-similarity score uz različitu koordinaciju nije greška — to su dve različite ose sličnosti. Koje od njih treba uključiti ostaje nepotvrđena projektna odluka, ne zaključak ove lekcije.

6.12 Mini-vežbe

1. Reakcijska stehiometrija

Koliko molekula vode idealno nastaje kada 2,6-diacetilpiridin sa dve karbonilne grupe potpuno reaguje sa dva primarna amina do bis-imina?

Odgovor

Dva. Svaka karbonilna grupa daje jednu iminsku vezu i jednu molekulu vode u idealizovanoj kondenzaciji.

2. Potencijalno naspram opaženog

Ligand ima piridinski N i dva iminska N, ali u kristalu samo jedan iminski N vezuje metal. Koji je njegov potencijalni, a koji opaženi denticitet?

Odgovor

Potencijalno je tridentatan za taj N3 donorski set, ali je u konkretnoj strukturi monodentatno koordinisan. Potrebno je sačuvati oba podatka.

3. Query logika

Zašto 2.038 rezultata drugog upita nisu automatski 2.038 potvrđena DAP kompleksa?

Odgovor

Dodatni 4M atom nema vezu ni geometrijski constraint prema DAP motivu. Upit traži motiv i metal u istom entry-ju, ne njihovu međusobnu koordinaciju.

4. CAPHAG i CAPHEK

Koji od ova dva lokalna primera je slobodni ligand, a koji potvrđen N3 kompleks?

Odgovor

CAPHAG je metal-free DAP bis-iminski ligand. CAPHEK sadrži Zn u N3Cl2 okolini; tri N iz DAP liganda vezuju isti Zn.

5. Hard negative

Zašto je SUZBAT bolji test modela od nasumičnog ugljovodonika bez N i metala?

Odgovor

SUZBAT prolazi široki DAP+metal query i zato deli relevantan scaffold/composition signal, ali Fe nije u ciljnom DAP–N3 okruženju. Model mora naučiti presudnu koordinacionu razliku, ne trivijalno odsustvo motiva.

6. Nedovoljni podaci

SMILES sadrži DAP motiv i metal u odvojenoj komponenti, a nemaš CIF koordinate. Koju etiketu daješ?

Odgovor

Možeš pouzdano označiti metal presence i odvojene komponente u toj reprezentaciji, ali ne treba izmišljati kristalografski contact zaključak. Za koordinaciju koristi `not shown in exported graph` ili `ambiguous/insufficient`, zavisno od ugovorenog annotation pravila.

6.13 Kriterijum prolaza

Poglavlje si savladao kada možeš da nacrtáš 2,6-diacetilpiridinski bis-iminski motiv, objasniš nastanak dve `C=N` veze, mapiraš N3 donorski set i napišeš test koji razlikuje:

DAP motiv + metal presence
od
isti metal direktno koordinisan mapiranim DAP N atomima.

Primarni i autoritativni izvori

- IUPAC Gold Book: imines
- IUPAC Gold Book: Schiff bases
- IUPAC Gold Book: denticity
- IUPAC Gold Book: chelation
- CCDC ConQuest User Guide and Tutorials
- CCDC Python API: substructure searching
- OpenStax Organic Chemistry: imine formation from aldehydes and ketones

7. Intermolekulske interakcije

Šta treba da umeš posle ovog poglavlja

Posle ovog poglavlja treba da možeš da:

- razlikuješ hemijsku vezu, geometrijski kontakt i fizički podržanu intermolekulsku interakciju;
- objasniš osnovne uloge elektrostatičke, disperzijske, odbijanja, vodoničnih i halogenih veza;
- pronađeš susede koji prelaze granicu jedinične ćelije;
- koristiš simetrijske operacije i celobrojne translacije pri traženju kontakata;
- izračunaš udaljenost i ugao kandidata za vodoničnu vezu;
- objasniš zašto jedan distance cutoff nije dovoljan za sve elemente i sva hemijska okruženja;
- predstaviš kristal kao periodični kontaktni graf sa poreklom i neizvesnošću svake ivice;
- prevedesh interakcije u objašnjive feature-e za obe 2CDC aplikacije.

Minimalni kristalografski most

Za računanje kontakata potrebna je sledeća notacija, pre njenog punog izvođenja u poglavljima 8 i 9. Matrica ćelije $\mathbf{A} = [\mathbf{a} \ \mathbf{b} \ \mathbf{c}]$ prevodi frakcionu koordinatu $\mathbf{f}$ u kartezijansku koordinatu $\mathbf{r} = \mathbf{A}\mathbf{f}$. Periodično ekvivalentni položaji zadovoljavaju

$$\mathbf{f} \sim \mathbf{f} + \mathbf{n}, \quad \mathbf{n} \in \mathbb{Z}^3.$$

Operacija prostorne grupe s deluje kao

$$\mathbf{f}' = \mathbf{R}_s \mathbf{f} + \mathbf{t}_s.$$


Ovde $\mathbf{n}$ opisuje celobrojne translacije izabranom ćelijom. Kod centrirane konvencionalne ćelije centrirajući pomaci moraju biti uključeni u puni skup simetrijskih translacija $\mathbf{t}_s$.

Zato se susedi ne traže samo među redovima asimetrične jedinice: iz nje se generišu simetrijske slike, zatim njihove celobrojno translirane kopije. Simetrijske kopije koje se poklope unutar tolerancije deduplikuju se samo kada predstavljaju isto kristalografsko mesto i slažu se vrsta atoma, occupancy i disorder identitet; sama blizina nije dovoljna. Ishod kontakta za isto fizičko atomsko mapiranje treba da ostane isti pod ekvivalentnim $(\mathbf{R}_s, \mathbf{t}_s, \mathbf{n})$ zapisima, dok se konkretni zapis čuva kao provenance njegovog pronalaženja.

Intuicija: molekul se ne završava ivicom nacrtane ćelije

Molekulski graf govori koji su atomi hemijski povezani unutar komponente. Kristal, međutim, nastaje kada se molekuli, joni ili koordinacioni entiteti periodično rasporede i međusobno utiču. Najbliži sused nekog atoma često nije u istoj nacrtanoj ćeliji niti u istoj asimetričnoj jedinici.

Zamisli atom blizu desne strane periodične slike. Njegov najbliži sused može biti tik preko leve strane sledeće slike:



Ako algoritam računa samo udaljenosti između redova atomskog loop-a, propustiće intermolekulske kontakte. Ako, suprotno tome, svaki kratak razmak proglašuje vezom, napraviće lažnu hemiju.

Kontakt nije automatski interakcija

Udaljenost je geometrijska činjenica izvedena iz kristalografskog modela. Naziv „vodonična veza“, „halogena veza“ ili „ π -interakcija“ zahteva hemijski kontekst i odgovarajuću geometriju, a tvrdnja o energetskom značaju može zahtevati dodatni proračun ili eksperimentalni dokaz.

Šta drži molekularni kristal

Intermolekularno ponašanje je zbir više doprinosa koji se međusobno preklapaju:

Doprinos	Osnovna ideja	Zašto jednostavan feature može da pogreši
elektrostatika	privlačenje suprotnih i odbijanje istih raspodela naboja	formalni naboj nije potpuna raspodela elektronske gustine
indukcija/polarizacija	električno polje jednog partnera deformiše drugi	zavisi od okruženja i polarizabilnosti
disperzija	korelisane trenutne fluktuacije elektrona	prisutna je i između nepolarnih grupa; nije samo „slaba slučajnost“

Doprinos	Osnovna ideja	Zašto jednostavan feature može da pogreši
Pauli odbijanje	elektronske gustine se ne mogu proizvoljno preklopiti	veoma kratko nije automatski veoma povoljno
usmerene interakcije	H-veze, halogene veze i srodni obrasci	traže donor/akceptor identitet i uglove, ne samo udaljenost

Za dve tačkaste naelektrisane čestice najjednostavniji elektrostatički model je:

$$U_{\text{el}}(r) = \frac{1}{4\pi\epsilon_0\epsilon_r} \frac{q_i q_j}{r}.$$

On dobro pokazuje znak i zavisnost od udaljenosti, ali molekuli nisu zbir fiksnih tačkastih formalnih naboja, a efektivna permitivnost kristala nije univerzalna konstanta.

Kombinacija kratkodometnog odbijanja i disperzione privlačnosti često se ilustruje Lennard-Jones izrazom:

$$U_{\text{LJ}}(r) = 4\epsilon \left[\left(\frac{\sigma}{r} \right)^{12} - \left(\frac{\sigma}{r} \right)^6 \right].$$

Ova jednačina je dobra intuicija za postojanje optimalnog razmaka. Nije dokaz da stvarni kristalni kontakt prati baš tu parametrizaciju, niti opisuje usmerenost, polarizaciju, transfer naboja ili višestruke kolektivne efekte.

Vodonična veza: donor, vodonik, akceptor i geometrija

Kandidat se zapisuje:



gde je D donor atom, H vodonik vezan za donor, a A akceptor. Za procenu se obično gledaju najmanje:

- hemijski identitet i stanje donora;
- hemijski identitet, protonacija i koordinaciono stanje akceptora;
- udaljenost $d(\text{H}, \text{A})$;
- udaljenost $d(\text{D}, \text{A})$;
- ugao $\angle \text{D} - \text{H} - \text{A}$.

Pravolinijskiji raspored je često geometrijski ubedljiviji, ali ne postoji jedan univerzalni prag koji bez izuzetka važi za sve donore, akceptore, temperature i kvalitet strukture. IUPAC definicija naglašava privlačnu interakciju i dokaz koji prevazilazi samo proizvoljan cutoff.

Tipični kandidati uključuju O-H i N-H donore. O i N mogu biti akceptori, ali ne u svakom stanju: protonacija, rezonanca, pozitivni naboj ili koordinacija metalu mogu promeniti njihovu sposobnost prihvatanja H-veze. Zbog toga feature `element == 0` nije dovoljan.

Položaj vodonika je deo neizvesnosti

U rendgenskim strukturama mnogi H atomi su postavljeni geometrijski i refinirani riding modelom. U drugim slučajevima položaj H može biti nezavisnije refiniran. U `cu_n14_a.cif` H2N ima refinirani položaj i prijavljenu vezu:

$$d(\text{N2} - \text{H2N}) = 0.876(19) \text{ \AA}.$$

To je korisnije od potpuno implicitnog H, ali ni tada ne treba zanemariti standardnu neizvesnost i kvalitet ostatka modela.

Rendgenski i normalizovani H nisu iste koordinate

Rendgensko zračenje rasipa se na elektronskoj gustini, dok neutroni daju informacije o položajima jezgara. Kod konvencionalnog rendgenskog refiniranja sa sfernim atomskim modelom elektronska gustina vezanog H pomerena je ka vezi, pa su dobijene X–H dužine tipično kraće od internuklearnih. To važi i kada je položaj H slobodno refiniran; napredniji asferni modeli mogu znatno smanjiti ovu razliku. [IUCr istraživanje IAM/TAAM modela](#) objašnjava zašto „refiniran H“ nije automatski precizan položaj jezgra.

Pri **neutronske normalizaciji** H se pomera duž postojeće X–H veze do izabrane referentne internuklearne dužine. To menja H⋯A udaljenost i D–H⋯A ugao, dok D⋯A ostaje isti. Referentne dužine zavise od pravila i hemijskog okruženja; normalizacija nije novo merenje niti opravdanje da se prepisu izvorne koordinate. [CCDC opis normalizacije](#) i [Allen–Bruno studija referentnih X–H dužina](#) daju osnovu ovog postupka. Sačuvaj raw geometriju i zasebno izvedenu geometriju sa metodom i ciljnom X–H dužinom. Svi N14 brojevi u nastavku računati su iz originalnih, nenormalizovanih CIF koordinata.

Ostale projektno relevantne interakcije

Jonske i charge-assisted interakcije

Suprotno naelektrisane komponente mogu dati dugodometan elektrostatički doprinos. Kod soli nije dovoljno analizirati samo najbliži atom; periodična raspodela naboja i counterion-i su deo sistema. Uklanjanje counterion-a pre izrade crystal feature-a menja fizički problem.

Halogene veze

Halogena veza uključuje elektrofilni region vezanog halogenog atoma i nukleofilni partner. Često je usmerena duž produžetka kovalentne veze R–X. Sama kratka X⋯A udaljenost nije potpuna definicija; potreban je i ugaoni/elektronski kontekst. IUPAC preporuka daje precizniji okvir.

π-sistemi

Za moguće π⋯π ili C–H⋯π kontakte mogu se koristiti centri prstenova, normale ravni, međuravanski ugao i lateralni pomak. Sam centroid-centroid razmak ne razlikuje povoljno preklapanje od geometrije u kojoj su prstenovi samo slučajno blizu.

Metal-involving kontakti

Kod koordinacionih jedinjenja granica između koordinacione veze i nekovalentnog kontakta može zavisi od oksidacionog stanja, donor-atoma, koordinacionog broja i geometrije. Jedinstveni globalni cutoff po paru elemenata posebno je rizičan za lantanoide, haptovezivanje i mostne ligande.

Van der Waals radijusi: koristan ekran, ne prirodni zakon

Jedan jednostavan deskriptor kontakta je:

$$\Delta_{\text{vdW}} = d_{ij} - (r_i^{\text{vdW}} + r_j^{\text{vdW}}),$$

ili normalizovan oblik:

$$R_{\text{norm}} = \frac{d_{ij}}{r_i^{\text{vdW}} + r_j^{\text{vdW}}}.$$

Negativan Δ_{vdW} , odnosno $R_{\text{norm}} < 1$, označava razmak kraći od zbira izabrane tabele radijusa. To je screening signal. Rezultat zavisi od tabele radijusa, protonacije, kvaliteta koordinata i hemijskog tipa atoma. Aplikacija mora čuvati naziv i verziju korišćenog skupa radijusa.

Kako se stvarno nalaze periodični susedi

Neka matrica ćelije $\mathbf{A}$ ima vektore $\mathbf{a}$, $\mathbf{b}$, $\mathbf{c}$ kao kolone. Frakcionu koordinatu atoma j , $\mathbf{f}_j$, simetrijska operacija s pretvara u:

$$\mathbf{f}_{j,s} = \mathbf{R}_s \mathbf{f}_j + \mathbf{t}_s.$$

Sve periodične slike dobijaju se dodavanjem celobrojnog vektora:

$$\mathbf{f}_{j,s,\mathbf{n}} = \mathbf{R}_s \mathbf{f}_j + \mathbf{t}_s + \mathbf{n}, \quad \mathbf{n} \in \mathbb{Z}^3.$$

Udaljenost od atoma i je:

$$d_{ij}^{(s,\mathbf{n})} = \|\mathbf{A} (\mathbf{f}_{j,s,\mathbf{n}} - \mathbf{f}_i)\|_2.$$

Pouzdan tok je:

1. pročitaj ćeliju i symmetry operations iz CIF-a;
2. generiši simetrijske slike;
3. odredi dovoljan opseg celobrojnih translacija za zadati radius pretrage;
4. računaj udaljenosti u Cartesian prostoru ili pomoću metric tensor-a;
5. ukloni duplikate nastale na specijalnim pozicijama;
6. tek zatim primeni hemijsko tipiziranje i geometrijske kriterijume;
7. uz svaku ivicu sačuvaj operaciju, translaciju, udaljenost, uglove i confidence.

Frakcioni prostor nije euklidski ekran

Razlika frakcionih koordinata nema jedinicu Å i njena obična Euklidska norma nije fizička udaljenost. Kod kose ćelije ni zaokruživanje svake komponente razlike na najbliži ceo broj nije uvek dovoljno za nalaženje najkraće slike. Koristi metric tensor ili proverenu periodičnu neighbor-search implementaciju.

Lokalni N14 primer: kontakt koji nije u atomskom loop-u

Lokalni CIF navodi simetrijsku operaciju:

$$(x, y, z) \mapsto (-x, y + \frac{1}{2}, -z + \frac{1}{2}).$$

Za O2 sa frakcionim koordinatama:

$$(0.50686, 0.40197, 0.21973)$$

primena operacije, a zatim translacija za jednu ćeliju duž $\mathbf{a}$, daje:

$$\text{O2}^{(ii)} = (0.49314, 0.90197, 0.28027).$$

H2N i donor N2 iz originalne asimetrične jedinice imaju:

$$\begin{aligned} \text{H2N} &= (0.4235, 0.7644, 0.3418), \\ \text{N2} &= (0.42369, 0.70769, 0.33548). \end{aligned}$$

Kada se sve koordinate pretvore pomoću stvarne monoklinične ćelije, dobija se geometrijski kandidat:

Veličina	Vrednost
$d(\text{H2N}, \text{O2}^{(ii)})$	približno 2,400 Å
$d(\text{N2}, \text{O2}^{(ii)})$	približno 3,182 Å
$\angle \text{N2} - \text{H2N} - \text{O2}^{(ii)}$	približno 148,9°

Ista symmetry-related molekulska kopija daje i O1 kandidat:

Veličina	Vrednost
$d(\text{H2N}, \text{O1}^{(ii)})$	približno 2,501 Å
$d(\text{N2}, \text{O1}^{(ii)})$	približno 3,332 Å
$\angle \text{N2} - \text{H2N} - \text{O1}^{(ii)}$	približno 158,9°

Ovi brojevi opravdavaju oznaku **geometrijski kandidati za N-H...O kontakte**. Sami ne dokazuju pojedinačnu energiju, niti opravdavaju automatsko biranje samo jednog od dva O atoma. Zato je naučno potreban geometrijski trag i poznata definicija klasifikacije; sam boolean `is_hbond=true` nije dovoljan dokaz.

Od liste kontakata do periodičnog grafa

Za aplikacije je korisno razlikovati dva grafa:

- **atomski kontakti graf:** čvorovi su atomi, a ivice su tipizirani periodični kontakti;
- **molekulski packing graf:** čvorovi su molekulske/komponentne kopije, a ivice sabiraju njihove kontakte.

Da bi periodični kontakt mogao da se protumači i reprodukuje, evidence mora da odgovori na:

Kategorija	Zašto je potrebna
atom/component mapping	da se zna ko sa kim interaguje
symmetry operation ID	da se kontakt reprodukuje
translation (n_a, n_b, n_c)	da se pronađe konkretna periodična slika
$d_{\text{H,A}}, d_{\text{D,A}}, \text{ugao}$	objašnjenje geometrije
interaction candidate type	H-bond, halogen, π , generic contact...
rule set i verzija	pragovi i atom typing se menjaju
quality/uncertainty	disorder, occupancy, H treatment, s.u.

Tabela je pojmovni model evidence-a, ne propisana edge schema. Graf treba da bude invarijantan na izbor origina, ekvivalentne jedinične ćelije i redosled atoma. Sirovi symmetry-operation indeks nije stabilan između dva ekvivalentna CIF zapisa, pa služi za provenance unutar konkretnog zapisa, ne kao globalni feature ID.

Zašto je ovo relevantno za dve aplikacije

Globalna pretraga

- Hemijski graf služi za brz molekulske dohvat; periodični kontakti deskriptori daju packing/interakcioni re-ranking.
- Donor/akceptor motiv može biti filter samo uz jasno poznatu definiciju pravila.
- Kontaktne mreže moraju uključiti symmetry-related i cross-boundary susede.

- Nedostajući H, disorder ili nepouzdan bond typing treba da smanje confidence, ne da postanu lažno odsustvo interakcije.
- Learned embedding kontakata ne objašnjava sam po sebi komponentne skorove ili geometrijski trag.

Poređenje svih parova

- Poredi se obrazac interakcija posle mapiranja hemijski odgovarajućih atoma i komponenti.
- Odvojeno vrati pokrivenost donora/akceptora, podudaranje tipa, geometrijsku razliku i topologiju mreže.
- Isti kontakt opisan drugom symmetry operation numeracijom ili ćelijskom translacijom mora ostati isti fizički kontakt.
- Razlika jedne slabe ivice ne treba automatski da nadvlada podudaranje cele mreže.
- Izveštaj mora razlikovati „kontakt nije pronađen“ od „nije bilo dovoljno pouzdanih podataka da se testira“.

Tipične zamke

1. Tražiti kontakte samo među atomima iz asimetrične jedinice.
2. Meriti Euklidsku udaljenost direktno u frakcionim koordinatama.
3. Ograničiti periodičnu pretragu na jednu unapred fiksiranu susednu ćeliju za svaki cutoff i oblik ćelije.
4. Proglasiti svaki O ili N za akceptor.
5. Proglasiti svaku udaljenost kraću od zbira van der Waals radijusa za stabilizujuću interakciju.
6. Ignorirati uglove kod usmerenih interakcija.
7. Ukloniti solvent ili counterion pre packing analize.
8. Tretirati symmetry-generated intermolekulski kontakt kao kovalentnu vezu.
9. Porediti symmetry-operation indekse između dva CIF-a kao stabilne kategorije.
10. Izjednačiti broj kontakata sa stabilnošću ili kristalnom energijom.
11. Zaključiti da interakcija ne postoji zato što H atom nije eksplicitno naveden.
12. Koristiti jedan skup geometrijskih pragova bez verzije i validacije na koordinacionim kompleksima.

Mini-vežbe

1. Granica ćelije

Atom A ima frakcionu koordinatu $x = 0.98$, a atom B $x = 0.03$, u ortogonalnoj ćeliji sa $a = 10 \text{ \AA}$. Kolika je njihova najkraća razlika duž **a**?

Odgovor

Ne koristi se $0.95a = 9.5 \text{ \AA}$, već periodična slika B sa $x = 1.03$. Razlika je $0.05a = 0.5 \text{ \AA}$.

2. N14 O2 slika

Primeni operaciju $(-x, y + \frac{1}{2}, -z + \frac{1}{2})$ na O2 i izaberi translaciju koja koordinatu smešta blizu H2N.

Odgovor

Posle operacije dobija se $(-0.50686, 0.90197, 0.28027)$. Dodavanje $(1, 0, 0)$ daje $(0.49314, 0.90197, 0.28027)$, periodičnu sliku korišćenu u lokalnom primeru.

3. Da li je to dokazana H-veza?

Da li $d(\text{H}, \text{A}) = 2.40 \text{ \AA}$ sam po sebi dokazuje vodoničnu vezu?

Odgovor

Ne. Potrebni su hemijski validan donor i akceptor, D-H...A geometrija i kontekst. Za snažniju energetska ili funkcionalnu tvrdnju mogu biti potrebni dodatni proračuni ili eksperimenti.

4. Nedostajući vodonik

CIF nema eksplicitne H atome. Kako aplikacija treba da prijavi odsustvo H-veza?

Odgovor

Ne kao dokazano odsustvo. Može pokušati kontrolisano dodavanje H na osnovu pouzdane hemijske strukture, ali mora čuvati da su položaji izvedeni i vratiti niži confidence ili status „nije procenjeno“ kada protonacija/bond typing nisu sigurni.

5. Stabilnost

Struktura A ima 12 geometrijskih H-bond kandidata, a B osam. Da li je A stabilnija?

Odgovor

To se ne može zaključiti iz broja. Kontakti se razlikuju po geometriji, partnerima, kooperativnosti i energetskim doprinosima, a stabilnost uključuje celokupnu rešetku, entropiju, temperaturu i druge forme.

6. Feature invarijantnost

Isti kontakt je u drugom CIF-u generisan operacijom broj 4 umesto broj 2. Da li feature treba da se promeni?

Odgovor

Ne ako je fizičko mapiranje isto. Indeks operacije je lokalni provenance podatak. Kanonski kontaktni deskriptor treba da zavisi od hemijskih partnera, geometrije i periodične topologije, a ne od redosleda operacija u fajlu.

Kriterijum prolaza

Poglavlje si savladao kada iz `cu_n14_a.cif` možeš da reprodukuješ N2-H2N...O2 geometrijski kandidat, navedeš tačnu simetrijsku operaciju i translaciju, objasniš zašto je to kandidat a ne automatski energetski dokaz i predložiš invarijantan zapis ivice za obe aplikacije.

Primarni i autoritativni izvori

- IUPAC preporuka: definicija vodonične veze
- IUPAC preporuka: definicija halogene veze
- IUCr Online Dictionary: crystal structure
- IUCr teaching pamphlet 21: crystal packing

- CCDC Python API: crystals, packing i contacts
- CCDC Python API: packing similarity
- Etter, MacDonald i Bernstein: graph-set opis H-veza
- Bernstein i saradnici: graph-set analiza H-bond obrazaca

8. Kristal, rešetka i jedinična ćelija

Šta treba da umeš posle ovog poglavlja

Posle ovog poglavlja treba da možeš da:

- razlikuješ kristalnu strukturu, rešetku, motiv i jediničnu ćeliju;
- protumačiš parametre $a, b, c, \alpha, \beta, \gamma$ i zapreminu ćelije;
- razlikuješ sedam kristalnih od sedam rešetkastih sistema i mapiraš 14 Bravaisovih tipova bez mešanja trigonal/rhombohedral pojmov;
- pretvaraš frakcione koordinate u Cartesian koordinate i obrnuto;
- računaš fizičke udaljenosti pomoću matrice ćelije ili metric tensor-a;
- pronađeš najkraću periodičnu sliku umesto da veruješ koordinatama unutar jednog nacrtanog okvira;
- objasniš zašto isti kristal može imati više legitimnih ćelija;
- razlikuješ primitive, conventional, reduced i supercell opis;
- protumačiš Z i, uz odgovarajuće uslove, izvedeš Z' ;
- izračunaš gustinu iz formule, ćelije i Z ;
- definišeš cell-level feature-e koji su invarijantni na setting, basis i origin.

Intuicija: ćelija je koordinatni izbor, ne fizička kutija

Ovde razmatramo trodimenzionalno periodične kristalne modele, kao u dostavljenim CIF primerima. Jedinična ćelija je jedan izabrani paralelopiped čijim celobrojnim translacijama ponavljamo njegov atomski sadržaj i dobijamo kristal. Kod centrirane konvencionalne ćelije taj sadržaj obuhvata i centrirajuće kopije; sami vektori njenih ivica ne generišu sve tačke pune translacione rešetke. Njene ivice nisu fizički zidovi: atom na $x = 0.99$ može biti bliži atomu u sledećoj ćeliji nego atomu na $x = 0.50$ u istoj nacrtanoj ćeliji.

U najkraćem:

Pojam	Značenje
rešetka	beskonačan skup translaciono ekvivalentnih tačaka
motiv/basis	atomski ili molekulski sadržaj pridružen rešetki
kristalna struktura	rešetka + motiv + simetrija i hemijski identitet
jedinična ćelija	izabrani koordinatni paralelopiped čiji sadržaj periodično ponavljamo; može biti primitivna ili centrirana konvencionalna
asimetrična jedinica	najmanji jedinstveni sadržaj iz kog space-group simetrija daje ćeliju

Ista ćelija nije isto što i ista struktura

Dva različita atomska rasporeda mogu imati jednake ili veoma slične parametre ćelije. Obrnuto, isti fizički kristal može biti zapisan drugom bazom, origin-om, setting-om ili supercell-om i zato imati veoma drugačije brojeve u CIF-u.

Rešetka kao celobrojna kombinacija tri vektora

Neka su $\mathbf{a}$, $\mathbf{b}$, $\mathbf{c}$ tri nekoplanarna vektora koji čine primitivni bazis. Tada je translaciona rešetka:

$$\mathbf{T}_n = n_1\mathbf{a} + n_2\mathbf{b} + n_3\mathbf{c}, \quad n_1, n_2, n_3 \in \mathbb{Z}.$$

Kod centriranog konvencionalnog bazisa $\mathbf{a}_c$, $\mathbf{b}_c$, $\mathbf{c}_c$, njegove celobrojne kombinacije daju samo podrešetku; preostale tačke daju centrirajući vektori. Na primer, I-centrirana ćelija ima i klasu pomerenu za $\frac{1}{2}(\mathbf{a}_c + \mathbf{b}_c + \mathbf{c}_c)$.

Vektori nisu nužno međusobno ortogonalni. Šest parametara ćelije su:

- $a = \|\mathbf{a}\|$;
- $b = \|\mathbf{b}\|$;
- $c = \|\mathbf{c}\|$;
- $\alpha = \angle(\mathbf{b}, \mathbf{c})$;
- $\beta = \angle(\mathbf{a}, \mathbf{c})$;
- $\gamma = \angle(\mathbf{a}, \mathbf{b})$.

Sedam kristalnih sistema postavljaju ograničenja na ove parametre. Na primer, u monokliničnom standardnom opisu sa jedinstvenom osom b :

$$\alpha = \gamma = 90^\circ, \quad \beta \neq 90^\circ \text{ u opštem slučaju.}$$

Ne treba memorisati 230 prostornih grupa da bi se koristila ćelija. Treba razumeti da ograničenja dolaze iz simetrije i da zaobljavanje ugla bliskog 90° nije dokaz više simetrije.

Sedam sistema i 14 Bravaisovih tipova bez taksonomske zamke

Ovde se često pomešaju **crystal system** i **lattice system**. Sedam kristalnih sistema su triclinic, monoclinic, orthorhombic, tetragonal, trigonal, hexagonal i cubic. Sedam rešetkastih sistema imaju istu listu osim što se **rhombohedral** pojavljuje umesto **trigonal**. Trigonalni kristal može imati rhombohedral (hR) ili hexagonal (hP) tip rešetke; zato **trigonal**, **rhombohedral** i **hexagonal setting** nisu sinonimi.

Sljedeća tabela zato klasifikuje svih 14 Bravaisovih tipova po **rešetkastom sistemu**. Ograničenja su za uobičajenu konvencionalnu ćeliju i predstavljaju simetrijski zahtev, ne test koji sam dokazuje space group.

Rešetkasti sistem	Konvencionalna metrička ograničenja	Bravaisovi tipovi
triclinic	nema simetrijski nametnutih jednakosti; uglovi su opšti	aP
monoclinic, unique- b	$\alpha = \gamma = 90^\circ$; β je opšti ugao	mP, mS
orthorhombic	$\alpha = \beta = \gamma = 90^\circ$; dužine su nezavisne	oP, oS, oI, oF
tetragonal	$a = b$, c nezavisno; svi uglovi 90°	tP, tI
rhombohedral, primitive axes	$a = b = c$; $\alpha = \beta = \gamma$, opšti jednaki ugao	hR
hexagonal axes	$a = b$, c nezavisno; $\alpha = \beta = 90^\circ$, $\gamma = 120^\circ$	hP
cubic	$a = b = c$; $\alpha = \beta = \gamma = 90^\circ$	cP, cI, cF

P je primitive, I body-centred, F all-face-centred, a IUCr oznaka S znači single-face-centred nezavisno od konkretnog A, B ili C setting-a. U CIF space-group simbolu ćeš češće videti konkretno slovo centriranja, na primer C 2/c ili F m $\bar{3}$ m.

Metrika može slučajno imati višu simetriju

Monoklinična ili orthorhombic ćelija može slučajno imati dve gotovo jednake ivice. To je **metric specialization**, ne automatski dokaz tetragonalne ili cubic simetrije. Crystal system se određuje iz point/space-group simetrije uz tolerancije i validaciju, ne samo poređenjem šest zaokruženih brojeva.

Lokalni `search2` eksport sadrži svih sedam raw cell-setting etiketa. Pri normalizaciji čuvaj raw vrednost, space-group identifikator i transformaciju. Posebno:

```
raw_cell_setting = "rhombohedral"
→ lattice_system = "rhombohedral"
→ crystal_system = "trigonal"
→ setting/provenance ostaju eksplicitni
```

Sama hexagonal metrika ne razdvaja trigonalni `hP` od hexagonalnog kristalnog sistema; za to je potreban space group/point group. Standardna lista i nomenklatura su u [IUCr tabeli sedam sistema i 14 rešetki](#) i [IUCr nomenklaturi Bravaisovih tipova](#).

Zapremina jedinične ćelije

Opšta zapremina je apsolutna vrednost skalarnog trostrukog proizvoda:

$$V = |\mathbf{a} \cdot (\mathbf{b} \times \mathbf{c})|.$$

Iz šest parametara:

$$V = abc \sqrt{1 + 2 \cos \alpha \cos \beta \cos \gamma - \cos^2 \alpha - \cos^2 \beta - \cos^2 \gamma}.$$

Za monokliničnu ćeliju sa $\alpha = \gamma = 90^\circ$:

$$V = abc \sin \beta.$$

Lokalni `cu_n14_a.cif` navodi:

Parametar	Vrednost
a	12,7138(3) Å
b	15,3951(4) Å
c	10,6106(3) Å
α	90°
β	93,235(1)°
γ	90°
prijavljeno V	2073,51(9) Å ³

Račun:

$$12.7138 \cdot 15.3951 \cdot 10.6106 \cdot \sin(93.235^\circ) \approx 2073.51 \text{ Å}^3$$

reprodukuje CIF vrednost. To proverava internu geometrijsku konzistentnost tih polja, ne hemijski identitet strukture.

Frakcione koordinate

Frakciona koordinata:

$$\mathbf{f} = \begin{bmatrix} x \\ y \\ z \end{bmatrix}$$

znači:

$$\mathbf{r} = x\mathbf{a} + y\mathbf{b} + z\mathbf{c}.$$

Vrednost $x = 0.25$ nije 0,25 Å. Ona znači četvrtinu vektora $\mathbf{a}$, uz doprinose ostalih koordinata. Frakcione koordinate su prirodne za simetriju i periodičnost; Cartesian koordinate su prirodne za fizičke udaljenosti, uglove i poravnanje.

Matrica ćelije i fractional $\rightarrow$ Cartesian

Postavi vektore ćelije kao kolone matrice:

$$\mathbf{A} = \begin{bmatrix} | & | & | \\ \mathbf{a} & \mathbf{b} & \mathbf{c} \\ | & | & | \end{bmatrix}.$$

Tada je:

$$\boxed{\mathbf{r} = \mathbf{A}\mathbf{f}}.$$

Jedna uobičajena Cartesian konvencija je:

$$\mathbf{A} = \begin{bmatrix} a & b \cos \gamma & c \cos \beta \\ 0 & b \sin \gamma & c \frac{\cos \alpha - \cos \beta \cos \gamma}{\sin \gamma} \\ 0 & 0 & \frac{V}{ab \sin \gamma} \end{bmatrix}.$$

Ovo je izbor frame-a. Drugi softver može rotirati celu Cartesian predstavu, a da fizička struktura ostane ista. Zato se Cartesian koordinate iz dva fajla ne porede direktno bez usaglašavanja frame-a.

Monoklinični N14 slučaj

Pošto su $\alpha = \gamma = 90^\circ$, matrica se pojednostavljuje:

$$\mathbf{A} = \begin{bmatrix} a & 0 & c \cos \beta \\ 0 & b & 0 \\ 0 & 0 & c \sin \beta \end{bmatrix}.$$

Zato:

$$\begin{aligned} X &= ax + cz \cos \beta, \\ Y &= by, \\ Z_{\text{cart}} &= cz \sin \beta. \end{aligned}$$

C1 u lokalnom CIF-u ima:

$$(x, y, z) = (0.55515, 0.54005, 0.15800).$$

Za $\cos 93.235^\circ \approx -0.0564314$ i $\sin 93.235^\circ \approx 0.9984065$:

$$\begin{aligned}
 X &= 12.7138(0.55515) + 10.6106(0.15800) \cos 93.235^\circ \\
 &= 7.05807 - 0.09461 \approx 6.96346 \text{ \AA}, \\
 Y &= 15.3951(0.54005) \approx 8.31412 \text{ \AA}, \\
 Z_{\text{cart}} &= 10.6106(0.15800) \sin 93.235^\circ \\
 &\approx 1.67380 \text{ \AA}.
 \end{aligned}$$

N14.mo12 navodi C1 kao približno:

$$(6.9635, 8.3141, 1.6738) \text{ \AA}.$$

To je jaka reproduktivna potvrda koordinatne transformacije i veze između lokalnog CIF-a i MOL2 izvoza.

Cartesian → fractional

Ako je matrica ćelije regularna:

$$\mathbf{f} = \mathbf{A}^{-1} \mathbf{r}.$$

Za lokalni monoklinični oblik:

$$\begin{aligned}
 z &= \frac{Z_{\text{cart}}}{c \sin \beta}, \\
 y &= \frac{Y}{b}, \\
 x &= \frac{X - cz \cos \beta}{a}.
 \end{aligned}$$

Round-trip test treba da proveriti:

$$\mathbf{f} \xrightarrow{\mathbf{A}} \mathbf{r} \xrightarrow{\mathbf{A}^{-1}} \mathbf{f}'$$

i da je $\mathbf{f}' - \mathbf{f}$ celobrojni vektor do numeričke tolerancije. Za periodične koordinate razlika od tačno 1 u jednoj komponenti nije fizička greška.

Periodična ekvivalencija i wrap

Frakcione koordinate:

$$\mathbf{f} \text{ i } \mathbf{f} + \mathbf{n}, \quad \mathbf{n} \in \mathbb{Z}^3$$

opisuju isti položaj u različito označenoj ćeliji.

Uobičajeni wrap u interval $[0, 1)$ je:

$$\text{wrap}(\mathbf{f}) = \mathbf{f} - \lfloor \mathbf{f} \rfloor$$

komponentno. Na primer, $(-0.02, 1.03, 0.40)$ se prikazuje kao $(0.98, 0.03, 0.40)$.

Ne gubi unwrapped poreklo

Wrap je prikazna/kanonizaciona operacija. Ako se svaka koordinata nezavisno wrap-uje, povezan molekul može vizuelno „pući“ preko granice ćelije. Čuvaj originalne koordinate, image-vektore i transformaciju; za molekulske deskriptore prvo napravi hemijski konzistentnu celu komponentu.

Metric tensor i fizička udaljenost

Metric tensor ćelije je:

$$\mathbf{G} = \mathbf{A}^T \mathbf{A}.$$

Za frakcionu razliku $\Delta \mathbf{f}$:

$$d^2 = \Delta \mathbf{f}^T \mathbf{G} \Delta \mathbf{f}.$$

Za periodični par traži se:

$$d_{\min} = \min_{\mathbf{n} \in \mathbb{Z}^3} \sqrt{(\Delta \mathbf{f} + \mathbf{n})^T \mathbf{G} (\Delta \mathbf{f} + \mathbf{n})}.$$

U ortogonalnoj ćeliji često je dovoljno svaku komponentu svesti u približno $[-0.5, 0.5]$. U veoma kosoj ćeliji komponentno zaokruživanje ne mora dati najkraći Cartesian vektor. Pouzdan sistem koristi redukovanu ćeliju, neighbor-list algoritam ili eksplicitnu pretragu matematički dovoljnog skupa slika.

Koliko susednih ćelija treba pretražiti?

Fiksno pravilo „uvek $-1, 0, 1$ u svakoj osi“ nije univerzalno:

- može biti dovoljno za mali cutoff i dobro uslovljenu ćeliju;
- može propustiti sliku za veći cutoff, veoma kratke/duge ili kose vektore;
- može nepotrebno duplirati mnogo kandidata.

Opseg treba izvesti iz cut-off radijusa i geometrije ćelije ili prepustiti validiranoj biblioteci. Rezultat treba testirati na transformisanim i supercell ekvivalentima istog kristala.

Jedinična ćelija nije jedinstvena

Ako su kolone $\mathbf{A}$ stara baza, a $\mathbf{P}$ matrica promene baze:

$$\mathbf{A}' = \mathbf{A} \mathbf{P}.$$

Za isti fizički položaj i isti origin:

$$\mathbf{f}' = \mathbf{P}^{-1} \mathbf{f}.$$

Metric tensor se menja kao:

$$\mathbf{G}' = \mathbf{P}^T \mathbf{G} \mathbf{P}.$$

Ako je $\mathbf{P}$ celobrojna unimodularna matrica, $|\det \mathbf{P}| = 1$, dobija se druga baza iste rešetke i iste zapremine. Ona je primitivna **ako je i početna baza primitivna**; unimodularna transformacija čuva primitivnost, ali ne pretvara centriranu konvencionalnu ćeliju u primitivnu.

Ako je $\mathbf{P}$ celobrojna matrica i $|\det \mathbf{P}| = m > 1$, nova baza razapinje podrešetku indeksa m u rešetki razapetoj početnom bazom i njena ćelija ima m puta veću zapreminu. Da bi takav supercell predstavljao isti beskonačni kristal, atomski motiv se ne „uvećava“ proizvoljno: generiše se m translacionih kopija, po jedan coset representative početne rešetke u odnosu na podrešetku, zatim se uklanjaju periodični duplikati.

Ako se origin pomeri za $\mathbf{o}$, nove frakcione koordinate su:

$$\mathbf{f}' = \mathbf{P}^{-1}(\mathbf{f} - \mathbf{o}).$$

Udaljenosti, uglovi, periodični kontakti obrazac i fizički kristal se time ne menjaju. Sirove koordinate, ćelijski parametri i zapisi symmetry operations mogu se promeniti.

Primitive, conventional, reduced i standardized

Opis	Svrha	Oprez
primitive cell	sadrži jednu rešetkastu tačku	ne mora biti najintuitivnija
conventional cell	prikazuje simetriju prema konvenciji	može biti veća od primitivne
reduced cell	metrički kanonizovaniji opis rešetke	slična reduced cell ne dokazuje isti atomski packing
standardized cell	softverski izabrana konvencija	zavisi od standarda, tolerancije i verzije
supercell	celobrojno proširenje ćelije	isti kristal dobija više atoma i veću zapreminu

Reduced-cell search je dobar kandidat-generator za slične rešetke. Nije dovoljan crystal-structure comparator, jer ne proverava hemijski identitet i potpuno atomsko pakovanje.

Z, Z' i sadržaj ćelije

Z je broj formula units u jediničnoj ćeliji. To nije:

- broj atoma;
- atomski broj elementa;
- broj molekula u CIF atomskom loop-u;
- broj redova posle symmetry expansion-a.

Z' , čita se „Z prime“, u molekulskom opisu označava broj formula units u asimetričnoj jedinici. Uz dosledno izabranu hemijsku formulu, ćeliju i multiplicity opšte pozicije m , standardna definicija daje:

$$Z' = \frac{Z}{m}, \quad Z = mZ'.$$

Specijalne pozicije ne ukidaju ovaj odnos: mogu dati razlomljeno Z' , na primer polovinu molekula nezavisno navedenu u ASU. Ono što ne sme da se radi jeste da se broj redova atomskog loop-a ili broj celih nacrtanih molekula proglasi za Z' . Višekomponentne forme, polimerne mreže, disorder i parcijalne occupancy vrednosti zahtevaju proveru šta predstavlja formula unit i da li se sastav iz site multiplicity-ja i occupancy-ja slaže sa prijavljenim Z . Definicija i granice tumačenja dati su u [IUCr rečniku za Z i Z'](#).

Za N14:

- space group $P2_1/c$ ima četiri opšte pozicije u navedenoj conventional ćeliji;
- ASU sadrži jednu kompletnu formulu $C_{25}H_{20}N_3O_2P$;
- sva navedena mesta imaju site-symmetry order 1 i occupancy 1;
- CIF navodi $Z = 4$.

Zato je u ovom urednom slučaju:

$$Z' = 1.$$

Četiri symmetry-related kopije daju $4 \times 51 = 204$ atomske pozicije po ćeliji kada se računaju i svi navedeni H atomi.

Gustina kao provera konzistentnosti

Za molarnu masu M , zapreminu V i Z :

$$\rho = \frac{ZM}{N_A V}.$$

Kada je V u $\text{\AA}^3$, koristi se:

$$1 \text{ \AA}^3 = 10^{-24} \text{ cm}^3.$$

Za N14:

$$\rho = \frac{4 \cdot 425.41 \text{ g mol}^{-1}}{(6.02214076 \times 10^{23} \text{ mol}^{-1})(2073.51 \times 10^{-24} \text{ cm}^3)} \approx 1.363 \text{ g cm}^{-3}.$$

To odgovara `_exptl_crystal_density_diffn 1.363`. Saglasnost proverava formulu, Z , zapreminu i račun kao paket. Ne dokazuje da je svaki atom ili bond type ispravan.

Pojmovni slojevi opisa ćelije

Šest normalizovanih brojeva nije dovoljno da se razume poređenje. Naučni opis razlikuje:

- originalne $a, b, c, \alpha, \beta, \gamma, V$ vrednosti i s.u.;
- originalni Cartesian cell matrix $\mathbf{A}$;
- originalni space-group/Hall zapis i symmetry operations;
- standardized/reduced matrix kao izvedeni sloj;
- $\mathbf{P}$ i origin shift $\mathbf{o}$;
- $\det(\mathbf{P})$ i odnos primitive/conventional/supercell;
- originalne i transformisane frakcione koordinate;
- tolerancije i verzije biblioteka;
- round-trip i atom-mapping validaciju;
- Z , izvedeni Z' samo kada je metod opravdan, i confidence.

Ovo su kategorije potrebne za tumačenje ekvivalentnosti i gubitka informacije, ne propisana record schema ili budući tok skladištenja.

Posledice za dve aplikacije

Globalna pretraga

- Originalna ćelija je provenance; reduced/standardized ćelija je indeksni prikaz.
- Cell similarity može brzo pronaći slične rešetke, ali mora biti odvojen od molecular i packing similarity.
- Feature mora biti robustan na permutaciju ekvivalentnih osa, setting i konvencionalnu/primitivnu predstavu.
- Temperatura i pritisak su potrebni jer ćelija fizički varira sa uslovima.
- Korisniku treba objasniti da je pogodak „sličan po metric tensor-u“, ne automatski „isti kristal“.

Poređenje svih parova

- Pre cell distance-a pokušaj standardizaciju i eksplicitne basis/origin transformacije.
- Poredi zapreminu po uporedivoj formula unit ili primitivnoj ćeliji kada se veličine ćelija razlikuju.
- Supercell par ne sme biti ocenjen kao potpuno različit samo zbog više atoma i veće zapremine.
- Posle lattice match-a obavezno proveriti hemijski identitet i periodično atomsko mapiranje.
- Vрати transformaciju koja reprodukuje podudaranje, residual metric error i atom-level coverage.

Tipične zamke

1. Tumačiti frakcionu koordinatu kao udaljenost u Å.
2. Računati udaljenost običnom normom frakcionih razlika.
3. Ignorirati $\beta \neq 90^\circ$ u N14.
4. Porediti Cartesian koordinate iz dva programa bez poravnanja frame-a.
5. Wrap-ovati svaki atom i tako rascepiti molekul preko granice.
6. Koristiti samo atome unutar $[0, 1)^3$ pri neighbor search-u.
7. Verovati da slična ćelija dokazuje isti packing.
8. Verovati da različita ćelija dokazuje različit kristal pre provere setting-a ili supercell-a.
9. Prepisati originalnu ćeliju standardizovanom i izgubiti provenance.
10. Pretpostaviti $Z' = Z / |\text{symmetry operations}|$ bez provere specijalnih pozicija i stehiometrije.
11. Mešati Z sa brojem atomskih redova u CIF-u.
12. Zaokružiti ćeliju/koordinate pre računanja i napraviti lažne razlike.

Mini-vežbe

1. Zapremina N14

Zašto se u formuli zapremine pojavljuje $\sin \beta$, a ne samo proizvod abc ?

Odgovor

Zato što a i c nisu ortogonalni. Proizvod abc važi za pravougaoni paralelepiped; faktor $\sin \beta$ uzima komponentu jednog vektora normalnu na drugi.

2. C1 fractional $\rightarrow$ Cartesian

Izračunaj C1 koristeći lokalnu monokliničnu matricu.

Odgovor

Dobija se približno (6.96346, 8.31412, 1.67380) Å, što se slaže sa N14.mo12 posle zaokruživanja na četiri decimale.

3. Periodična ekvivalencija

Da li (0.98, 0.03, 0.40) i (−0.02, 1.03, 0.40) predstavljaju različite frakcione položaje?

Odgovor

Ne. Razlikuju se za celobrojni vektor (−1, 1, 0), pa su periodično ekvivalentni.

4. Supercell

Od ćelije napraviš $2 \times 1 \times 1$ supercell. Šta se događa sa zapreminom, brojem formula units i gustinom?

Odgovor

Zapremina i Z se udvostručuju, dok gustina ostaje ista. Ako comparator koristi sirovu zapreminu ili atom count bez normalizacije, isti kristal može izgledati različito.

5. Z' za N14

Zašto je opravdano $Z' = 1$, a nije samo slepo deljenje?

Odgovor

ASU sadrži jednu kompletnu formula unit, sva atomska mesta su na opštim pozicijama sa occupancy 1, multiplicity opšte pozicije je četiri i CIF navodi $Z = 4$. Svi delovi dokaza su međusobno saglasni.

6. Reduced-cell pogodak

Dve strukture imaju gotovo iste reduced-cell parametre. Šta još moraš proveriti pre tvrdnje da su iste?

Odgovor

Hemijski sastav i komponente, symmetry/setting transformaciju, periodično atomsko mapiranje, konformaciju i packing, kao i temperaturu, pritisak i kvalitet određivanja.

7. Raw `rhombohedral` etiketa

Eksport ima `_cell_setting = rhombohedral`. Koja tri odvojena polja treba sačuvati?

Odgovor

Sačuvaj originalnu raw etiketu, normalizuj `lattice_system = rhombohedral` i `crystal_system = trigonal`, pa odvojeno sačuvaj space group, setting i svaku primenjenu transformaciju. Sama metrika nije dovoljna za potpunu klasifikaciju simetrije.

Kriterijum prolaza

Poglavlje si savladao kada možeš da iz `cu_n14_a.cif` konstruišeš cell matrix, reprodukuješ zapreminu, C1 Cartesian koordinatu i gustinu, mapiraš svih 14 Bravaisovih tipova na rešetkaste sisteme bez učenja napamet i objasniš kako bi comparator prepoznao isti kristal zapisan drugim origin-om, bazom ili supercell-om.

Primarni i autoritativni izvori

- IUPAC Gold Book: unit cell
- IUCr Online Dictionary: unit cell
- IUCr Online Dictionary: primitive cell
- IUCr Online Dictionary: centred lattice
- IUCr teaching pamphlet 9: matrices, translations and transformations
- IUCr teaching pamphlet 10: metric tensor
- IUCr teaching pamphlet 21: crystal packing

- [CCDC Python API: reduced-cell searching](#)
- [spglib: symmetry dataset and standardized cells](#)
- [MIT OpenCourseWare 3.091: Introduction to Solid-State Chemistry](#)

9. Simetrija, prostorne grupe i periodičnost


Šta treba da umeš posle ovog poglavlja

Posle ovog poglavlja treba da možeš da:

- objasniš šta symmetry operation radi nad frakcionim koordinatama;
- razlikuješ identity, rotation/screw, reflection/glide i inversion;
- iz asimetrične jedinice generišeš sadržaj jedinične ćelije;
- razlikuješ asimetričnu jedinicu, opštu i specijalnu poziciju;
- protumačiš Z , Z' , multiplicity, occupancy i site symmetry bez njihovog mešanja;
- pročitáš osnovno značenje oznake $P2_1/c$, IT broja i Hall simbola;
- objasniš zašto $P2_1/c$ i $P2_1/n$ mogu biti različiti setting-i istog space-group type-a #14;
- transformišeš ćeliju, koordinate i symmetry operations pri promeni basis-a i origin-a;
- dizajniraš poređenje koje je invarijantno na setting, basis, origin, red atoma i red operacija;
- izbegneš i false-negative i false-positive zaključke zasnovane samo na space-group stringu.

Intuicija: jedna instrukcija proizvodi mnogo ekvivalentnih kopija

Simetrijska operacija je transformacija koja preslikava celu idealizovanu kristalnu strukturu na samu sebe. Ona ne pomera samo jedan atom. Ako se operacija primeni na sve atome asimetrične jedinice, dobija se symmetry-related sadržaj.



Asimetrična jedinica nije nužno ceo molekul, niti je jedinična ćelija nužno „četiri puta kopiran fajl“ bez dodatne logike. Specijalne pozicije, disorder, occupancy i komponente mogu promeniti jednostavno brojanje.

Simetrijska operacija kao afina transformacija

U frakcionim koordinatama operacija se piše:

$$\mathbf{f}' = \mathbf{R}\mathbf{f} + \mathbf{t}$$

gde je:

- $\mathbf{R}$ rotacioni/refleksioni deo;
- $\mathbf{t}$ translacioni deo u frakcionim jedinicama;
- rezultat se posmatra modulo celobrojne lattice translacije.

Zato su:

$$\mathbf{f}' \text{ i } \mathbf{f}' + \mathbf{n}, \quad \mathbf{n} \in \mathbb{Z}^3$$

isti periodični položaj.

Za kristalografske symmetry operations elementi $\mathbf{R}$ u odgovarajućoj frakcionoj bazi tipično su mali celi brojevi. Translacioni deo može sadržati razlomke poput $1/2$, $1/3$ ili $1/4$.

Osnovni tipovi operacija

Tip	Geometrijska ideja	Translacioni dodatak
identity	ništa se ne menja	nema
proper rotation	rotacija oko ose	nema netrivialne translacije duž ose
screw axis	rotacija + translacija paralelno osi	da
mirror	refleksija kroz ravan	nema glide komponente
glide plane	refleksija + translacija paralelno ravni	da
inversion	$\mathbf{r} \mapsto -\mathbf{r}$ oko centra	origin određuje zapis
rotoinversion	rotacija praćena inverzijom	zavisi od setting-a

Translation subgroup zatim ponavlja sve dobijene položaje kroz ceo kristal.

Za projekat je važnija operacija od imena

Naziv screw/glide elementa pomaže razumevanju, ali comparator treba da radi sa punim ($\mathbf{R}, \mathbf{t}$) operacijama i njihovim transformacijama. Sam tekstualni label nije dovoljan za reproduktivno atomsko mapiranje.

Lokalni $P2_1/c$ primer

cu_n14_a.cif navodi:

- kristalni sistem: monoclinic;
- IT broj: 14;
- Hermann–Mauguin oznaku: $P\ 2_1/c$;
- Hall simbol: $-P\ 2ybc$;
- četiri symmetry operations:

1. (x, y, z) ,
2. $(-x, y + \frac{1}{2}, -z + \frac{1}{2})$,
3. $(-x, -y, -z)$,
4. $(x, -y - \frac{1}{2}, z - \frac{1}{2})$.

Četvrta operacija se može zapisati sa drugim celobrojnim translacionim predstavnikom, na primer dodavanjem celih brojeva komponentama. Time se dobija ista klasa operacija **modulo ćelijske translacije**, pa su wrap-ovani položaji isti. U punom beskonačnom prostoru to ipak jesu različite operacije: mogu dati atome u različitim ćelijama. Pri računu konkretnog kontakta promena predstavnika zato mora biti praćena suprotnom promenom image/translacionog vektora, tako da se sačuva ista fizička kopija atoma.

U standardnoj interpretaciji:

- P označava primitive lattice;
- 2_1 označava screw simetriju paralelnu jedinstvenoj osi b ;
- c označava glide komponentu u odgovarajućoj ravni;
- point-group tip je $2/m$.

Ovaj kratki opis nije zamena za punu listu operacija. Položaj osa/ravni zavisi od origin-a i setting-a.

Simetrija kristala i hiralnost molekula

Inverzija menja hiralni molekul u njegovu suprotnu enantiomernu sliku. Zato uređen kristal koji zaista pripada centrosimetričnoj grupi, kao što je $P2_1/c$, ne može sadržati samo jedan enantiomer hiralnih molekula: ako su oni prisutni, simetrija zahteva i suprotnu sliku. To ne dokazuje da je svaki pojedinačni molekul u takvoj grupi ahiralan.

Uređeni enantiomerno čisti molekulski kristali pripadaju jednoj od 65 **Sohncke** grupa, koje imaju samo translacije, rotacije i screw operacije. Sama Sohncke grupa ipak ne dokazuje enantiomernu čistoću molekulskog sadržaja; treba pregledati sve nezavisne komponente i eksperimentalni dokaz. Hiralnost molekula, hiralnost pakovanja i apsolutna struktura zato su odvojena pitanja. Videti IUCr: [Sohncke grupe](#) i IUCr primeri izbora simetrije kod enantiomerno čistih kristala; eksperimentalna granica obrađena je u poglavlju 10.

Generisanje četiri C1 položaja

C1 u ASU ima:

$$\mathbf{f}_{C1} = (0.55515, 0.54005, 0.15800).$$

Primena četiri operacije i wrap u $[0, 1)$ daje:

Operacija	Pre wrap-a	Posle wrap-a
1	(0.55515, 0.54005, 0.15800)	(0.55515, 0.54005, 0.15800)
2	(-0.55515, 1.04005, 0.34200)	(0.44485, 0.04005, 0.34200)
3	(-0.55515, -0.54005, -0.15800)	(0.44485, 0.45995, 0.84200)
4	(0.55515, -1.04005, -0.34200)	(0.55515, 0.95995, 0.65800)

Isti postupak se primenjuje na svih 51 položaj u ASU. Važno je da se molekulske kopije formiraju konzistentno: ako se svaki atom nezavisno wrap-uje, jedna symmetry-generated molekulaska kopija može izgledati rascepljeno preko više lica ćelije.

Asimetrična jedinica

Asimetrična jedinica, ASU, jeste najmanji jedinstveni deo kristalne strukture iz kog se space-group simetrijom dobija sadržaj ćelije, a translacijama ceo kristal.

ASU može sadržati:

- jedan ceo molekul;
- više nezavisnih molekula;
- samo deo molekula ako ostatak generiše specijalna simetrija;
- više komponenti soli, solvata ili kokristala;
- disorder alternative sa parcijalnim occupancy vrednostima;
- deo beskonačne koordinacione ili polimerne mreže.

Zato atom count u ASU nije samostalni hemijski identifikator.

ASU nije sinonim za molekul

Molecular RMSD nad ASU koordinatama može porediti različite fragmente ili različit broj nezavisnih molekula. Pre poređenja mora se rekonstruisati hemijska komponenta i definisati da li se poredi molekul, formula unit, local environment ili packing cluster.

Opšta i specijalna pozicija

Atom je na opštoj poziciji ako ga nijedna netrivialna operacija ne preslikava na isti položaj modulo lattice translacije. Broj različitih kopija jednak je multiplicity-ju opšte pozicije.

Atom je na specijalnoj poziciji ako ga jedna ili više netrivialnih operacija ostavljaju na istom periodičnom mestu. Tada:

- site symmetry je viša;
- multiplicity je manji od multiplicity-ja opšte pozicije;
- nezavisni deo molekula može biti frakcija cele hemijske jedinice;
- occupancy i multiplicity moraju se tumačiti zajedno.

Na primer, atom tačno u inversion centru $(0, 0, 0)$ zadovoljava:

$$(-x, -y, -z) = (x, y, z)$$

modulo celobrojnu translaciju. Operacija inverzije ne daje novu kopiju tog atoma.

Pri symmetry expansion-u zato nije ispravno samo proizvesti sve operacije i zadržati duplikate. Duplikati se uklanjaju po periodičnoj geometriji, elementu/species-u, disorder grupi i numeričkoj toleranciji.

Z, Z', multiplicity i occupancy

Četiri pojma odgovaraju na različita pitanja:

Pojam	Pitanje
Z	koliko formula units ima u navedenoj jediničnoj ćeliji?
Z'	koliko kristalografski nezavisnih formula units ima u ASU, u primenljivoj molekulskoj definiciji?
multiplicity	koliko ekvivalentnih položaja dato crystallographic site daje u ćeliji?
occupancy	koji udeo tih site-ova zauzima navedena vrsta/modelovana alternativa?

Za jedno atomsko mesto doprinos broju atoma po ćeliji je konceptualno:

$$N_{\text{cell,site}} = m_{\text{site}} \cdot \text{occupancy},$$

uz pažljiv tretman mešanih vrsta i disorder alternativa.

Za N14:

- četiri su opšte operacije;
- svako navedeno atomsko mesto ima site-symmetry order 1;
- occupancy je 1;
- ASU sadrži jednu kompletnu formulu;
- $Z = 4$.

Zato je $Z' = 1$ i jedna formula iz ASU generiše četiri formula units u ćeliji.

Molekul na inversion centru mogao bi imati samo polovinu svojih atoma nezavisno navedenu i dati $Z' = 0.5$ u uobičajenoj molekulskoj terminologiji. To nije „pola fizičkog molekula“; druga polovina je generisana simetrijom.

Prostor-na grupa nije samo string

Jedan CIF može pružiti više nivoa identifikacije:

Zapis	Šta primarno govori
crystal system	najšira geometrijska klasa
Bravais/lattice centering	translaciona rešetka i centriranje
Hermann–Mauguin simbol	čitljiv opis simetrijskih elemenata u setting-u
IT broj	tip space group-a, nezavisniji od tekstualne varijante
Hall simbol	eksplicitniji opis generatora, ose i origin konvencije
puna lista (R, t)	operacije koje se zaista primenjuju u tom zapisu

Sistem treba da proveri saglasnost tih slojeva. Ne treba tiho „ispraviti“ neslaganje na osnovu samo jednog polja.

P₂/c naspram P₂/n

P_{2_1}/c i P_{2_1}/n mogu biti alternativni setting-i istog space-group type-a sa IT brojem 14. Promenom basis-a, a po potrebi i origin-a, glide komponenta i ćelijski vektori dobijaju drugi zapis, dok fizička struktura može ostati ista.

Lokalni `search1` audit daje:

- 489 zapisa sa raw stringom P_{2_1}/c ;
- 380 sa P_{2_1}/n ;
- ukupno 885 zapisa sa IT brojem 14, jer postoje i druge tekstualne/postavne varijante.

Ako model koristi raw string kao kategoriju, veštački razdvaja veliki broj struktura istog space-group type-a. Ali obrnuta prečica je podjednako pogrešna:

Isti IT broj ne znači isti kristal

Dve potpuno različite strukture mogu obe pripadati space group-u #14. IT broj uklanja setting-level false negative; ne dokazuje isti sastav, ćeliju, konformaciju ili packing.

Ispravan comparator traži konkretnu transformaciju ćelije i periodično atomsko mapiranje.

Promena basis-a i origin-a

Neka je stara cell matrix $\mathbf{A}$, a nova:

$$\mathbf{A}' = \mathbf{A}\mathbf{P}.$$

Definišimo $\mathbf{o}$ kao položaj novog origina izražen u starim frakcionim koordinatama. Tada:

$$\mathbf{f}' = \mathbf{P}^{-1}(\mathbf{f} - \mathbf{o}).$$

Za staru symmetry operation:

$$\mathbf{f}_{\text{out}} = \mathbf{R}\mathbf{f} + \mathbf{t},$$

operacija u novom setting-u je:

$$\boxed{\mathbf{R}' = \mathbf{P}^{-1}\mathbf{R}\mathbf{P}}$$

i:

$$\boxed{\mathbf{t}' = \mathbf{P}^{-1}[\mathbf{t} + (\mathbf{R} - \mathbf{I})\mathbf{o}]}$$

modulo celobrojne translacije.

Znak origin člana zavisi od toga kako softver definiše smer transformacije; gornje jednačine važe za eksplicitno navedenu konvenciju $\mathbf{f}' = \mathbf{P}^{-1}(\mathbf{f} - \mathbf{o})$. API poziv bez dokumentovanja konvencije nije reproduktivan.

Šta sme da se promeni

- brojevi $a, b, c, \alpha, \beta, \gamma$;
- raw frakcije i Cartesian koordinate;
- Hermann–Mauguin setting string;
- translacioni delovi symmetry operations;
- redosled operacija;
- redosled atoma i način na koji molekul prelazi granicu ćelije;
- Z i atom count ako se pređe na supercell ili ćeliju druge zapremine.

Šta fizički ne sme da se promeni

- hemijski sastav i stvarni atomski identitet;
- periodične međuatomske udaljenosti i uglovi;
- koordinaciono i kontaktno okruženje;
- chirality fizičkog objekta, iako koordinatni frame može promeniti handedness;
- gustina;
- apstraktni space-group type za ekvivalentan setting;
- whole-crystal packing, posle ispravnog periodičnog mapiranja.

Origin invariance

Promena origina za isti vektor svim koordinatama ne menja relativne vektore:

$$(\mathbf{f}_i - \mathbf{o}) - (\mathbf{f}_j - \mathbf{o}) = \mathbf{f}_i - \mathbf{f}_j.$$

Međutim, translacioni delovi symmetry operations se menjaju prema prethodnoj formuli. Zato nije dovoljno pomeriti atome, a ostaviti stare operacije.

Jedan learned model koji direktno koristi apsolutne frakcije koordinate bez periodične/origin invarijantnosti može naučiti proizvoljnu CIF konvenciju umesto strukture.

Basis i setting invariance kao test, ne obećanje

Pouzdan standardizacioni tok je:

1. sačuvaj originalni CIF i checksum;
2. parsiraj ćeliju, koordinate i punu listu symmetry operations;
3. proveri internu saglasnost space-group tagova i operacija;
4. standardizuj uz eksplicitnu biblioteku, verziju i tolerance;
5. sačuvaj $\mathbf{P}$, $\mathbf{o}$, determinant i smer transformacije;
6. transformiši koordinate i operacije;
7. symmetry-expand i periodično mapiraj atome nazad na original;
8. proveri element/species, occupancy, maksimalni Cartesian residual i broj mapiranih atoma;
9. tek zatim izračunaj kanonske feature-e.

Metamorphic test treba da napravi ekvivalentne zapise istog kristala:

- promenjen atom order;
- promenjen red operacija;
- celobrojno pomereni atomi;
- drugi origin;
- unimodularna basis promena;
- alternativni $P2_1/c/P2_1/n$ setting;
- primitive/conventional ili validni supercell prikaz.

Skor fizičke sličnosti treba da ostane isti unutar numeričke tolerancije.

Simetrija i periodični susedi

Za atom j , operaciju s i lattice translation $\mathbf{n}$:

$$\mathbf{f}_{j,s,\mathbf{n}} = \mathbf{R}_s \mathbf{f}_j + \mathbf{t}_s + \mathbf{n}.$$

Udaljenost od atoma i računa se:

$$d_{ij}^{(s,\mathbf{n})} = \|\mathbf{A} (\mathbf{f}_{j,s,\mathbf{n}} - \mathbf{f}_i)\|_2.$$

U N14 primeru periodičnog kontakta iz poglavlja 7, O2 kontakt nije dobijen iz originalnog O2 reda, već iz operacije 2 i translacije (1, 0, 0):

$$\text{O2}^{(ii)} = (1 - x, y + \frac{1}{2}, -z + \frac{1}{2}).$$

Promena setting-a može isti fizički kontakt opisati drugim $(R, t, \mathbf{n})$ trojcem. Zato contact feature treba da bude kanonizovan po fizičkom atomskom mapiranju i geometriji, dok se originalni trojac čuva kao provenance.

Specijalne pozicije i ML/graf greške

Na specijalnoj poziciji više operacija može proizvesti isti atom. Ako se duplikati ne uklone:

- koordinacioni broj se lažno povećava;
- contact count se duplira;
- graph degree postaje zavisao od CIF encoding-a;
- formula i gustina se mogu pogrešno izračunati;
- packing comparator kažnjava potpuno ekvivalentne strukture.

Deduplication tolerance mora biti:

- izražena u Cartesian udaljenosti, ne samo frakcionoj razlici;
- manja od hemijski relevantnih razmaka;
- dokumentovana i verzionisana;
- testirana na velikim i malim ćelijama;
- svesna elementa/species-a, occupancy-ja i disorder grupe.

Ne spajaj dva različita disorder atoma samo zato što su blizu, niti zadržavaj dve symmetry-generated kopije istog specijalnog mesta.

Simetrija je deo eksperimentalnog modela

Space group nije nepogrešiva nalepnica:

- moguća je propuštena viša simetrija;
- pseudosymmetry može izgledati kao prava simetrija;
- twinning i disorder mogu otežati određivanje;
- tolerancije programa mogu dati različite standardizacije;
- CIF tag, Hall simbol i navedene operacije mogu biti nesaglasni.

Zato se originalna dodela ne prepisuje automatski rezultatom biblioteke. Čuvaju se oba sloja:

- reported symmetry;
- computed/standardized symmetry sa alatom, verzijom, tolerancijom i upozorenjima.

IUCr [checkCIF](#) i odgovarajući lokalni alati služe kao dijagnostika. Za poverljive strukture ne šalji CIF javnom servisu bez dozvole.

Teorijske posledice za dve aplikacije

Globalna pretraga

- IT number/type, Hall simbol, reported setting i standardized setting nose različite informacije i ne treba ih poistovetiti.
- Koristi space group kao filter ili feature, ne kao dokaz identiteta.
- Cell/packing poređenje zahteva kompatibilnu reprezentaciju ćelije i koordinata uz očuvanu vezu sa originalom i transformacijom.
- Candidate generation može koristiti lattice i symmetry klasu; reranking mora proveriti hemiju i periodično atomsko okruženje.
- Raw $P21/c/P21/n$ kategorije mogu stvoriti lažnu udaljenost ako se setting ne razreši.
- Symmetry-confidence i detected-vs-reported neslaganje treba da utiču na uncertainty.

Poređenje svih parova

Za tumačenje pairwise poređenja relevantni su:

- da li je nađena validna basis/origin transformacija;
- cell i symmetry residual;
- atom-mapping coverage;
- maksimalnu i RMS periodičnu atomsku razliku;
- odnos primitive/conventional/supercell;
- slaganje komponenti, koordinacije, konformacije i packing-a;
- nejasnoće zbog specijalnih pozicija, disorder-a i tolerancije.

Sledeći redosled izražava algoritamske zavisnosti, ne plan implementacije:

1. proveriti sastav i komponente;
2. pronaći kompatibilne lattice/basis transformacije;
3. usaglasiti space-group setting i origin;
4. generiši/dedupliciraj periodične položaje;
5. pronaći hemijski validan atom mapping;
6. poredi lokalnu geometriju, konformaciju, packing i kontakte;

7. poveži zaključak sa dokaznom transformacijom i uncertainty-jem.

Tipične zamke

1. Tretirati ASU kao obavezno ceo molekul.
2. Tretirati svaku symmetry-generated kopiju kao novu hemijsku vrstu.
3. Zaboraviti wrap modulo celobrojnih translacija.
4. Zadržati duplikate specijalne pozicije.
5. Izračunati Z' prostim deljenjem bez provere occupancy-ja i multiplicity-ja.
6. Tretirati $P2_1/c$ i $P2_1/n$ kao nepovezane klase.
7. Zaključiti da su dve strukture iste samo zato što imaju IT broj 14.
8. Promeniti basis koordinata, ali ne i symmetry operations.
9. Pomeriti origin atoma, ali ostaviti stare translacione delove operacija.
10. Koristiti indeks symmetry operation kao globalni feature.
11. Verovati jednoj softverskoj standardizaciji bez čuvanja tolerancije i verzije.
12. Pretvoriti pseudosymmetry u „ispravljenju“ višu simetriju bez kristalografskog pregleda.
13. Koristiti apsolutne frakcije koordinate kao ML feature bez origin invarijantnosti.
14. Dopustiti da izbor supercell-a promeni crystal similarity.

Mini-vežbe

1. Četiri C1 položaja

Primeni sve četiri operacije lokalnog CIF-a na C1 i wrap-uj rezultat.

Odgovor

Dobijaju se (0.55515, 0.54005, 0.15800), (0.44485, 0.04005, 0.34200), (0.44485, 0.45995, 0.84200) i (0.55515, 0.95995, 0.65800).

2. Broj položaja u ćeliji

ASU ima 51 atomsko mesto, sva su opšta i potpuno zauzeta. Koliko symmetry-expanded položaja ima ćelija?

Odgovor

$51 \times 4 = 204$. To je saglasno sa četiri formula units, odnosno $Z = 4$, jer jedna formula ima 51 navedeni atom.

3. $P2_1/c$ i $P2_1/n$

Da li dva CIF-a, jedan označen $P2_1/c$, drugi $P2_1/n$, automatski predstavljaju isti kristal?

Odgovor

Ne. Oznake mogu biti alternativni setting-i istog space-group type-a #14, pa raw string razlika nije dokaz različitosti. Ipak, potrebno je pronaći basis/origin transformaciju i proveriti hemijski sadržaj i periodično atomsko mapiranje.

4. Promena origina

Svim atomima oduzmeš isti origin shift. Koje veličine sigurno ostaju iste, a šta još moraš transformisati?

Odgovor

Relativne fizičke udaljenosti, uglovi i packing ostaju isti. Moraju se transformisati i translacioni delovi symmetry operations; raw frakcione koordinate i njihov zapis se menjaju.

5. Specijalna pozicija

Atom na $(0, 0, 0)$ u centrosimetričnoj grupi generisan je identity i inversion operacijom. Da li su to dva atoma?

Odgovor

Ne. Inverzija ga vraća na isto periodično mesto. To je specijalna pozicija sa smanjenim multiplicity-jem; duplikat se uklanja uz odgovarajuću toleranciju i species proveru.

6. Metamorphic test

Comparator daje 0,72 za originalni CIF, a 0,41 kada se samo promeni red symmetry operations. Šta je zaključak?

Odgovor

Comparator ima encoding artefakt. Red operacija nema fizičko značenje. Test treba da padne, a feature/mapping sloj mora biti kanonizovan ili permutaciono invarijantan.

7. Dve strukture sa IT #14

Koji je minimalni sledeći dokaz posle jednakog IT broja?

Odgovor

Potrebna je kompatibilna transformacija ćelije i origin-a, zatim periodično atomsko mapiranje uz isti hemijski sadržaj. Bez toga IT broj samo kaže da strukture pripadaju istom apstraktnom tipu prostor-ne grupe.

Kriterijum prolaza

Poglavlje si savladao kada možeš da generišes četiri N14 C1 položaja, obrazložiš $Z = 4$ i $Z' = 1$, objasniš $P2_1/c$ naspram $P2_1/n$, napišeš basis/origin transformaciju i definišeš metamorphic test kojim se dokazuje da rezultat obe aplikacije ne zavisi od proizvoljnog CIF setting-a.

Primarni i autoritativni izvori

- IUCr Core CIF dictionary
- IUCr CIF dictionaries browser
- IUCr teaching pamphlet 9: matrices, translations and transformations
- IUCr teaching pamphlet 13: symmetry
- IUCr teaching pamphlet 14: space groups
- IUCr Online Dictionary: Z and Z'

- IUCr checkCIF PLAT128: non-standard $P2_1/n$ setting
- IUCr discussion of alternative monoclinic settings
- spglib: symmetry dataset, transformations and origin shifts
- CCDC Python API: packing similarity

10. Difrakcija, refiniranje i kvalitet

Šta treba da umeš posle ovog poglavlja

Posle ovog poglavlja treba da možeš da:

- objasniš kako od difrakcionih intenziteta nastaje atomski model;
- povežeš Millerove indekse, reciprocal lattice, $d(hkl)$ i položaj pika 2θ ;
- razlikuješ simulirani powder pattern izveden iz CIF modela od izmerenog PXRD bulk uzorka;
- razlikuješ merenje, izračunati model i deskriptore slaganja između njih;
- protumačiš R, wR, goodness of fit, occupancy, disorder i standardnu neizvesnost;
- pročitaš ključna polja iz `cu_n14_a.cif` bez proglašavanja jednog broja za presudu o kvalitetu;
- koristiš checkCIF kao dijagnostički sistem, a ne kao automatski sertifikat;
- prevedeš kvalitet i neizvesnost u zahteve za obe 2CDC aplikacije.

Intuicija: CIF nije fotografija kristala

Kristal rasipa rendgensko zračenje. Detektor ne vidi atome direktno; meri položaje i intenzitete difrakcionih refleksija. Iz tih merenja, uz pretpostavljenu simetriju i hemijsko znanje, kristalograf gradi model atomskih položaja i zatim ga iterativno podešava.

Zato postoje tri različita objekta:

Sloj	Primer	Šta može biti pogrešno
eksperiment	refleksija sa indeksima h, k, l , intenzitetom I i neizvesnošću $\sigma(I)$	slab kristal, apsorpcija, preklapanje, zračenjem oštećen uzorak
model	atomi, koordinate, occupancy, displacement parametri, simetrija	pogrešan element, propušten solvent, pogrešna space group, loše modelovan disorder
izvedena geometrija	dužina veze, ugao, torzija, kontakt	zavisi od modela i njegove kovarijanse

Najvažnija rečenica

Eksperimentalna kristalna struktura je najbolje podržan model za data merenja pod navedenim uslovima. Nije savršeno poznata i nije isto što i izolovani molekul bez kristalnog okruženja.

Od Braggovog pika do modela

Za familiju ravni sa razmakom d , konstruktivna interferencija nastaje kada važi Braggov zakon:

$$n\lambda = 2d \sin \theta$$

Položaji pikova prvenstveno nose informaciju o jediničnoj ćeliji i simetriji. Intenzitet refleksije je, u idealizovanom obliku, proporcionalan kvadratu modula strukturnog faktora:

$$I(hkl) \propto |F(hkl)|^2$$

$$F(hkl) = \sum_j f_j \exp [2\pi i(hx_j + ky_j + lz_j)]$$

Ovde je f_j faktor rasipanja atoma j , a x_j, y_j, z_j njegove frakcione koordinate. Detektor meri intenzitet, ali ne i fazu kompleksnog F ; to je suština faznog problema. Rešenje strukture daje početni model, a refiniranje podešava njegove parametre da bi izračunati podaci bolje odgovarali merenim.

U ovoj pojednostavljenoj sumi j obuhvata sve atome jedinične ćelije, uključujući simetrijske kopije, uz puno zauzeće i zanemareno atomsko pomeranje. U stvarnom računu svaki doprinos nosi occupancy i displacement faktor, a atomski faktor rasipanja zavisi od ugla/rezolucije i zračenja. Suma samo preko redova ASU bez simetrijskog proširenja nije isti račun.

U `cu_n14_a.cif` piše:

- Cu K α zračenje, $\lambda = 1.54178 \text{ \AA}$;
- merenje na 100 K;
- monoklinična ćelija, $P 2_1/c$;
- refiniranje na F^2 , označeno poljem `_refine_ls_structure_factor_coef Fsqd`;
- 87.254 izmerene refleksije, svedene na 4.237 jedinstvenih refleksija za refiniranje;
- 3.891 refleksija zadovoljava $I > 2\sigma(I)$;
- izmerena frakcija do navedenog ugla je 1.000;
- 284 parametra i nijedan geometrijski restraint.

Odnos 4.237 refleksija prema 284 parametra je približno 14,9. To je korisna informacija o količini podataka u odnosu na složenost modela, ali ni taj odnos sam ne dokazuje da je model hemijski ispravan.

Za širi uvod vidi [IUCr definiciju refiniranja](#), a za formalna značenja CIF polja [IUCr Core CIF dictionary](#).

Constraint i restraint nisu isto

Constraint nameće tačnu vezu između parametara ili fiksira vrednost, pa smanjuje broj nezavisnih parametara. U riding modelu položaj H prati geometriju roditeljskog atoma. **Restraint** uvodi ciljnu geometriju sa težinom/neizvesnošću: odstupanje je dozvoljeno, ali doprinosi funkciji koja se minimizuje. Zato lokalnih `restraints` ne znači da su svi položaji nezavisno određeni — N14 istovremeno ima riding H atome i slobodnije refiniran H2N. Ovo razlikovanje objašnjava i broj parametara i neizvesnost geometrije. [IUCr rečnik restraints/constraints](#) daje formalnu razliku.

Reciprocal space: operativni most $hkl \rightarrow d \rightarrow 2\theta$

Millerovi indeksi (hkl) su celi brojevi koji opisuju orijentaciju i period ravni u odnosu na ćeliju. U frakcionim koordinatama ravni zadovoljavaju $hx + ky + lz = m$, gde je m ceo broj. Ako je neki indeks nula, ravni su paralelne toj osi; (000) ne definiše familiju sa konačnim razmakom. Na primer, (200) daje ravni $x = m/2$, pa u kubnoj ćeliji imaju razmak $a/2$. U difrakciji indekse ne svodiš automatski na najmanji odnos: (100) i (200) su različite refleksije duž istog recipročnog pravca. [IUCr: Millerovi indeksi](#).

Real-space ćeliju opisuju **a**, **b**, **c**. Za desnoruku bazu, sa $V = \mathbf{a} \cdot (\mathbf{b} \times \mathbf{c}) > 0$, i konvenciju bez faktora 2π , recipročna baza je:

$$\mathbf{a}^* = \frac{\mathbf{b} \times \mathbf{c}}{V}, \quad \mathbf{b}^* = \frac{\mathbf{c} \times \mathbf{a}}{V}, \quad \mathbf{c}^* = \frac{\mathbf{a} \times \mathbf{b}}{V}.$$

Refleksiju označenu celobrojnim Millerovim indeksima (hkl) predstavlja reciprocal-lattice vektor:

$$\mathbf{g}_{hkl} = h\mathbf{a}^* + k\mathbf{b}^* + l\mathbf{c}^*, \quad d(hkl) = \frac{1}{\|\mathbf{g}_{hkl}\|}.$$

Za cubic ćeliju ivice a :

$$d(hkl) = \frac{a}{\sqrt{h^2 + k^2 + l^2}}.$$

Sintetički CIF iz lekcije 12A ima cubic NaCl teaching ćeliju $a = 5.6400 \text{ \AA}$. Za refleksiju (200):

$$d(200) = \frac{5.6400}{2} = 2.8200 \text{ \AA}.$$

Ako se simulira Cu $K\alpha$ obrazac sa $\lambda = 1.5406 \text{ \AA}$ i uzme prvi red $n = 1$:

$$2\theta = 2 \arcsin \left(\frac{\lambda}{2d} \right) \approx 31.7^\circ.$$

To je deterministički položaj idealizovanog pika za zadatu ćeliju i talasnu dužinu. Promena ćelije pomera d i 2θ ; promena atomskih položaja/vrsta pre svega menja structure factor i intenzitet.

U single-crystal radu „rezolucija“ se često prijavljuje najmanjim dosegnutim razmakom:

$$d_{\min} = \frac{\lambda}{2 \sin \theta_{\max}}.$$

Veći $\theta_{\max}$ daje manji $d_{\min}$, odnosno višu prostornu rezoluciju. Nemoj pomešati „viša rezolucija“ sa numerički većim $d_{\min}$: smer je obrnut.

Sistematska odsustva: nedostajući pik može biti zahtev simetrije

Translacioni deo space group-a može učiniti da se doprinosi refleksiji tačno ponište. To daje **systematic absence** ili extinction. Primer je F centriranje sintetičke F m -3 m ćelije. Doprinos četiri rešetkaste tačke sadrži faktor:

$$1 + e^{\pi i(k+l)} + e^{\pi i(h+l)} + e^{\pi i(h+k)}.$$

On je nenula samo kada su h, k, l svi parni ili svi neparni. Zato su 100 i 110 zabranjeni samim F centriranjem, dok su 111 i 200 dozvoljeni. Njihovi stvarni intenziteti i dalje zavise od Na/Cl basis-a, atomskih scattering faktora, occupancy-ja, displacement parametara i eksperimentalnih efekata.

Odsustvo nije isto što i slab pik

Systematic absence je tačno selection rule svojstvo idealne simetrije. Dozvoljena refleksija može biti veoma slaba ili se slučajno poništiti zbog konkretnog motiva. Izmereni pik može izostati zbog limita detekcije, preferred orientation-a ili preklapanja. Zato se space group ne određuje jednim „ima/nema“ pravilom.

Measured, unique, merged i refined nisu isti brojevi

Broj	Šta broji
measured reflections	sva zabeležena opažanja, uključujući ponavljanja i symmetry-equivalent merenja
unique reflections	ekvivalentna opažanja svedena na jedinstvene hkl indekse pod usvojenom simetrijom
merged data	agregirane intenzitete i neizvesnosti posle skaliranja/kombinovanja ekvivalenata
reflections used in refinement	konkretna skup koji ulazi u least-squares model; kriterijum mora biti naveden

Lokalnih 87.254 measured i 4.237 unique/refinement refleksija zato nisu konflikt. Redundancy, simetrija i merging objašnjavaju razliku; R_{int} opisuje slaganje ekvivalentnih opažanja pre finalnog modela.

Simulirani naspram izmerenog PXRD-a

Pitanje	Simulirani pattern iz CIF-a	Izmereni PXRD
ulaz	ćelija, space group, atomski model, wavelength i simulation settings	bulk uzorak, instrument i eksperimentalni protokol
šta daje	očekivane položaje i relativne intenzitete idealizovanog modela	stvarne counts/intensity kroz 2θ , q ili d osu
šta utiče	radiation, range, profile broadening, occupancy/ADP tretman, software/version	kalibracija, pozadina, $K\alpha_1/\alpha_2$, veličina/strain, texture, mešavine, amorfni sadržaj, priprema i temperatura
epistemološka uloga	koristan fingerprint i predikcija onoga što bi model trebalo da daje	bulk-phase evidence i mogući dokaz mešavine/fazne promene
granica	izveden je iz istog CIF-a, pa nije nezavisna potvrda tog modela	dobro slaganje podržava fazni identitet, ali samo ne potvrđuje svaki atom ili refinement detalj SCXRD modela

Ako se pattern-i porede, interpretacija zahteva poznate kategorije eksperimentalnog/simulacionog konteksta:

- `pattern_type = simulated | measured` i izvorni fajl/hash;
- probe/radiation; wavelength(s) gde je primenljivo; tip i kalibraciju ose (2θ , q ili d);
- opseg, korak/binning, intensity scale i background/preprocessing;
- instrument/profile parametrizaciju, temperaturu, pritisak i sample preparation;
- preferred-orientation, mixture/phase i amorphous-status anotacije kada su poznate;
- software/verziju i sve simulation settings;
- comparison metric, peak-matching toleranciju i razlog svake isključene regije.

To nije propisana manifest schema, već spisak promenljivih koje mogu promeniti značenje poređenja.

Ne pravi kružni dokaz

„Simulirao sam PXRD iz CIF-a i simulacija se slaže sa istim CIF-om“ proverava implementaciju, ne fazni identitet uzorka. Nezavisan evidence nastaje tek poređenjem sa stvarno izmerenim bulk podatkom, uz unapred definisan protokol i granice zaključka.

R faktor: koliko se amplitude ne slažu

Konvencionalni R faktor se najčešće piše:

$$R = \frac{\sum_{hkl} ||F_o| - |F_c||}{\sum_{hkl} |F_o|}$$

Za isti skup podataka i refleksija, manja suma apsolutnih razlika između $|F_o|$ i $|F_c|$ daje manji R. Ipak, R zavisi od kvaliteta i rezolucije podataka, hemijskog sastava, twinning-a, disorder-a, apsorpcije, skupa uključenih refleksija i samog modela.

Lokalni CIF daje dve vrednosti:

CIF polje	Vrednost	Skup
<code>_refine_ls_R_factor_all</code>	0,0347	sve refleksije uključene u refiniranje
<code>_refine_ls_R_factor_gt</code>	0,0322	refleksije iznad kriterijuma $I > 2\sigma(I)$

Očekivano je da je R za jači podskup nešto manji. Poređenje modela A preko `R_gt` sa modelom B preko `R_all` nije čisto poređenje.

Ne pravi univerzalni prag

Pravilo tipa „ $R < 0,05$ je dobar CIF, ostalo odbaci“ je naučno neodbranljivo. Metalni kompleks sa disorder-om, struktura merena pri visokoj temperaturi i jednostavna uredna organska struktura nemaju isti očekivani profil. R može biti nizak i za pogrešan, previše fleksibilan ili nepotpun model.

wR: težinski ostatak, često na F^2

Za refiniranje na F^2 , težinski faktor se može zapisati kao:

$$wR(F^2) = \left[\frac{\sum w(F_o^2 - F_c^2)^2}{\sum w(F_o^2)^2} \right]^{1/2}$$

Težine w određuju koliko pojedina refleksija utiče na optimizaciju. U lokalnom CIF-u:

- `_refine_ls_wR_factor_ref = 0.0838;`
- `_refine_ls_wR_factor_gt = 0.0820;`
- fajl beleži i konkretnu SHELXL formulu za težine.

wR je često numerički veći od konvencionalnog R jer nije ista formula ni ista skala. Ne upoređuj ih kao da su dve procene iste veličine. Formalne definicije su u [IUCr CIF rečniku](#).

Goodness of fit: da li su ostaci saglasni sa težinama

Za least-squares refiniranje bez restraints, kao u lokalnom N14 primeru:

$$S = \left[\frac{\sum w(Y_o - Y_c)^2}{N_{\text{ref}} - N_{\text{param}}} \right]^{1/2}$$

Ovde je $Y = F^2$ za ovaj CIF. Vrednost bliska 1 često je poželjna samo ako su procenjene neizvesnosti i težine realistične.

`cu_n14_a.cif` ima:

$$S = 1.095$$

To je kompatibilno sa razumno podešenim težinama, ali nije dokaz da su hemijski identitet, space group, svi solventi i svaki disorder ispravno modelovani. GoF značajno iznad ili ispod 1 može ukazivati na loše težine, potcenjene ili precenjene neizvesnosti, model defect ili druge probleme; tumačenje mora biti kontekstualno.

Standardna neizvesnost: brojevi u zagradama nisu dekoracija

IUCr danas koristi izraz standard uncertainty, skraćeno s.u. Starija literatura često kaže e.s.d. Kada CIF navede:

- $a = 12.7138(3) \text{ \AA}$ znači procenu $12.7138 \text{ \AA}$ sa $u(a) = 0.0003 \text{ \AA}$;
- $\beta = 93.235(1)^\circ$ znači $u(\beta) = 0.001^\circ$;
- $V = 2073.51(9) \text{ \AA}^3$ znači $u(V) = 0.09 \text{ \AA}^3$;
- $d(\text{N2} - \text{N3}) = 1.3608(14) \text{ \AA}$ znači $u(d) = 0.0014 \text{ \AA}$.

Zagrade se odnose na poslednje prikazane cifre. Zapis $x \pm u(x)$ je skraćen način da se navedu procena i njena standardna neizvesnost; nije tvrd interval u kome „prava vrednost mora ležati“, niti je automatski confidence interval sa zadatim nivoom pokrivenosti. Takvo verovatnosno tumačenje zahteva dodatne pretpostavke o modelu i

raspodeli, a interval pokrivenosti mora navesti odgovarajući faktor/nivo. Standardna neizvesnost takođe nije garancija ukupne tačnosti: sistematska greška, pogrešan model ili pogrešan element mogu ostati van nje. Lokalni CIF navodi da su s.u. geometrije uglavnom izračunate iz pune kovarijanske matrice i da su s.u. ćelije uključene u račun.

Za poređenje dve dužine, gruba neizvesnost razlike nezavisnih veličina je:

$$u_{\Delta} = \sqrt{u_1^2 + u_2^2}$$

Ako je razlika manja od nekoliko u_{Δ} , aplikacija ne bi smela samouvereno da je proglasi hemijski značajnom. Korelisani parametri zahtevaju punu kovarijansu, pa je ova formula samo minimum, ne univerzalno rešenje.

Autoritativna polazna tačka je IUCr pregled [Statistical descriptors in crystallography](#).

Occupancy: koliko je kristalografsko mesto zauzeto

Occupancy opisuje udeo jediničnih ćelija u prosečnom kristalu u kojima dato mesto zauzima navedeni atom ili modelovana alternativa. Nije:

- verovatnoća da je softver „pogodio atom“;
- confidence score;
- količina elementa u molovima;
- automatski znak lošeg kvaliteta kada je manja od 1.

Occupancy ispod 1 može predstavljati vakanciju, dve alternativne pozicije, mešanu populaciju elemenata ili disorder. Alternative koje opisuju isto fizičko mesto obično moraju imati hemijski i simetrijski smislen zbir. Posebna kristalografska pozicija dodatno zahteva pažljivo razlikovanje occupancy od site multiplicity; [IUCr checkCIF primer PLAT076](#) pokazuje tipičnu zabunu.

U atomskom loop-u `cu_n14_a.cif` sva navedena mesta imaju occupancy 1, a polja za disorder assembly/group su prazna. To znači da autor nije eksplicitno modelovao parcijalno zauzeće ili alternativne disorder grupe. Ne znači da je opštim pregledom dokazano da nikakav nered ili sistematski problem ne postoji.

Disorder i displacement parametri

Kristalografski model je prostorni i vremenski prosek ogromnog broja ćelija. Ako atom ili grupa zauzimaju više položaja, moguć je:

- statički disorder: različite ćelije biraju različite konfiguracije;
- dinamički disorder: atom se tokom merenja kreće između položaja;
- occupational disorder: različite vrste ili vakancije dele mesto;
- positional disorder: ista vrsta ima više položaja.

Model može koristiti alternativne atomske pozicije, parcijalne occupancy vrednosti i grupe koje se međusobno isključuju. Atomic displacement parameters, Uiso ili Uani, opisuju prostornu raspodelu rasipanja oko srednjeg položaja. Velika ili izrazito anizotropna vrednost može biti stvarno kretanje, disorder, loš tip atoma ili drugi model problem; nije samostalna dijagnoza.

U lokalnom fajlu većina nevodonikovih atoma ima anizotropne U parametre. Većina H atoma je geometrijski postavljena riding modelom, dok je H2N naveden sa eksperimentalno refiniranim položajem. Zato ni svi atomi unutar istog CIF-a nemaju istu epistemološku težinu. Čak i slobodno refiniran H u konvencionalnom rendgenskom modelu može dati sistematski prekratku X–H internuklearnu dužinu; [poglavlje 7 objašnjava razliku i neutronske normalizaciju](#). Pri poređenju H-veza zato proveriti i koordinatnu konvenciju H, a ne samo njegovu s.u.

Apsolutna struktura i granica stereokemijskog zaključka

3D koordinate omogućavaju da se nekoj nacrtanoj molekulskoj konfiguraciji dodeli stereooznaka, ali same ne dokazuju da je odabrana pravilna enantiomerna slika eksperimentalnog uzorka. Za necentrosimetričan kristal **apsolutna struktura** razlikuje model od njegove inverzne slike. Rendgenski dokaz može koristiti razlike intenziteta Friedelovih parova (h, k, l) i $(-h, -k, -l)$ usled anomalnog rasipanja, uz odgovarajuću analizu, na primer Flack parametar sa njegovom s.u. Kada je signal nedovoljan, zaključak ostaje neodređen ili se oslanja na nezavisan hemijski dokaz.

Apsolutna konfiguracija odnosi se na molekul, a apsolutna struktura na kristal. Lokalni N14 ima centrosimetričnu grupu $P2_1/c$, za koju takav izbor apsolutne strukture nije primenljiv; to nije manjkavost CIF-a. Skor poravnanja ne sme prikriti nedostajuću ili neprimenjivu stereoinformaciju. IUCr: [absolute structure](#).

Još četiri broja koja treba čuvati

Rint

`_diffn_reflns_av_R_equivalents = 0.0470` meri međusobnu saglasnost simetrijski ekvivalentnih merenja pre finalnog strukturnog modela. Nizak Rint je dobar znak konzistentnosti redukcije, ali ne potvrđuje hemijsku ispravnost modela.

Completeness

Merena frakcija 1.000 znači da su, za navedeni opseg i definiciju, prikupljene sve očekivane refleksije. Potpun skup može i dalje biti slab ili sistematski pogrešan.

Residualna elektronska gustina

Lokalni CIF navodi:

- maksimum $+0.327 \text{ e } \text{\AA}^{-3}$;
- minimum $-0.349 \text{ e } \text{\AA}^{-3}$;
- RMS $0.043 \text{ e } \text{\AA}^{-3}$.

Veliki rezidualni pik pored teškog atoma, neobjašnjen solvent ili pogrešna absorpciona korekcija imaju različita značenja. Prostorni položaj reziduala je važniji od samog maksimuma.

Shift/s.u.

Maksimalni i srednji shift/s.u. su u ovom fajlu 0.000. To pokazuje numeričku konvergenciju poslednjih ciklusa, ali algoritam može konvergirati i ka pogrešnom lokalnom modelu.

checkCIF: linter i naučni dijagnostičar, ne semafor istine

IUCr [checkCIF](#) proverava CIF sintaksu, ćeliju i geometriju, simetriju, displacement parametre, structure factors i neke obrasce mogućih duplikata. Alert znači „pregledaj i, ako treba, objasni“.

Logika stručne provere je:

1. pokreni validaciju odgovarajućeg nivoa;
2. sačuvaj kompletan izveštaj i verziju alata;
3. za svaki alert utvrdi da li je greška, opravdani izuzetak ili nedostajući podatak;
4. zabeleži odluku i dokaz;
5. ne skrivaj alert samo da bi status postao zelen.

IUCr FAQ naglašava da se anomalije rangiraju po ozbiljnosti i da opravdani izuzeci mogu dobiti Validation Response Form. Čak i objavljeni pragovi pojedinačnih testova služe kao screening pravila tog testa, ne kao univerzalni zakon za sve strukture.

Poverljivi fajlovi

Online checkCIF podrazumeva slanje fajla eksternom servisu. Za proprietary CIF prvo proveri licencu, ugovor i politiku poverljivosti. Ako slanje nije odobreno, koristi lokalno odobrenu validaciju ili testiraj samo javni/sintetički primer.

Profil kvaliteta, ne jedna etiketa

Kvalitet se može razmatrati kao vektor više pokazatelja:

$$q = [R_{\text{all}}, R_{\text{gt}}, wR, S, R_{\text{int}}, \text{completeness}, d_{\text{min}}, \rho_{\text{min}}, \rho_{\text{max}}, N_{\text{refl}}, N_{\text{param}}, \text{restraints}, \text{disorder}, \text{occupancy flags}]$$

Svaka komponenta je tumačiva samo uz poznat:

- izvorno CIF polje i originalni tekst;
- status nedostaje/neprimenljivo/izmereno/izvedeno;
- verziju parsera i checkCIF-a;
- temperaturu, talasnu dužinu i tip eksperimenta;
- upozorenja i ljudsko obrazloženje.

Jedinstven „quality score“ može postojati samo kao verzionisan, dokumentovan i kalibrisan pomoćni skor. Nikada ne sme zameniti sirove pokazatelje.

Teorijske posledice za dve aplikacije

Globalna pretraga

- Sintaksa, simetrija, hemijska konzistentnost i quality profile određuju koje su analize uopšte podržane.
- Teška greška ili disorder ne znače automatski istu odluku za svaki search mode; mora biti vidljivo koja je reprezentacija nepouzdana.
- Quality filter ima kontekst i ne predstavlja univerzalni skriveni prag.
- R i srodna polja mogu biti feature za re-ranking ili uncertainty, ne zamena za hemijsku sličnost.
- Nedostajuća vrednost mora ostati „nepoznato“, a ne nula.

Poređenje svih parova

- Geometrijska razlika mora se posmatrati uz s.u. i način tretmana H atoma.
- Disorder alternative ne smeju se mapirati kao dva istovremeno prisutna atoma.
- Zaključak treba tumačiti zajedno sa kvalitetom atomskog mapiranja i pokrivenošću upoređenog dela.
- Nizak RMSD između dva slaba modela nije snažan dokaz.
- „Strukturno različito“ i „nema dovoljno pouzdanih podataka“ jesu različita stanja znanja.

Validnost se ne može proceniti samo na urednim primerima: disorder, nepotpunost, redeterminations i kontrolisani oštećeni primeri otkrivaju drugačije failure mode-ove. Tačan budući testni skup i pragove mora da odobri stakeholder.

Tipične zamke

1. Tretirati R kao accuracy.
2. Uporediti R na F sa wR na F^2 .
3. Pretvoriti svaki checkCIF alert u automatsko odbacivanje.
4. Tumačiti occupancy 0,5 kao „atom je polovično tačan“.
5. Ignorirati da su mnogi H atomi konstrainovani, ne nezavisno opaženi.
6. Zaokružiti koordinate pre računanja geometrije i izgubiti preciznost.
7. Koristiti s.u. kao potpunu meru tačnosti i ignorirati sistematsku grešku.
8. Sabiti missing, unknown i not applicable u istu numeričku nulu.
9. Verovati da numerička konvergencija dokazuje hemijski ispravan model.
10. Poslati poverljiv CIF javnom validatoru bez dozvole.

Mini-vežbe

1. Čitanje zagrada

Šta znači 1.2825(16) Å?

Odgovor

Nominalna dužina je 1.2825 Å, a standardna neizvesnost 0.0016 Å. Zgrade se odnose na poslednje prikazane cifre.

2. Dva R faktora

Zašto su 0,0322 i 0,0347 oba legitimna za isti model?

Odgovor

Prva vrednost koristi samo refleksije iznad kriterijuma $I > 2\sigma(I)$, a druga sve refleksije uključene u refiniranje. Slabije refleksije obično povećavaju ostatak.

3. Da li je GoF 1,095 dokaz?

Možeš li samo iz $S = 1.095$ zaključiti da je struktura tačna?

Odgovor

Ne. To pokazuje razumno slaganje normalizovanih ostataka sa korišćenim težinama. Pogrešan hemijski model, propušten solvent ili druga sistematska greška i dalje su mogući.

4. Occupancy alternativa

Dve alternativne pozicije istog atoma imaju occupancy 0,62 i 0,38. Kako ih aplikacija treba tretirati?

Odgovor

Kao međusobno isključive alternative čiji zbir iznosi 1, a ne kao dva istovremeno prisutna atoma. Potrebno je

sačuvati disorder grupu i propagirati neizvesnost u deskriptore.

5. Projektantska odluka

Globalni indeks dobija CIF sa $R = 0,09$, occupancy disorder-om i validnim checkCIF obrazloženjem. Da li ga automatski odbacuješ?

Odgovor

Ne na osnovu tih podataka. Struktura ide kroz kontekstualnu validaciju. Može biti legitimna, ali geometrijski i packing deskriptori treba da nose quality/uncertainty oznaku, a korisnik može zahtevati stroži filter.

6. Jedan cubic pik

Za cubic ćeliju $a = 5.6400 \text{ \AA}$ i Cu $K\alpha$, $\lambda = 1.5406 \text{ \AA}$, izračunaj $d(200)$ i približan 2θ . Da li je taj simulirani pik dokaz da NaCl uzorak postoji u laboratoriji?

Odgovor

$d(200) = a/2 = 2.8200 \text{ \AA}$, a $2\theta \approx 31.7^\circ$. To je predikcija sintetičkog modela pod zadatim settings-ima, ne dokaz postojanja uzorka. Za bulk evidence potreban je nezavisno izmeren PXRD i definisan protokol poređenja.

Kriterijum prolaza

Poglavlje si savladao kada možeš da uzmeš `cu_n14_a.cif`, napraviš tabelu svih navedenih quality polja, protumačiš ih bez univerzalnog praga, izvedeš $hkl \rightarrow d \rightarrow 2\theta$ za jednostavnu ćeliju i jasno odvojiš simulirani pattern od izmerenog PXRD bulk dokaza.

Primarni i autoritativni izvori

- [IUCr Online Dictionary: Refinement](#)
- [IUCr Core CIF dictionaries](#)
- [IUCr checkCIF](#)
- [IUCr checkCIF FAQ](#)
- [IUCr Statistical descriptors in crystallography](#)
- [IUCr definition of CIF](#)
- [IUCr Online Dictionary: Miller indices](#)
- [IUCr Online Dictionary: reciprocal lattice](#)
- [IUCr powder CIF dictionary](#)
- [CCDC API: powder-pattern simulation settings](#)

11. Polimorfi i druge čvrste forme

Šta treba da umeš posle ovog poglavlja

Posle ovog poglavlja treba da možeš da:

- razlikuješ hemijski entitet, čvrstu formu, kristalnu strukturu i pojedinačno eksperimentalno određivanje;
- razdvojiš polimorf od soli, hidrata, solvata i kokristala;
- objasniš zašto ista aktivna supstanca može imati različitu solubilnost, melting point i stabilnost;
- koristiš Gibbsovu slobodnu energiju kao minimalni termodinamički model;
- objasniš zašto kinetika kristalizacije može dati metastabilnu formu;
- formiraš solid-form familije bez oslanjanja samo na SMILES, formulu ili CSD refcode;
- prevedeš čvrstu formu u filtere, reprezentacije i ground truth za obe aplikacije.

Intuicija: isti molekul, drugačiji materijal

Zamisli jednake kockice koje možeš da složiš u više stabilnih zidova. Kockice su iste, ali raspored kontakata, gustina i način na koji se zid lomi nisu isti. Kod molekulskih kristala „kockice“ mogu i da promene konformaciju, pa različiti kristalni rasporedi imaju različite intermolekulske interakcije i slobodne energije.

Zbog toga isti molekulski graf ne određuje jedinstven čvrsti materijal. Promena forme može promeniti:

- equilibrium solubility i brzinu rastvaranja;
- melting point i toplotu topljenja;
- fizičku i hemijsku stabilnost;
- higroskopsnost;
- gustinu, tvrdoću i crystal habit;
- tok praha, filtraciju, mlevenje i druge proizvodne osobine.

IUPAC definicija **polymorph-a** upravo naglašava različite kristalne vrste istog solidnog materijala i mogućnost različitih fizičkih svojstava.

Četiri nivoa identiteta

U farmaceutskim primerima **API** znači *active pharmaceutical ingredient*, odnosno aktivna farmaceutska supstanca. To je drugo značenje skraćenice od programskog API-ja (*application programming interface*) u ML/AI delu projekta.

Nivo	Pitanje	Primer identifikatora
hemijski entitet	koji su povezanost atoma, stereokemija i protonaciono stanje?	InChI, standardizovani molekulski graf
sastav čvrste forme	koje su komponente, naboji i stehiometrija?	API:HCl:H ₂ O = 1:1:1
faza/polimorf	kako su komponente konformisane i periodično upakovane?	forma I, forma II
određivanje	kojim uzorkom, metodom, temperaturom i publikacijom je model izmeren?	jedan CIF/deposition/refcode

Jedan hemijski entitet može imati više formi. Jedna forma može imati više redeterminations pri različitim temperaturama. Jedan CIF data block može sadržati jednu određenu strukturu, ali to nije dokaz da je ona jedina moguća forma.

Precizne definicije

Polimorf

Polimorfi su različite kristalne strukture istog hemijskog materijala, uz isti sastav. U molekulskom slučaju sama jednakost sumarne formule nije dovoljna: različiti konstitucionni izomeri nisu time postali polimorfi; moraju se proveriti identitet komponenti, stereokemija i stehiometrija. Razlika između polimorfa može biti:

- samo u pakovanju gotovo iste konformacije;
- u molekulskoj konformaciji i pakovanju;
- u mreži vodoničnih i drugih interakcija;
- u space group, jediničnoj ćeliji ili broju nezavisnih molekula.

Uska kristalografska definicija zahteva isti sastav. Zato dodavanje vode, rastvarača, counterion-a ili koformera stvara drugu vrstu čvrste forme, ne samo novi polimorf originalne bezvodne neutralne supstance.

So

So je višekomponentna jonska forma. U farmaceutskom primeru proton se može preneti sa kiseline na bazni API, pa kristal sadrži kation i anion. „API hydrochloride“ nije isti hemijski sastav kao neutralni API.

Granica između soli i kokristala ponekad nije potpuno oštra samo iz formalnog 2D crteža: položaj protona može zahtevati kvalitetne strukturne i spektroskopske podatke. Razlika pKa može biti koristan trag, ali nije nepogrešiva presuda.

Hidrat

IUPAC [hydrate](#) u ovom kontekstu definiše kao kristalnu formu u kojoj su molekuli vode deo kristalne strukture. Voda može biti stehiometrijska, parcijalno zauzeta ili podložna gubitku pri promeni temperature i relativne vlažnosti.

Solvat

IUPAC [solvate](#) je kristalna forma u kojoj su jedan ili više molekula rastvarača deo strukture. Hidrat je poseban slučaj u kome je taj rastvarač voda.

Solvent u kristalnoj šupljini, kanalima ili kao deo mreže interakcija može biti teško modelovan. Desolvacija može ostaviti novu fazu, kolaps rešetke ili amorfni materijal.

Kokristal

IUCr [Online Dictionary](#) opisuje kokristal kao jednofazni kristalni materijal sa dva ili više različitih molekulskih i/ili jonskih jedinjenja u uglavnom stehiometrijskom odnosu, koji nije prost solvat ili so. U farmaceutskom kontekstu često su to neutralni API i neutralni koformer u istoj rešetki.

FDA [guidance za farmaceutske kokristale](#) koristi regulatornu definiciju i zahteva dokaz da klasifikacija zaista odgovara materijalu. Terminologija zato mora biti verzionisana i vezana za naučni/regulatorni kontekst. Klasična stručna diskusija je Aitipamula et al., “Polymorphs, Salts, and Cocrystals: What’s in a Name?”.

Kategorije mogu da se kombinuju

Nazivi nisu uvek međusobno isključivi:

- so može biti hidrat;
- so može biti solvat;
- kokristal može imati vodu ili drugi solvent;

- jedna konkretna so ili kokristal može imati sopstvene polimorfe;
- višekomponentna forma može sadržati i neutralne i jonske komponente.

Zato jedan enum sa vrednostima POLYMORPH | SALT | HYDRATE | SOLVATE | COCRYSTAL nije dovoljan. Razumniji model čuva:

1. listu komponenti;
2. formalne naboje i protonaciona stanja;
3. stehiometriju;
4. uloge: API, counterion, water, solvent, coformer;
5. fazni identitet unutar istog sastava;
6. dokaz i confidence ljudske klasifikacije.

Primer iz projekta: šta znamo iz cu_n14_a.cif

Lokalni CIF navodi:

- `_chemical_formula_moiety 'C25 H20 N3 O2 P'`;
- istu sumarnu formulu;
- $Z = 4$;
- jednu potpuno zauzetu listu atomskih mesta;
- nema eksplicitne water/solvent komponente;
- nema deklariranih disorder grupa;
- `_chemical_melting_point ?`.

Najoprezniji zaključak glasi:

Fajl modeluje jednu, naizgled jednokomponentnu kristalnu strukturu sastava C₂₅H₂₀N₃O₂P, izmerenu na 100 K, bez eksplicitno modelovanog kristalnog solvata ili hidrata.

Ime fajla nije hemijski dokaz

Prefiks `cu` u nazivu fajla ne znači da struktura sadrži bakar: navedena formula nema Cu. Kompoziciju izvodi iz validiranog sadržaja i provenance-a, ne iz korisničkog imena fajla.

Iz tog fajla ne smeš zaključiti:

- da jedinjenje ne može stvarati hidrate ili solvate;
- da nema drugi polimorf;
- da je prikazana forma termodinamički najstabilnija;
- da je ista forma prisutna na sobnoj temperaturi;
- koliki joj je melting point;
- da je odsustvo solventa dokazano svim drugim analitičkim metodama.

Jedan SCXRD CIF je posmatranje jedne forme jednog uzorka pod jednim skupom uslova.

Primer iz white paper-a

CCDC white paper na stranama 3 i 10 koristi melting point da pokaže zašto property mora biti vezan za konkretnu čvrstu formu. Vrednost „150 °C“ vezana samo za molekulski identitet može pomešati:

- polimorf I i polimorf II;
- anhidrat i hidrat;
- neutralnu formu i so;
- različite metode i brzine zagrevanja;
- početak topljenja, opseg ili raspad.

Na stranama 17–18 white paper opisuje polymorph-risk workflow: Mogul za konformacionu geometriju, packing comparison i hydrogen-bond propensity. To su izvori dokaza i prioriteta za eksperimente; nisu dokaz da neotkrivena forma sigurno postoji niti da je poznata forma najstabilnija.

Kako se gradi i tumači referentna geometrijska raspodela, zašto su torzije kružne i kako HBP razlikuje propensity, observed vezu, grouping i coordination score obrađeno je u [lekciji 11A](#).

[GSK/CCDC analiza](#) dodatno pokazuje koliko se interni i javni skupovi razlikuju po raspodeli solidnih formi. Autori su morali ručno da pregledaju strukture jer canonical SMILES, stereokemija i bond-order dodele nisu bili dovoljni za pouzdano grupisanje.

Termodinamički minimum

Pri konstantnoj temperaturi, pritisku i ukupnom sastavu, ravnotežno stabilno stanje ima najnižu Gibbsovu slobodnu energiju. Za poređenje polimorfa istog sastava koristi se ista količina supstance, na primer jedan mol iste formula unit:

$$G = H - TS$$

Ovde je H entalpija, S entropija, a T apsolutna temperatura. U računima po molu i G , H i S odnose se na tu istu molarnu osnovu. Ne možeš samo uporediti sirove G vrednosti anhidrata i hidrata sa različitim brojem molekula vode: potrebno je bilansirati i vodu razmenjenu sa okolinom. Tada stabilnost zavisi i od njenog hemijskog potencijala, odnosno aktivnosti vode pri zadatim uslovima. [Eksperimentalna studija hidrata/anhidrata karbamazepina](#) pokazuje zašto se redosled stabilnosti može promeniti sa aktivnošću vode pri istoj temperaturi.

Za dve forme A i B:

$$\Delta G_{B-A}(T) = \Delta H_{B-A} - T\Delta S_{B-A}$$

- ako je $\Delta G_{B-A} > 0$, A ima niži G i termodinamički je stabilnija;
- ako je $\Delta G_{B-A} < 0$, B je stabilnija;
- ako je $\Delta G_{B-A} = 0$, forme su u ravnoteži pri datim uslovima.

Numerički primer

Pretpostavi, samo za ovaj idealizovani račun, da su ΔH_{B-A} i ΔS_{B-A} konstantni u posmatranom temperaturnom opsegu. Time zanemarujemo razliku toplotnih kapaciteta ΔC_p , kao i topljenje, raspad i sve druge fazne prelaze koji bi se mogli javiti pre izračunatog preseka:

$$\Delta H_{B-A} = 1.0 \text{ kJ mol}^{-1}$$

$$\Delta S_{B-A} = 4.0 \text{ J mol}^{-1}\text{K}^{-1}$$

Tada:

$$\Delta G_{B-A} = 1000 - 4T \quad \text{J mol}^{-1}$$

- na 100 K, $\Delta G = +600 \text{ J mol}^{-1}$: A je stabilnija;
- na 298 K, $\Delta G = -192 \text{ J mol}^{-1}$: B je stabilnija;
- linearno ekstrapolirani presek je na 250 K.

U ovom modelu redosled stabilnosti menja se sa temperaturom, što je obrazac **kompatibilan** sa enantiotropijom. Sam presek dve aproksimirane prave nije dokaz enantiotrofnog odnosa: treba pokazati da obe faze postoje u relevantnom opsegu i potvrditi fazni odnos eksperimentima, uz ΔC_p , topljenje, raspad i druge prelaze. U monotrofnom odnosu jedna forma ostaje stabilnija u čitavom fizički relevantnom opsegu ispod topljenja.

Melting point nije slobodna energija

Viši melting point može biti važan trag, ali sam ne određuje stabilnost na svim temperaturama. Potrebni su entalpija/entropija, fazni prelazi, toplotni kapaciteti i eksperimentalni kontekst.

Kinetika: zašto se prvo pojavi „pogrešna“ forma

Termodinamika kaže koja forma ima najniži G u ravnoteži. Kinetika određuje koliko brzo faza nukleira, raste ili prelazi u drugu fazu.

Kristalizacija zavisi od:

- supersaturacije;
- solventa i aktivnosti vode;
- temperature i brzine hlađenja;
- brzine isparavanja;
- mešanja;
- nečistoća i površina;
- seeding-a;
- koncentracije i pH;
- vremena.

Metastabilna forma je lokalni minimum slobodne energije odvojen kinetičkom barijerom. Može nastati brže i opstati dovoljno dugo da bude izolovana, iako druga forma ima niži G . „Metastabilno“ ne znači „trenutno se raspada“ niti „loš podatak“.

Nukleacija i rast takođe stvaraju selection bias baze: u bazi vidimo ono što je pokušano, kristalisalo, bilo merljivo i sačuvano, ne ceo prostor mogućih formi.

Solubilnost i fazna stabilnost

Pri istoj temperaturi, rastvaraču i hemijskom stanju, metastabilna kristalna forma često daje višu **solubilnost u odnosu na tu fazu** nego stabilna forma, jer je izlazak iz njene rešetke termodinamički povoljniji. Ako se zasićenje uspostavi dok ta faza ostaje nepromenjena, rezultat se može opisati kao **metastabilna, fazno-uslovljena solubilnost** — ravnoteža rastvor–metastabilna faza pod kinetičkim ograničenjem. Strogo govoreći, globalna ravnoteža ne zadržava metastabilnu čvrstu fazu ako je prelaz u stabilnu fazu dostupan; dugotrajnu zasićenu ravnotežu tada određuje stabilna faza. Vrednost se zato može pripisati metastabilnoj fazi samo ako je njen identitet potvrđen tokom merenja i ako se na vremenskoj skali eksperimenta uspostavio reproduktivan odnos čvrsta faza–rastvor. Ako se faza transformiše ili zasićenje nije dostignuto, izmereni plato može biti samo kinetički ili prividan. Pored toga:

- dissolution rate nije isto što i equilibrium solubility;
- veličina čestice, površina i habit utiču na brzinu;
- forma se tokom merenja može transformisati;
- pH i jonizacija mogu dominirati;
- hidrat/solvat može menjati aktivnost i sastav;
- rezultat mora biti vezan za fazu koja je stvarno prisutna pre i posle merenja.

Zato property tabela mora imati najmanje: form ID, temperaturu, solvent/pH, metodu, jedinicu, uzorak, vreme, neizvesnost i dokaz faznog identiteta.

Kako se forme eksperimentalno razlikuju

Nijedna pojedina metoda nije univerzalno dovoljna:

Metoda	Primarni doprinos
SCXRD	atomski i periodični model jednog pogodnog kristala
PXRD	fazni fingerprint bulk uzorka i mešavine
DSC	endotermni/egzotermni događaji, topljenje i prelazi
TGA	gubitak mase, npr. desolvacija/dehidratacija
DVS	odgovor na relativnu vlažnost
IR/Raman/solid-state NMR	lokalno hemijsko okruženje i komponente
hot-stage microscopy	vizuelno praćenje faznih događaja

„Isti SMILES“ ne razlikuje polimorfe. „Različita ćelija“ je jak trag, ali redetermination, temperatura, druga postavka ćelije ili pogrešna simetrija mogu napraviti prividnu razliku. Potrebno je kombinovati sastav, strukturu, uslove i eksperimentalne obrasce.

Hijerarhija koja ne meša nivoe

Za teorijsko razumevanje treba razlikovati:

Entitet	Ključne veze
Compound	standardizovani graf, stereokemija, tautomer/protomer politika
Component	compound, formalni naboj, uloga
Form composition	komponente i stehiometrija
Phase/Form	sastav, polymorph label, fazni odnosi
Determination	CIF, temperatura, pritisak, metoda, publikacija
Sample	batch, priprema, istorija, čistoća
Measurement	property, vrednost, jedinica, uslovi, uncertainty
Evidence	PXRD/SCXRD/DSC/TGA izvor i quality status

Ovo je pojmovna hijerarhija identiteta, ne propisana data schema. Naziv „Form I“ nije globalni identifikator: različite organizacije mogu različito numerisati forme, pa etiketa ima značenje samo uz izvor i namespace.

Moguće ose relevantne za dve aplikacije

Globalna pretraga

Tri različite moguće namere su:

1. sličan hemijski entitet bez obzira na formu;
2. ista/kompatibilna kompoziciona klasa;
3. slično kristalno pakovanje unutar uporedivih formi.

Mogući filteri, ako ih product scope potvrdi, uključuju:

- neutral/free form, salt, hydrate, solvate, cocrystal;
- broj komponenti i stehiometrija;
- charge state;
- prisustvo vode/solventa;
- ista formula ili isti parent compound;
- temperatura i quality profil određivanja.

Pogodak može biti sličan po molekulu, sastavu ili periodičnom pakovanju; jedan zbirni skor bez te dekompozicije može visoko rangirati hemijski sličnu, ali razvojno nerelevantnu formu. Koje ose budući proizvod prikazuje ostaje stakeholder odluka.

Poređenje svih parova

Pre izbora metrike potrebno je konceptualno razjasniti odnos:

- isto određivanje/duplikat;
- redetermination iste faze;
- kandidat za polimorf;
- salt/solvate/hydrate/cocrystal odnos;
- drugačiji hemijski entitet.

Tek zatim treba računati odgovarajuće metrike. Packing RMSD između anhidrata i hidrata može biti koristan kao parcijalna analiza zajedničkog API okruženja, ali nije isto pitanje kao dokaz polimorfnosti.

Za stručno tumačenje para relevantni su:

- mapiranje komponenti i atoma;
- razliku sastava i naboja;
- konformacionu razliku;
- packing/interakcioni profil;
- uslove merenja;
- quality/uncertainty;
- klasifikaciju odnosa sa obrazloženjem.

Tipične zamke

1. Nazvati svaki različit CIF polimorfom.
2. Nazvati hidrat polimorfom anhidrata bez označavanja promene sastava.
3. Tretirati so i neutralni API kao isti graf posle uklanjanja counterion-a.
4. Zaključiti „nema solventa“ samo zato što ga 2D reprezentacija ne prikazuje.

5. Koristiti InChIKey kao identifikator kristalne faze.
6. Zaključiti stabilnost iz jedne neobične torzije.
7. Izjednačiti thermodynamic stability, chemical stability i shelf-life.
8. Izjednačiti equilibrium solubility i dissolution rate.
9. Ignorirati temperaturu SCXRD merenja.
10. Napraviti train/test split u kome redeterminations ili forme istog parent compound-a cure na obe strane.

Mini-vežbe

1. Isto ili različito?

Dva kristala imaju isti neutralni molekul i istu sumarnu formulu, ali različito pakovanje. Kako ih klasifikuješ?

Odgovor

Kao kandidate za polimorfe. Potrebno je isključiti trivijalnu promenu postavke ćelije, temperaturnu ekspanziju, redetermination i grešku modela.

2. API, HCl i voda

Jedna forma sadrži protonovani API, hlorid i jednu vodu po API. Koje oznake su relevantne?

Odgovor

To je so i hidrat. Kategorije se kombinuju; nije dovoljno izabrati samo jednu.

3. Šta dokazuje lokalni CIF?

Da li `cu_n14_a.cif` dokazuje da C25H20N3O2P nema polimorfe?

Odgovor

Ne. Dokazuje samo da je za jedan uzorak pod navedenim uslovima modelovana jedna konkretna kristalna struktura.

4. Termodinamički prelaz

Za $\Delta H_{B-A} = 1.0 \text{ kJ mol}^{-1}$ i $\Delta S_{B-A} = 4.0 \text{ J mol}^{-1}\text{K}^{-1}$, pri kojoj temperaturi su A i B približno u ravnoteži?

Odgovor

Uz pretpostavku konstantnih ΔH i ΔS , i uz zanemarene ΔC_p , topljenje, raspad i druge fazne prelaze, $\Delta G = 0$ daje $T = \Delta H / \Delta S = 1000 / 4 = 250 \text{ K}$. To je presek idealizovanog modela, ne samostalan dokaz enantiotropije.

5. Dizajn split-a

Zašto nasumični split po CIF redovima može dati lažno dobru ML metriku za klasifikaciju formi?

Odgovor

Redeterminations, skoro identične strukture i više formi istog parent compound-a mogu završiti u treningu i testu. Model tada prepoznaje familiju ili eksperimentalni izvor umesto da generalizuje. Split treba grupisati najmanje po parent compound-u i povezanim određivanjima, a po potrebi i po scaffold-u ili vremenu.

Kriterijum prolaza

Poglavlje si savladao kada za proizvoljan par CIF-ova možeš prvo da postaviš pitanje o sastavu i faznom identitetu, zatim izabereš prikladno strukturno poređenje i objasniš koje dodatne eksperimente treba tražiti pre tvrdnje o polimorfnosti ili stabilnosti.

Primarni i autoritativni izvori

- IUPAC Gold Book: polymorph
- IUPAC Gold Book: solvate
- IUPAC Gold Book: hydrate
- IUCr Online Dictionary: co-crystal
- FDA: Regulatory Classification of Pharmaceutical Co-Crystals
- Aitipamula et al. 2012, DOI 10.1021/cg3002948
- Kalash et al. 2021, GSK/CCDC solid-form analiza

11A. Referentne raspodele, Mogul i hydrogen-bond propensity

Ova lekcija objašnjava kako se CSD koristi kao **empirijska referenca**, a ne kao oracle. White paper na stranama 17–18 pominje Mogul, packing comparison i hydrogen-bond propensity (HBP) u proceni polymorph risk-a. Da bi taj tok imao značenje, moraš umeti da razdvojiš tri pitanja:

1. da li je jedna geometrijska vrednost tipična među hemijski uporedivim fragmentima;
2. koliko je statistički model dobro podržan relevantnim fitting podacima;
3. šta iz rezultata **ne** sledi o energiji, stabilnosti ili postojanju polimorfa.

Svi brojevi u worked primerima na ovoj strani su **ručno napravljeni sintetički podaci za račun**. Nisu CSD statistika, Mogul output ni rezultat dostavljenih fajlova.

Šta treba da umeš posle ovog poglavlja

Treba da možeš da:


- definišeš tačno koju dužinu, ugao ili torziju porediš i kako je mapiran fragment;
- dokumentuješ query, filtere, bazu/release, broj pogodaka i domain coverage;
- izračunaš jednostavan percentile ili robustan outlier signal bez proglašavanja energije;
- pravilno tretiraš kružne torzione uglove i multimodalne raspodele;
- objasniš kako HBP fitting skup, positive/negative ishodi i logistička regresija daju propensity;
- razlikuješ individual propensity, observed H-bond, grouping i coordination score;
- uvedeš abstention kada nema dovoljno relevantnog dokaza.

Referentna raspodela nije „svi brojevi iz baze“

Ako kandidat ima C–N dužinu 1,390 Å, besmisleno je porediti je sa svim C–N vezama bez konteksta. Referentna populacija mora da odgovara pitanju. Reproductivno tumačenje zahteva sledeće kategorije:

Sloj	Primer pitanja koje mora biti zamrznuto
merena veličina	koji atom mapping i koja bond/angle/torsion definicija?
hemijsko okruženje	element, bond typing/aromaticity, formalni naboj, susedne grupe, ring status
koordinacioni kontekst	slobodan donor ili vezan za metal; koji metal/oxidation state/CN?
kristalografski filter	3D coordinates, disorder, errors, polymeric status, R/temperature pravilo
baza	CSD release i skup dozvoljenih privatnih/javnih baza
deduplikacija	po entry-ju, fragmentu, compound/form familiji ili drugoj jedinici?
podrška	broj exact/generalized pogodaka, missingness i razlog proširenja query-ja
računarski kontekst	alat/verzija, parametri, transformacije i random seed ako postoji

Bez ovoga „98. percentil“ nije reproduktivna tvrdnja. Promena protonacije, bond type-a ili filtera može promeniti populaciju više nego sama razlika koju meriš.



Worked primer: neobična dužina kao signal

Pretpostavi da je hemijski uparen, sintetički referentni skup dao:

Veličina	Vrednost
broj pogodaka n	250
medijana	1,340 Å
MAD, medijana apsolutnih odstupanja	0,012 Å
kandidat	1,390 Å
broj referentnih vrednosti $\leq$ kandidatu	247

Jednostavan empirical percentile po ovde eksplicitno izabranoj konvenciji je:

$$P_{\text{emp}} = 100 \frac{\#\{x_i \leq x\}}{n} = 100 \frac{247}{250} = 98.8.$$

Robustni standardizovani signal može se napisati:

$$z_{\text{robust}} = \frac{x - \text{median}}{1.4826 \text{ MAD}} = \frac{1.390 - 1.340}{1.4826(0.012)} \approx 2.81.$$

Faktor 1,4826 daje MAD-u skalu standardne devijacije za normalnu raspodelu; ne dokazuje da je konkretna hemijska raspodela normalna i ne pretvara ovaj signal automatski u p-vrednost. Račun zahteva $\text{MAD} > 0$. Kada je MAD nula, na primer zbog jednakih ili jako zaokruženih vrednosti, ovaj skor nije definisan: treba prijaviti ograničenje i pregledati raspodelu ili koristiti drugi opravdan opis rasipanja. [Zvanična R dokumentacija za MAD](#) objašnjava faktor skaliranja; neki alati vraćaju već skalirani MAD, pa ga ne treba pomnožiti dva puta.

Oba broja kažu: kandidat je na dugom repu **ove konkretne** raspodele. Ne kažu zašto. Najmanje četiri hipoteze ostaju otvorene:

1. atom/bond mapping, protonacija ili disorder model je pogrešan;
2. geometrija je stvarna i hemijski retka, na primer zbog koordinacije ili strain-a;
3. referentni query je preuzak, pristrasan ili iz drugog domena;
4. kandidat je slab eksperimentalni model i s.u./quality profil ne podržavaju oštar zaključak.

Outlier nije energija

Percentile, z -signal ili mala lokalna gustina nisu lattice energy, conformer energy ni verovatnoća polimorfa. Za energetska tvrdnja potreban je posebno validiran energetski model; za faznu tvrdnju eksperimentalni i termodinamički evidence.

Šta kada je podrška mala

Ne postoji univerzalan broj pogodaka koji svaku raspodelu čini „dobrom“. Potrebna podrška zavisi od heterogenosti i cilja. Sistem ipak mora razlikovati:

Situacija	Pošten output
dovoljno hemijski bliskih pogodaka i stabilna raspodela	prijavi signal, support, filtere i uncertainty
nekoliko exact pogodaka, mnogo generalized pogodaka	prikaži oba nivoa odvojeno i sensitivity na generalizaciju
multimodalna raspodela	prijavi modove/local density; jedna sredina može biti besmislena
nula ili premalo relevantnih pogodaka	insufficient_reference_support, ne „ekstremni outlier“
kandidat van domena query/model-a	abstention + razlog i predlog stručnog pregleda

Generalizovanje query-ja sme da povećava coverage samo ako se istovremeno beleži šta je hemijski relaksirano. U suprotnom broj n raste, a relevantnost pada nevidljivo.

Torzije su kružne, ne obične linearne promenljive

Uglovi -179° i $+179^\circ$ udaljeni su 2° , ne 358° . Minimalna kružna razlika je:

$$d_{\text{circ}}(\alpha, \beta) = \min(|\alpha - \beta|, 360^\circ - |\alpha - \beta|).$$

Za torzione raspodele zato ne koristi slepo linearnu sredinu i standardnu devijaciju preko granice $-180/180^\circ$. Koristi circular statistics, periodičnu kernel density ili eksplicitne modove. Ako su konformacije grupisane oko 60° i 180° , globalna sredina može pasti u oblast gde nema nijednog realnog konformera.

Gornji izraz pretpostavlja da su oba ugla već svedena na isti osnovni interval dužine 360°. Za proizvoljan broj punih obrtaja najpre izračunaj $\delta = \text{wrap}_{[-180,180)}(\alpha - \beta)$, pa koristi $|\delta|$; inače zapis 540° može proizvesti pogrešan rezultat u naivnoj formuli.

Kako hydrogen-bond propensity metod radi

CCDC implementacija je parametrizovana i version-dependent, ali metodski tok može da se nauči bez pristupa licenci:

- 1. Identifikuj funkcionalne grupe.** Za ciljnu strukturu određuju se donorni i akceptorski atomi, uključujući intra- i intermolekulske mogućnosti.
- 2. Napravi fitting skup.** Iz izabranih baza uzimaju se kandidatne strukture koje mogu da odgovaraju funkcionalnim grupama cilja. Matching i filteri određuju applicability domain.
- 3. Anotiraj evidence.** Za svaki relevantan donor/acceptor tip broje se positive i negative ishodi u fitting strukturama. „Negative“ ovde znači da je prilika pod definisanim pravilom postojala, ali ishod nije opažen; to nije dokaz fizičke zabrane.
- 4. Fituj logistički model.** Explanatory features mogu obuhvatiti identitet donor/acceptor grupe, competition, steric density i aromaticity. Model vraća verovatnoću tipa:

$$\text{logit}(p) = \log \frac{p}{1-p} = \beta_0 + \sum_j \beta_j x_j, \quad p = \frac{1}{1 + e^{-(\beta_0 + \sum_j \beta_j x_j)}}.$$

- 1. Proveri model i coverage.** Čuvaju se fitting counts, excluded grupe, regresiona jednačina/feature-i, AUC ili drugi dijagnostički output, uncertainty i savet alata. Dobar AUC ne popravlja target van domena.
- 2. Izračunaj individualne propensity vrednosti.** Svaki potencijalni donor–acceptor par dobija model output, bounds/uncertainty i vezu sa dokazima. Posebno se beleži da li je veza stvarno opažena u target kristalu.
- 3. Generiši groupings.** Kompatibilni skupovi mogućih H-veza predstavljaju putative network-e. Group H-bond score sažima propensity uključenih veza, dok coordination score sažima koliko su donorni/akceptorski coordination outcomes saglasni sa modelom. Ovde „coordination“ znači koliko H-veza donor donira ili akceptor prihvata u predloženoj mreži, na primer „donira jednom“. To nije koordinacioni broj metala iz poglavlja 5.

Zvanična [CCDC HBP dokumentacija](#) eksplicitno prikazuje fitting counts, positive/negative evidence, logistic regression, AUC, propensity uncertainty i group/coordination scores. Originalni metod je opisan u [Galek et al., Acta Cryst. B 2007](#).

Worked HBP primer: četiri output-a, četiri značenja

Pretpostavi sintetički cilj sa jednim donorom **D1** i dva akceptora **A1**, **A2**. Posle dokumentovanog fitting-a alat daje:

Kandidat	Propensity	90% model interval	Opažen u target kristalu?
D1...A1	0,72	0,61–0,81	da
D1...A2	0,61	0,46–0,74	ne

Ovo se ne čita kao „A1 veza postoji sa 72% fizičke sigurnosti“. Preciznije:

- **0,72** je output konkretnog modela za definisani par i fitting domen;
- **observed = da** je zasebna geometrijsko-kristalografska činjenica pod korišćenim H-bond kriterijumom;
- alternativni grouping sa D1...A2 može imati drugačiji H-bond i coordination score;
- neopaženi, ali visoko rangirani par je **hipoteza za pregled**, ne dokaz druge ostvarive packing strukture;

- razlika 0,72 naspram 0,61 možda nije odlučiva ako su intervali široki ili je fitting support slab.

Izlaz	Odgovara na pitanje	Ne odgovara automatski
individual propensity	šta model očekuje za jedan mogući donor–acceptor par?	da li je veza opažena u target strukturi
observed H-bond	da li target geometrija zadovoljava definisani kriterijum?	da li je to energetski najpovoljnija interakcija
grouping/H-bond score	kakav je skup međusobno kompatibilnih putative veza?	da li taj network gradi realan kristal
coordination score	koliko su donor/acceptor coordination outcomes tipični po modelu?	ukupnu stabilnost, lattice energy ili polymorph probability

Moguće primene u dve aplikacije

Globalna pretraga

- Referentni signal može imati smisla kao filter/rerank feature samo uz query, release, support i applicability.
- Retka geometrija ne sme biti automatski odbačena; može biti upravo naučno zanimljiv kandidat.
- Promena CSD snapshot-a, standardizacije ili filtera menja referentnu raspodelu i prekida direktnu uporedivost rezultata.
- Proprietary i public fitting slojevi moraju ostati odvojeni ako licenca ili provenance to zahtevaju.

Poređenje svih parova

- Poređenje geometrije ima smisla uz raw vrednosti, s.u., atom mapping i položaj u istoj referentnoj raspodeli.
- Poredi support i applicability, ne samo dva percentile-a.
- Za torzije koristi circular distance/modove.
- HBP poređenje razdvaja potential pairs, observed network, grouping i coordination rezultate; jedna zbirna ocena ne sme sakriti različit uzrok.

Ovo su mogući načini upotrebe, ne unapred odobren feature set. Dostupni izvori ne potvrđuju da li je referentni signal deo targeta; za to je potreban zaseban fakultetski odgovor. Bez obzira na format budućeg evidence-a, moraju ostati vidljivi merena veličina, referentni query/release i podrška, outlier signal, applicability i zabranjena inferencija „nije energija niti polymorph probability“.

Tipične zamke

1. Uključiti isti compound/redetermination mnogo puta i tretirati redove kao nezavisne uzorke.
2. Pomešati exact i generalized query hits bez oznake.
3. Koristiti globalni z -score za multimodalnu ili kružnu raspodelu.
4. Zanimariti s.u., disorder i pogrešan atom/bond typing kandidata.
5. Proglasiti „nema pogodaka“ za ekstremni outlier umesto za nedostatak reference.
6. Tumačiti propensity kao opaženu H-vezu ili verovatnoću postojanja polimorfa.
7. Uporediti output-e iz različitih CSD release-a/settings-a kao da su ista skala.
8. Objaviti fitting-derived artefakt bez licence i provenance pregleda.

Provera znanja

1. Kandidat je na 99. percentilu referentne dužine. Navedi tri moguća objašnjenja koja nisu „visoka energija“.
2. Zašto su -179° i $+179^\circ$ bliski?

3. Da li HBP propensity 0,8 znači da je veza opažena?
4. Šta radiš kada target funkcionalna grupa ima premalo fitting evidence-a?
5. Zašto simulated „alternativni grouping“ nije predviđen polimorf?

Odgovori

1. Greška/mapiranje ili disorder; stvarna retka koordinacija/strain; pogrešan ili pristrasan referentni domen; može i slab eksperimentalni model.
2. Ugao je kružna veličina: minimalna razlika preko granice je 2° .
3. Ne. To je output modela za kandidatni par; observed status se određuje zasebno.
4. Prijavi insufficient support/abstention, ne forsiraj broj; po potrebi transparentno generalizuj query i uradi sensitivity proveru.
5. Grouping je kombinatorna/statistička hipoteza o H-bond network-u. Ne dokazuje geometrijsku ostvarivost, povoljnu energiju, nukleaciju ni eksperimentalnu fazu.

Kriterijum prolaza: dobiješ jednu neobičnu dužinu ili HBP chart i možeš da rekonstruišeš population/fitting evidence, izračunaš ili proveriš signal, razlikuješ sva četiri HBP output-a i napišeš zaključak koji ne prelazi granicu dokaza.

Primarni i autoritativni izvori

- CCDC API: molecular geometry/Mogul analiza
- CCDC API: hydrogen-bond propensities
- Galek et al. 2007: Knowledge-based model of hydrogen-bonding propensity
- Taylor & Wood 2019: A Million Crystal Structures
- CCDC API: packing similarity

12. CIF, MOL, MOL2, SDF i SMILES


Prioritet: MORAŠ. Format nije samo ambalaža. Svaki format čuva drugi deo hemijskog značenja, pa konverzija može tiho promeniti pitanje koje aplikacija odgovara.

12.1 Dva sveta podataka

Najpre razdvoji:

- **molekulski zapis** — atomi, veze, naboji i eventualno jedna 2D/3D konformacija;
- **kristalografski zapis** — asimetrična jedinica, jedinična ćelija, simetrija, periodično pakovanje, eksperimentalni i refinementski metapodaci.

MOL, MOL2, SDF i SMILES su prvenstveno molekulski formati. CIF može da nosi čitav kristalografski eksperiment. Pretvaranje CIF-a u SMILES zato nije „promena ekstenzije“, već projekcija mnogo bogatijeg objekta na molekulski graf.



12.2 CIF: datoteka i Crystallographic Information Framework

CIF datoteka (*Crystallographic Information File*) koristi tekstualni, samopisujući format zasnovan na **data names** i rečnicima. Širi *Crystallographic Information Framework* obuhvata i standarde i rečnike koji daju značenje zapisu. Autoritativna definicija pojedinačnih polja je [IUCr core CIF dictionary](#); praktični uvod je [IUCr CIF guide](#).

Za pun, bezbedan i parsabilan primer pređi odmah i [anatomiju jednog CIF fajla](#). Tamo možeš da preuzmeš sintetički `.cif` i pročitáš svaku vrstu reda bez objavljivanja licenciranog projekta/CSD sadržaja.

Osnovni oblici su:

```
data_N14
_cell_length_a      12.7138(3)
```

```

_cell_angle_beta      93.235(1)

loop_
  _atom_site_label
  _atom_site_fract_x
  _atom_site_fract_y
  _atom_site_fract_z
C1  0.1234  0.5678  0.9012

```

Važne ideje:

- `data_...` otvara blok podataka;
- `par _ime` vrednost čuva jednu stavku;
- `loop_` čuva tabelu čije se vrednosti ponavljaju po redovima;
- `12.7138(3)` znači vrednost 12.7138 sa standardnom nesigurnošću 0.0003, ne „12.7138 puta 3“;
- `.` i `?` nisu broj nula: prvi označava neprimenljivo/namerno nepodato, drugi nepoznato;
- atom-site koordinate su često **frakcione**, u odnosu na ose ćelije, a ne kartezijanske u ångströmima;
- occupancy, disorder assembly/group, symmetry i alternativne pozicije moraju ostati povezani sa atomom;
- jedan CIF može sadržati više data blokova, dodatne rečnike, refleksije ili ugrađen refinement sadržaj.

Lokalni CIF

`cu_n14_a.cif` navodi monoklinsku ćeliju, prostornu grupu $P2_1/c$, $Z = 4$, temperaturu 100 K i kristalografske pokazatelje kvaliteta. Fajl je velik jer sadrži i ugrađene SHELX podatke. Ime počinje sa `cu_`, ali u formuli i atomskim mestima nema bakra: Cu K α označava korišćeno rendgensko zračenje. Naziv fajla nije hemijski dokaz.

12.3 MOL: kompaktan connection table

MDL MOL obično sadrži:

1. zaglavlje;
2. counts line;
3. atom block sa koordinatama i simbolima elemenata;
4. bond block sa parovima indeksa i formalnim redom veze;
5. dodatne property linije i `M END`.

Primer ideje, ne punog zapisa:

```

3  2  ... V2000
... C
... O
... N
1  2  2
1  3  1
M  END

```

MOL je jednostavan za razmenu, ali tip atoma i veze može biti siromašniji od internog hemijskog modela. U lokalnom `N14.mo1` mnogo veza je izvezeno kao single; iz toga se ne sme zaključiti da molekul nema delokalizaciju ili da je bond perception sigurno tačan.

12.4 MOL2: atom tipovi, bond tipovi i charges

Tipos MOL2 ima označene sekcije, na primer:

```
@<TRIP0S>MOLECULE
@<TRIP0S>ATOM
@<TRIP0S>BOND
@<TRIP0S>SUBSTRUCTURE
```

Pored elementa, atom često dobija softverski **atom type** poput C.ar ili N.3; veza može biti 1, 2, ar, am ili un. To su model i dodela izvoznika, ne direktno eksperimentalno opažanje.

Lokalni N14.mo12 kaže NO_CHARGES i daje nule u charge koloni. To znači da **parcijalni naboji nisu dodeljeni**. Ne znači da je svaka lokalna raspodela elektronske gustine ravnomerna, niti da molekul nema polarne veze.

MOL2 može sadržati i opcionu sekciju @<TRIP0S>CRYISIN sa parametrima ćelije i oznakom prostorne grupe; lokalni N14.mo12 je sadrži. Zato nije tačno da svaki MOL2 nužno gubi svu kristalografsku informaciju. Ipak, prisustvo CRYISIN ne vraća kompletan CIF: izbor atoma/komponenti, disorder, eksperimentalni metapodaci i podrška parsera i dalje ograničavaju periodičnu analizu.

12.5 SDF: mnogo MOL zapisa i svojstva

Structure Data File je niz MOL zapisa razdvojenih sa:

```
$$$$
```

Posle connection table-a mogu stajati imenovana polja:

```
> <CCDC_REF_CODE>
CAPHAG
```

SDF je zgodan za skupove molekula i labels/deskriptore. Ipak, naziv polja, jedinica, tip nedostajuće vrednosti i poreklo nisu automatski standardizovani. Schema mora biti eksplicitna.

12.6 SMILES: linijski zapis grafa

SMILES kodira atome i veze kao tekst:

- CCO — etanol, lanac C-C-O; vodonici se u ovom zapisu podrazumevaju prema pravilima valence;
- c1ccncc1 — aromatični šestoprsten sa jednim N;
- C(=N)N — grananje i double veza;
- [Na+].[Cl-] — dve nepovezane jonske komponente;
- @, / i \ mogu kodirati određene stereoodnose ako su prisutni.

Brojevi u c1ccncc1 označavaju zatvaranje prstena, ne broj atoma niti red veze. Veliko C i malo c razlikuju alifatični/nearomatični i aromatični prikaz ugljenika. SMILES tačka označava prekid neposrednog povezivanja; nema značenje CIF missing-value tačke.

Daylight SMILES theory opisuje jezik. Bitne posledice:

- isti graf može imati mnogo validnih SMILES stringova;
- canonical SMILES zavisi od implementacije i verzije**, pa nije globalni identifikator;
- izostavljena stereokemija ostaje nepoznata, ne „automatski racemična“;

- standardni SMILES ne čuva jediničnu ćeliju, space group, occupancy, termalne parametre ni periodično pakovanje;
- metal-ligand veze i aromatičnost mogu biti različito zapisane u različitim alatima.

12.7 Šta se gubi pri konverziji

Konverzija	Tipični gubitak ili odluka
CIF → MOL/SDF	ćelija, simetrija, pakovanje, većina eksperimentalnih metapodataka; izbor komponente i veze
CIF → SMILES	sve prethodno plus 3D koordinate i konformacija
MOL2 → MOL	detaljni atom/bond tipovi, substructure, parcijalni charge model i eventualni CRYSTAL podaci
SDF → SMILES	3D i većina property polja; komponente i podržani stereo mogu se očuvati, ali to zavisi od export policy-ja
SMILES → 3D	generisana konformacija je hipoteza; nije eksperimentalna kristalna geometrija

[Open Babel format documentation](#) može objasniti sintaksu konverzija, ali hemijski smisao rezultata i dalje mora biti testiran.

12.8 Loss-aware provenance princip

Formati pokazuju zašto original, interpretacija i izvedeni prikaz nisu ista vrsta informacije. Reproductivno tumačenje zato mora da razlikuje:

Kategorija	Zašto je potrebna
originalni sadržaj i identitet	omogućava proveru šta je stvarno primljeno
format/parser kontekst	značenje može zavisi od standarda, alata i verzije
direktno deklarirani podaci	ne smeju se pomešati sa dodeljenim vezama ili normalizacijom
izvedeni task-specific prikazi	mogu biti korisni, ali su potencijalno lossy i uslovljeni pravilima
warnings, coverage i provenance	„parse success“ ne znači hemijsku ili kristalografsku potpunost

Ovo su semantičke kategorije, ne propisana storage schema ili budući ingest pipeline.

12.9 Provera znanja

1. Zašto SMILES nije dovoljan za poređenje crystal packing-a?
2. Šta znači NO_CHARGES u MOL2?
3. Da li 12.7138(3) u CIF-u predstavlja opseg od 3 jedinice?
4. Zašto uspešna konverzija CIF → SDF nije dokaz da ništa nije izgubljeno?
5. Zašto ime cu_n14_a.cif ne dokazuje prisustvo Cu?

Odgovori

1. Ne čuva ćeliju, simetriju, periodičnost ni kristalnu konformaciju/pakovanje.
2. Parcijalni charges nisu dodeljeni u tom zapisu.
3. Ne; zagrada kodira standardnu nesigurnost poslednjih cifara.
4. Parser može napraviti validan siromašniji objekat nakon odluka o komponentama, vezama i disorder-u.
5. Sastav se proverava u formuli/atom sites; ovde CuK\alpha opisuje zračenje.

Kriterijum prolaza: za svaki od pet formata možeš da navedeš šta čuva, šta ne čuva i jednu opasnu pretpostavku pri konverziji.

12A. Anatomija jednog CIF fajla

Prioritet: MORAŠ. CIF nije binarni „crtež kristala“, već strukturisan tekst. Možeš ga otvoriti u običnom editoru, ali njegovo hemijsko i kristalografsko značenje tumačiš pomoću CIF rečnika i odgovarajućeg parsera.

Ova lekcija koristi [ceo sintetički CIF za preuzimanje](#). Fajl je ručno napisan za kurs, ne predstavlja eksperiment i ne sadrži CSD, fakultetske ni korisničke podatke. Zato jedini `.cif` koji se nalazi u repozitorijumu može bezbedno da se deli.

12A.1 Ovako CIF zaista izgleda

```
# SYNTHETIC TEACHING FIXTURE -- NOT AN EXPERIMENTAL OR CSD RECORD
# Hand-written for this course. CC0-1.0. CIF 1.1-compatible ASCII text.

data_synthetic_nacl_tutorial
_audit_creation_method      'Hand-written teaching fixture; no experiment'
_chemical_name_common       'Synthetic sodium chloride tutorial'
_chemical_name_systematic   ?
_chemical_formula_sum       'Cl Na'
_chemical_formula_weight    58.44

_cell_length_a              5.6400(10)
_cell_length_b              5.6400(10)
_cell_length_c              5.6400(10)
_cell_angle_alpha           90
_cell_angle_beta            90
_cell_angle_gamma           90
_cell_volume                179.41(10)
_cell_formula_units_Z       4

_symmetry_space_group_name_H-M 'F m -3 m'
_symmetry_Int_Tables_number  225
_diffraction_ambient_temperature .
_experimental_crystal_density_diffraction 2.164

# These values deliberately demonstrate CIF missing-value tokens.
_refinement_ls_R_factor_gt .
_refinement_ls_wR_factor_ref .

_public_section_comment
;
This is a synthetic syntax example, not a measured crystal structure.
Its deliberately small data block is meant for parser and reading exercises.
;

loop_
_atom_site_label
_atom_site_type_symbol
_atom_site_fract_x
_atom_site_fract_y
_atom_site_fract_z
_atom_site_occupancy
Na1 Na 0.00000 0.00000 0.00000 1.0
Cl1 Cl 0.50000 0.50000 0.50000 1.0
```

Ovo je mali, sintaksno validan **CIF 1.1 data block**, ali nije publication-ready crystallographic information file. Nema merene refleksije, refinement model, displacement parametre, detalje instrumenta ni bibliografiju. „Parser ga čita“ i „dokazuje eksperiment“ potpuno su različite tvrdnje.

12A.2 Čitanje red po red

Deo	Primer	Šta znači
komentar	# SYNTHETIC ...	# započinje komentar do kraja reda; parser ga ne tumači kao data item
data block	data_synthetic_nacl_tutorial	otvara imenovani blok; jedan fajl može imati više data_ blokova
scalar item	_chemical_formula_weight 58.44	data name i jedna vrednost
quoted value	'F m -3 m'	razmaci pripadaju jednoj tekstualnoj vrednosti, pa su potrebni navodnici
broj sa s.u.	5.6400(10)	procena 5,6400 uz standardnu nesigurnost 0,0010 u istim jedinicama
nepoznato	?	vrednost nije poznata
neprimenljivo/namerno bez vrednosti	.	nema vrednosti za taj item u ovom kontekstu; nije broj nula
višeredni tekst	redovi između samostalnih ; u prvoj koloni	jedna tekstualna vrednost može zauzimati više redova
tabela	loop_ + imena kolona + vrednosti	vrednosti se dele u redove prema broju navedenih kolona

Autoritativna pravila za tokene, quoting, komentare, loop_, ?, ., višeredni tekst i brojeve sa nesigurnošću daje IUCr CIF 1.1 sintaksa. Značenje pojedinačnih data names ne određuje izgled imena, već IUCr core CIF dictionary.

Missing-value značenje imaju samostalni **nenavodnički** tokeni ? i . . Znak '?' u navodnicima ili ? unutar semicolon-delimited tekstualnog polja sintaksno je tekst, čak i kada ga je autor upotrebio kao placeholder. Upravo tako je zapisano systematic-name polje lokalnog N14 CIF-a. Parser treba da očuva tu razliku; kasnija kuracija može prepoznati placeholder uz trag izmene.

Zagrada nije interval ni množenje

U 5.6400(10) cifre u zagradi odnose se na poslednje cifre vrednosti. Dakle, s.u. je 0,0010. To samo po sebi ne znači da je „prava vrednost sigurno između 5,6390 i 5,6410“; standardna nesigurnost nije tvrda granica.

12A.3 Kako se čita loop_

Posle loop_ dolazi šest data names, pa parser očekuje vrednosti u grupama od šest:

label	element	fract_x	fract_y	fract_z	occupancy
Na1	Na	0.00000	0.00000	0.00000	1.0
Cl1	Cl	0.50000	0.50000	0.50000	1.0

Prelomi reda služe čitaocu, ali CIF petlju suštinski čini ravan niz tokena. Broj vrednosti zato mora biti celobrojni umnožak broja kolona. Ako jedna ćelija nedostaje, mora stajati odgovarajući ? ili ., inače se sve sledeće vrednosti mogu pomeriti u pogrešne kolone ili će parser odbiti petlju.

Ovde su `fract_x`, `fract_y` i `fract_z` **frakcione koordinate** u bazu jedinične ćelije. Tačka `(0.5, 0.5, 0.5)` nije automatski `(0.5 Å, 0.5 Å, 0.5 Å)`. Kartezijanska pozicija dobija se množenjem frakcionog vektora matricom ćelije, kao u poglavlju 8.

`occupancy = 1.0` znači da model tom atomskom mestu dodeljuje punu zauzetost. Ne znači „jedan atom u celom kristalu“: space-group operacije i translaciona periodičnost generišu ekvivalentna mesta.

12A.4 Od kojih slojeva se realan CIF često sastoji

Redosled nije obavezan, a mnoga polja mogu nedostajati. Tipičan small-molecule CIF može sadržati:

1. identitet bloka, audit istoriju, autora i bibliografiju;
2. formulu, relativnu formulsku masu i opis uzorka;
3. parametre ćelije, prostornu grupu, (Z), temperaturu i gustinu;
4. instrument, talasnu dužinu, strategiju prikupljanja i obradu refleksija;
5. detalje rešavanja i refiniranja, R faktore, restraints i upozorenja;
6. atom-site petlju sa frakcionim koordinatama, occupancy i displacement parametrima;
7. opciono anisotropne parametre, geometrijske tabele i H-bond/contact liste;
8. opciono višeredne ugrađene refinement ili reflection blokove.

Veze nisu obavezno primarni sadržaj CIF-a. Program ih može preuzeti iz eksplicitne geometrijske tabele ili ih **percipirati** iz elemenata, udaljenosti, simetrije i hemijskih pravila. Zato dva alata iz istih koordinata mogu izvesti različite molecular graphs, naročito kod metala, disorder-a ili neobičnih bond orders.

12A.5 Gde se nalazi „ceo kristal“

Atom-site petlja obično opisuje **asimetričnu jedinicu**, ne listu svakog atoma u jediničnoj ćeliji, a još manje beskonačni kristal. Za periodični model potrebni su zajedno:

ćelija + prostorna grupa/simetrija + atom sites + occupancy/disorder

U sintetičkom NaCl primeru nema eksplicitne petlje simetrijskih operacija: kristalografski alat ih mora dobiti iz pouzdane tabele za zadatu grupu $Fm\bar{3}m$. Čisto tekstualni CIF parser to ne mora da ume. U ovom konkretnom slučaju ekvivalentne pozicije daju četiri Na i četiri Cl u konvencionalnoj ćeliji, u skladu sa $Z=4$; specijalne pozicije se ne broje više puta. Kod realnih grupa treba proveriti i setting i izbor koordinatnog početka, jer sam broj grupe ne određuje uvek ceo koordinatni prikaz.

Parser zatim primenjuje simetrijske operacije i celobrojne translacije. Ako izvučesh samo atom-site redove i protumačiš ih kao izolovan molekul, možeš izgubiti simetrijskog suseda, preseći molekul preko granice ćelije ili pogrešno zaključiti da kontakt ne postoji.

12A.6 Kako izgleda dostavljeni `cu_n14_a.cif`, bez objavljivanja fajla

Dostavljeni fajl koristi istu gramatiku, ali je mnogo veći: oko 2,7 MB. U njemu se mogu prepoznati sledeći slojevi:

Šta tražiš	Tipičan prefiks/tag	Šta dobijaš
data block	<code>data_</code>	granica zapisa
formula	<code>_chemical_formula_...</code>	deklarisani sastav
ćelija	<code>_cell_length...</code> , <code>_cell_angle...</code>	metrički okvir periodičnog modela
simetrija	<code>_symmetry...</code> / <code>_space_group...</code>	prostorna grupa i operacije

Šta tražiš	Tipičan prefiks/tag	Šta dobijaš
atom sites	loop_ + _atom_site_...	oznake, elementi, koordinate, occupancy i displacement model
geometrija	_geom_bond_..., _geom_angle_...	izvedene ili prijavljene geometrijske relacije
kvalitet/refinement	_refine_..., _reflns_...	pokazatelji modela i podataka
ugrađeni sadržaj	višeredno polje između ;	razlog zbog kojeg fajl može biti neobično velik

Iz imena `cu_n14_a.cif` ne zaključuj da struktura sadrži bakar. U tom lokalnom primeru sastav i atom-site lista nemaju Cu; oznaka Cu K α opisuje rendgensko zračenje. Uvek proveriti data items, ne filename.

Za formalnu i kristalografsku proveru koristi CIF-aware validator, na primer IUCr-ov [checkCIF](#).

Ne šalji poverljiv CIF na javni servis

Pre slanja proveriti pravo i poverljivost. Sintaksna, kristalografska i hemijska validacija nisu ista provera; nijedan alat ih sam ne garantuje.

12A.7 Minimalna provera pre tumačenja

Pre zaključivanja utvrdi CIF dijalekt i rečnik, izabrani data block i parser warnings; zajedno proveriti ćeliju, simetriju, atom sites, occupancy/disorder i sastav; `?` i `.` sačuvaj kao različita značenja nedostajanja; vizuelno uporedi asimetričnu jedinicu, proširenu ćeliju i periodične kontakte. Uvek razlikuj originalne, parsirane i izvedene podatke.

12A.8 Provera znanja

1. Zašto `loop_` nije isto što i proizvoljna tabela u CSV-u?
2. Kolika je s.u. u `5.6400(10)`?
3. Šta je razlika između `?`, `.` i `0`?
4. Da li dva atom-site reda u primeru znače da cela ćelija ima samo dva atoma?
5. Zašto sintaksno validan CIF nije automatski naučno validna struktura?
6. Koji sadržaj gubiš ako iz CIF-a uzmeš samo molekulski graf?

Odgovori

1. Kolone definišu data names iz dictionary sistema, a vrednosti su token stream čiji broj mora odgovarati broju kolona.
2. `0.0010` u istoj jedinici kao vrednost.
3. `?` je nepoznato, `.` nema primenljivu/dodeljenu vrednost u tom kontekstu, a `0` je poznata numerička nula.
4. Ne; to su jedinstvena mesta, dok simetrija i translacije grade ćeliju i kristal.
5. Sintaksa proverava da je zapis čitljiv; ne potvrđuje poreklo, eksperiment, hemiju, model ni kvalitet.
6. Ćeliju, simetriju, periodično pakovanje, većinu eksperimentalnih metapodataka i moguće occupancy/disorder značenje.

Kriterijum prolaza: bez pomoći možeš da otvoriš nepoznat CIF, označiš data block, scalar items, jednu petlju, missing-value tokene, cell/symmetry i atom-site polja, a zatim jasno kažeš šta još nije dokazano.

13. Standardizacija bez gubitka značenja

Prioritet: MORAŠ. Najskuplje greške često ne nastaju u modelu već pre njega, kada različite hemijske forme budu nevidljivo spojene ili jedna forma pogrešno rastavljena.

13.1 Normalizacija nije isto što i „popravi molekul“

Ovde koristimo precizne radne termine:


- **parsiranje:** tekst/bajtovi → strukturisan objekat;
- **validacija:** provera sintakse, rečnika, hemijske i kristalografske konzistentnosti;
- **normalizacija:** tehničko ujednačavanje koje treba da očuva značenje;
- **standardizacija:** izbor projektne konvencije, npr. kako tretirati soli ili tautomere;
- **kuracija:** stručna odluka potkrepljena izvorom i tragom izmene.

Standardizovani prikaz nije „istinitiji original“. On je pogled namenjen određenom pitanju.

13.2 Četiri konceptualna pogleda

Isti izvor može se razmatrati kroz više pogleda, bez tvrdnje da su oni jedna obavezna storage arhitektura:

Pogled	Sadržaj	Tipična upotreba
original	verna ulazna datoteka i parser output	audit, ponovljivost
crystal	komponente, ćelija, simetrija, disorder, packing	solid-form i packing poređenje
molecular/component	svaka hemijska komponenta sa nabojem i vezama	substructure i interakcije
parent/query	dokumentovano uklonjeni solventi/counterions ili normalizovani tautomer	brzi retrieval, nikad jedini zapis



13.3 Logičke zavisnosti standardizacije

Sledeći redosled objašnjava stručnu zavisnost — na primer, izvorni i dodeljeni naboji moraju biti razdvojeni pre parent transformacije — a ne plan realizacije projekta. Komponente, veze i protonacija često se razjašnjavaju zajedno, uz ponovnu proveru; CIF ne mora već sadržati pouzdan molekulski graf:

1. **Identifikuj datoteku** po sadržaju, ne samo ekstenziji; sačuvaj hash.
2. **Parsiraj bez prepisivanja originala** i sakupi sva upozorenja.
3. **Validiraj CIF prema rečniku** i osnovnim numeričkim/relacionim pravilima.
4. **Sačuvaj prijavljeni sastav, naboje i H mesta**, uključujući šta nije poznato; ne izmišljaj nulti naboj kada ga izvor ne daje.
5. **Obradi disorder i occupancy** kao eksplicitnu neizvesnost, ne kao duplikate atoma.
6. **Preuzmi ili izvedi i proveri veze** uz izvor pravila i confidence; metalne veze i periodičnu povezanost tretiraj posebno.
7. **Inventariši komponente i proveri njihovu protonaciju/naboje**: glavna organska vrsta, metal, counterion, coformer, solvent, voda. Ako su veze ili H neodređeni, zadrži tu neodređenost i po potrebi ponovi prethodnu proveru.
8. **Primeni task-specific policy** nad kopijom.
9. **Ponovo izračunaj** formulu, charge balance gde su naboji poznati i druge invariants.
10. **Upiši provenance**: alat, verzija, parametri, timestamp, warnings i pre/posle hash.

13.4 Identitet ima hijerarhiju

„Isto jedinjenje“ može značiti različito:

```
hemijski scaffold
├─ konkretna molekulska/protonaciona vrsta
│   └─ sastav čvrste forme (salt/solvate/co-crystal)
│       └─ polymorph/phase
│           └─ pojedinačno kristalografsko određivanje
```

Dva CSD refcode-a mogu biti ponovljena određivanja iste forme, različiti polymorphs, različiti solvates, različite temperature ili različite komponente iste compound family. Duplikat za jedan ML cilj može biti validan zaseban primer za drugi.

13.5 Najopasnije transformacije

Uklanjanje „malih fragmenata“

Najveći fragment nije nužno jedini relevantan. Mali halid može balansirati charge i oblikovati packing; voda može biti član H-bond mreže; metal može imati malo atoma, ali biti centar kompleksa.

Neutralizacija

Automatsko dodavanje/uklanjanje H može promeniti ligand donor status, ukupan charge, salt identitet i H-bond mrežu. Parent-scaffold prikaz sme postojati samo uz očuvan original.

Aromatičnost i tautomer

Aromatičnost je model koji toolkit percipira. Tautomer canonicalization menja formalne single/double veze i položaj H. Fingerprint score može zato zavisiti od policy-ja, a ne samo od hemijske bliskosti.

Metal-ligand povezanost

Organski valence modeli često nisu dovoljni za koordinacione spojeve. Ne treba nasilno popravljati svaku neuobičajenu valencu brisanjem veze. Čuvaj i eksperimentalnu geometriju i eksplicitno poreklo connectivity modela.

Disorder i occupancy

Alternativne pozicije nisu dve istovremene pune kopije. Ako dve pozicije occupancy 0.5 pretvoriš u dva puna atoma, masa, kontakti i graf postaju pogrešni.

CCDC opisuje neke praktične posledice disorder-a u [CSD Python API dokumentaciji](#).

13.6 Missing, unknown i not applicable

Nikada ne spajaj sledeće u broj nula:

- nije izmereno;
- nije prijavljeno;
- parser ne podržava;
- algoritam nije uspeo;
- osobina nije primenljiva;
- pouzdano je izmerena vrednost 0.

Za svaki feature čuvaj value, unit, missing-reason, method i confidence. ML model inače može učiti ponašanje parsera ili laboratorije umesto hemije.

13.7 Invariants i testovi

Posle svake transformacije automatski proveriti očuvane invarijante i unapred deklarisanu očekivanu promenu:

- broj i identitet elemenata, uz eksplicitno evidentirane dodate ili uklonjene atome/komponente;
- formalni total charge i charge balance; kada politika menja protonaciju/naboj ili uklanja naelektrisanu komponentu, proveriti deklarisanu Δcharge umesto jednakosti;
- atom map za očuvane atome, uz eksplicitno evidentirane dodate ili uklonjene atome;
- stereocentri koji nisu cilj transformacije;
- formula/molecular weight u skladu sa sastavom;
- kristalna ćelija i symmetry netaknuti u crystal pogledu;
- deterministic output za istu verziju pravila.

Regression primeri iz lokalnog skupa

- N14.mo12: NO_CHARGES ne sme postati dokaz o nultoj polarizaciji.
- N14.mo1 i .mo12: različit bond typing ne sme neopaženo dati dva „ground truth“ identiteta.
- cu_n14_a.cif: reč Cu iz imena/zračenja ne sme ući u element filter.
- metalni query: prisustvo 4M atoma u zapisu ne sme automatski postati etiketa „DAP koordinira metal“.

13.8 Verzije i reproducibilnost

Svaka politika standardizacije mora imati stabilan identitet i verziju. Da bi njeno značenje bilo proverljivo, opisuje najmanje sledeće pojmovne kategorije:

Kategorija	Šta mora biti jasno
cilj i pogled	za koje naučno pitanje i koji pogled — crystal, component ili parent/query — derivat važi
tretman komponenti	kako se razmatraju solventi, counterions, cocrystals, voda i metali, uz razlog za svako uklanjanje ili zadržavanje
hemijske konvencije	kako se tumače formalni naboj, protonacija, tautomerija, aromatičnost, stereo i metal–ligand povezanost
kristalografski sadržaj	da li i kako ostaju ćelija, simetrija, disorder, occupancy i periodična geometrija
gubici i veze sa izvorom	šta je očuvano, izvedeno, promenjeno ili izgubljeno i kako se derivat mapira nazad na original
provere	koji invariants, upozorenja i granice primenljivosti prate transformaciju
poreklo pravila	koja verzija pravila i alata je primenjena i na kom verzionisanom izvoru

Nazivi polja, format serijalizacije i način tehničkog prenosa te politike ostaju implementacioni izbori. Promena toolkita ili pravila zahteva novu verziju politike i ponovno izvođenje ili proveru zavisnih derivata. Embeddings, fingerprints i drugi derivati nastali pod različitim politikama nisu međusobno uporedivi samo zato što imaju isti format ili broj dimenzija; uporedivost mora biti posebno dokazana uz feature provenance i očuvane invariants.

13.9 Provera znanja

1. Zašto ne treba menjati originalni zapis „in place“?
2. Kada je uklanjanje solventa korisno, a kada štetno?
3. Zašto disorder atom occupancy 0.5 nije pola elementa niti dva atoma?
4. Koja je razlika između unknown i measured zero?
5. Zašto ista standardizacija nije optimalna za scaffold i packing search?

Odgovori

1. Gubi se dokaz, mogućnost audit-a i ponovnog izvođenja drugim pravilima.
2. Može pomoći parent-scaffold retrieval-u; šteti solid-form/interaction analizi gde solvent učestvuje u strukturi.
3. To je model alternativne ili delimične zauzetosti kristalografskog mesta; mora ostati vezan za disorder model.
4. Prvo nema poznatu vrednost, drugo je rezultat sa vrednošću nula.
5. Scaffold želi kontrolisano ignorisati neke komponente/formalne prikaze; packing zavisi upravo od punog sastava i periodične geometrije.

Kriterijum prolaza: možeš da nacrtas loss-aware pipeline i za svaku transformaciju navedeš cilj, rizik, invariant i način povratka do originala.

14. Molekul kao graf i skup deskriptora

Prioritet: MORAŠ. Ovo poglavlje spaja hemiju sa ML projektovanjem. Reprezentacija određuje koje razlike model može da vidi, a koje ne može.

14.1 Molekulski graf

Molekul se često modeluje kao označen graf $G = (V, E)$:

- čvor $v \in V$ je atom;
- grana $e \in E$ je model hemijske veze;
- čvor nosi element, formal charge, aromaticity, hybridization, koordinaciono okruženje, eventualno 3D položaj;
- grana nosi bond type/order, aromatic/conjugated status i eventualno dužinu.

Graf je korisna apstrakcija, ali nije cela elektronska struktura. Bond order i aromaticity mogu biti dodeljeni modeli; koordinacione veze nisu uvek prirodno opisane običnim integer bond order-om.

14.2 Kristal zahteva periodični graf

Kristal nije samo graf asimetrične jedinice. Simetrijske operacije i translacije stvaraju periodične slike. Kontakt preko granice ćelije može biti najvažnija H-veza u mreži.

Periodični model zato mora da pamti:

- lattice vectors / cell parameters;
- fractional coordinates;
- symmetry operation i translation image za svaku međumolekulsku ivicu;
- component/occupancy/disorder identitet;
- cutoff i hemijsko pravilo kojim je kontakt napravljen.

Ako sve atome samo preseliš u jednu kartezijansku kutiju, možeš prekinuti stvarnu mrežu ili duplirati interakcije.

14.3 Deskriptori: sažetak uz gubitak

Deskriptor je izračunata osobina reprezentacije. Primeri relevantni projektu:

Nivo	Primeri	Šta približno hvata
formula/composition	element counts, molecular weight, metal class	sastav, ali ne connectivity
2D topologija	atom/bond counts, rings, rotatable bonds, HBD/HBA	graf i funkcionalnost
fingerprint	hashed local substructures	brzo hemijsko susedstvo
3D molekul	distance matrix, torsions, shape moments, pharmacophore features	konformaciju/oblik
koordinacioni centar	donor set, coordination number, geometry distortion	lokalnu metalnu geometriju
kristal	cell/space group/density, packing motifs, contact network	periodičnu čvrstu formu
eksperiment	temperature, radiation, R values, disorder flags	uslove i kvalitet određivanja

Deskriptor nije neutralan. „Broj H-bond acceptora“ zavisi od protonacije i feature definicije; „density“ može biti prijavljena ili izračunata; „space group“ je kategorija, ne numerička udaljenost.

14.4 Circular fingerprints

Extended-connectivity/circular fingerprint algoritmi iterativno opisuju lokalna atomska okruženja do određenog radijusa, a zatim ih mapiraju u skup ili bit-vektor. Osnovni rad je [Rogers i Hahn, 2010](#); praktična implementacija i parametri su opisani u [RDKit vodiču](#).

Radijus je broj koraka kroz veze, ne udaljenost u Å. Radijus 0 opisuje centralni atom; radijus 1 dodaje njegove neposredne susede, a radijus 2 i susede tih suseda. Oznaka ECFP4 se uobičajeno odnosi na dijametar 4, odnosno radijus 2; RDKit Morgan koristi parametar radijusa. Bit-vektor beleži prisustvo okruženja pomoću 0/1, dok count-vektor beleži i broj pojavljivanja. To su različite reprezentacije i zahtevaju odgovarajuću definiciju mere sličnosti.

Važni parametri:

- atom invariants/features;
- radius;
- bit-vector length ili sparse counts;
- useCounts vs binary presence;
- stereochemistry uključena/isključena;
- aromaticity i standardization policy;
- toolkit i verzija.

Fingerprint collision znači da različita okruženja mogu završiti u istom bitu. Zato fingerprint score nije dokaz identiteta, a objašnjenje treba vratiti na stvarne matched substructures kada je moguće.

14.5 3D reprezentacija

Koordinate nose dužine, uglove, torsions i shape, ali uvode invariance zahteve:

- prevod i rotacija celog molekula ne smeju menjati rezultat;
- permutacija ekvivalentnih atoma ne sme proizvesti lažnu razliku;
- mirror image ne treba automatski tretirati isto kada je chirality relevantna;
- različite konformacije istog grafa mogu biti namerno slične ili različite, zavisno od zadatka;
- kristalne i generisane 3D koordinate ne smeju se pomešati bez oznake porekla.

RMSD je smislen tek nakon definisanja atom mapping-a, alignment-a, symmetry-equivalent atom treatment-a i H atom policy-ja.

14.6 Interakcioni i packing grafovi


Za crystal-level poređenje mogu se graditi:

- atom-contact graf;
- molecule-centroid graf;
- H-bond network;
- coordination network;
- fingerprint intermolecular interactions;
- local coordination environment oko odabranog atoma/molekula.

Svaka ivica mora nositi rule provenance. Geometrijski cutoff sam po sebi nije hemijska istina; donor/acceptor type, angle, periodic image i uncertainty menjaju tumačenje.

14.7 Multimodalni zapis, ne jedna magična reprezentacija

Za prvu aplikaciju je razumna hijerarhija:



Ova kaskada je korisna kada je sličan molekulski graf deo definicije relevantnosti. Ako tražimo isti koordinacioni ili packing motiv među hemijski različitim strukturama, strogo odbacivanje po 2D fingerprintu može ukloniti pravi pogodak. Tada treba drugačije generisati kandidate ili sjediniti više skupova kandidata i izmeriti šta svaki korak propušta.

Za drugu aplikaciju, gde su ulazi već izabran skup CIF-ova, mogu se uporedo izračunati:

- chemical graph similarity;
- conformational/geometric similarity;
- coordination environment similarity;
- packing similarity;
- interaction-network similarity;
- data-quality compatibility.

Ne sabiraj ih dok nisu normalizovani, validirani i semantički objašnjeni.

14.8 Feature provenance i uncertainty

Feature je interpretabilan samo kada uz vrednost postoji dovoljno konteksta da se razume njegova jedinica i strukturni nivo, metod i verzija, izvorni atomi/polja, parametri, neizvesnost i razlog odsustva. To su kategorije dokaza, ne propisana buduća record schema.

Posebno razdvoji:

- **observed/refined** koordinate i polja;
- **derived** vrednosti, poput bond length iz koordinata;
- **assigned** kategorizacije, poput atom type-a;
- **predicted** vrednosti, poput ML property-ja.

Modelu se može dati svaka od njih, ali korisniku se ne smeju prikazati kao ista vrsta činjenice.

14.9 Data leakage

Kod CSD-derived skupa nasumični split po pojedinačnim refcode-ovima može staviti vrlo slična ponovljena određivanja ili polymorph family u train i test. Rezultat tada meri prepoznavanje familije, ne generalizaciju.

Split jedinica treba da prati naučno pitanje, na primer:

- scaffold split za novi hemijski scaffold;
- compound-family split za novu supstancu;
- publication/time split za buduće zapise;
- laboratory/source split za robusnost prema poreklu;
- solid-form family split za polymorph zadatak.

14.10 Provera znanja

1. Koju informaciju formula ne može da odredi?
2. Zašto fingerprint parametri moraju biti verzionisani?
3. Koje invariance treba 3D model?
4. Zašto asimetrična jedinica nije potpuni packing graf?
5. Kako bliski CSD refcode-ovi mogu izazvati data leakage?

Odgovori

1. Connectivity, izomeriju, konformaciju i packing.
2. Menjaju bitove/features i time vrednosti sličnosti i kompatibilnost indeksa.
3. Najmanje translation, rotation i atom-permutation invariance/equivariance uz pažljiv chirality tretman.
4. Periodični susedi nastaju symmetry/translation operacijama, često preko granice ćelije.
5. Mogu predstavljati isto ili gotovo isto jedinjenje/formu/određivanje pa završiti na obe strane split-a.

Kriterijum prolaza: za svaku feature porodicu umeš da kažeš njen nivo, poreklo, invariance, šta gubi i za koji od dva proizvoda služi.

15. Sličnost nije jedna veličina

Prioritet: MORAŠ. „Nađi slične strukture“ je nepotpun zahtev. Pre implementacije se mora reći: slične po čemu, za koju odluku, pod kojom standardizacijom i sa kakvim dokazom?

15.1 Pet odvojenih pitanja

Nivo	Pitanje	Primer metode
sastav	da li sadrže iste elemente/formulu?	set/count distance, filter
2D hemijski graf	da li dele scaffold/substructures?	fingerprint, subgraph, MCS
konformacija/geometrija	da li isti mapirani atomi imaju sličan 3D raspored?	aligned RMSD, torsion comparison
kristalno pakovanje	da li se molekuli periodično slažu slično?	packing overlay/COMPACT-like search
interakcije	da li grade slične H-bond/coordination/contact mreže?	interaction fingerprints/graph comparison

Dve strukture mogu biti identične na prvom i drugom nivou, a različite polymorphs na četvrtom. Mogu imati različite supstituente, ali isti coordination motif. Jedan scalar ne može bez gubitka objasniti sve.

15.2 Exact, substructure i similarity nisu isto

- **exact graph match** traži isti definisani graf, uz policy za stereo/charge/isotopes;
- **substructure search** pita da li target sadrži query podgraf — odnos je asimetričan;
- **similarity search** rangira po numeričkoj meri — prag je projektna odluka;
- **MCS** traži najveću zajedničku podstrukturu pod zadatim pravilima i može biti skup/višeznačan.

Kod MCS-a „najveća“ mora imati kriterijum: broj atoma, broj veza ili druga unapred definisana veličina, uz odluku da li zajednički podgraf mora biti povezan. Ograničenje vremena može dati najbolji dotad pronađen podgraf bez dokaza da je globalno najveći; taj status treba prijaviti, kao u [RDKit MCS dokumentaciji](#). Substructure i MCS zato nisu zamenljivi sa brzim fingerprint rangiranjem.

CCDC dokumentacija razdvaja [search pristupe](#), [substructure searching](#) i [similarity searching](#).

15.3 Tanimoto nad binarnim fingerprintima

Ako su A i B skupovi uključenih bitova:

$$T(A, B) = \frac{|A \cap B|}{|A| + |B| - |A \cap B|}.$$

Primer: A ima 10 bitova, B 8, a dele 6:

$$T = \frac{6}{10 + 8 - 6} = 0.50.$$

Vrednost zavisi od fingerprinta, radius-a, bit length-a, stereochemistry i standardizacije. „Tanimoto 0.8“ bez tih podataka nije reproducibilna činjenica. Isti prag nema isto značenje za male i velike molekule, različite hemijske domene ili različite ciljeve.

Formula iznad važi za **binarna prisustva**. Kod count-vektora postoji više proširenja i mora se navesti tačno korišćena formula. Ako su oba skupa bitova prazna, imenilac je nula; softverska konvencija za taj slučaj nije dokaz hemijskog identiteta. Posebno, neuspešno parsiran ili prazan atomski zapis iz lokalnog izvoza ne sme postati „savršeno sličan“ drugom neuspešnom zapisu.

15.4 RMSD i geometrijska sličnost

Za mapiranih N parova atoma, posle optimalnog poravnanja:

$$\text{RMSD} = \sqrt{\frac{1}{N} \sum_{i=1}^N \|\mathbf{x}_i - \mathbf{y}_i\|^2}.$$

Ali rezultat zavisi od:

- atom mapping-a i izabranog common core-a;
- heavy atoms vs all atoms;
- symmetry-equivalent atoma;
- rigidnog ili fleksibilnog alignment-a;
- crystal coordinates vs generated conformer-a;
- disorder/occupancy izbora.

Zato izveštaj prikazuje i N , mapping coverage, RMSD, maksimum odstupanja i policy, ne samo jednu decimalu.

Za RMSD izražen u Å manja vrednost znači bolje prostorno poklapanje; to još nije similarity score na skali 0–1. Poravnanje treba ograničiti na rotacije i translacije kada hiralnost mora biti očuvana: dozvoljena refleksija mogla bi veštački poklopiti enantiomere.

15.5 Packing similarity

Packing comparison traži lokalni periodični klaster molekula oko referentnog molekula i pokušava da nađe dovoljno velik skup koji se geometrijski poklapa. CCDC-ov [Packing Similarity API](#) vraća broj matched molecules i RMSD; zasnovan je na COMPACT pristupu opisanom u [Chisholm i Motherwell, 2005](#).

Neophodni parametri uključuju veličinu shell-a/klastera, tolerancije, molecular matching i izbor komponente. Slična ćelija sama po sebi ne dokazuje isti packing; ista space group takođe ne dokazuje isti polymorph.

15.6 Interaction similarity

Za H-bond ili coordination mreže mogu se porediti:

- tipovi čvorova i ivica;
- donor/acceptor/metal identities;
- distance i angle distributions;
- periodic topology i dimensionality;
- motivi/rings/chains;
- pokrivenost i pouzdanost detekcije.

Kontakt koji ispunjava cutoff je kandidat, ne automatski „jaka veza“. Hydrogen positions, protonation, disorder i temperatura utiču na sigurnost.

15.7 Hibridni rezultat treba da ostane rastavljiv

Ako je poslovno potreban combined score, prvo prikaži komponente:

2D graph	0.84
mapped 3D core	0.71 (28/34 heavy atoms; RMSD 0.62 Å)
coordination env.	exact donor set; geometry mismatch
packing	9/15 molecules; RMSD 0.91 Å
interaction network	0.58
quality compatibility	medium

Tek zatim može postojati verzionisana formula, kalibrisana prema konkretnom zadatku. Težine ne treba birati „po osećaju“ niti trenirati bez jasno označenih ekspertskih parova.

15.8 Računska cena za dostavljeni skup

Potpuno poređenje n struktura zahteva:

$$\binom{n}{2} = \frac{n(n-1)}{2}$$

parova. Za 2.110 zapisa to je **2.224.995** parova; za 2.038 metal-filterovanih zapisa **2.075.703**. Ako jedna duboka analiza traje samo 0,5 s, prvi posao bi serijski trajao skoro 13 dana.

Porodice metoda za smanjenje troška uključuju jeftine eligibility/filter korake, približno nalaženje kandidata, exact reranking manjeg skupa i odlaganje skupih 3D/packing analiza. To je coarse-to-fine algoritamski princip, ne izbor buduće baze, cache ključa ili redosled implementacije.

Kada zahtev zaista glasi „svi parovi“, candidate pruning menja zadatak. Za traženje svih parova iznad praga potrebna je empirijska provera recall-a prefiltera; top- k sam može propustiti relevantan par.

15.9 Kako se prag validira

Ne postoji univerzalni „slično“. Napravi ekspertno označen evaluation set sa:

- jasnim use case-om i nivoom sličnosti;
- pozitivnim, lakim negativnim i teškim negativnim parovima;
- grupisanjem da bliske family kopije ne procure u test;
- više nezavisnih eksperata i pravilom za neslaganje;
- confidence/ambiguous oznakama;
- metrikama retrieval-a: recall@ k , precision@ k , MAP/nDCG i latency;
- kalibracijom i error slicing-om po metalima, solvatima, disorder-u, veličini i kvalitetu.

15.10 Provera znanja

1. Da li Tanimoto 0.8 ima smisla bez fingerprint definicije?
2. Zašto substructure relation nije simetrična?
3. Da li ista space group znači isti packing?
4. Koje informacije moraju pratiti RMSD?
5. Koliko parova ima 100 struktura?

Odgovori

1. Ne; rezultat zavisi od reprezentacije, parametara i standardizacije.
2. Mali query može biti sadržan u velikom target-u, dok obrnuto ne važi.
3. Ne; mnogo različitih pakovanja deli istu space group.
4. Mapping/common core, broj/pokrivenost atoma, alignment, atom/H/stereo/symmetry policy i poreklo koordinata.
5. $100 \times 99/2 = 4.950$.

Kriterijum prolaza: možeš da napišeš similarity specification koja navodi objekat, reprezentaciju, metriku, parametre, threshold/calibration, evidence i failure modes.

16. CSD i ConQuest tok podataka

Prioritet: MORAŠ. Ova strana objašnjava šta lokalni izvozi jesu, šta nisu i koje semantičke, licencne i provenance obaveze postoje kada se radi sa CSD podacima. Ne propisuje buduću implementaciju.

16.1 CSD, CSD entry i refcode

Cambridge Structural Database (CSD) je kurirana, licencirana baza kristalnih struktura malih organskih i metal-organskih jedinjenja. CCDC-ov pregled razvoja baze je [A Million Crystal Structures: The Whole Is Greater than the Sum of Its Parts](#). Zvanični CCDC snapshot od **1. januara 2026.** navodi 1.431.347 struktura; broj je vremenski promenljiv i ne treba ga hardkodovati kao trajnu činjenicu ([CSD Entry Summary Statistics 2026](#)).

CSD entry nije nužno jedna jedinstvena hemijska supstanca. Može predstavljati konkretno kristalografsko određivanje pri određenim uslovima, sa sastavom, 3D modelom, bibliografijom i kuriranim anotacijama. Bliski refcode-ovi mogu biti povezane redeterminations ili forme; identitet se ne određuje samo string poređenjem.

Tri nivoa se moraju držati odvojeno:

```
CSD entry / eksperimentalno određivanje
└─ kristal: ćelija + simetrija + sastav + packing
    └─ jedna ili više hemijskih komponenti/molekula
```

16.2 ConQuest nije samo text search

ConQuest je CCDC alat za crtanje i kombinovanje 2D/3D strukturnih i tekstualno-numeričkih upita. Podstrukturni query definiše atom/bond constraints; opciono se dodaju geometric constraints i entry filters. CCDC dokumentacija objašnjava [search philosophy](#) i [substructure searching](#).

`.cqs` je binarni ConQuest query/session objekat. U dostavljenim lokalnim fajlovima sadrži i sačuvano stanje/rezultate, ali nije obična prenosiva result-lista niti univerzalni javni standard za razmenu. Statička forenzika zato nije zamena za vizuelnu i runtime potvrdu u kompatibilnoj ConQuest verziji, sa eksplicitno zabeleženim constraints/filterima.

16.3 Šta smo utvrdili za dva lokalna upita

Forenzički pregled čitljivog serializovanog sadržaja dva `.cqs` fajla pokazuje:

Upit	Strukturni deo	Dodatni uslov	Lokalni rezultati
1 - Sifove baze DAP.cqs	18-atomsko DAP query jezgro sa dve C=N veze	nema dodatnog metalnog uslova; metal nije ni zahtevan ni zabranjen	2.110
2 - Kompleksi sa DAP SB.cqs	isti 18-atomski motiv	odvojeni atom tipa 4M	2.038

CCDC ConQuest vodič definiše 4M kao svoju grupu „svih metalnih elemenata“ ([ConQuest User Guide](#)). To je softverska klasifikacija: preko podgrupe 2M uključuje i Ge i Sb, koji se često svrstavaju u polumetale. U ovom opisu „metal-containing“ znači prisustvo člana te verzionisane 4M grupe, ne univerzalnu klasifikaciju periodnog sistema. U query objektu atom 19 je **nepovezan** sa DAP motivom: nema metal–N bond/contact/geometric constraint.

Zato je dokazano samo:

entry sadrži DAP motiv i neki metal negde u istom entry-ju.

Nije dokazano:

taj DAP ligand koordinira taj metal preko očekivana tri N donor-atoma.

search2 je tačan podskup search1 ; razlika je 72 entry-ja. Semantika „kompleks sa DAP“ zahteva drugi korak: component assignment, metal-neighbor perception, donor mapping i geometric/chemical validation.

Naziv upita nije ground truth

Naziv „Kompleksi sa DAP SB“ izražava nameru autora, ali mašinska etiketa mora da prati stvarne constraints. Konačnu nameru i dozvoljene edge cases treba potvrditi sa naučnim timom.

16.4 Filteri i selection bias

Serialized query pokazuje da standardni filteri za 3D coordinates, R factor, errors, disorder, polymers, ions, powder i organic/organometallic classification nisu uključeni. Lokalni rezultati zato sadrže heterogeni kvalitet i zapise bez pune 3D reprezentacije.

To je legitimno za širok recall, ali ima dve posledice:

1. svaki downstream korak mora eksplicitno da prijavi da li je određena analiza moguća;
2. skup nije slučajan uzorak celog CSD-a, već query-conditioned subset.

Ne sme se iz lokalne učestalosti metala, space groups ili missing SMILES zaključivati globalna CSD distribucija.

16.5 Entry filters nisu isto što i hemijski uslov

Primeri različitih slojeva:

- **query graph constraint:** ciljno piridinsko query jezgro sa dve C=N veze;
- **entry composition constraint:** prisutan neki metal;
- **geometric constraint:** određeni M...N distance/angle;
- **curation/metadata filter:** 3D coordinates present, bez disorder-a, maksimalni R;
- **post-processing classification:** donor atoms zaista pripadaju DAP komponenti i grade metal coordination environment.

Jedan sloj ne može neopaženo zameniti drugi.

16.6 Odvojene odgovornosti u licenciranom okruženju

Bez obzira na izabranu tehnologiju, nekoliko vrsta odgovornosti ne sme da se pomeša:

Odgovornost	Pitanje koje mora imati odgovor
izvor i verzija	Koji CSD release, proizvod i snapshot predstavljaju populaciju?
značenje upita	Koji graph/geometric/entry constraints i filteri određuju skup?

Odgovornost	Pitanje koje mora imati odgovor
prava	Ko sme da čita, obrađuje, čuva, prikazuje ili preuzima raw i izvedene podatke?
transformacija	Koji alat, verzija i pravilo su proizveli svaki izvedeni prikaz?
coverage	Koji zapisi su uspeali, delimični, nepodržani ili neuspešni?
dokaz rezultata	Sa kojom verzijom upita, korpusa i reprezentacije je rezultat dobijen?

Ovo su kategorije provenance-a i odgovornosti, ne propisana baza, API, cache, indeks ili redosled realizacije.

16.7 API funkcionalnosti i granica licence

CCDC Python API dokumentuje [IO](#), [descriptors](#), [molecular geometry analysis](#) i [packing similarity](#). Dostupnost pojedinih funkcija zavisi od licence/proizvoda.

Bez institucijskog pristupa nije moguće pošteno tvrditi da globalna pretraga radi nad celim CSD-om. Coverage, dostupnost funkcija i performanse mogu se potvrditi samo nad odobrenim snapshot-om u stvarnom licencnom okruženju.

16.8 Reproductivni opis upita

Reproduktivnost ne zavisi od jedne konkretne YAML šeme, već od toga da opis razdvoji sledeće činjenice:

Kategorija	Nalaz za drugi lokalni CQS
identitet izvora	SHA-256 065c31c2669bca2fb087a58650e1a9b8c71ea6bb8f87050b8cab6bd79416aaa5
alat i baza	ConQuest 2022.2.0; CSD 5.43 sa March/June 2022 segmentima
izvršivi strukturni uslov	18-atomsko DAP query jezgro sa dve <chem>C=N</chem> veze plus odvojeni <chem>4M</chem> atom
broj povezanih komponenti query grafa	dve; ne postoji metal–motiv constraint
sačuvani entry filteri	<code>require_3d=false</code> ; maksimalni R nije zadat
trag vremena	2026 temp/save trag ne dokazuje da je baza ili run iz 2026.
ljudska namera	naziv sugerise „komplekse“, ali tačan scope čeka potvrdu fakulteta

Druga serializacija ili terminologija je prihvatljiva ako čuva iste razlike i ne predstavlja ljudski naziv kao izvršivi constraint.

16.9 Provera znanja

- Šta dokazuje prisustvo nepovezanog 4M query atoma?
- Zašto CSD entry nije sinonim za molekul?
- Da li 2.038 rezultata čine unbiased globalni trening skup?
- Koja četiri artefakta su potrebna da se upit reprodukuje?

Odgovori

- Samo da isti entry sadrži neki metal, ne metal–DAP koordinaciju.
- Entry opisuje određivanje kristala i može imati više komponenti, formi i metapodataka.
- Ne; izabrani su jednim query-jem, filteri su specifični, a pun CSD nije dostupan.
- Verzija alata/baze, potpuna query+filter definicija, snapshot/refcode manifest i provenance/hash.

Kriterijum prolaza: možeš da prevedeš ConQuest nameru u eksplicitne mašinske constraints i odvojiš candidate retrieval od hemijski validirane etikete.

17. Forenzika dostavljenog skupa

Prioritet: MORAŠ. Ova strana je data sheet lokalnog materijala: šta je direktno pročitano iz fajlova, šta je izvedeno, gde reprezentacije gube podatke i zašto skup nije gotov ML ground truth.

Granica dokaza

Sve brojke označene kao lokalne potiču iz snapshot-a dostavljenog u folderu 2CDC. Prvobitna beleška nosi datum 22. avgusta 2026; agregati formata i metadata ponovo su provereni 5. septembra 2026. pomoću Gemmi 0.7.5 i zasebnog čitanja MOL2/SDF/SMILES zapisa. One nisu statistika današnjeg punog CSD-a. Originalni CSD izvozi, .cqs, eksperimentalni CIF/MOL fajlovi i ugrađeni HKL podaci **nisu commit-ovani u ovaj dokumentacioni repo**; ovde su samo agregati, metod i minimalni didaktički primeri. Pre bilo kakvog javnog objavljivanja ili distribuiranja derivata potrebna je licencna provera.

17.1 Tri sloja: izvor, nalaz i interpretacija

Forenzički izveštaj mora da razlikuje:

Sloj	Primer	Koliko je jak dokaz
direktno polje/bajt	CQS navodi ConQuest 2022.2.0; CIF formula sadrži Zn	reproduktivno čitanje izvora
izvedena statistika	search2 je podskup search1; median R je 0,051	zavisi od parsera i jasno definisanog postupka
hemijska interpretacija	CAPHEK ima N3Cl2 Zn okolinu; APHZUC nije DAP-metal N3 kompleks	zahteva graf, mapping, geometriju i stručna pravila

Naziv fajla nije poseban četvrti izvor istine. 2 - Kompleksi sa DAP SB.cqs opisuje nameru autora, ali izvršiva semantika query-ja je slabija od tog naziva.

17.2 Šta je dostavljeno

Projektni zahtev

dve funkcionalnosti.txt definiše dva različita proizvoda:

- Globalna pretraga:** jedan uploadovani CIF se pretvara u hemijske/kristalogrfske reprezentacije, filtrira se i poredi sa velikom CSD kolekcijom; rezultat je rangirana lista sličnih struktura. Tekst predlaže slojeve za metadata, vektorsku i graf pretragu, ali ne definiše metriku relevantnosti ni ground truth.
- Poređenje svakog para:** za n uploadovanih CIF-ova obrađuje se $n(n-1)/2$ parova uz detaljnije grafovsko, geometrijsko, packing i interaction poređenje. Veća tačnost je cilj iz zahteva; manji broj ulaza omogućava skuplje metode, ali sam po sebi ne dokazuje da će one biti tačnije.

To je product brief, ne hemijska specifikacija. Pojmovi „sličan“, „tip jedinjenja“, „osobina“ i „preciznije“ tek treba da se pretvore u merljive ugovore.

Strukturni primer N14

Fajl	Veličina	Forenzički tip
cu_n14_a.cif	2.700.216 B	jedan bogat eksperimentalni SHELX/coreCIF zapis sa koordinatama, refinement podacima i ugrađenim RES/HKL blokovima

Fajl	Veličina	Forenzički tip
N14.mol	2.803 B	jedan MDL MOL V2000 zapis, uz završni \$\$\$\$ delimiter
N14.mol2	5.233 B	jedan Tripos MOL2 zapis sa Cartesian koordinatama i CRYGIN sekcijom

Dve CSD pretrage

Artefakt	search1	search2	Uloga
.cqs	548.864 B	532.480 B	ConQuest query + sačuvano stanje/rezultati; binarno
.cif	2.110 data blokova	2.038 data blokova	entry metadata, ćelija/simetrija i, kada postoje, frakcione koordinate
.mol2	2.110 record-a	2.038 record-a	molekulski graf/koordinate; neki record-i nemaju atomsku strukturu
.sd	2.110 record-a	2.038 record-a	MDL V2000 record-i; neki su prazni zbog matching problema
.smi	1.877 reda	1.805 redova	SMILES<TAB>refcode; nepotpun podskup

Refcode redosled u CIF/MOL2/SD izvozu je međusobno jednak unutar svake pretrage. SMILES zadržava isti relativni redosled, ali preskače zapise bez dostupnog izvoza.

17.3 Dokazani odnos search1 i search2

Rezultati nisu dva nezavisna dataseta:

```
search1: 2.110 DAP-motif entry-ja
└─ search2: 2.038 istih entry-ja sa bar jednim 4M elementom

razlika: 72 entry-ja bez metala
```

- search2 je **strogi podskup** search1;
- njegovi refcode-ovi se javljaju u potpuno istom redosledu kada se search1 filtrira;
- tačno 72 refcode-a iz search1 nedostaju u search2;
- svih 72 imaju SMILES i njihove formule su metal-free;
- svih 2.038 formula u search2 sadrži najmanje jedan element iz ConQuest grupe 4M;
- u nijednom kompletnom izvozu nema dupliranog punog refcode-a.

CAPHAG je prvi koristan član razlike: DAP-derived bis-iminski ligand formule C25 H27 N3, bez metala. **CAPHEK** je prvi search2 primer: Zn koordinisan preko N3 liganda i dva Cl donora, uz odvojene molekule acetonitrila i vode.

Kontraprimeri **APHZUC**, **FOWLEJ**, **GEHCOM**, **MINQUV**, **SUZBAT** i **UJIXES** pokazuju zašto search2 članstvo nije koordinaciona etiketa: metal može biti u odvojenom jonu/komponenti ili u okolini koja ne uključuje ciljane DAP azote.

17.4 Tačna rekonstrukcija oba query-ja

Oba .cqs sadrže isti povezani 2D connectivity motiv:

Osobina	Vrednost iz query objekta
eksplicitni atomi	18: 9 C, 3 N, 6 H
kostur	centralni pyridine-like prsten, supstituisan na 2,6 položajima
ruke	dve ring-C-C(=N)-CH ₃ grupe
prstenaste veze	6 veza sa kodom 5

Osobina	Vrednost iz query objekta
dvostruke C=N veze	2, kod 2
ostale veze	10 Any veza, kod 99
search flags	exhaustive=1, symmchk=1

search1 nema dodatni metalni criterion. To **ne znači** da zabranjuje metale; zato sadrži svih 2.038 metal-containing članova search2 i još 72 metal-free zapisa.

search2 dodaje nepovezan devetnaesti atom tipa 4M. ConQuest vodič definiše $4M = 1M + 2M + TR + LN + AN$, odnosno svoju grupu metalnih elemenata. U nju preko 2M ulaze i Ge i Sb; izrazi „metal-containing“ i „metal-free“ u ovoj forenzici prate tu softversku grupu. U query objektu ne postoji:

- bond-order veza od AT19 do jednog od tri DAP N;
- contact/distance constraint;
- uslov da su metal i DAP motiv u istoj povezanoj komponenti;
- zahtev da isti metal vezuje sva tri mapirana N.

Zato je formalna semantika:

```
EXISTS mapped 18-atom DAP-derived bis-C=N query core
AND EXISTS any metal atom in the same database entry
```

a ne:

```
EXISTS metal coordinated to the mapped N_imine-N_pyridine-N_imine donors
```

Serialized default filter flags 3dco, rfac, diso, erro, poly, ions, powd i orga svi su isključeni. Pretraga zato nije zahtevala punu 3D strukturu, maksimalni R, odsustvo disorder-a/error-a, nepolimernost, određeni ionski/powder status ili organic/organometallic klasu.

Granica forenzičke rekonstrukcije

Ova rekonstrukcija je forenzičko čitanje sačuvanog objekta. Jača tvrdnja o originalnoj ljudskoj nameri zahtevala bi nezavisnu vizuelnu proveru u kompatibilnom, licenciranom ConQuest okruženju i stručnu potvrdu; ovaj dokument ne propisuje postupak te buduće provere.

17.5 CSD snapshot iz 2022. naspram datuma pretrage iz 2026.

.cqs navodi ConQuest verziju 2022.2.0 i tri izabrana CSD segmenta:

Segment	Broj entry-ja kodiran u CQS-u
osnovni CSD 5.43, novembar 2021.	1.161.919
mart 2022. update	19.425
jun 2022. update	15.998
ukupno izabrano	1.197.342

Lokalne putanje/timestamp vrednosti u sačuvanom objektu nose trag pokretanja ili čuvanja pretraga 6. juna 2026. oko 18:49 i 18:53; vremenska zona i tačna semantika događaja nisu zabeležene. Otkrivena lokalna korisnička putanja namerno je redigovana u ovoj knjizi.

Ovo daje dve različite vremenske ose:

data cutoff: najkasnije CSD June 2022 update
search/save event: tragovi iz June 2026
local audit: August 2026; ponovljena provera agregata September 2026

Pretraga pokrenuta 2026. nad instalacijom iz 2022. **nije CSD snapshot iz 2026.** Raspon publication year-a lokalnih rezultata 1967–2022 dodatno je konzistentan sa starim cutoff-om.

Pouka za provenance: release baze, verzija query alata, vreme pokretanja pretrage, vreme eksporta i vreme kasnije analize predstavljaju različite događaje. Njihovo stapanje u jednu oznaku „datum skupa“ napravilo bi ozbiljnu provenance grešku i pokvarilo temporalnu evaluaciju. Ovo je semantički zahtev, ne predlog naziva polja.

17.6 Bezbednosni i provenance status `.cqs` artefakta

Lokalna inspekcija oba `.cqs` fajla pokazuje binarni Berkeley DB sadržaj sa Python pickle tokovima i lokalnim putanjama. Pickle deserializacija može izvršiti kod, pa poreklo fajla nije dokaz bezbednosti; CQS može sadržati i tragove o korisniku i lokalnom okruženju. Ovaj nalaz pripada provenance-u dostavljenih upita, ne hemijskoj semantici niti ulaznom formatu budućih aplikacija.

17.7 Šta svaki CSD izvozni format čuva i gubi

CIF eksport

Lokalni multi-block CSD CIF ima 51 jedinstven tag. Dobar je za:

- refcode i entry metadata;
- formula, godina, CCDC deposition number kada postoji;
- ćeliju, crystal system i space group;
- frakcione koordinate kada postoji 3D model;
- pojedine quality/descriptive fields.

Ali ovaj **pojednostavljeni CSD CIF eksport** nema bond loop, occupancy niti ADP podatke. Atom-site petlja sadrži label, element i frakcione koordinate; CSD poluprečnici su u odvojenoj atom-type petlji (`_atom_type_symbol`, `_atom_type_radius_bond`). Zato ne treba iz njega očekivati isti nivo kao iz originalnog publication/deposition CIF-a niti samostalno smatrati graf eksplicitno zadatim.

Pretraga	Svi CIF blokovi	Sa atom loop-om/koordinatama	Bez njih
search1	2.110	2.023	87
search2	2.038	1.954	84

MOL2 eksport

Tripos MOL2 čuva Cartesian koordinate, atom types, bond records, substructures i često `CRYSIN`. Ipak:

- sam eksport upozorava da atom types treba proveriti;
- metal–ligand order i `un`/unknown tipovi su reprezentacione konvencije;
- charge model je `NO_CHARGES` za 1.232 i `USER_CHARGES` za 806 `search2` record-a;
- integer-like atom charges se javljaju od –2 do +3, a 192 coordinate-bearing record-a imaju nenulti zbir, ali to nisu automatski oksidaciona stanja;
- `Du` dummy atomi označavaju suppressed/disorder alternative i zahtevaju posebnu obradu.

MOL2 mera	search1	search2
ukupno atoma, uključujući Du	225.185	220.031
Du atoma	7.998	7.805
atoma bez Du	217.187	212.226
bond records	232.486	227.384

U search2 se 7.805 Du atoma javlja u 627 record-a, uglavnom u SUP* substructure grupama. Oni nisu običan novi hemijski element.

SDF/SD eksport

SDF koristi MDL V2000 fixed-width counts i bond records. Parser mora čitati kolone, ne samo split() :

```
121150 ...
```

može značiti 121 atom i 150 veza, a ne jedan broj 121150. Formalni naboji mogu biti u M CHG linijama.

U search2 bond kodovi u strukturama su:

Kod/tip	Broj
single	164.839
aromatic	47.822
double	11.187
triple	2.227
any	1.308

SDF sadrži 212.226 atoma — tačno MOL2 broj bez Du — i 227.383 veze. Jedna MOL2 veza dodiruje Du, pa je nema u SDF-u.

Svih 2.038 search2 SD record-a ima status komentar:

- 1.778: No disordered atoms;
- 176: Matching problem. No disordered atoms;
- 84: Matching problem. Disorder unknown.

Poslednjih 84 odgovara record-ima bez upotrebljivog koordinatnog modela. Status nije dekoracija; ulazi u data quality i abstention logiku.

SMILES eksport

.smi je po jedan red SMILES<TAB>refcode. Čuva 2D connectivity/stereo/charge onoliko koliko ih zapis kodira, ali ne čuva ćeliju, packing, eksperimentalni kvalitet ni 3D kristalne koordinate.

Mera	search1	search2
svi entry-ji	2.110	2.038
SMILES dostupni	1.877	1.805
nedostaju	233	233
exact unique SMILES	1.722	1.661
redundantni redovi	155	144

Istih 233 zajednička metal-containing entry-ja nedostaje u oba SMILES izvoza; svih 72 metal-free članova razlike imaju SMILES. Nedostajanje zato ima obrazac povezan sa sastavom i izvozom, pa se ne sme bez provere pretpostaviti da je potpuno slučajno. To samo po sebi ne određuje formalni MCAR/MAR/MNAR mehanizam. U `search2` ono pogađa oko 11,4% entry-ja, uz zastupljenost složenijih Mn/Fe/Co/Ni zapisa.

Od 1.805 dostupnih `search2` SMILES-a:

- 1.306 ima više komponenti razdvojenih tačkom, oko 72,4%;
- 769 sadrži eksplicitne znakove naboja;
- broj komponenti ide do 5;
- najduži SMILES string ima 1.114 karaktera; ceo red sa tabulatorom i refcode-om ima 1.121 karakter bez završetka reda.

SMILES-only model bi zato trenirao nad selektovanim podskupom i izgubio deo metalnih zapisa relevantnih za projekat. Da li su preostali primeri za određeni ML zadatak lakši mora se posebno ispitati; to ne sledi samo iz dostupnosti izvoza.

17.8 N14: jedan identitet, tri vrlo nejednake reprezentacije

`cu_n14_a.cif` je jedan bogat eksperimentalni CIF, a ne CSD multi-entry eksport.

Šta CIF direktno navodi

Osobina	Vrednost
formula	C25 H20 N3 O2 P
formula mass	425,41
temperatura	100 K
space group	P 21/c , broj 14
ćelija	a=12,7138 , b=15,3951 , c=10,6106 Å; α=90 , β=93,235 , γ=90°
volumen / Z	2.073,51 Å³ / 4
calculated density	1,363 g cm ⁻³
talasna dužina	1,54178 Å, Cu Kα
refleksije	87.254 measured; 4.237 unique; 3.891 I>2σ(I)
refinement	R1(gt)=0,0322; R1(all)=0,0347; wR2(gt)=0,0820; wR2(ref)=0,0838; GoF 1,095
model	284 parametra; 0 restraints; completeness 1,000
residual density	+0,327 / -0,349 e Å ⁻³

Nezavisna provera ćelije, Z i formula mass daje gustinu približno 1,36273 g cm⁻³, konzistentnu sa CIF vrednošću.

Fajl sadrži 51 atom site (C25 H20 N3 O2 P), 31 anisotropic records, 54 eksplicitne veze, 85 uglova i 59 torzija. Ugrađuje i oko 170 linija SHELX RES sadržaja i 89.111 HKL linija; zato ima oko 2,7 MB iako je molekul mali.

Dve opasne pretpostavke iz imena

`cu_` u imenu nije dokaz prisustva bakra: formula nema Cu; ovde je konzistentno sa Cu Kα zračenjem. N14 je sample/file label, ne dokaz izotopa azot-14. Hemiju čitaj iz sadržaja, a ime čuvaj samo kao provenance.

Šta su MOL i MOL2 izgubili

Osobina	N14.mol	N14.mol2	bogati CIF
atomi / veze	51 / 54	51 / 54	51 site / 54 bond records
bond tipovi	svih 54 single	34 single + 20 un	distance/geometrija i hemijski kontekst
charges	nema	svi 0	širi eksperimentalni/strukturni kontekst
crystal data	nema	CRYGIN	puna ćelija, simetrija i refinement
RES/HKL	nema	nema	prisutni

MOL zato ne prenosi očiglednu iminsku/aromatičnu/nitro bond-order hemiju. MOL2 otvoreno ostavlja 20 veza kao un . To je loss, ne kontradikcija da je realni molekul „samo single-bonded“.

Strukturne distance u CIF-u podržavaju razumnu hemiju: P–C 1,841–1,853 Å uz trigonalno-piramidalni P(III) centar; nitro N–O 1,2272/1,2274 Å; hydrazone-like C=N 1,2825 Å i N–N 1,3608 Å. Ove tvrdnje se ne bi smele rekonstruisati iz V2000 bond orders ovog konkretnog MOL fajla.

Pouka za parsiranje: cu_n14_a.cif pokazuje da mali koordinatni model može biti upakovan sa višemegabajtnim semicolon-delimited HKL blokom. Resource-bounded čitanje i razlikovanje refleksionog teksta od hemijskih reprezentacija zato su bezbednosno i naučno važni; ova činjenica ne propisuje parser arhitekturu niti konkretan fixture.

17.9 Profil search2 metadata i kvaliteta

Pokrivenost polja

Polje	Dostupno / 2.038
formula, parametri ćelije, godina	2.038
H–M oznaka prostorne grupe	2.035
atom koordinate	1.954
R factor	2.023
CCDC deposition number	1.838
density	1.927
crystal colour	1.796
description	1.618
preparation text	290
common name	50

?, ., odsutno polje i broj nula moraju ostati različita stanja. Tri zapisa nemaju poznatu H–M oznaku grupe, iako postoje parametri ćelije; potrebno je proveriti ostale simetrijske podatke pre periodičnog poređenja. Na primer, common name nedostaje za ogromnu većinu; to nije prazan string koji model sme da tumači kao hemijsku osobinu.

R faktori

- medijana lokalnog R: 0,0512 (zaokruženo 0,051);
- maksimum: 0,1711;

- 71 zapisa ima $R > 0,10$;
- 15 nema R.

U svih 2.023 record-a u kojima postoje oba polja, `_refine_ls_wR_factor_gt` je tačno jednak `_refine_ls_R_factor_gt`. Izvoz uz ta polja izričito navodi da su obe vrednosti dobijene iz jednog CSD polja; taj komentar se javlja 2.023 puta. Ovo je dokaz dupliranog izvoznog mapiranja, pa ta polja nisu dva nezavisna pokazatelja kvaliteta. Stvarni ponderisani R ne može se rekonstruisati iz njihove jednakosti: zahteva izvorni eksperimentalni/refinement zapis ili drugi pouzdan podatak.

Godine publikovanja u lokalnom `search2` idu od 1967. do 2022, sa medijanom 2012. To je istorijska raspodela ovog query subset-a, a ne ravnomeran temporalni uzorak.

Raw cell-setting etikete i space groups

Raw <code>_symmetry_cell_setting</code> vrednost	Broj
monoclinic	1.232
triclinic	491
orthorhombic	264
tetragonal	26
rhombohedral	12
hexagonal	12
cubic	1

Ovo su doslovne etikete pojednostavljenog eksporta, a ne već završena standardizovana taksonomija. Vrednost `rhombohedral` treba pri normalizaciji mapirati u **trigonalni kristalni sistem**, uz čuvanje raw vrednosti i rhombohedral setting-a kao odvojenih provenance polja.

Najčešći space groups su `P-1` (480), `P21/c` (473), `P21/n` (368) i `C2/c` (228). Ovo opisuje DAP+metal query subset, ne baznu verovatnoću svih CSD struktura.

Formule i elementi

Sve formule imaju C, H i N zbog query motiva. Najčešći dodatni elementi uključuju:

Element	Entry-ja u čijoj se formuli javlja
O	1.404
Cl	930
Fe	511
Co	273
Mn	242
Ni	148
Zn	133
Cu	123
Cr	83
Mo	68
Ru	60
Cd	54

Element	Entry-ja u čijoj se formuli javlja
Dy	52
Sn	51
U	44

Brojevi se preklapaju: jedan entry može sadržati više elemenata, a 264 entry-ja imaju više od jednog različitog metalnog elementa. `metal=Fe` nije jednaka kategorija `only metal=Fe`.

Čak 250 `search2` formula ima fractional stoichiometry, na primer `08.33` ili `Mn0.5`. Formula parser mora koristiti decimalne koeficijente; pretvaranje u `int` ili brojanje tekstualnih simbola daje pogrešan sastav.

17.10 Profil molekulskog/koordinacionog grafa

U 1.954 coordinate-bearing `search2` record-a:

- ima 4.070 eksplicitnih 4M centara nakon isključivanja `Du`; izbor elemenata prati ConQuest legacy grupu `4M`, uključujući Ge i Sb;
- median broja non-`Du` atoma po record-u je 92, prosek 108,61, maksimum 646;
- median broja povezanih komponenti je 2, prosek 2,93, maksimum 36;
- 1.425/1.954, odnosno 72,9%, ima više od jedne povezane komponente;
- 6 record-a nema nijednu metal-N ivicu;
- 35 nema metal sa najmanje tri N suseda;
- 1.919 ima neki metal sa najmanje tri N suseda, ali to još ne mapira te N na ciljni DAP podgraf.

Najčešće kompletne metal-neighbor signature uključuju `W-06` (198 centara), `Fe-C12N3` (152), `Mn-N7` (89), `Co-C12N3` (89), `Ni-N6` (71), `Mn-N5O2` (68), `Co-N5O2` (58), `Zn-C12N3` (35) i `Cu-N4O1` (35).

Ove signature su korisne kao features, ali imaju tri caveat-a:

1. izvedene su iz eksportovanog grafa, ne nužno iz punog symmetry-expanded kristala;
2. ne govore koji N pripada DAP motivu bez atom mapping-a;
3. isti CN/signature može imati različitu 3D geometriju.

17.11 Selection bias: šta ovaj skup sistematski favorizuje

Ovaj skup je **query-conditioned convenience snapshot**, ne slučajan uzorak CSD-a:

1. svaki entry mora imati usko 18-atomsko 2,6-diacetilpiridinsko query jezgro sa dve `C=N` veze;
2. `search2` dodatno bira metal presence, ne validiranu DAP koordinaciju;
3. svi standardni quality/disorder/polymer/ion/3D filteri bili su isključeni;
4. snapshot prestaje sa June 2022 update-om i ne predstavlja kasnije deponovane strukture;
5. metal distribution je snažno skewed ka određenim istraživačkim i sintetičkim serijama;
6. multi-component kristali dominiraju coordinate-bearing delu;
7. nema reprezentativnog skupa molekula van DAP motiva;
8. query membership ne sadrži similarity score, relevance order niti expert label.

Ne može se pošteno trenirati „univerzalna hemijska sličnost“ tako što se `search1=positive`, a ostatak sveta proglasi negativnim. Isto tako, `search2=complex` bi unelo label noise dokumentovan kontraprimerima.

17.12 Dokazi ne podržavaju nekritičku MCAR pretpostavku

Nedostajuće reprezentacije pokazuju obrasce povezane sa procesom izvoza i složenošću strukture. Bez formalnog statističkog testa ne tvrdimo da je mehanizam missingness-a potpuno određen, ali sledeći dokazi ne podržavaju nekritičku pretpostavku *missing completely at random* (MCAR):

- 84 `search2` entry-ja nema koordinatni/atomski model u ovim izvozima;
- 233 nema SMILES, i to su isti metal-containing zapisi koji nedostaju i u `search1`;
- SMILES missing grupa je obogaćena većim i složenijim Mn/Fe/Co/Ni strukturama;
- deposition number nedostaje u 200, density u 111, description u 420, preparation tekst u 1.748;
- `Du/suppressed disorder` postoji u stotinama record-a;
- 176 SD record-a ima matching problem iako status kaže „No disordered atoms“, a 84 matching problem uz unknown disorder.

Za tumačenje missingness-a treba razlikovati poznatu vrednost, odsustvo podatka, nepoznato, neprimenljivo i neuspeh parsiranja, kao i poreklo, način izvođenja i kvalitet nalaza. To su različite semantičke kategorije, ne predlog konkretne data schema-e.

Model se evaluira po missingness slice-ovima. „Drop rows with missing SMILES“ nije neutralno čišćenje: menja hemijsku populaciju.

17.13 Duplikati, refcode porodice i leakage

Exact SMILES duplikati

U `search2` postoji 1.805 SMILES redova, ali samo 1.661 exact string vrednosti. Najveći exact cluster ima 36 entry-ja: `ORIFON`, `ORIGII` i `ORIGII01–ORIGII34`. `FAVKIA` porodica ima šest exact-identičnih SMILES zapisa.

Isti 2D molekul može zato predstavljati više kristalogrfskih određivanja, temperatura, polimorfa, solvata ili redeterminations. Za crystal/packing zadatak to mogu biti legitimno različiti target-i; za 2D ligand retrieval mogu biti gotovo duplikati.

Refcode porodice

Minimalna CSD family heuristika koristi prvih šest slova refcode-a. Lokalno:

Mera	search1	search2
base-refcode porodice	1.960	1.899
suffixed refcode-ovi	170	159
porodice sa više članova	97	89

Samo split po punom refcode string-u dopušta da, na primer, `ORIGII01` završi u train-u, a `ORIGII22` u test-u. Model tada može memorisati ligand/seriju i dati lažno visok rezultat.

Minimalna split politika

1. grupiši najmanje po base refcode-u;
2. dodatno grupiši exact canonical graph/SMILES identitete;
3. za ozbiljnu generalizaciju grupiši po scaffold/chemical family i, kada je cilj packing, jasno odluči da li polymorph/solvate parovi moraju ostati zajedno ili su namerni challenge parovi;
4. pravi temporalni split po **database release/deposition vremenu**, ne po datumu kada je stari snapshot pretražen;

5. deduplikuj pre podele i fituj sve learned preprocessing korake samo na train-u;
6. objavi koliko je porodica, ne samo koliko record-a, u svakom split-u.

Base refcode nije dovoljan

Exact-identičan SMILES cluster može da pređe granicu dve različite base-refcode porodice, kao `ORIFON` naspram `ORIGII...`. Zato je base refcode minimalna, ne konačna zaštita od leakage-a.

17.14 Šta lokalna forenzika znači za naučni dizajn

Ulaz i reprezentacije

Lokalni fajlovi pokazuju da ulaz može biti velik, multi-block, sadržati duga tekstualna polja, različite missing oznake, neizvesnosti i frakcije koordinate van osnovnog intervala. Entry, crystal, komponente i koordinacioni graf nisu isti objekat, a lossy reprezentacija ne može bez upozorenja zameniti bogatiji izvor. Poravnanje formata po refcode-u mora očuvati i vidljivost nedostajućih reprezentacija. Ovo su naučni zahtevi za značenje ingest-a, ne izbor parsera, storage slojeva ili izvršnog toka.

Aplikacija 1: globalna pretraga

Lokalni izvozi nisu globalni CSD corpus i ne mogu dokazati performanse nad punom bazom. `search1/2` opisuju DAP-uslovljen slice, a 233 od 2.038 metal-containing zapisa nemaju SMILES. Zato 2D scaffold, prisustvo metala, potvrđena koordinacija i crystal similarity ostaju različite ose, dok rezultat mora biti tumačen uz release, mapping, score komponente, missingness, kvalitet i licencni scope. Poglavlje ne bira indeks, fallback ili način prikaza.

Aplikacija 2: svi parovi

Za n ulaza postoji $n(n-1)/2$ neuređenih parova, ali nijedan pair score nema smisla bez izabranog nivoa: ligand, coordination entity, conformer ili crystal packing. N14 pokazuje da različiti eksporti iste strukture mogu imati različite bond-order informacije. Packing claim nema dovoljan dokaz bez ćelije, simetrije i 3D podataka, dok atom mapping mora biti neosetljiv na fizički ekvivalentne promene zapisa. Tumačenje para zato zavisi od porekla reprezentacija, mapping-a, obima dokaza i razloga za neocenjen rezultat, bez propisivanja result schema-e.

Ground truth

Stručna anotacija može razdvojiti valjanost motiva, scope prisustva metala, mapirane DAP donore i metal-donor veze, opaženi denticitet i geometriju, uloge komponenti, dovoljnost podataka, task-specific relevantnost i poreklo stručne odluke. To su dimenzije ground truth-a, ne fiksna lista polja.

Članstvo u query rezultatu može biti candidate label, nikada automatski similarity rank ili konačna koordinaciona istina.

17.15 Pitanja za proveru reproduktivnosti zaključka

- Da li broj potiče iz originalnog izvora ili je izveden pod poznatim pravilima?
- Da li su CSD release, datum query-ja i datum analize pravilno razdvojeni?
- Da li forenzičko čitanje query objekta potvrđuje samo mašinsku semantiku ili i ljudsku nameru?
- Da li je CQS analiziran bez izvršavanja nepoverljivog pickle sadržaja?
- Da li odnos `search2  $\subset$  search1` i redosled refcode-ova važe za tačno navedeni snapshot?
- Da li nedostajanje CIF/MOL2/SDF/SMI reprezentacije ostaje vidljivo po entry-ju?
- Da li su `Du`, matching problem, fractional formula i multi-component status uključeni u tumačenje?

- Da li split sprečava curenje refcode/hemijskih familija i poštuje vremenski claim?
- Da li statistika navodi parser/verziju, populaciju i denominator?
- Da li interpretativni i licencni zaključci imaju odgovarajući stručni ili ugovorni dokaz?

17.16 Mini-vežbe

1. Dva datuma

CQS je sačuvan 2026, ali bira CSD bazu i update segmente samo do juna 2022. Koji datum određuje data coverage?

Odgovor

June 2022 release/update cutoff. Datum pretrage 2026 govori kada je stari snapshot upitan, ne da uključuje strukture deponovane do 2026.

2. Broj pogodaka

Zašto `search2` ima 2.038 record-a, ali samo 1.954 coordinate-bearing strukture?

Odgovor

Query nije zahtevao 3D. Osamdeset četiri entry-ja imaju record/metadata i matching/disorder status, ali nemaju upotrebljiv atomski koordinatni model u eksportu.

3. Razlika pretraga

Šta tačno predstavlja 72 člana `search1 \ search2`?

Odgovor

DAP-motif entry-je bez metala prema 4M composition kriterijumu. To nisu svi „slobodni ligandi u hemijskom univerzumu“, već metal-free članovi ovog konkretnog query snapshot-a.

4. SMILES čišćenje

Data scientist odbacuje svih 233 `search2` entry-ja bez SMILES i kaže da je to nasumičnih 11,4%. Zašto je zaključak pogrešan?

Odgovor

Nedostajanje je isto u obe pretrage i koncentrisano u većim/složenijim metalnim zapisima, naročito Mn/Fe/Co/Ni. Complete-case skup menja ciljnu hemijsku distribuciju.

5. Refcode split

ORIGII01 je u train-u, ORIGII22 u test-u. Šta nije u redu?

Odgovor

Članovi iste refcode porodice i exact-SMILES klastera cure preko split-a. Grupisati najmanje po base refcode-u i hemijskom identitetu pre podele.

6. N14 ime

Da li `cu_n14_a.cif` dokazuje Cu kompleks sa izotopom ^{14}N ?

Odgovor

Ne. Formula nema Cu, `cu` je konzistentno sa Cu Ka zračenjem, a `N14` je label. Izotopski i elementarni identitet se ne izvode iz imena fajla.

7. Jedna formula, jedan CN?

CAPHEK formula ima Zn, četiri N i dva Cl. Zašto je koordinaciona signatura `N3C12`, a ne `N4C12`?

Odgovor

Formula obuhvata i odvojeni acetonitril i vodu. Samo tri ligandna N i dva Cl su neposredni susedi Zn; CN se određuje iz koordinacionog grafa/geometrije, ne iz ukupnog broja elemenata.

17.17 Kriterijum prolaza

Poglavlje si savladao kada možeš da reprodukuješ broj zapisa po formatu, nacrtáš stvarnu logiku oba query-ja, objasniš 2022/2026 provenance razliku, pokažeš najmanje tri izvora label leakage/bias-a i objasniš zašto nepoverljivi CQS i missingness zahtevaju različite bezbednosne i statističke provere.

Primarni i autoritativni izvori

- CCDC ConQuest User Guide and Tutorials — query atoms, element groups i search workflow
- CCDC Python API: substructure searching
- CCDC Python API: reading/writing molecules, crystals i podržani formati
- CCDC Python API: entry, crystal i molecule kao različiti objekti
- CCDC Python API: components, atoms i bonds
- CCDC Python API: disorder i entry metadata
- IUCr: Crystallographic Information Framework
- IUCr: CIF dictionaries
- Python dokumentacija: pickle bezbednosno upozorenje
- Oracle Berkeley DB Reference Guide
- CCDC CSD Portfolio Conditions of Use

18. Globalna pretraga: teorijski okvir

Cilj prve aplikacije: korisnik učitava jedan CIF, zadaje filtere i dobija rangirane, objašnjene CSD kandidate sa jasno navedenim nivoom sličnosti, kvalitetom i pravima pristupa.

Ovo nije „jedan embedding + vector DB“. Pouzdana pretraga je kaskada hemijskih i kristalografskih prikaza.

18.1 Značenje pre modela

Različita značenja pretrage mogu se razložiti kroz sledeća pitanja:

Pitanje	Primer mogućeg odgovora
objekat pretrage	glavni ligand / ceo coordination entity / puna crystal form
relevantnost	isti scaffold, sličan metal environment, sličan packing...
obavezne razlike	charge, stereo, metal, solid form, disorder
filter semantika	element u formuli vs koordinisan metal
evidence	matched subgraph, atom mapping, score components
granica zaključka	nema pouzdanog grafa; nema 3D; ambiguous disorder

Odvojena značenja sličnosti su naučno transparentnija od neobjašnjivog univerzalnog pojma „similar“. Ovo je semantičko razlaganje problema, a ne specifikacija korisničkog interfejsa.

18.2 Naučna dovoljnost ulaza

Pre pretrage mora biti jasno koji je CIF data block predmet analize; da li su formula, atom sites i komponente konzistentni; da li ćelija, simetrija, occupancy/disorder i dostupne koordinate podržavaju traženi nivo sličnosti; šta je direktno, izvedeno ili dodeljeno; i koje verzije i upozorenja ograničavaju zaključak. Veliki refleksioni ili tekstualni blokovi jesu deo izvora, ali nisu samim tim hemijska reprezentacija niti signal za ML sličnost.

18.3 Filter semantika

Filter „metal: Cu“ nema jedno značenje. Može označavati, na primer:

- Cu prisutan u punoj entry formuli;
- Cu u coordination entity;
- Cu direktno koordinisan ciljnom ligandu;
- Cu kao counterion/odvojena komponenta;
- exclude/include solvents and coformers;
- required/forbidden elements u parent graph-u ili punom sastavu;
- kriterijum kvaliteta, 3D dostupnosti, disorder-a ili temperature.

Objašnjiva pretraga zato mora razlikovati scope uslova i učinak svakog uslova na populaciju kandidata. To je zahtev za značenje rezultata, ne predlog konkretnog UI-ja.

18.4 Višeslojne reprezentacije

Sloj informacije	Primer sadržaja	Naučna uloga
provenance	refcode, release, hash, permission	identitet i audit
metadata	elementi, formula, components, quality flags	jeftini exact/range filteri
2D graph	fingerprint + substructure index	širok candidate recall
coordination	metal, donor set, CN/geometry features	complexes search
3D molecule	conformer/shape features	geometric rerank
crystal	standardizovana ćelija + packing/contact reprezentacija	solid-form search

Promena standardizacije ili feature pravila menja semantiku reprezentacije. Zato rezultat ima smisla samo uz poznatu verziju pravila, a score-ovi izvedeni pod nekompatibilnim pravilima ne treba da se tumače kao ista veličina.

18.5 Candidate generation i reranking

Jedna **ilustrativna, nenormativna** kaskada može sadržati sledeće uloge:

- ograničavanje dozvoljenog korpusa i exact metadata uslova;
- exact ili substructure proveru kada je ona deo pitanja;
- visok-recall candidate generation;
- preciznije graph, coordination, geometry ili packing poređenje kada su potrebni podaci dostupni;
- kalibraciju i objašnjenje rezultata.

Konkretan sistem može ove uloge organizovati drugačije. Bitna teorijska razlika je da jeftino generisanje kandidata, precizno poređenje i konačna procena relevantnosti nisu isti zadatak.

ANN candidate generation i konačni proizvod ne mere se istim recall-om:

- **ANN candidate recall@N prema exhaustive exact oracle-u iste reprezentacije i metrike** meri koliko kandidata iz referentnog skupa, dobijenog nad istim dozvoljenim korpusom, uz iste hard filtere i istu tie/self-match politiku, preživi aproksimativnu fazu. To je test gubitka infrastrukture; exact skup nije samim tim ekspertski ground truth relevantnosti.
- **End-to-end recall@k prema ekspertske relevantnosti** meri koliko ekspertske potvrđenih relevantnih zapisa završi u prvih k rezultata posle svih filtera, candidate generation-a i reranking-a. To je metrika naučnog/proizvodnog claim-a.

Za obe metrike unapred fiksirati N/k , korpus, denominator i postupanje sa upitima bez relevantnog zapisa. Brzina bez izmerene propuštenosti nije validacija, ali ni visok ANN candidate recall ne dokazuje da je konačni ranking hemijski relevantan.

18.6 Rezultat nije samo lista identifikatora

Stručna interpretacija jednog pogotka zahteva više vrsta konteksta: identitet i sastav, poreklo i dozvoljeni obim, značenje ranga, obim mapiranog grafa, koordinacioni i 3D dokaz kada je primenljiv, packing/interakcione signale, kvalitet ulaza i razloge zbog kojih je neki nivo ostao neocenjen. Ovo su kategorije dokaza, ne fiksna result schema.

Lokalni `dve funkcionalnosti.txt` traži i mogućnost preuzimanja CIF-a pogotka. Naučno i podatkovno mora biti jasno da li se preuzima originalni deponovani CIF ili pojednostavljeni/izvedeni eksport, iz koje verzije izvora i u kom dozvoljenom obimu. Rangirani pogodak ili dostupnost javnog metadata zapisa sami po sebi ne daju pravo

redistribucije njegovog CIF-a.

Score bez explanation-a ne omogućava stručnjaku da otkrije da je rezultat visok samo zbog velikog zajedničkog aromatičnog dela, a ključni metal environment različit.

18.7 Failure-aware ponašanje

Problem	Naučna posledica
nema ćelije/symmetry	2D zaključak može ostati moguć, ali packing nema potreban dokaz
nepoznate/un veze	fingerprint/MCS zavise od low-confidence grafa
više komponenti	claim zavisi od izbora komponente i full-crystal konteksta
disorder	alternative i occupancies nisu skup nezavisnih punih atoma
nepoznata stereo	nema dokaza za exact poklapanje definisane stereokemije
metal connectivity ambiguous	postoji kandidat ili neodređenost, ne potvrđen coordinated match
out-of-license rezultat	licenca ograničava koji dokaz i sadržaj sme biti vidljiv

18.8 Skaliranje, verzije i poreklo

Na velikom korpusu originalni izvori, standardizovani prikazi, numeričke reprezentacije i indeksi nemaju isti epistemološki status. Indeks je izvedena i potencijalno zastarela projekcija, ne izvor istine. Promena baze, standardizacije ili metrike može promeniti skup kandidata i rang, pa poređenje rezultata zahteva poznato poreklo i kompatibilne verzije. Licencna ograničenja pritom važe i za izvedene reprezentacije i izlaze, ne samo za originalni CIF.

18.9 Provera znanja

1. Zašto vector database nije source of truth?
2. Šta znači Cu filter na četiri različita nivoa?
3. Kada se packing reranker mora preskočiti?
4. Kako meriš kvalitet ANN candidate generation-a?
5. Zašto svaki indeks ima representation version?

Odgovori

1. Sadrži izvedene, verzionisane i potencijalno lossy features; original/provenance žive drugde.
2. Prisustvo u entry formuli, u entity-ju, direktna koordinacija ligandu ili odvojena komponenta/counterion.
3. Kada nema validne ćelije/symmetry/3D ili je quality/representation nedovoljna.
4. Recall-om prema exhaustive exact oracle-u iste reprezentacije, metrike, korpusa, hard filtera i tie/self-match politike, ukupno i po slice-ovima.
5. Promena hemijskog modela/parametara menja features i score semantiku.

Kriterijum prolaza: možeš da odbraniš značenje ulaza, filtera, candidate-generation-a, preciznog poređenja i konačne relevantnosti pred hemičarem, kristalografom, ML inženjerom i licencnim vlasnikom.

19. Precizno poređenje parova

Cilj druge aplikacije: za učitani skup CIF-ova obraditi svaki neuređeni par i vratiti rastavljiv, stručno proverljiv izveštaj — ne samo matricu neobjašnjenih brojeva. Kada ulazi ne omogućavaju određeno poređenje, taj par ostaje u obuhvatu sa jasnim razlogom neocenjenog nivoa. Manji korpus omogućava više računskog vremena po paru, ali sam po sebi ne dokazuje veću naučnu tačnost od globalne pretrage; to se proverava evaluacijom.

19.1 Prvo definiši jedinicu poređenja

Jedan upload može sadržati:

- jedan hemijski molekul;
- coordination entity i counterions;
- solvate/hydrate/co-crystal;
- više independent molecules u asymmetric unit;
- disorder alternatives;
- polymeric coordination network.

Pre bilo kakvog score-a mora biti jasno koje se komponente porede, da li je objekat ligand, ceo entity ili crystal i koji nivoi imaju dovoljno podataka u oba zapisa. Ovde je **comparison plan** naziv za tu semantičku odluku, ne specifikacija softverskog objekta.

19.2 Kvadratna složenost

Za n izabranih ulaznih strukturnih zapisa broj neuređenih parova je:

$$N_{pairs} = \frac{n(n-1)}{2}.$$


Ovde se broje zapisi izabrani za poređenje, a ne broj jedinstvenih molekulskih grafova. Dva određivanja istog jedinjenja mogu biti dva legitimna ulaza. Ako CIF ima više data blokova, najpre razjasni koji blokovi predstavljaju ulaze, pa tek onda odredi n ; deduplikacija ne sme neopaženo smanjiti obećani obuhvat „svih parova“.

n	parova
10	45
100	4.950
1.000	499.500
2.110	2.224.995

Kvadratni rast objašnjava nekoliko opštih principa skaliranja: veličine koje zavise samo od jedne strukture mogu se ponovo koristiti, simetrično poređenje ne treba računati u oba smera bez naučnog razloga, a exhaustive all-pairs analiza nije isto što i candidate-pruned aproksimacija. Ako se koristi aproksimacija, njena propuštenost mora biti merena; način izvršavanja i skladištenja nije deo ovog teorijskog poglavlja.

19.3 Pair pipeline

Sledeći dijagram je **nenormativna ilustracija** zavisnosti između vrsta poređenja, a ne propis redosleda ili komponenti konkretnog sistema.



Pojedina grana može dati validno merenje, ostati neodređena, biti neprimenljiva, nemati potreban ulaz ili ne uspeti. Te situacije imaju različito značenje i ne smeju se sve pretvoriti u score nula.

19.4 Component mapping

Pre atom mapping-a rešava se problem komponenti:

1. classify components bez brisanja originala;
2. generiši candidate pairings po sastavu/grafu/ulozi;
3. pronađi globalno konzistentno uparivanje komponenti;
4. prijavlji unmatched solvents, counterions i coformers;
5. odvojeno izračunaj parent i full-composition poređenje.

„Uporedi samo najveći fragment“ je neprihvatljiv default za metalne komplekse i solid forms.

19.5 Molekulski graf i atom mapping

Za tumačenje graph poređenja relevantni su:

- exact/substructure/MCS status;
- broj i procenat mapiranih heavy atoms;
- mapirane atom pairs;
- unmatched atoms/bonds i funkcionalne grupe;
- charge, stereo i tautomer policy;
- multiple equivalent mappings i chosen-tie-breaker;
- confidence ako bond typing nije pouzdan.

Za DAP use case posebno se mapiraju centralni pyridine N, dva terminalna N atoma u C=N granama i scaffold atoms, pa tek zatim terminalni supstituenti.

19.6 Koordinaciono okruženje

Za svaki relevantni metal naučno poređenje razmatra:

- element i formal/oxidation-state evidence;
- koordinacioni broj pod eksplicitnim neighbor modelom;
- donor atom elements/types i ligand membership;
- denticity/bridging/hapticity flags;
- ideal geometry candidates i distortion measure;
- M–donor distances i ključni angles;
- da li mapirani DAP donors stvarno koordiniraju isti metal.

Ne koristi jedan globalni distance cutoff za sve elemente i oxidation states. Nejasan connectivity rezultat ostaje ambiguous i ide na human review.

19.7 Konformaciono/3D poređenje

Za svaki validni common core važno je razmotriti:

- alignment policy;
- RMSD i maksimalno odstupanje;
- coverage $N_{\text{mapped}}/N_{\text{eligible}}$;
- ključne torsion razlike;
- symmetry-equivalent atom handling;
- mirror/stereo status;
- experimental vs generated coordinate provenance.

Visok coverage sa umerenim RMSD često je informativniji od veoma niskog RMSD nad tri atoma.

19.8 Cell i packing nisu isto

Cell grana može porediti:

- crystal system/space-group type;
- standardized/reduced lattice parameters;

- volume per formula unit;
- density i temperature.

Packing poređenje se odnosi na periodični raspored mapiranih molekula/komponenti i zavisi od obima okruženja, tolerancija, broja poklopljenih molekula i geometrijskog odstupanja. Slična reduced cell je candidate signal, ne packing proof.

19.9 Interakcije

Periodični contact networks omogućavaju poređenje:

- H-bond donor/acceptor pairs i geometriju;
- halogen/ π i druge definisane kontakte;
- coordination links;
- chain/ring/network motifs;
- solvent-mediated veze;
- coverage i uncertainty zbog H/disorder-a.

Tumačenje interakcionog rezultata zavisi od definicije kontakta i korišćenih geometrijskih parametara.

19.10 Zašto rezultat mora ostati rastavljiv

Razmotrimo nenormativan primer: dva zapisa mogu imati visok 2D graph score i dobro mapiran common core, ali različite komponente, neodređenu metalnu povezanost i nedostupno packing poređenje zato što jedan zapis nema validnu ćeliju. Jedan ukupni broj bi sakrio upravo razliku koju stručnjak treba da vidi. U takvom slučaju je naučno tačnije reći da pojedini nivoi nisu ocenjeni nego izmišljati univerzalni overall score. Primer ilustruje semantiku parcijalnog rezultata, ne predlaže result schema-u.

19.11 Matrice i klasteri

Matrica ima smisla samo za jasno imenovanu metric component. Heatmap, hijerarhijsko klasterovanje ili mreža mogu pomoći istraživanju, ali njihovo značenje zavisi od definicije distance, linkage-a, threshold-a, missing vrednosti i populacije. Vizuelni obrazac nije zamena za atomski ili periodični dokaz pojedinačnog para.

Ne mešati `not comparable` sa numeričkom nulom: prvo znači da odgovor nije poznat/primenljiv, dok značenje nule zavisi od metrike. Kod binarnog Tanimota za neprazne fingerprinte $T = 0$ znači da nema zajedničkih uključenih bitova; kod RMSD-a 0 znači potpuno poklapanje mapiranih koordinata posle poravnanja. Uz svaku matricu zato navedi i da li veća ili manja vrednost označava bolje poklapanje.

19.12 Metamorphic i adversarial testovi

Ista struktura treba da ostane ista nakon:

- permutacije redosleda atoma/komponenti;
- rigidne rotacije/translacije;
- wrap-a preko cell boundary-ja;
- symmetry-equivalent ASU/origin izbora;
- ekvivalentnog $P2_1/c \leftrightarrow P2_1/n$ setting-a;
- invertibilne basis/conventional-cell promene;
- validnog različitog SMILES atom ordering-a.

Ove promene moraju očuvati **isti fizički periodični model**. Rotira se cela struktura zajedno sa ćelijom; kod promene bazisa ili početka dosledno se transformišu koordinate i simetrijske operacije. Za dva primitivna bazisa istu rešetku garantuje celobrojna transformacija sa determinantom ± 1 . Prelaz na ne-primitivnu konvencionalnu ćeliju dodatno zahteva odgovarajući broj i raspored ekvivalentnih atomskih mesta. Proizvoljno skaliranje ćelije ili rotacija samo atomskih koordinata nisu ekvivalentno prekodiranje kristala.

Namerno različiti testovi:

- isti ligand, drugi metal;
- isti metal/donor set, druga geometry;
- isti molekul, drugi polymorph;
- ista formula, drugi constitutional isomer;
- metal samo u counterion-u;
- solvent-mediated vs direct H-bond;
- disorder alternative i missing H.

19.13 Provera znanja

1. Zašto `not comparable` nije score 0?
2. Šta mora prethoditi RMSD-u?
3. Zašto se component mapping radi pre atom mapping-a?
4. Da li reduced-cell hit dokazuje isti packing?
5. Koja promena CIF encoding-a ne sme promeniti rezultat?

Odgovori

1. Nema validnog merenja; numerička nula ima značenje određene metrike, npr. RMSD 0 označava potpuno prostorno poklapanje mapiranih atoma.
2. Definisan common core/atom mapping, alignment i symmetry/H/stereo policy.
3. Inače se mogu mapirati solvent/counterion/nezavisni molekuli na pogrešne uloge.
4. Ne, samo generiše kandidata na lattice nivou.
5. Atom ordering, rigid transform, periodic wrap i ekvivalentni setting/origin/basis, u granicama definisanog zadatka.

Kriterijum prolaza: možeš za jedan par napraviti report u kome je svaka tvrdnja vezana za atomski/periodični evidence, algoritam, parametre i confidence.

20. Evaluacija i naučna validacija

Prioritet: MORAŠ. Model je validan tek kada je jasno koju naučnu tvrdnju test meri, ko je dao referentni odgovor i na kojim slučajevima sistem sme da kaže „ne znam“.

20.1 Počni od claim-a

Primer lošeg cilja:

Praviti AI koji nalazi slične kristale.

Primer proverljivog cilja:

Za query CIF sa pouzdano percipiranim ligandnim grafom, sistem vraća najmanje 95% ekspertske potvrđene DAP scaffold analogues u prvih 100 kandidata na held-out compound-family testu, uz dokumentovanu standardizaciju.

Drugi claim je ograničen, merljiv i navodi populaciju, task, metric i uslove važenja.

Proveri i matematičku ostvarivost cilja: ako upit ima R_q relevantnih zapisa, najveći mogući recall@100 iznosi $\min(100, R_q)/R_q$. Sa 200 relevantnih zapisa ni savršeno rangiranje ne može preći 50% recall@100. Primer sa 95% zato zahteva odgovarajuću populaciju i broj relevantnih zapisa; broj 95% ovde nije dokazana performansa niti projektni zahtev iz 2CDC.

20.2 Ground truth je višeslojna odluka

Jedan par može biti sličan na jednom, a različit na drugom nivou. Ekspertska odluka zato može razdvojiti dimenzije kao što su:

- composition/component identity;
- molecular graph/scaffold;
- DAP motif;
- metal direktno koordinisan DAP-u;
- donor set i coordination geometry;
- conformation;
- lattice/cell;
- whole-crystal packing;
- interaction network;
- task-specific relevantnost;
- sigurnost, obrazloženje i dokaz na kom se odluka zasniva.

Jedan binary `similar=true` skriva neslaganje i ne omogućava dijagnostiku.

20.3 Ekspertska anotacija

Sledeći redosled je obrazovni primer dobro kontrolisane anotacije, ne plan konkretnog produkcionog procesa:

1. napiši rubricu sa pozitivnim, negativnim i ambiguous primerima;
2. sakrij model score i identitet metode od anotatora;
3. najmanje dva stručna anotatora nezavisno pregledaju critical set;
4. meri agreement po label komponenti;
5. neslaganje ide na adjudication, ne na tiho majority preglasavanje;
6. čuvaj obrazloženje, atomski mapping/evidence i confidence;
7. verzioniši rubricu i reanotiraj slučajeve pogođene promenom definicije.

White paper i imena ConQuest upita nisu ground truth. Oni daju kontekst i candidate set; label zahteva operational definition.

20.4 Evaluation skup

Koristan evaluacioni skup obično kombinuje više vrsta slučajeva:

- **sanity/self pairs**: isti objekat i ekvivalentni encoding;
- **easy negatives**: potpuno različit sastav/graf;
- **hard negatives**: ista formula ili scaffold, ali drugi metal/geometry/packing;
- **near positives**: isto coordination okruženje uz supstituent/promenu setting-a;
- **edge cases**: salts, solvates, $Z' > 1$, disorder, missing H, unknown bonds, polymers;
- **out-of-scope**: records bez podataka potrebnih za claim;
- **future/temporal**: noviji CSD release ili publikacije, ako licenca dozvoli.

Lokalni `search1/search2` je koristan za DAP-focused stress test, ali nije dovoljan za globalnu validaciju.

20.5 Split bez curenja

Nasumičan record split može staviti povezane refcode redeterminations, istu compound family ili istu publikaciju u train i test. Biraj grupisanje prema claim-u:

Claim	Minimalna split jedinica
nov analog istog scaffold-a	compound/entry family
novi scaffold	scaffold family
nova crystal form	compound + solid-form family
buduća literatura	vreme/publication
druga institucija/lab	source/laboratory, gde je dostupno i dozvoljeno

Pre split-a radi dedup/family analysis nad podacima koji su dozvoljeni za taj postupak; ne koristi test labels za tuning.

Kod učenja iz parova nije dovoljno nasumično podeliti redove (A, B). Ako je (A, B) u treningu, a (A, C) u testu, model već poznaje strukturu A. Za claim o **novim strukturama ili familijama** najpre podeli osnovne strukture/familije, pa formiraj parove unutar odgovarajućih split-ova. Namerno testiranje novih kombinacija već poznatih struktura jeste drugi legitiman cilj, ali ga tako i nazovi. Milion parova nastalih od malog broja struktura ne predstavlja milion nezavisnih hemijskih opažanja.

20.6 Baselines pre ML-a

Svaki složeni model se poredi sa transparentnim baseline-ima:

- exact formula/element filter;
- exact/substructure graph search;
- Morgan/ECFP + Tanimoto;
- simple metal + donor-set rule;
- torsion/RMSD baseline na istom mapping-u;
- reduced-cell candidate search;
- licencirani CCDC packing similarity ili peer-reviewed reprodukovan baseline, gde je dozvoljeno.

Ako ML ne popravlja relevantnu metricu uz prihvatljivu cenu/objašnjivost, nije opravdan samo zato što je moderniji.

20.7 Metrike po proizvodu

Global search

- ANN candidate recall@N prema exhaustive exact oracle-u iste reprezentacije i metrike, nad istim korpusom, hard filterima i tie/self-match politikom — koliko je aproksimativna faza propustila pre reranking-a; ovo nije mera ekspertске relevantnosti;
- end-to-end recall@k prema ekspertski potvrđenoj relevantnosti — koliko relevantnih zapisa je u vrhu konačne liste;
- precision@k — koliko prikazanih je relevantno;
- MAP ili nDCG — kvalitet celog rangiranja;
- coverage/abstention rate;
- latency p50/p95 i index freshness;
- error rate po parse/representation statusu.

Za jedan upit sa $R_q > 0$ relevantnih zapisa u dozvoljenom korpusu, ako je među prvih k rezultata h_q relevantno, onda su $\text{recall}@k = h_q/R_q$ i, kada postoji k rangiranih mesta, $\text{precision}@k = h_q/k$. Na primer, 4 relevantna pogotka u prvih 10 uz ukupno 8 relevantnih daju recall 0,50 i precision 0,40. Ako se vraća manje od k rezultata, unapred odredi da li prazna mesta računaju kao promašaji ili koristiš imenilac broja vraćenih; te dve konvencije nisu ista metrika. Neocenjen kandidat nije automatski negativan: nepotpuna ekspertska anotacija ograničava i procenu ukupnog R_q , pa prijavi obuhvat anotacije.

Za count-based precision/recall prijavi **query-macro** i **pooled-micro** rezultat sa eksplicitnim brojiocem i imeniocem. MAP i nDCG prijavi kao prosek query-level vrednosti; svaki alternativni ponderisani agregat mora imati navedenu formulu i težine, a ne samo oznaku „micro“. Pre otvaranja test skupa definiši politiku za query bez ijednog relevantnog zapisa: recall je tada nedefinisan, pa takve upite ne pretvaraj proizvoljno u nulu ili jedinicu; prijavi njihov broj/udeo odvojeno i oceni false-positive ili abstention ponašanje. Denominator i politika moraju pratiti svaku tabelu rezultata.

Pair comparator

- agreement sa ekspertskim component labels;
- rank correlation kada eksperti daju poredak;
- classification precision/recall za validirane thresholds;
- calibration error i Brier score za **predikciju verovatnoće** ekspertске relevantnosti za precizno definisan claim; prethodna kalibracija nije uslov da se ove metrike izračunaju — njima se mogu oceniti i nekalibrisane

verovatnosne prognoze. Sirovi similarity score i input/evidence confidence nisu automatski verovatnoće;

- symmetry: $s(A, B) = s(B, A)$ gde metric to zahteva;
- invariance/metamorphic pass rate;
- coverage i razlog neuporedivosti;
- runtime/memory po pair kategoriji.

Clustering se ocenjuje tek nakon definisanja ciljnih grupa; lepa heatmap nije naučna validacija.

Za binarni ishod $y_i \in \{0, 1\}$ i predikciju $p_i = P(y_i = 1)$, uobičajeni binarni Brier score je $\frac{1}{m} \sum_{i=1}^m (p_i - y_i)^2$; manja vrednost je bolja. Ako sistem predvidi 0,8 za jedan stvarno relevantan par, doprinos je $(0,8 - 1)^2 = 0,04$. To ocenjuje verovatnosnu prognozu, a ne samo kalibraciju: na rezultat utiče i koliko model razlikuje relevantne od nerelevantnih slučajeva. Za proveru kalibracije zato posmatraj i slaganje predviđenih verovatnoća sa opaženim učestalostima, uz dovoljno nezavisnih primera (scikit-learn: [Brier score](#), [kalibracija verovatnoća](#)).

20.8 Slice analiza

Ukupni prosek može sakriti ozbiljnu grešku. Prijavi rezultate po:

- metal element/group i coordination number;
- metal-free vs metal-containing;
- single vs multi-component;
- salt/solvate/hydrate/co-crystal;
- ordered vs disordered;
- 3D complete vs incomplete;
- bond-perception confidence;
- molecule size/flexibility;
- space-group/crystal-system, bez pretvaranja kategorije u uzrok;
- data-quality bands i source period.

Missing SMILES/failed conversion je poseban slice, jer lokalni dokazi ne podržavaju nekritičku MCAR pretpostavku; uzrok missingness-a tek treba eksplicitno ispitati.

20.9 Calibration i abstention

Sistem treba da razlikuje:

- **similarity score** — vrednost određene metrike;
- **probability of expert relevance** — modelom iskazana procena verovatnoće za konkretan claim, čija se kalibracija posebno proverava;
- **confidence in input/representation** — kvalitet dokaza;
- **coverage** — deo objekta koji je uopšte poređen.

Visok fingerprint score uz unknown metal bonds može imati visok 2D score, ali nizak confidence za coordination claim. Ako ključno polje nedostaje, ispravan izlaz može biti `not assessed`.

Kalibrator i prag za abstention uče se na zasebnom **calibration skupu**, odvojenom od testa po istoj compound-family/grouping logici kao ostali split-ovi. Ako validation skup istovremeno služi za kalibraciju, to mora biti unapred navedeno i sve odluke se zamrzavaju pre jednokratne evaluacije na netaknutom testu.

Neizvesnost nikada ne prikazuje kao neoznačen broj `confidence`. Uz procenu navedi etiketu izvora i scope-a, na primer `input/representation uncertainty`, `model/finite-data uncertainty`, `calibration uncertainty` ili `out-of-domain`; interval dodatno označi nivoom, metodom i jedinicom uzorkovanja.

Za svaki abstention prag nacrtaj **coverage–risk krivu**: coverage je udeo slučajeva na koje sistem odgovara, a risk unapred definisana greška među tim odgovorima. Prag izaberi na calibration skupu, zatim na testu prijavi krivu i intervale poverenja ukupno i po kritičnim slice-ovima. Sama coverage bez greške zadržanih odgovora nije dokaz bezbednog abstention-a.

20.10 Uncertainty i ponovljivost

Objavljeni rezultat mora biti poveziv sa populacijom i verzijom podataka nad kojima je dobijen, granicom licence, pravilima standardizacije i reprezentacije, verzijom modela/metrike, stohastičkim uslovima i razlozima isključivanja. To su kategorije dokaza potrebne za ponavljanje i tumačenje rezultata, a ne propisana šema artefakata ili okruženja.

Uz svaki primarni rezultat obavezno prijavi **point estimate i unapred definisan interval poverenja**. Pre evaluacije zapiši nivo intervala, metod i nezavisnu jedinicu uzorkovanja. Bootstrap ne radi nad pojedinačnim hitovima ili parovima kada dele isti query ili hemijsku porodicu: resampluj na nivou nezavisnog query-ja, odnosno compound-family grupe koja odgovara claim-u, da korelisani primeri ne glume dodatni uzorak.

Za stohastičke modele/ANN indekse pokreni unapred određen skup ponovljenih seed-ova. Baseline i kandidat koriste iste split-ove i, gde je primenljivo, iste seed-ove; prijavi point estimate razlike i **paired delta** interval poverenja. Varijacija kroz seed-ove opisuje algoritamsku ponovljivost, ali se seed-ovi ne smeju tretirati kao nezavisni hemijski uzorci niti zamenjuju grouped bootstrap.

20.11 Ilustrativna evidencija tvrdnji

Sledeća tabela je nenormativan primer kako se činjenica odvaja od scope-a i dokaza; njene kolone nisu projektna schema.

Tvrdnja	Precizan scope	Dokaz/izvor	Lokalni test	Confidence	Datum/verzija	Izuzeci
4M je ConQuest grupa „svih metala“	softverska grupa uključuje i Ge/Sb	CCDC vodič	oba .cqs	high	query snapshot	ne dokazuje koordinaciju niti univerzalnu taksonomiju
search2 je podskup search1	lokalni export	refcode set diff	2038/2110	high	SHA-256 snapshot	samo dostavljeni fajlovi

Za interpretativni claim koristi dve nezavisne stručne potvrde gde je moguće. Za ponašanje CCDC alata i licence koristi zvanični, datirani izvor.

20.12 Koliko jak claim dokazi podržavaju

Spremnost za naučni claim nije jedna univerzalna kapija. Snaga tvrdnje zavisi od toga da li su populacija i prava poznati, reprezentacija hemijski proverena, poređenje izvedeno na nezavisnim podacima, intervali i kritični slice-ovi prijavljeni, a ograničenja i failure modes jasno opisani. Slabost bilo kog od tih dokaza sužava claim ili zahteva abstention; ovo nije release plan niti lista faza realizacije.

20.13 Provera znanja

1. Zašto nije dovoljan jedan binary similarity label?
2. Koji leakage nastaje ako redeterminations završe u train i test?
3. Zašto se retrieval meri recall@k, a ne samo accuracy?
4. Koja je razlika između score-a, probability i evidence confidence-a?

5. Kada model treba da abstain?

Odgovori

1. Meša različite naučne nivoe i skriva razlog/nesigurnost.
2. Model može prepoznati gotovo isti family record umesto da generalizuje.
3. Search ima rangiranu listu i mnogo neizabranih kandidata; accuracy ne meri da li su relevantni vraćeni u vrhu.
4. Metric similarity, kalibrisana relevantnost i pouzdanost ulaza/modela su odvojene veličine.
5. Kada claim nema potrebne podatke, representation je ambiguous/out-of-domain ili confidence ispod unapred definisanog praga.

Kriterijum prolaza: možeš da napišeš testable claim, formiraš leakage-safe evaluation i objasniš svaki exclusion, threshold i failure slice.

21. Licence, FAIR i poreklo podataka

Šta treba da umeš posle ovog poglavlja

Posle ovog poglavlja treba da možeš da:

- razdvojiš tehničku mogućnost pristupa od pravne/ugovorne dozvole za upotrebu;
- objasniš zašto raw CSD podaci i CSD-derived skupovi nisu deo ovog repoa;
- pokažeš zašto privatni GitHub repo nije automatsko rešenje licencnog problema;
- primeniš FAIR na podatke koji ostaju poverljivi i kontrolisano dostupni;
- objasniš koje vrste provenance dokaza povezuju izvor, transformaciju, model i rezultat;
- prepoznaš nevidljivi, tematski nepodudarni embedded PDF tekst kao ingest i provenance incident;
- objasniš licence-aware pitanja koja obe 2CDC aplikacije moraju da razjasne.

Granica ovog poglavlja

Ovo je inženjersko čitanje javno dostupnih uslova i principa, ne pravni savet. Merodavan je konkretan ugovor organizacije sa CCDC-om i pisano tumačenje vlasnika podataka.

Prvo pravilo: mogu da pročitam nije isto što i smem da koristim

Za svaki dataset postoje najmanje četiri odvojena pitanja:

1. **Pristup:** može li nalog ili proces tehnički da pročita podatak?
2. **Dozvoljena obrada:** sme li da pretražuje, transformiše, indeksira ili trenira model?
3. **Deljenje:** sme li raw ili izvedeni rezultat napustiti licenciranu organizaciju/lokaciju?
4. **Objavljivanje:** smeju li kod, statistika, embedding, model ili primer biti javni?

Dozvola za jedno ne povlači automatski ostala. Download dugme nije licenca za redistribuciju; API token nije dozvola za javni mirror; mogućnost računanja embedding-a nije dokaz da se embedding sme objaviti.

Šta javni CCDC uslovi zaista kažu

CCDC Conditions of Use za CSD Python API i CSD Portfolio navode, između ostalog, da:

- CSD Portfolio, njegovi programi, data files, baza i izvedeni podskupovi predstavljaju vlasničke komponente CCDC-a i njegovih licencora;
- upotreba zavisi od važećeg Licence of Access ili Products Licence and Support Agreement;
- komponente se tretiraju kao poverljive i ne redistribuiraju trećim licima u celini ili delovima;
- distribucija softvera ili podataka izvedenih iz ili razvijenih korišćenjem CSD Portfolio-a zahteva prethodno pisano odobrenje CCDC-a;
- naučni rezultati mogu biti objavljeni uz odgovarajuću citaciju i u granicama ugovora;
- zajednički akademsko-komercijalni projekti mogu zahtevati posebno odobrenje.

Merodavan je ugovor konkretne institucije, uz [CCDC informacije o standardnoj licenci](#). Javna [CCDC stranica o redistribuciji](#) potvrđuje da bulk deljenje izvornog CSD sadržaja izvan organizacije nije dozvoljeno standardnim pristupom i da za izvedene podatke ili modele treba proveriti konkretne ugovorne uslove. Javni izvori provereni su

5. septembra 2026; njihov sažetak ne utvrđuje koju licencu ima ovaj projekat.

Zašto CSD izvozi nisu u ovom repou

Originalni CSD izvozi nisu deo ovog obrazovnog repoa zato što dostupnost u licenciranom alatu ne daje automatski pravo kopiranja na drugog hosta ili redistribucije. Nastavni tekst može opisati agregate, metode i sintetičke primere, ali prihvatljivost svakog konkretnog raw ili izvedenog artefakta zavisi od ugovora, porekla i mogućnosti rekonstrukcije zaštićenog sadržaja. Ovo je objašnjenje sadašnjeg dokumentacionog scope-a, ne trajna allow/deny lista za budući razvoj.

Čak i private repo može predstavljati kopiju kod trećeg pružaoca usluge, imati širi krug naloga, backup-e i drugačiju geografsku lokaciju. „Private“ je kontrola pristupa, ne nova licenca.

Derived nije automatski slobodno

Embedding, fingerprint indeks, trenirani model, agregirane karakteristike ili eksportovani result set mogu biti izvedeni materijal. Da li se konkretan artefakt sme distribuirati zavisi od ugovora, mogućnosti rekonstrukcije, poslovne namene i pisanog odobrenja. Odsustvo jasne dozvole nije dokaz da je eksport dozvoljen.

Konceptualne granice odgovornosti

Za licencnu analizu korisno je razlikovati sledeće domene, bez pretpostavke kako će oni tehnički biti realizovani:

Domen	Sadržaj	Ključno pitanje
otvoreni kod i znanje	algoritmi, dokumentacija, sintetički primeri	šta se može zakonito deliti i ponoviti bez zaštićenih podataka?
licencirani podaci i derivati	CSD podaci, izvedene reprezentacije i licencirani alati	ko, gde i za koju namenu sme da ih koristi?
interni projektni podaci	interni CIF-ovi, svojstva i laboratorijski metadata	ko kontroliše poverljivost, obradu i rok čuvanja?
publikovani rezultat	odobrene metrike, slike, tabele ili modeli	da li izlaz otkriva ili rekonstruiše zaštićen sadržaj?

Granice među domenima određuju prava i značenje podataka; same po sebi ne propisuju servis, API, lokaciju skladišta ili deployment arhitekturu.

FAIR nije isto što i open

Originalni [FAIR Guiding Principles](#) znače:

Slovo	Princip	Konceptualna posledica
F - Findable	podatak i metadata imaju globalno jedinstven, trajan identitet i mogu se pronaći	identitet ne treba da zavisi od filename-a ili trenutne lokacije
A - Accessible	postoji standardizovan postupak pristupa	pristup može zahtevati autentikaciju i autorizaciju
I - Interoperable	koriste se formalni jezici, rečnici i kvalifikovane veze	značenje jedinica, relacija i termina mora biti deljivo
R - Reusable	značenje, poreklo, licence i domenski standardi su dovoljno bogati	ponovna upotreba zavisi od konteksta, kvaliteta i dozvole

Princip A1.2 eksplicitno dozvoljava autentikaciju i autorizaciju kada su potrebne. Zbog toga proprietary ili licencirani podatak može biti FAIR:

- metadata kaže da zapis postoji;
- identifikator je stabilan;
- uslovi pristupa su mašinski i ljudski razumljivi;
- ovlašćeni korisnik koristi standardni protokol;
- licenca i dozvoljene namene su eksplicitne;
- semantika i provenance ostaju dostupni u dozvoljenom obimu.

GO FAIR objašnjenje standardizovanog pristupa primenjuje isti princip na otvoren i ograničen pristup. Obrnuto takođe važi: fajl može biti javno dostupan, ali ne-FAIR ako nema stabilan identifikator, šemu, provenance, mašinski čitljivu licencu ili dosledne jedinice.

FAIR nije quality sertifikat

FAIR pomaže da se podatak pronađe, pristupi mu, poveže i ponovo upotrebi. Ne garantuje da je kristalografski model tačan, da je property dobro izmeren ili da ML skup nema bias. Quality i FAIR su povezani, ali različiti kontrolni slojevi.

Licenca je deo značenja upotrebe, ne fusnota

Procena dozvoljenosti zavisi od više od naziva licence. Potrebno je razumeti ko kontroliše izvor, koji ugovor je merodavan, na koje korisnike, lokacije i namene se odnosi, da li pokriva čitanje, transformaciju, trening, čuvanje, deljenje i publikovanje, kao i šta se dešava pri isteku ili opozivu. Ove dimenzije su pitanja pravnog i podatkovnog scope-a, ne predlog konkretne permission schema-e ili policy engine-a.

Opšti bezbednosni princip je konzervativan: nepoznata dozvola ne može se tumačiti kao pozitivna dozvola.

Provenance: dokazni lanac za svaki bajt i svaku tvrdnju

Provenance odgovara na pitanja:

- odakle je artefakt došao;
- ko ga je uneo i kada;
- koji ugovor/licenca važi;
- koji alat i verzija su ga parsirali;
- koje transformacije su izvršene;
- koji izlaz je nastao iz kojih ulaza;
- ko je pregledao alert ili izuzetak;
- da li se posledice opoziva ili isteka mogu pratiti kroz izvedene artefakte.

To zahteva identitet izvora, dokaz integriteta bajtova, vreme i poreklo prijema, vlasništvo i dozvolu, klasifikaciju poverljivosti, verzije alata i pravila, transformacioni lineage, status pregleda i veze ka roditeljskim artefaktima. Spisak opisuje kategorije dokaza; ne propisuje manifest, nazive polja ili storage model.

Hash dokazuje da je konkretan niz bajtova isti; ne dokazuje da je sadržaj tačan, vidljiv korisniku ili licencno dozvoljen.

Lokalni CIF kao provenance primer

cu_n14_a.cif sadrži mnogo korisnih provenance tragova:

- `_audit_creation_method SHELXL-2013`;
- APEX5 verziju za data collection;
- SAINT verziju za cell refinement i reduction;
- XT/SHELXT za structure solution;
- SHELXL-2013 za refinement;
- ugrađene `_shelx_res_file` i `_shelx_hkl_file` blokove.

Istovremeno, common name, melting point, diffraction source i deo publication metadata polja imaju nenavodnički token `?`, odnosno nepoznatu vrednost. Systematic-name polje sadrži znak `?` unutar višerednog tekstualnog polja: ljudski deluje kao placeholder, ali sintaksno je string, što parser i kasnija kuracija treba da razlikuju. Ni jedno ni drugo nije broj nula. Fajl zato nije samodovoljan dokaz o vlasništvu, dozvoli upotrebe, identitetu uzorka ili svim eksperimentalnim svojstvima.

Ugrađeni HKL podaci takođe znače da fajl sadrži više od atomskih koordinata. Pravilo eksportovanja „dozvoljen je CIF“ mora precizirati da li uključuje structure factors i refinement source.

Nevidljivi, tematski nepodudarni embedded PDF tekst: stvarni ingest incident

Vizuelni pregled CCDC white paper-a pokazuje naslov „Maximising the Impact of Proprietary Structural Data“. Međutim, standardna tekstualna ekstrakcija sa strana 1–2 vraća i nevidljivi, tematski nepodudarni embedded tekst:

Ultra-large docking. How to run ultra-large GOLD docking jobs on cloud resources.

Taj tekst se ne vidi na renderovanim stranama, a njegova tema se ne podudara sa vidljivim sadržajem dokumenta. Da je reč o zaostalom sloju ili šablonu PDF-a jeste **inferencija**, ne utvrđena činjenica; uzrok zahteva dodatnu forenzičku proveru PDF objekata i strukture slojeva.

Ako ingest sačuva samo izvučeni tekst:

- pretraga može pogrešno indeksirati white paper kao docking dokument;
- RAG može citirati tvrdnju koja korisniku nije vidljiva;
- klasifikator teme dobija pogrešan label signal;
- deduplikacija može povezati nepovezane dokumente;
- audit ne može objasniti odakle je rečenica došla.

Koje dokaze PDF ingest mora da razlikuje

Ovaj incident pokazuje da originalni PDF, njegov hash i metadata, tekst koji vraća određeni parser, vizuelni render, eventualni OCR i odluka o tome koji sadržaj je vidljiv nisu ista vrsta dokaza. Razlika između embedded i vidljivog teksta mora ostati proverljiva, a sadržaj sa nerešenim konfliktom ne može imati isti status kao vizuelno potvrđen tekst. To su provenance i quality principi; konkretan workflow, statusi i način skladištenja zavise od budućeg okruženja.

Zašto je ovo FAIR problem

Bez provenance-a ne možemo znati da li je rečenica došla iz vidljivog sadržaja, OCR-a, nevidljivog embedded sloja ili naknadne transformacije. Podatak može biti lako pronađen, ali nije pouzdano reusable jer mu poreklo i značenje nisu jasni.

Konceptualni životni ciklus hemijskih i dokumentnih izvora

Kod hemijskih i dokumentnih izvora korisno je razlikovati registrovani izvor, parsiranu reprezentaciju, validacioni nalaz, stručno protumačen zapis, izvedene rezultate i kasniji status pristupa ili povlačenja. Svaki nivo odgovara na drugo pitanje: integritet bajtova, tehničku čitljivost, naučnu konzistentnost, stručnu odluku, poreklo derivata ili dozvoljenost dalje upotrebe.

Originalni, protumačeni i izvedeni sadržaj ne treba predstavljati kao istu vrstu činjenice. Ovaj životni ciklus je pojamovni model za razmišljanje o provenance-u, ne propisan ingest pipeline.

Pitanja licence za globalnu pretragu

Globalna pretraga nad velikom licenciranom bazom otvara nekoliko odvojenih pitanja: gde je obrada dozvoljena, ko sme da vidi koji nivo rezultata, da li su indeksiranje i privremeni derivati dopušteni, da li rezultat omogućava bulk rekonstrukciju, šta sme da napusti organizaciju i kako istek ili opoziv utiču na ranije izvedene artefakte. I telemetrija i eksterni servisi mogu postati neželjen kanal podataka. Poglavlje ne bira API, tenant model, cache ili UI; ono pokazuje koje pravne granice takav dizajn mora da razjasni.

Pitanja licence za poređenje svih parova

Kod korisničkih CIF-ova potrebno je razjasniti pravo na obradu, poverljivost, razdvajanje različitih vlasnika/projekata, eventualnu ponovnu upotrebu za trening, rok čuvanja i dozvoljeni sadržaj bogatog pairwise rezultata. Rezultat izveden iz dva izvora može naslediti ograničenja oba izvora. To su pitanja scope-a i lineage-a, ne predlog upload, retention ili export implementacije.

Kako restricted podaci mogu biti FAIR

FAIR ne zahteva objavljivanje sadržaja CSD-a. Restricted podatak može imati stabilan identitet i bogate metadata bez otkrivanja koordinata, standardizovan ali kontrolisan pristup, interoperabilne rečnike i jedinice, eksplicitnu licencu i pun provenance. Princip [A2](#) traži da metadata ostanu dostupni i kada sam podatak više nije dostupan. Ako ugovor ograničava i metadata, opiši dozvoljeni obuhvat i preostalo ograničenje FAIR usklađenosti; privatnost pristupa nije opravdanje da se princip trajnosti metadata izostavi.

Identifikator ne mora otkriti sadržaj i može se razrešavati kroz interni kontrolisani servis. Ipak, [F1](#) zahteva globalnu jedinstvenost i trajnost: lokalni broj [123](#) bez trajnog imenskog prostora i upravljanja identitetom nije dovoljan. „Ne postoji za neovlašćenog korisnika“ i „postoji, ali zahteva dozvolu“ jesu različite odluke pristupa, čiji uticaj na pronalaženje i dostupnost metadata treba navesti.

Tipične zamke

1. Privatni repo proglasiti licencom.
2. Pretpostaviti da se svaki API rezultat sme trajno keširati.
3. Objaviti embedding jer „nije raw CIF“.
4. Pomešati FAIR sa open, free ili public domain.
5. Pomešati open-source kod sa pravima na podatke koje kod obrađuje.
6. Sačuvati samo canonical record i izgubiti originalni dokaz.
7. Izgubiti verziju parsera, baze, checkCIF ruleset-a ili modela.
8. Tretirati [?](#) kao nulu.
9. Indeksirati nevidljivi, tematski nepodudarni embedded PDF tekst bez vizuelnog cross-check-a.

10. Propagirati brisanje na raw fajl, ali ostaviti cache, embedding i model derivative.
11. Slati proprietary sadržaj eksternom validatoru ili LLM-u bez odobrenja.
12. Verovati da citiranje izvora zamenjuje dozvolu za redistribuciju.

Mini-vežbe

1. Privatni GitHub

Imaš CSD eksport i private repo sa dva saradnika. Da li ga smeš commit-ovati zato što repo nije javan?

Odgovor

Ne možeš to zaključiti. Private repo je tehnička kontrola, ali i dalje pravi kopiju kod treće strane i daje pristup drugim nalogima. Proveri konkretni CCDC ugovor i organizacionu politiku; bez dozvole raw eksport ostaje van repoa.

2. FAIR, ali zatvoreno

Može li interni proprietary dataset biti FAIR ako pristup zahteva login?

Odgovor

Da. FAIR A1.2 dozvoljava authentication/authorization. Potrebni su stabilni identifikatori, bogati metadata, standardan protokol, jasna licenca/uslovi, interoperabilna semantika i provenance.

3. Nevidljivi embedded PDF tekst

Parser nalazi docking tekst na naslovnoj strani, ali render ga ne prikazuje. Šta zaključuješ?

Odgovor

Embedded tekst i vidljivi sadržaj su različiti dokazi. Sporni tekst ne tretiraj kao potvrđen sadržaj dok se konflikt ne proveri renderom/OCR-om; sačuvaj poreklo ekstrakcije, parser i verziju.

4. Embedding za objavu

Model je treniran nad CSD-derived fingerprintima. Da li je dovoljno što model weights ne sadrže čitljive CIF redove?

Odgovor

Ne. Model može biti ugovorno izvedeni materijal i može memorisati ili omogućiti inference o podacima. Potrebna je licencna analiza i, kada uslovi zahtevaju, prethodno pisano odobrenje CCDC-a. Test rekonstrukcije/memorisanja može proceniti tehnički rizik, ali dobar rezultat testa ne daje pravo distribucije.

5. Istek licence

Licenca za izvor ističe sutra. Koji artefakti moraju biti pronađeni?

Odgovor

Raw kopije, canonical zapisi, cache, indeks, embeddings, trenirani/evaluirani modeli, report-i i backup-i povezani lineage grafom. Za svaki se primenjuje ugovorena retention/deletion ili review odluka.

Kriterijum prolaza

Poglavlje si savladao kada možeš da objasniš kako se pristup, obrada, deljenje i objavljivanje razlikuju, zašto provenance mora povezati izvor i derivative i zašto FAIR ne ukida licencna ograničenja.

Primarni i autoritativni izvori

- [CCDC CSD Portfolio Conditions of Use](#)
- [CCDC Standard Licence Agreement](#)
- [CCDC: Can I redistribute data from the CSD?](#)
- [Wilkinson et al. 2016: FAIR Guiding Principles](#)
- [GO FAIR: standardizovan pristup otvorenim i ograničenim podacima](#)
- [GO FAIR: globalno jedinstveni i trajni identifikatori](#)
- [GO FAIR: metadata ostaju dostupni](#)
- [IUCr: Crystallographic Information Framework](#)
- [W3C PROV-O](#)

22. White paper tokovi i federativno učenje

Prioritet: MORAŠ za razumevanje izvora. FL se ovde obrađuje samo teorijski; implementacija nije deo ovog materijala. Ova strana zatvara teorijske teme iz dostavljenog white paper-a: provenance i lifecycle proprietary podataka, povezivanje strukture i svojstva, manufacturability, polymorph risk i federativno učenje.

Dostavljeni dokument *Maximising the Impact of Proprietary Structural Data* je CCDC white paper. On je koristan za problemski okvir i opis CCDC ekosistema, ali nije nezavisna evaluacija proizvoda, tehnička specifikacija naših aplikacija niti dokaz da će određeni ML metod raditi na našem skupu.

22.1 Četiri nivoa tvrdnje

Nemoj spajati sledeće rečenice:

1. **White paper kaže** da određeni tok ili alat može doneti korist.
2. **Zvanična dokumentacija** opisuje da funkcija postoji u određenom proizvodu/verziji.
3. **Nezavisan ili primarni rad** daje rezultat pod određenim skupom, metodom i ograničenjima.
4. **Naš test** potvrđuje dostupnost, dozvolu, tačnost i vrednost u konkretnom lokalnom okruženju.

Prva rečenica motiviše istraživanje. Tek četvrta može postati lokalni dokaz za ograničenu tvrdnju.

22.2 Obim izvora

Nastavne tvrdnje white paper-a nalaze se pre svega na stranama 3–18: proprietary podaci i provenance, structure–property veze, lifecycle/curation, federativno učenje i indikatori polymorph risk-a. Strane 1–2 i 19–22 jesu front/back matter, zaključak/testimonial, reference i kontakt, a ne nezavisna validacija. Teorija je obrađena u sekcijama 22.3–22.6 i povezanim poglavljima; konflikt embedded teksta i rendera analiziran je u [poglavlju 21](#).

22.3 Lifecycle stanja i dokazni status

White paper razlikuje sadržaj pre pune kuracije od sadržaja odobrenog za standardnu upotrebu. Prenosiva teorijska razlika je između primljenog izvora, tehnički parsiranog sadržaja, automatski validiranog nalaza, stručno pregledanog ili kuriranog zapisa i sadržaja odobrenog ili povučenog za određenu namenu. Nazivi i prelazi zavise od institucije.

`parser_ok` ne dokazuje hemijsku ispravnost, automatska validacija nije stručna ili policy odluka, a vendor oznaka kao „early access“ nije sama po sebi quality dokaz. Svako stanje ima smisla samo uz provenance, pravila, upozorenja, odgovornost, dozvoljeni scope i veze među verzijama.

22.4 Struktura–svojstvo nije običan SQL join po imenu

White paper ispravno naglašava da melting point, solubility ili stabilnost postaju korisniji kada su vezani za konkretnu strukturu/solid form. Pojemovno, jedna property opservacija povezuje identitet materijala i čvrste forme sa vrstom svojstva, vrednošću i jedinicom, uslovima, metodom, uzorkom, neizvesnošću i poreklom. Ovo je opis značenja opservacije, ne predlog YAML-a ili konkretne data schema-e.

Bez solid form-a, temperature, solvent/pH, metode i porekla dve brojke mogu izgledati uporedivo, a meriti različite pojave. Isto važi za melting point kada postoje raspad, solvat desolvation, različita brzina zagrevanja ili različit način prijavljivanja.

Manufacturability u white paper-u nije jedna fundamentalna skalarna osobina kristala. To je skup procesno zavisnih ishoda: mogućnost pouzdane kristalizacije i izolacije, filtrabilnost/sušenje, stabilnost forme, ponašanje čestica, flow/compaction i reproduktivnost procesa mogu doprinosti odluci. Zato neoznačen binarni pojam „manufacturable“ nema dovoljno naučno značenje bez definisanog procesa, uslova i ekspertskog protokola.

Šta ML model zapravo predviđa

Umesto „predviđamo stabilnost“, napiši: „za definisanu solid-form familiju, temperaturu, measurement protocol i vremenski horizont rangiramo verovatnoću transformacije, uz dataset/version i calibration interval“. Uža tvrdnja je naučno testabilna.

22.5 Tri alata nisu oracle za polymorph risk

White paper na stranama 17–18 spaja više signala. Njihova uloga mora biti precizna:

Signal	Šta može da pruži	Šta sam ne dokazuje
Mogul/geometrijska distribucija	koliko je bond length/angle/torsion tipičan u verzionisanom, filtriranom skupu sličnih fragmenata	energiju konformera, metastabilnost ili postojanje drugog polimorfa
packing comparison	sličnost lokalnih molecular clusters pod navedenim atom mapping-om, veličinom klastera, tolerancijama i tretmanom H/disorder-a	jednaku lattice energy, termodinamički poredak ili identitet faze u svim uslovima
hydrogen-bond propensity	statističku sklonost donor–acceptor parova i upozorenje da očekivana interakcija izostaje	da se veza mora formirati, da je postojeća forma nestabilna ili da je predložena packing alternativa ostvariva

Mogul dokumentacija opisuje [knowledge-base geometrijsku analizu](#), a CSD Python API dokumentuje parametrizovanu [packing similarity](#). To su implementation izvori; claim o stabilnosti i performansama zahteva poseban eksperiment. Worked primer izbora referentne populacije, robustnog outlier signala, kružnih torzija i celog HBP logistic/fitting/grouping toka nalazi se u [lekciji 11A](#).

Razuman evidence stack je:

```
kuriran identitet forme
→ neuobičajena intra/intermolekulska geometrija kao signal
→ packing/contact poređenje kao strukturni kontekst
→ energy/thermodynamic i property analiza sa navedenim modelom
→ nezavisno izmereni PXRD/thermal/spectroscopic i ciljano crystallisation potvrđivanje
```

Nijedan korak ne sme da bude prećutno zamenjen prethodnim. Simulirani PXRD iz istog CIF-a je koristan derivat modela, ali nije nezavisan dokaz; [lekcija o difrakciji](#) daje potreban measurement/simulation manifest. [GSK/CCDC rad](#) podržava užu tvrdnju da su se analizirani proprietary i javni skup razlikovali u relevantnom solid-form prostoru; ne dokazuje univerzalno povećanje tačnosti svakog polymorph predictor-a.

22.6 Federativno učenje, od mehanizma do threat model-a


Opis dve tražene aplikacije sam po sebi ne zahteva FL. Tema je ovde zato što zauzima strane 15–16 white paper-a i može postati važna ako više institucija želi zajednički model bez centralnog skladišta raw struktura.

Osnovni tok

U najjednostavnijem FedAvg obrascu koordinator pošalje model w_t odabranim lokacijama. Lokacija k trenira lokalno i vraća $w_{t+1}^{(k)}$ ili update. Koordinator računa težinski prosek:

$$w_{t+1} = \sum_{k \in S_t} \frac{n_k}{\sum_{j \in S_t} n_j} w_{t+1}^{(k)},$$

gde je S_t skup lokacija izabranih za rundu, a n_k veličina lokalnog trening skupa lokacije k korišćenog za taj update; ponavljanje istih primera kroz više epoha ne povećava ovaj broj. Model je skup usaglašenih numeričkih parametara w , a update je njihova promena posle lokalnog učenja. Ako dve lokacije imaju 40 i 60 primera, njihove težine u ovom proseku su 0,4 i 0,6. Potrebni su ista arhitektura i isto značenje parametara/reprezentacija; ne mogu se proizvoljno prosečiti dva različito definisana modela. Originalni obrazac je [McMahan et al. 2017](#).



Raw CIF ne mora da napusti lokaciju, ali kroz mrežu i dalje prolaze model/update, metadata protokola, veličine/timing i metrike. Konačni model je takođe izvedeni artefakt.

Zašto „podaci ostaju lokalno“ nije puna bezbednosna tvrdnja

Rizik	Primer u ovom domenu	Potrebna vrsta kontrole
update/gradient leakage	retka struktura ili svojstvo utiču na update koji omogućava inferenciju	clipping, batching, leakage test; po potrebi formalni DP
honest-but-curious coordinator	server pokušava da vidi pojedinačni update	secure aggregation pod jasno navedenim pretpostavkama

Rizik	Primer u ovom domenu	Potrebna vrsta kontrole
malicious participant	šalje poisoned update ili pokušava izvlačenje iz modela	authentication, robust aggregation gde je opravdana, anomaly test, incident response
final-model leakage	membership/property inference iz objavljenog modela	release review, access control, attack evaluation, DP kada utility dozvoljava
licence/IP	model ili embedding može biti ugovorno regulisan derivat	permission matrix i pisano odobrenje; tehnologija ne daje pravno pravo
endpoint compromise	lokalni worker, log ili cache otkrije raw data	izolacija, least privilege, secret management, retention i audit

Deep Leakage from Gradients je konkretan dokaz da update informacije mogu otkriti trening input u određenim uslovima. Secure aggregation skriva pojedinačne update-e od koordinatora pod svojim threat model-om; ne štiti automatski endpoint, finalni model, malicious clients niti rešava licencu.

Diferencijalna privatnost (DP) postavlja formalnu granicu tome koliko se raspodela objavljenog izlaza može promeniti kada se doda ili ukloni jedna unapred definisana zaštićena jedinica. Parametri ϵ i δ opisuju tu granicu; nisu procenat „privatnosti“ niti mera tačnosti modela. Najpre se mora odrediti da li štitimo jedan kristalografski zapis, celu familiju povezanih zapisa ili doprinos jedne institucije. Garancija za pojedinačni zapis ne postaje automatski garancija za celu instituciju.

U DP-SGD primeru **clipping** ograničava normu doprinosa gradijenta pojedinačnog primera, a zatim se dodaje odgovarajuće podešen slučajni šum i prati kumulativni gubitak privatnosti kroz korake učenja (Abadi et al. 2016). Sam clipping, grupisanje primera u batch ili proizvoljan šum nisu dokaz DP-a. Secure aggregation može sakriti pojedinačne doprinose tokom sabiranja; DP ograničava šta se može zaključiti iz objavljenog rezultata pod navedenom definicijom susednih skupova. Zbog toga se ove kontrole mogu dopunjavati.

Hemijska heterogenost je centralni, ne sporedni problem

Za partnerske podatke ne sme se bez provere pretpostaviti IID — da su primeri nezavisni i potiču iz iste raspodele. Partneri mogu biti heterogeni zato što:

- imaju različite scaffold-e, metale, solid forms i razvojne faze;
- mere svojstva različitim protokolima i jedinicama;
- koriste različite parser/curation verzije;
- razlikuju se po veličini i missingness-u;
- label semantics mogu nositi lokalna, nekompatibilna značenja.

Smisleno federativno poređenje zahteva zajedničko značenje targeta, jedinica i uslova, identiteta materijala/solid form-a, reprezentacija, missing vrednosti i evaluacione populacije. FL nad neusaglašenim labelama samo efikasnije agregira nesporazum.

Pitanja validnosti federativnog poređenja

Pre tumačenja rezultata moraju biti jasni threat model i učesnici, dozvoljeni artefakti i posledice povlačenja; kompatibilnost reprezentacija, modela i aggregation pravila; razlika između lokalnog, dozvoljenog centralnog i federativnog baseline-a; leakage-safe hemijski i vremenski split; globalni i per-site rezultat sa neizvesnošću; ponašanje pod non-IID, dropout, poisoning i leakage stresom; kao i odnos koristi prema jednostavnijim alternativama. Ovo su dimenzije naučne i bezbednosne validacije, ne plan treninga, deployment-a ili release-a.

FL je opravdan kada podaci zaista ne smeju da se centralizuju i kada dodatna složenost donosi merljivu korist. Nije cilj sam po sebi.

22.7 Granica prema dve aplikacije

Teme iz ovog poglavlja ograničavaju tumačenje dokaza, ali nisu same po sebi zahtevi za globalnu pretragu ili poređenje parova; te dve funkcije ne zahtevaju federativno učenje.

22.8 Provera znanja

1. Zašto early-access i main baza ne smeju biti samo dva foldera bez stanja i politike?
2. Koji minimum mora stajati uz solubility vrednost da bi structure–property veza imala smisla?
3. Da li Mogul „unusual torsion“ dokazuje visoku energiju ili metastabilnost?
4. Šta tačno napušta lokaciju u tipičnom FedAvg toku?
5. Zašto secure aggregation nije zamena za differential privacy, endpoint security ili licencu?

Odgovori

1. Downstream sistemi moraju znati quality/review stanje, dozvoljene upotrebe, verziju, prelaze i audit; folder ne daje tu semantiku.
2. Identitet materijala i solid form-a, vrednost/jedinica, uslovi, metoda, uzorak/batch, poreklo i quality/uncertainty.
3. Ne; to je odstupanje od referentne distribucije pod datim query/filter uslovima i signal za dalju proveru.
4. Model/update i protokolarni metadata/metrics; raw podaci mogu ostati lokalno, ali to nije dokaz da ništa o njima ne curi.
5. Svaka kontrola pokriva drugi threat model; nijedna sama ne daje univerzalnu privatnost ni pravno pravo.

Kriterijum prolaza: možeš da prevedesh ključne tvrdnje white paper-a u proverljiva pitanja i ograničene tvrdnje, odvojiš vendor claim od lokalnog dokaza i nacrtáš FL threat model bez rečenice „raw fajlovi ne odlaze, dakle privatno je“.

Opcione nastavne laboratorijske vežbe

Ove male, ograničene vežbe služe isključivo da teoriju pretvore u intuiciju. **Nisu faze, prototipi, backlog niti redosled realizacije budućeg 2CDC projekta.** Mogu se prolaziti konceptualno, ručnim računom ili nad sintetičkim primerom; programsko izvođenje nije uslov za završetak plana učenja.

Ako se koriste originalni lokalni fajlovi, rad je **read-only**: ne menjaj ih, ne šalji ih javnim servisima i ne commit-uj ih u ovaj repo.

Pre početka

Napravi za svaki rezultat malu evidenciju:

```
vežba / datum
source file + SHA-256
alat + verzija + parametri
šta je direktno pročitano
šta je izračunato
šta je hemijski dodeljeno/pretpostavljeno
warnings i nerešena pitanja
```

Za opcioni programski rad korisni su [Gemmi](#) za CIF/crystallography i [RDKit](#) za molekulske grafove. Oni su pomoćna sredstva, ne propisani projektni stack i ne autoritet nad značenjem. Svaki rezultat proveri na malom ručno razumljivom primeru.

L0 — Inventar i dokazni lanac

Cilj: naučiti da dataset počinje poreklom, ne DataFrame-om.

1. U okviru 2CDC popiši isključivo 15 izvornih artefakata prikazanih u [strukтури lokalnih fajlova](#): pet fajlova u korenu i deset fajlova u [Pretrage CSD](#); ne ulazi u [crystallography-and-ml-theory](#), tmp ni generisane izlaze.
2. Zabeleži relativni path, bytes, extension, SHA-256 i vreme izmene.
3. Format detektuj i po sadržaju; ekstenzija je samo signal.
4. Za multi-record formate izbroj records nezavisno na dva načina gde je moguće.
5. Označi fajlove koje licenca/provenance ne dozvoljava da napuste lokalni data plane.

Kontrola: dobijaš isti hash pri ponovnom čitanju; nijedan original nije promenio vreme/hash.

Isporuka: `source-manifest.local.csv`, van Git repoa.

L0A — Anatomija celog bezbednog CIF-a

Ulaz: repo fixture [tutorial-minimal.cif](#). Ovo je jedini CIF u praktikumu koji sme da se deli javno: ručno je napravljen i sintetički.

1. Otvori fajl kao običan tekst i označi komentar, `data_` blok, scalar data items, quoted value, semicolon text field i `loop_`.
2. Za svaki atom-site red poveži šest vrednosti sa šest loop kolona.
3. Pronađi standard uncertainty zapis, nepoznatu vrednost `?` i neprimenljivu vrednost `..`.
4. Parserom pročitaj broj blokova/items/atom rows; uporedi sa ručnim brojanjem.

5. Iz $a = b = c = 5.6400 \text{ \AA}$ reprodukuji zapreminu.
6. Iz formule NaCl , $Z = 4$, formule mase i zapremine proveriti gustinu.
7. U privatnoj privremenoj kopiji ukloni jednu vrednost iz atom loop reda i zabeleži kako parser prijavljuje cardinality grešku; original ne menjaj.

Kontrola: parser i ručno čitanje moraju dati isti atom-column mapping. `?` i `.` ostaju različiti tokeni, a sintetički model se ne opisuje kao eksperimentalni dokaz.

L1 — Formula, molarna masa i kristalna gustina

Ulaz: `cu_n14_a.cif`.

1. Pronađi moiety i sum formula, Z , cell volume i reported density.
2. Izračunaj molarnu masu iz standardnih atomskih masa ili proveriti reported formula weight.
3. Pretvori $\text{\AA}^3$ u cm^3 i izračunaj:

$$\rho = \frac{ZM}{N_A V}.$$

1. Objasni svaki faktor i jedinicu.
2. Dokaži iz formule i atom-site petlje da fajl nema Cu atom.
3. Pronađi gde se `Cu` zaista pojavljuje i objasni njegovo značenje.

Kontrola: dimenziona analiza mora završiti sa g cm^{-3} .

L2 — Veza kao model: N14 cross-format audit

Ulazi: `cu_n14_a.cif`, `N14.mol`, `N14.mol2`.

Napravi tabelu:

Svojstvo	CIF	MOL	MOL2	observed / derived / assigned
atoms				
bonds				
bond types				
formal/partial charge				
coordinates				
cell/symmetry				
uncertainty/quality				

Zatim:

1. uporedi dve N–O distance oko nitro-like N/O motiva;
2. uporedi te distance sa single/double/unknown oznakama u MOL/MOL2;
3. objasni resonance i zašto geometrija ne potvrđuje naivni integer bond assignment;
4. napiši loss matrix za $\text{CIF} \rightarrow \text{MOL} \rightarrow \text{MOL2}$.

Kontrola: `NO_CHARGES` ne sme postati tvrdnja „svi naboji fizički nula“.

L3 — Frakcione i kartezijanske koordinate

Ulazi: isti N14 fajlovi.

Za monoklinsku ćeliju sa jedinstvenom b osom, $\alpha = \gamma = 90^\circ$, jedan čest izbor matrice je:

$$\begin{aligned}x_c &= ax_f + c \cos \beta z_f \\y_c &= by_f \\z_c &= c \sin \beta z_f.\end{aligned}$$

1. Iz CIF-a pročitaj a , b , c , β i frakcione koordinate C1.
2. Ručno i programski izračunaj Cartesian koordinatu.
3. Uporedi je sa C1 u MOL2 uz toleranciju na zaokruživanje.
4. Transformiši još pet atoma.
5. Primeni proizvoljnu rigidnu translaciju/rotaciju i pokaži da distance ostaju iste.

Kontrola: ne pretpostavljaj orthogonal ćeliju samo zato što tri parametra nose oznake a,b,c.

L4 — Simetrija i periodični susedi

Ulaz: `cu_n14_a.cif`.

1. Pročitaj space-group symbol i IT number.
2. Izlistaj symmetry operations.
3. Od jednog atoma generiši general-position ekvivalente i wrap-uj fractional coordinates u $([0,1))$.
4. Za ovaj N14 fixture koristi $4.0 \text{ \AA}$ kao radijus enumeracije kontaktnih kandidata — ne kao definiciju veze ili „jakog kontakta“ — pa, nakon provere dometa, generiši candidates preko $3 \times 3 \times 3$ translations oko referentnog molekula.
5. Ukloni duplikate koristeći symmetry/site identitet, ne samo zaokružen Cartesian string.
6. Pronađi najbliže međumolekulske O/N kontakte.
7. Za svaki zapiši symmetry operation i translation image.

Kontrola: kontakt preko granice ćelije mora ostati isti nakon wrap-a referentnog molekula.

$3 \times 3 \times 3$ nije univerzalno pravilo. U opštem algoritmu potreban broj translacionih slika izvodi se iz cutoff-a i geometrije ćelije, a zatim se testira na vrlo kratkim i kosim ćelijama.

L5 — Od kratkog kontakta do interakcione hipoteze

Koristi kandidate iz L4.

1. Za svaki kontakt navedi elemente, distance, potencijalne donor/acceptor uloge i dostupni angle.
2. Proveri protonation i H position confidence.
3. Obeleži `geometric candidate`, `chemically plausible`, `ambiguous` ili `rejected`.
4. Napiši jednu rečenicu dokaza i jednu moguću alternativu.
5. Uporedi pravila sa [IUPAC H-bond preporukom](#).
6. Zabeleži da li su X–H dužine iz izvornog rendgenskog modela ili su neutron-normalizovane prema [lekciji o interakcijama](#). Ako porediš oba prikaza, odvojeno prijavi $H \cdots A$ distance i uglove; normalizovana H pozicija je izvedena, a ne novo merenje.

Kontrola: nijedan kontakt nije automatski „jak“ samo zato što je kratak.

L6 — ConQuest query anatomija

Ulazi: dva `.cqs` fajla i [ConQuest vodič](#).

1. Napravi atom/bond tabelu za 18-atomski zajednički query motif.
2. Označi centralni pyridine N i dva terminalna N atoma u `C=N` granama.
3. U drugom query-ju pronađi atom 19 i njegov tip `4M`.
4. Nacrtaj connected components oba query-ja.
5. Napiši minimalnu tvrdnju koju drugi query dokazuje.
6. Predloži post-validation algoritam za tvrdnju „DAP koordinira metal“.
7. Sastavi šest pitanja za autora upita.

Kontrola: drugi query ima dve disconnected components; ne izmišljaj metal–N edge.

L7 — Multi-format audit CSD izvoza

Ulazi: `search1.*` i `search2.*`.

Za svaki format izmeri:

- record count i identifier coverage;
- prazan/failed record count;
- 2D/3D availability;
- component count;
- unknown/dummy atom i bond type;
- cell/`CRYGIN` availability;
- SMILES coverage i duplicates;
- refcode family/revision groups.

Zatim:

1. proveriti da je `search2` set i ordered subset `search1`;
2. izračunaj 72 uklonjena entry-ja;
3. proveriti da li isti IDs nedostaju iz svih formata;
4. napravi contingency tabelu missing SMILES vs `un bonds/Du atoms/empty structure`;
5. objasni zašto opaženi dokazi ne podržavaju nekritičku MCAR pretpostavku i koje bi dodatne testove zahtevala jača tvrdnja;
6. napravi quality/error taxonomy umesto da obrišeš problematične rows.

Kontrola: broj SMI linija nije broj CIF entries i ne sme postati denominator bez oznake.

L8 — Prvi similarity baseline

Radi samo na zapisima sa dovoljno pouzdanim molekulskim grafom.

1. Verzoniši standardization profile.
2. Izračunaj Morgan/circular fingerprints sa dokumentovanim radius/bit/stereo parametrima.
3. Izaberi jedan query i rangiraj Tanimoto candidates.
4. Za top 10 vizuelno/strukturno obeleži matched i unmatched motif.
5. Promeni radius ili tautomer/aromaticity policy i izmeri promenu ranga.
6. Dodaj exact DAP substructure filter.

7. Napiši tri hard negative primera.

Kontrola: fingerprint radi na grafu koji je parser dodelio; excluded/problematic records moraju biti prijavljeni, ne nevidljivi.

L9 — Jedan evidence-rich par

Izaberi metal-free DAP ligand i jedan kandidat sa metalom, zatim dva koordinaciona kandidata.

Za svaki par popuni:

- composition/component relation;
- graph mapping i coverage;
- tri DAP donor atoma;
- metal membership i metal–donor edges;
- coordination number/geometry i uncertainty;
- conformational RMSD/torsions;
- cell/packing comparability;
- H-bond/contact evidence;
- data-quality compatibility;
- odluku po nivou, confidence i reviewer note.

Kontrola: dozvoljeno je ostaviti ukupni score `null` ako ključna semantika nije potvrđena.

L10 — Invariance i adversarial suite

Napravi kontrolisane varijante jednog fixture-a:

1. promenjen atom order;
2. promenjen component order;
3. rigid rotation/translation;
4. periodic wrap;
5. symmetry-equivalent ASU;
6. ekvivalentan cell setting;
7. drugi validni SMILES traversal;
8. uklonjena stereo oznaka;
9. metal premešten u odvojenu komponentu;
10. dodata solvent voda.

Za svaku unapred napiši koje score komponente moraju ostati iste, koje se smeju promeniti i gde sistem mora da upozori.

Kontrola: očekivanja se pišu pre gledanja izlaza algoritma.

L11 — Referentni signal i diffraction evidence

Ulazi: sintetički brojevi iz [lekcije 11A](#) i `tutorial-minimal.cif`.

1. Reprodukuj empirical percentile 247/250 i robustni z za 1,390 Å, medijanu 1,340 Å i MAD 0,012 Å.
2. Napiši četiri alternativna objašnjenja outlier-a koja ne tvrde energiju.
3. Izračunaj kružnu udaljenost između -179° i $+179^\circ$.

4. Za sintetički HBP primer napravi odvojena polja za individual propensity, uncertainty, observed status, grouping score, coordination score i fitting support.
5. Za cubic ćeliju $a = 5.6400 \text{ \AA}$ izračunaj $d(200)$ i 2θ za $\lambda = 1.5406 \text{ \AA}$.
6. Napiši dva različita claim-a: jedan koji podržava simulated pattern i jedan koji bi zahtevao measured PXRD.

Kontrola: nijedan output ne sme da kaže „outlier = nestabilan“, „propensity = opažena veza“ ili „simulacija = potvrđen bulk uzorak“.

Završna evidencija

Vežba je završena tek kada možeš odgovoriti:

- Šta je bio source of truth?
- Koje transformacije su bile lossy?
- Koju hemijsku tvrdnju rezultat podržava?
- Koju ne podržava?
- Koji edge case bi oborio zaključak?
- Može li drugi inženjer ponoviti rezultat iz manifesta?

Završna projektantska analiza — bez implementacije

Zadatak

Ovo je završna provera teorijskog razumevanja, ne prototip, backlog niti plan izrade stvarnog projekta. Nije potrebno pisati kod, praviti baze, trenirati modele, definisati produkcijske šeme ili izvršavati budući 2CDC tok.

Na jednom hipotetičkom primeru treba usmeno ili u belešci objasniti:

- šta dve aplikacije pokušavaju da odgovore;
- koje hemijske i kristalografske nivoe ne smeju da pomešaju;
- koje porodice algoritama mogu biti relevantne i pod kojim uslovima;
- koje informacije nedostaju i moraju se potvrditi sa fakultetom;
- kakav dokaz bi jednog dana bio potreban da se rezultat smatra validnim.

Poenta nije broj feature-a. Poenta je da svaki ulaz, score, izuzetak i claim imaju precizno značenje i dokaz.

Deo A — Konceptualna analiza globalne pretrage

Za hipotetički query CIF objasni, bez realizacije:

1. zašto se original, provenance i izvedeni prikazi moraju razlikovati;
2. kako syntax, chemistry i crystal-quality problemi menjaju dostupne search modes;
3. zašto ligand, coordination entity i puna crystal form nisu isti objekat pretrage;
4. koje značenje mogu imati formula, element, component, coordination i quality filteri;
5. ulogu širokog candidate retrieval-a i skupljeg reranking-a;
6. razliku između 2D, coordination, molecular-3D i packing sličnosti;
7. zašto rezultat mora pokazati coverage, evidence, warning i abstention;
8. zašto licence određuju šta korisnik sme da vidi ili preuzme;
9. koju vrstu stručnog gold-a bi zahtevao imenovani search claim;
10. koje još nepotvrđene odluke blokiraju tačno značenje aplikacije.

Ovaj redosled je samo redosled objašnjavanja znanja, ne redosled buduće implementacije.

Deo B — Konceptualna analiza all-pairs poređenja

Za hipotetički skup od n CIF-ova:

1. izvedi broj neuređenih parova $n(n - 1)/2$;
2. objasni zašto se composition, graph, coordination, conformation, cell, packing i interaction rezultati drže odvojeno;
3. objasni component mapping pre atom mapping-a i atom mapping pre RMSD-a;
4. razlikuj `not comparable` od validno izmerenog score-a 0;
5. navedi encoding promene na koje rezultat treba da bude invarijantan;
6. objasni zašto jedna overall cifra bez target-specific labela može biti obmanjujuća;

7. opiši kakav atomski/periodični evidence stručnjaku omogućava proveru;
8. izdvoji najmanje pet failure ili ambiguous klasa;
9. objasni koje dodatne informacije zahteva tvrdnja o packing-u ili polimorfnosti;
10. navedi koje App2 odluke mora da potvrdi fakultet pre evaluacije.

Deo C — Nacrt naučnog dokaza

Ne pravi se stvarni gold skup. Umesto toga treba obrazložiti kako bi valjan evaluation design razlikovao:

- self/equivalent encoding slučajeve;
- lake negative primere;
- hard negatives koji dele veliki deo grafa, ali ne ciljnu relaciju;
- near positives;
- edge, ambiguous i insufficient-evidence slučajeve.

Treba objasniti ulogu nezavisne anotacije, agreement-a, adjudication-a, family/group split-a, hard-negative pokrivenosti, intervala poverenja i unapred definisanog primarnog claim-a. Brojevi, pragovi i veličina budućeg skupa ostaju odluka stakeholdera, a ne zadatak ove vežbe.

Claim analiza

Za jednu zamišljenu tvrdnju popuni pojmovni okvir:

Pitanje	Odgovor koji mora biti poznat
korisnička odluka	šta će stručnjak uraditi drugačije zbog rezultata?
populacija / scope	na koje strukture i uslove tvrdnja važi?
objekat	entry, komponenta, ligand, coordination entity ili solid form?
relevantnost / label	šta tačno znači pozitivan, negativan i ambiguous slučaj?
reprezentacija	koji hemijski/kristalografski nivo nosi signal?
algoritamska porodica	koji tip metoda odgovara pitanju i koje su mu granice?
evaluation evidence	koji gold, split i metrika mogu proveriti tvrdnju?
failure i abstention	kada se odgovor ne sme dati?
licence/provenance	koje pravo i poreklo moraju biti vidljivi?
otvorena odluka	ko na fakultetu mora da je potvrdi?

Ovo je okvir za razmišljanje, ne buduća schema ili acceptance specifikacija.

Similarity analiza

Za jedan hipotetički par razmotri:

Osa	Pitanje
objekat A/B	da li se porede ista vrsta hemijskog/kristalografskog entiteta?
komponente	kako solventi, counterions i cofomers menjaju značenje?
graf	koje odluke o charge-u, H, stereo, tautomeriji i metalnim vezama utiču na rezultat?
geometrija	koji mapping, alignment, symmetry i coordinate-origin uslovi važe?

Osa	Pitanje
periodičnost	kako cell setting, image i shell/tolerance menjaju poređenje?
metrika	šta formula meri, a šta ne meri?
coverage/status	koliko je objekta stvarno upoređeno i da li je analiza primenljiva?
dokaz	šta bi stručnjak morao da vidi da proveri zaključak?

Studije slučaja za usmeno objašnjenje

Za svaki scenario navedi najjaču dozvoljenu tvrdnju, najmanje jednu zabranjenu prečicu i dodatni dokaz koji nedostaje:

1. `cu_n14_a.cif` — filename `cu` ne postaje Cu filter;
2. MOL/MOL2 bond-typing neslaganje;
3. DAP motiv bez metala;
4. DAP motiv + metal u entry-ju, bez dokazane koordinacije;
5. kandidat kod koga mapirani DAP donori geometrijski podržavaju koordinaciju;
6. zapis bez 3D;
7. multi-component solvate ili salt;
8. `Du`, `un` ili neuspešan molekulski graf;
9. isti kristal u ekvivalentnom cell/atom encoding-u;
10. isti molekulski graf sa različitim packing-om;
11. Mogul/HBP outlier signal bez nezavisnog dokaza stabilnosti;
12. simulated PXRD koji se poredi sa source CIF-om, bez measured bulk obrasca.

Rubrika razumevanja

Oblast	Šta pokazuje prolaz
hemijska semantika	razlikuje sastav, komponentu, graf, koordinaciju i čvrstu formu
kristalografija	razume ćeliju, simetriju, periodičnost, packing i kvalitet
loss/provenance	ume da objasni šta formati čuvaju/gube i šta je source of truth
algoritmi	bira porodicu metoda prema pitanju, bez proglašavanja unapred pobednika
evaluacija	razlikuje gold, split, metriku, coverage, uncertainty i generalizaciju
failure handling	missing/ambiguous/not-applicable ne pretvara u score 0
licence i FAIR	razlikuje tehničku mogućnost, dostupnost i dozvoljenu operaciju
granica izvora	ne pripisuje DAP ili dve aplikacije white paper-u
pitanja za fakultet	prepoznaje odluke koje dostupni fajlovi ne mogu dati

Automatski pad

- tvrditi da CIF filename određuje sastav;
- proglasiti svaki 4M rezultat koordinisanim DAP kompleksom;
- mešati SMILES/molekulski graf sa crystal packing-om;
- prikriti problematične zapise iz denominatora;

- koristiti nasumični split uz očigledne family duplikate;
- tretirati licencirane raw CSD izvoze kao slobodno objavljive;
- prikazati predicted/assigned vrednost kao eksperimentalno izmerenu;
- dati overall score kada ključni sloj nije validno procenjen;
- tvrditi da white paper propisuje DAP, App1, App2, Pinecone ili Neo4j;
- predstaviti ovu analizu kao redosled buduće izrade.

Usmena odbrana

Prolaz znači da možeš bez koda i bez prototipa da:

1. objasniš pet nivoa strukture;
2. protumačiš jedan forenzički nalaz uz provenance ograničenje;
3. odbraniš jedan informativan i jedan varljiv search hit;
4. rastaviš jedan pair zaključak do atoma i periodičnog evidence-a;
5. objasniš failed/abstained slučaj;
6. odbraniš zamišljeni split, metric i granicu generalizacije;
7. navedeš šta se ne može odlučiti bez fakulteta i licenciranog CSD pristupa.

Kriterijum prolaza: tačne i dosledne veze između hemije, kristalografije, algoritama, dokaza i otvorenih odluka — bez realizacije pravog projekta.

Rešenja i rubrike

Ne čitaj ovo pre prvog pokušaja. Rešenja daju kontrolne vrednosti za opcione nastavne vežbe, ali ne zamenjuju sopstveni provenance i objašnjenje. Ona nisu acceptance testovi, fixture specifikacija ili implementacioni zahtevi budućeg projekta.

L0 — očekivani inventar

U dostavljenom korenu postoji 15 izvornih fajlova:

- white paper PDF;
- opis dve funkcionalnosti TXT;
- jedan CIF, jedan MOL i jedan MOL2 za N14;
- dva .cqs upita;
- po četiri export formata za search1 i search2: CIF, MOL2, SD i SMI.

Za multi-record eksport očekuj:

Skup	CIF	MOL2	SD	SMI lines
search1	2.110	2.110	2.110	1.877
search2	2.038	2.038	2.038	1.805

SMI nije potpuna record lista. Razlika 233 u oba skupa je signal konverzije/representability, ne dozvola da se rows izbrišu.

L0A — ceo sintetički CIF

- uz repozitorijumski propisane LF završetke redova, SHA-256 je E6740DCB099445C3D4C30B94213CBCE915A844E81AFF39306F6FAFBB5BC9B6DE ;
- očekuje se jedan data block sa 26 različitih data names: 20 skalarnih stavki i šest kolona jedne petlje; Gemmi zato vraća 21 stavku bloka (20 parova + jedan loop), a ne 26; atom-site loop ima dva reda, Na1 / C11 ;
- 5.6400(10) znači $5.6400 \pm 0.0010 \text{ \AA}$ na nivou standardne neizvesnosti zapisa;
- ? znači unknown, a . not applicable/inapplicable u datom kontekstu;
- $V = a^3 = 179.406144 \text{ \AA}^3$, što se slaže sa zaokruženih 179,41 $\text{\AA}^3$;
- NaCl, $Z = 4$, formula mass 58,44 i ta zapremina daju približno 2.164 g cm^{-3} .

Parser koji prihvati nepotpun loop red bez jasnog warning-a nije dovoljan za produkcionu ingest test.

L1 — gustina i Cu zamka

Iz CIF-a:

- formula $\text{C}_{25}\text{H}_{20}\text{N}_3\text{O}_2\text{P}$;
- formula mass $M = 425.41 \text{ g mol}^{-1}$;
- $Z = 4$;
- $V = 2073.51 \text{ \AA}^3$;

- ista zapremina je $2.07351 \times 10^{-21} \text{ cm}^3$.

Najpre masa jedne jedinične ćelije:

$$m_{\text{cell}} = \frac{4(425.41)}{6.02214076 \times 10^{23}} = 2.82564 \times 10^{-21} \text{ g.}$$

$$\rho = \frac{2.82564 \times 10^{-21}}{2.07351 \times 10^{-21}} \approx 1.363 \text{ g cm}^{-3}.$$

Formula i atom sites nemaju Cu. Raw CIF vrednost `CuK\alpha` označava Cu K α zračenje; talasna dužina je približno 1,54178 Å.

L2 — N14 formati

- sva tri molekulska prikaza imaju 51 atom;
- MOL i MOL2 imaju 54 bond records;
- MOL je vrlo siromašan bond-order izvoz;
- MOL2 sadrži mnogo `un` bond types i `NO_CHARGES`;
- CIF čuva cell, symmetry, experiment/refinement i uncertainties koje molekulski formati ne čuvaju;
- dve N–O distance su obe približno 1.2273 Å, što je kompatibilno sa delokalizovanim nitro-like motivom i upozorava protiv doslovnog single/double čitanja eksportovanih veza.

L3 — coordinate kontrola

Ćelija:

```
a = 12.7138 Å
b = 15.3951 Å
c = 10.6106 Å
beta = 93.235 degrees
```

Za C1, korišćenjem odgovarajuće fractional-to-Cartesian matrice, očekuj približno:

```
(6.9635, 8.3141, 1.6738) Å
```

Mala odstupanja poslednjih cifara dolaze od zaokruživanja i konvencije ispisa. Veliko odstupanje obično znači pogrešnu matricu, stepene/radijane ili atom mapping.

L4 — symmetry kontrola

Lokalni CIF je monoklinski, $P2_1/c$, International Tables broj 14, sa $Z = 4$. Za atom na opštoj poziciji očekuju se četiri symmetry-equivalent položaja u conventional cell-u. Precizne operacije čitaj iz CIF/dictionary-aware biblioteke i čuvaj zajedno sa translation image-om; nemoj ih pamtit kao neprovereni string.

L5 — kontakt i interakciona hipoteza

Za L5 ne postoji unapred zadata lista „pravih“ interakcija bez izabranog kontakta i pravila. Ispravno rešenje navodi atome, periodičnu sliku, distancu, dostupnost/izvor H položaja i hemijsku ulogu, pa odvajja geometrijskog kandidata od zaključka o H-vezi. Ako H položaj ili protonacija nisu poznati, dozvoljen ishod je `ambiguous`, uz tačno navedeni nedostajući dokaz.

L6 — query semantika

- oba query-ja dele isto povezano 18-atomsko DAP query jezgro sa dve C=N veze;
- drugi dodaje atom 19 tipa 4M;
- 4M je ConQuest legacy element-grupa nazvana „all metals“, koja uključuje i Ge/Sb; koristi se softverska definicija, ne univerzalna podela elemenata na metale i nemetale;
- atom 19 je nepovezana query component;
- minimalni zaključak: isti CSD entry sadrži motiv i element iz 4M grupe, uz navedenu softversku definiciju;
- metal–DAP koordinacija zahteva zasebnu proveru connectivity/geometrije i component membership-a.

L7 — ključne forenzičke vrednosti

- search2 je ordered i set subset search1;
- uklonjeno je tačno 72 records;
- svi 72 imaju SMI i ne zadovoljavaju 4M uslov u query semantici;
- 3D/strukturna reprezentacija nije potpuna za sve records jer query nije zahtevao 3D;
- 87 search1 i 84 search2 zapisa imaju praznu/neupotrebljivu strukturnu reprezentaciju u relevantnom export pogledu;
- MOL2 audit nalazi Du atoms, un bonds, records bez CRYSTIN i mnogo multi-component entries;
- search2 ima 2.038 records, ali 1.899 base-refcode families; suffix/revision leakage je realan;
- 1.805 SMI redova daju manje unique exact strings, pa exact SMILES duplicate nije nužno nezavisna hemijska struktura.

Tačne counts po svakoj error kategoriji zavise od precizne parser definicije. U izveštaju uvek navedi definiciju, npr. šta znači „empty molecule“ i da li Du brojiš po atomu ili record-u.

L8–L10 — rubrike za zadatke bez jednog numeričkog odgovora

L8: top 10 zavisi od upita i profila, pa ne postoji univerzalno tačna rang-lista. Rešenje je potpuno kada daje isti rezultat pri ponavljanju istog profila, prikazuje isključene zapise i objašnjava promene ranga pri promeni radius-a ili standardizacije. Za tri hard negatives navedi zajednički signal i ciljnu razliku, npr. sličan ligand uz drugačiju koordinacionu geometriju. Sam visok Tanimoto nije potvrda da je kandidat relevantan za pakovanje.

L9: oceni par rubrikom ispod. Ne izmišljaj nedostajući koordinacioni ili packing dokaz radi ukupnog skora. Za nivo koji nije deo imenovanog pitanja zapiši not applicable, a za nivo kome nedostaju ulazi missing input; obrazloži oba.

L10: redosled atoma/komponenti i alternativni validni SMILES obilazak moraju očuvati rezultate istog semantičkog objekta. Rigidna rotacija/translacija čuva molekulске distance; za kristal mora se dosledno transformisati ceo model, uključujući ćeliju, koordinate i simetriju. Periodični wrap i ekvivalentan ASU/setting moraju očuvati fizičko pakovanje. Uklanjanje stereo oznake smanjuje dokaz identiteta; odvajanje metala menja koordinacioni graf; dodavanje vode menja puni kristalni sastav, dok unapred definisan parent-only rezultat može ostati isti. To nisu tri bezuslovne invarijanse.

Ocena evidence-rich para

Stavka	0	1	2
component relation	izostavljena	zaključak bez mapping-a	mapping + unmatched + role evidence

Stavka	0	1	2
graph	score samo	policy ili coverage	mapping + policy + coverage + differences
coordination	metal present	distance-only	donor membership + CN/geometry + uncertainty
3D	raw RMSD	RMSD + N	mapping/alignment/coverage/symmetry provenance
packing	space group only	cell comparison	periodic packing method + parameters + evidence
interactions	short contacts	typed contacts	geometry + periodic image + H/disorder confidence
quality	ignorisana	jedan R value	multi-field compatibility + missing/error status
conclusion	universal scalar	component scores	task claim + confidence + abstention where needed

Ako je svih osam redova primenljivo, maksimum je 16, a za prolaz treba najmanje 13. Red koji po unapred izabranom pitanju nije primenljiv označi N/A i izuzmi iz maksimuma; prag je 13/16 dostupnih bodova, zaokružen naviše (npr. šest primenljivih redova: najmanje 10/12). Nivo potreban za claim kome samo nedostaje dokaz ostaje u oceni, ne postaje N/A. Ni u jednom primenljivom component, coordination, packing ili quality redu ne sme biti nula. Ovo je nastavna rubrika, ne validirani naučni prag.

L11 — referenca i PXRD kontrola

- empirical percentile je $100(247/250) = 98.8$;
- robustni imenilac je $1.4826 \cdot 0.012 = 0.0177912$, pa je $z_{\text{robust}} = (1.390 - 1.340)/0.0177912 \approx 2.81$;
- kružna udaljenost između -179° i $+179^\circ$ je 2° ;
- $d(200) = 5.6400/2 = 2.8200 \text{ \AA}$;
- za $\lambda = 1.5406 \text{ \AA}$, $2\theta \approx 31.7^\circ$;
- dozvoljen claim: „model predviđa pik oko $31,7^\circ$ pod navedenim simulation settings-ima“;
- claim „bulk uzorak je ova faza“ zahteva nezavisno izmeren PXRD, metadata/protokol i kontekst mešavine/texture/background-a;
- individual HBP propensity, observed status, grouping i coordination score moraju ostati odvojeni, uz fitting counts i applicability.

Najvažniji kriterijum

Tačan broj bez značenja nije dovoljno rešenje. Za svaku vrednost odgovori:

1. iz kog polja/atoma je došla;
2. kojim pravilom je izvedena;
3. koja je jedinica i uncertainty;
4. koja verzija alata/profile-a;
5. koji slučaj bi je učinio neupotrebljivom.

Brzi pojmovni podsetnik

Ova strana sažima teorijske razlike koje treba razumeti. Nije operativna kontrolna tabla, runbook, release checklist ili redosled realizacije projekta.

Prvo pitanje nije: koji model?

Prvo odredi **koji objekat** porediš i **po kom svojstvu**. Sastav, molekulski graf, koordinaciono okruženje, 3D konformacija, kristalno pakovanje i mreža interakcija nisu ista stvar. Jedan broj bez tih specifikacija nema stabilno naučno značenje.

Dve aplikacije na nivou problema

	Aplikacija 1 — globalna CSD pretraga	Aplikacija 2 — precizno poređenje svih parova
ulaz	jedan korisnički CIF i potvrđeni filter/search intent	skup korisničkih CIF-ova i potvrđeni comparison intent
pitanje	koji zapisi iz dozvoljenog korpusa su relevantni za imenovanu vrstu sličnosti?	kako se svaki potreban par slaže i razlikuje po imenovanim osama?
tipičan algoritamski obrazac	širok candidate retrieval i skuplja provera/rangiranje	component/atom mapping i više odvojenih poređenja
ključni rizik	brz metod tiho propušta relevantne strukture	prividno precizan score spaja neuporedive pojmove
naučni dokaz	ekspertna relevantnost, coverage, recall/ranking i jasno ograničenje populacije	evidence po osi, coverage/status i invariance provere
otvorene odluke	search modes, filteri, korpus, izlaz, prava i metrike	comparison profile, grane, agregacija, limiti, prava i metrike

Šta tačno znači „slično“?

Svaki claim može se dopuniti ovako:

Za objekat ____, u svrhu odluke ____, relevantnost znači ____; obavezno razlikujemo ____, a rezultat važi samo kada su dostupni ____.

Sloj	Pitanje	Potreban evidence	Šta ne dokazuje
sastav	isti elementi, broj atoma, naboj i komponente?	formula/component kontekst	isti graf ili ista supstanca
2D graf	isti scaffold, podstruktura ili povezanost?	graph policy i atom mapping	ista konformacija ili packing
koordinacija	isti metal, donor set, CN i geometrija?	metal–donor mapping, geometrija i neizvesnost	samo prisustvo metala u entry-ju
3D konformacija	mapirani atomi imaju sličan raspored?	mapping, alignment, coverage i RMSD	isti periodični kristal
ćelija/rešetka	metrike rešetke su kompatibilne?	kompatibilna/redukovana ćelija i tolerancije	isti packing
packing	isto periodično okruženje molekula?	periodični cluster, coverage, RMSD i parametri	isto svojstvo ili stabilnost

Sloj	Pitanje	Potreban evidence	Šta ne dokazuje
interakcije	isti definisani kontakti/motivi/mreže?	definicije, geometrija, periodična topologija i uncertainty	energiju bez dodatnog modela
svojstvo	slično ponašanje za tačno određeni target?	vrednost, jedinica, uslovi, forma i provenance	strukturnu identičnost

Pet nivoa identiteta

```

hemijski scaffold
├─ molekulska/protonaciona vrsta
│   └─ sastav čvrste forme
│       └─ polymorph/phase
│           └─ pojedinačno kristalografsko određivanje

```

„Isto“ na višem nivou ne garantuje isto na nižem. Dva polymorph-a mogu imati isti molekulski graf; dva redetermination zapisa mogu predstavljati istu fazu; salt i neutralna forma ne postaju isti materijal samo uklanjanjem counterion-a.

Formati i gubitak značenja

Format	Tipično čuva	Tipično ne čuva ili ostavlja zavisnim od alata
CIF	ćeliju, simetriju, atom sites, occupancy i eksperimentalne metadata	kompletan i nedvosmislen molekulski bond graph
MOL/SDF	molekulski graf i opcione koordinate/properties	periodičnost, packing i većinu eksperimentalnog konteksta
MOL2	atom/bond tipove, substructure i opcione charge-e	univerzalno tačnu metalnu povezanost ili pun crystal provenance
SMILES	kompaktan molekulski graf	ćeliju, packing, eksperimentalnu konformaciju i često potpunu stereo/metal semantiku

Uspešna konverzija je sintaktički događaj, ne dokaz semantičke bezgubitnosti.

DAP/CQS činjenice

- oba sačuvana upita sadrže isto povezano 18-atomsko DAP query jezgro sa dve $C=N$ veze;
- drugi dodaje nepovezani 4M atom;
- 4M zahteva element iz ConQuest legacy grupe „all metals“ negde u istom entry-ju (grupa uključuje i Ge/Sb); ne dokazuje DAP–metal koordinaciju;
- search2 je strogi podskup search1, ali membership nije coordination gold;
- potencijalna tri donorska N atoma nisu isto što i opažena tridentatna koordinacija;
- naziv query fajla izražava ljudsku nameru, dok constraints određuju šta je stvarno pretraženo.

Nameravani DAP i coordination scope ostaje nepotvrđena fakultetska odluka.

Kristalografske invarijanse

Ekvivalentan zapis može promeniti:

- redosled atoma ili komponenti;
- izbor origina i periodične slike;

- cell setting ili kompatibilnu basis predstavu;
- ASU prikaz i symmetry-operation redosled;
- translaciju/rotaciju molekulske geometrije.

Promena zapisa ne sme automatski postati promena fizičkog kristala. Nasuprot tome, ista formula, space-group etiketa ili reduced cell ne dokazuju isti packing.

Mapping pre metrike

Component mapping prethodi atom mapping-u, a hemijski validan atom mapping prethodi RMSD-u. RMSD bez common core-a, coverage-a, alignment/symmetry/stereo pravila i porekla koordinata nema stabilno značenje.

Za neuređene parove važi:

$$N_{pairs} = \frac{n(n-1)}{2}.$$

Kvadratna složenost je matematička činjenica; scheduler, cache, storage i produkcionni limiti nisu deo ovog podsetnika.

Quality, missing i uncertainty

- R faktor nije accuracy procenat.
- `parse success` nije dokaz hemijske ni kristalografske validnosti.
- disorder, partial occupancy i missing H menjaju primenljivost pojedinih analiza.
- `not comparable`, `missing`, `ambiguous` i validni score 0 nisu sinonimi.
- simulated PXRD iz CIF-a nije nezavisna potvrda istog CIF modela.
- Mogul/HBP outlier ili propensity nije energija, stabilnost ili dokaz polimorfa.

ML/AI razlike

- exact oracle proverava aproksimativni ANN indeks; ekspertni gold proverava semantičku relevantnost;
- candidate recall i finalni ranking nisu ista metrika;
- random split bliskih structure families može dati leakage;
- property target mora biti vezan za formu, jedinicu, uslove, metod i vreme;
- model ili embedding ne zamenjuje parser, PBC, atom mapping, licencu ili stručni dokaz;
- složeniji model je opravdan samo ako pod istim uslovima rešava imenovanu grešku.

Licence i FAIR

- „mogu da pročitam“ nije „smem da obrađujem ili delim“;
- private GitHub nije dozvola za CSD redistribuciju;
- FAIR nije isto što i open, bez greške ili licencno slobodno;
- raw podatak, izvedeni feature, embedding, model i report mogu imati različita prava;
- vendor opis funkcije nije dokaz institucijskog product tier-a ili entitlement-a;
- FL ne daje automatski confidentiality, privacy, security ili licencnu usklađenost.

Provera znanja

1. Isti molekulski graf i drugačiji packing — koji slojevi se slažu, a koji ne moraju?
2. Zašto reduced-cell pogodak nije dokaz istog polimorfa?
3. Koje informacije uz RMSD sprečavaju najčešću pogrešnu interpretaciju?
4. Šta je ispravan zaključak packing grane kada CIF nema ćeliju?
5. Da li CSD-derived embedding automatski sme u javni repo?
6. Zašto 4M nije koordinaciona etiketa?

Odgovori

1. Slaže se 2D identitet/graf; konformacija može, ali ne mora; packing i interaction mreža mogu biti različiti.
2. Različiti kristali mogu imati sličnu metriku ćelije; potrebno je periodično poređenje mapiranih molekula i eksplicitni parametri.
3. Common core/atom mapping, broj i coverage mapiranih atoma, alignment/symmetry/H/stereo pravilo i poreklo koordinata.
4. Analiza nije podržana zbog missing input-a; to nije score 0.
5. Ne. Potrebno je proveriti ugovor, derivative prava, rekonstruktivnost i pisano odobrenje.
6. Zato što query zahteva samo metal negde u entry-ju, bez veze ili geometrijskog constraint-a ka DAP motivu.

Rečnik pojmova

Rečnik je namenjen ML inženjeru koji kreće od nule. Definicije su dovoljno precizne za projektovanje dve 2CDC aplikacije, ali nisu zamena za puni IUPAC/IUCr rečnik. Kada termin ima više značenja, ovde je navedeno značenje koje mora stajati u data contract-u ili izveštaju.

Najopasnija reč je „struktura“

Može označavati molekulski graf, jednu 3D konformaciju, kristalnu strukturu, eksperimentalni model ili zapis u bazi. U zahtevima i šemi koristi precizniji termin.

Kako čitati oznake

Oznaka	Značenje
Å	ångström, 10^{-10} m; tipična jedinica atomskih rastojanja
°	stepen; koristi se za uglove i torzije
K	kelvin; apsolutna temperatura
s.u.	standard uncertainty, standardna neizvesnost
ASU	asymmetric unit, asimetrična jedinica
CN	coordination number, koordinacioni broj
F, F^2, I	strukturna amplituda, njen kvadrat i izmereni intenzitet
(hkl)	Millerovi indeksi refleksije/ravni
R, wR, GoF	različiti pokazatelji slaganja modela i difrakcionih podataka
Z, Z'	formula units u ćeliji; nezavisne formula units u ASU u jednostavnom slučaju

Osnovni hemijski jezik

Atom, element i čestice

Atom

Najmanja elektroneutralna jedinica elementa koja zadržava njegov hemijski identitet: jezgro sa protonima i neutronima i elektronski omotač. U molekulskom grafu je čvor, ali „atom site“ u kristalografiji je model položaja/populacije, ne nužno jedna trajno označena čestica.

Proton / neutron / elektron

Proton ima pozitivno elementarno naelektrisanje, neutron je neutralan, elektron negativan. Broj protona određuje element; promena broja elektrona daje jon; promena broja neutrona daje izotop.

Atomski broj Z_{atom}

Broj protona u jezgru. Ne mešati ga sa kristalografskim Z , brojem formula units u ćeliji.

Element

Vrsta atoma sa istim atomskim brojem. Simbol **Cu** znači bakar samo kada je hemijski element u odgovarajućem polju; **Cu K α** opisuje rendgensko zračenje sa bakarne mete.

Izotop

Atomi istog elementa sa različitim brojem neutrona. Izotopska oznaka može uticati na masu i ponekad svojstva; exact-match politika mora reći da li je razlikuje.

Jon / katjon / anjon

Jon ima neto električno naelektrisanje; katjon je pozitivan, anjon negativan. Poliatomski jon sadrži više povezanih atoma sa ukupnim nabojem.

Jedinke, sastav i količina

Hemijska vrsta (chemical species)

Skup hemijski identičnih molekulskih entiteta u definisanom kontekstu. U praksi treba navesti charge, izotopsko i stereo stanje kada utiču na identitet.

Molekulski entitet

Pojedinačna konstitucionalno ili izotopski određena jedinka koja može biti molekul, jon, radikal i slično. Precizniji termin od svakodnevnog „molekul“ kada su uključeni joni.

Molekul

Elektroneutralna jedinka sa više atoma povezanih dovoljno snažno da se tretiraju kao celina. Jonski kristal poput NaCl nema diskretne NaCl molekule u istom smislu; koristi se formula unit.

Jedinjenje

Čista supstanca sastavljena od dva ili više elemenata u određenom odnosu. Ne govori automatski da li su osnovne jedinice diskretni molekuli, joni ili mreža.

Komponenta / fragment

Povezana ili funkcionalno izdvojena celina u zapisu. U soli su katjon i anjon odvojene komponente; u solvatu je rastvarač posebna komponenta. „Fragment“ može biti tehnički rezultat cepanja grafa i ne sme automatski dobiti hemijsku ulogu.

Formula unit

Najmanji stehiometrijski odnos sastojaka koji predstavlja sastav nemolekulskog/jonskog materijala ili se koristi kao računovodstvena jedinica kristala. Z broji formula units u ćeliji, prema formuli prijavljenoj u CIF-u.

Empirijska formula

Najjednostavniji celobrojni odnos elemenata. Ne daje povezanost, oblik, naboj po komponenti ni čvrstu formu.

Molekulska formula

Stvarni broj atoma svakog elementa u molekulu, ali i dalje ne određuje graf: C_2H_6O može biti etanol ili dimetil-etar.

Formula sum / formula moiety

CIF polja za ukupni sastav i opis komponenti. Treba ih proveriti prema atom sites, occupancy, symmetry multiplicity i Z ; nisu nepogrešiva etiketa.

Stehiometrija

Kvantitativni odnos sastojaka. U kokristalu 1:1 i 2:1 nisu ista forma; occupancy i disorder ne smeju pokvariti račun.

Mol

SI jedinica količine supstance, tačno $6,02214076 \times 10^{23}$ navedenih jedinki. Ne mešati sa „mol“ molekulskim formatom.

Relativna molekulska masa / molarna masa

Prva je bezdimenziona relativna veličina; druga je masa po količini supstance, tipično $g\ mol^{-1}$. CIF formula weight ulazi u račun kristalne gustine.

Elektroni, naboji i veze

Valentni elektron

Elektron u spoljašnjem delu elektronske strukture koji najviše učestvuje u hemijskom vezivanju. Jednostavna pravila grupa dobro rade za glavne elemente, manje univerzalno za prelazne metale.

Lewisova struktura

2D računovodstveni prikaz valentnih elektrona, veza i slobodnih parova. Koristan model; nije slika elektronske gustine i često je nedovoljan za metale/delokalizaciju.

Slobodni elektronski par (lone pair)

Par valentnih elektrona formalno nevezan u Lewisovom prikazu. Može omogućiti baznost, H-bond prihvatanje ili koordinaciju metalu, ali dostupnost zavisi od protonacije, rezonance i geometrije.

Formalni naboj

Celobrojna knjigovodstvena dodela elektrona unutar izabrane Lewisove strukture. Nije isto što i oksidaciono stanje ili parcijalni naboj.

Oksidaciono stanje

Formalni broj dobijen jonskom aproksimacijom raspodele veznih elektrona. Koristan je za metalnu hemiju, ali se ne čita pouzdano samo iz oznake elementa ili koordinacionog broja.

Parcijalni naboj

Modelom dodeljen neto naboj atoma, obično necelobrojan, ali može biti i nula. Zavisi od načina raspodele elektronske gustine; `NO_CHARGES` u MOL2 znači da takav model nije dodeljen, ne da su atomi nepolarni.

Hemijska veza

Stabilizujuća interakcija koja drži atome u hemijskoj celini. Granice između „jonske“, „kovalentne“ i „koordinacione“ nisu tri nepovezana fizička prekidača.

Kovalentna veza

Vezivanje povezano sa deljenjem elektronske gustine između atoma. Jednostruka/dvostruka/trostruka oznaka je koristan model reda veze.

Jonsko vezivanje

Elektrostatičko privlačenje suprotno naelektrisanih jedinki u široj strukturi. Jonski kristal je periodična mreža, ne nužno zbir izolovanih parova.

Koordinaciona (dativna) veza

U Lewisovom formalizmu zajednički par potiče od donora/liganda i veže se za centralni atom. Posle formiranja nije univerzalno posebna vrsta `bond type` koju svaki format čuva.

Red veze (bond order)

Model multipliciteta/delokalizacije veze. Integer `1/2/3`, aromatični ili `unknown` tip zavise od representation modela; rendgenska difrakcija ga ne meri direktno kao etiketu.

Rezonanca / delokalizacija

Više Lewisovih crteža deli isti raspored jezgara, a prava elektronska struktura nije smenjivanje tih crteža već delokalizovan hibrid.

Aromatičnost

Stabilizovana ciklična delokalizacija definisana određenim hemijskim kriterijumima. Aromaticity perception je algoritamski model; različiti alati mogu dati različite `ar` oznake.

Elektronegativnost

Relativna tendencija atoma u vezi da privlači elektronsku gustinu. Koristi se kvalitativno; postoji više skala.

Polarna veza / dipolni moment

Polarna veza ima neravnomernu raspodelu naboja. Molekulski dipol je vektorski zbir doprinosa i zavisi od 3D geometrije; polarne veze mogu dati nepolaran molekul ako se vektori ponište.

Intermolekulska interakcija

Privlačna/odbojna interakcija između hemijskih jedinki: disperzija, dipol–dipol, H-veza, halogena veza, jon–dipol i druge. Geometrijski kontakt je kandidat, ne automatski dokaz energetski dominantne „veze“.

Vodonična veza

Usmerena privlačna interakcija u kojoj H vezan za donor učestvuje sa prihvataocem, uz hemijske i geometrijske dokaze. Nije svaki kratak $H\cdots X$ kontakt H-veza.

Halogena veza

Privlačna interakcija u kojoj elektrofilni region halogenog atoma tipično usmereno interaguje sa nukleofilnim regionom. Potrebni su kontekst i geometrija.

Organska, stereo i acid–base hemija

Funkcionalna grupa

Prepoznatljiv atomski motiv koji daje tipično hemijsko ponašanje: karbonil, imin, hidroksil, piridin i slično. Ista grupa u drugačijem charge/rezonantnom okruženju može imati drugu donor/acceptor ulogu.

Scaffold

Izabrano osnovno molekulsko jezgro za poređenje. Nema jednu univerzalnu definiciju; algoritam, prstenovi, side-chain pravila i metal handling moraju biti verzionisani.

DAP

U ovom projektu DAP znači 2,6-diacetilpiridin. Lokalni ConQuest upiti sadrže 18-atomske DAP-derived query jezgre sa dve $C=N$ veze. Sama podstrukturalna podudarnost ne dokazuje da je pogodak bis-imin ili Schiffova baza; to zahteva proveru neposrednog supstituenta na svakom $C=N$ azotu u kompletnoj strukturi. Tačan pozitivni opseg (supstituenti, protonacija, donor set, bridging) mora potvrditi naučni tim.

Schiffova baza / imin

Imin sadrži motiv $C=N$. U užoj IUPAC definiciji *Schiffove baze*, na iminskom N je vezana hidrokarbilna grupa, npr. alkil ili aril; tipičan put nastanka je kondenzacija primarnog amina i karbonilnog jedinjenja. Sama $C=N$ veza zato nije dovoljna etiketa: oksim $C=N-OH$ i hidrazon $C=N-N$ pripadaju drugim klasama. Iminski N može biti donor, ali protonacija i supstitucija menjaju ponašanje.

Kiselina/baza po Brønsted–Lowryju

Kiselina donira proton; baza prima proton. Acid–base stanje menja formalni naboj, H-bond uloge, komponente i često čvrstu formu.

Lewisova kiselina/baza

Lewisova kiselina prihvata elektronski par, a baza ga donira. Metalni centar i ligandni donor se često opisuju tim jezikom.

pKa

Logaritamska mera ravnoteže disocijacije kiseline u određenom rastvaraču, temperaturi i standardnom stanju. Nije nepromenljiva etiketa samog CIF-a.

Protomer

Jedna od struktura koje se razlikuju položajem dodatog/uklonjenog protona pri datom ukupnom sastavu/naboju. Protonation standardization može promeniti query rezultat.

Tautomer

Konstitucioni izomeri koji se tipično razlikuju položajem protona i dvostruke veze i mogu međusobno da se pretvaraju. Brzina i ravnoteža zavise od rastvarača, pH, temperature, katalize i energetske barijere; u čvrstoj fazi tautomer može biti stabilizovan ili kinetički zarobljen. „Tautomer canonicalization“ je projektna politika, ne neutralno formatiranje.

Izomer

Jedno od jedinjenja sa istom molekulskom formulom, ali različitim rasporedom atoma ili prostornim uređenjem.

Konstitucioni izomeri

Imaju istu formulu, ali različitu povezanost atoma. Formula filter ih ne razlikuje.

Stereoizomeri

Ista povezanost, različit prostorni raspored koji nije samo rotacija celog objekta.

Enantiomeri / diastereoizomeri

Enantiomeri su nesuperponibilne ogledalske slike; diastereoizomeri nisu ogledalski par. Racemat sadrži jednake količine enantiomera, ali kristalno ponašanje zavisi od forme.

Hiralnost

Osobina objekta koji se ne može superponirati sa ogledalskom slikom. Centar hiralnosti je čest, ali nije jedini izvor hiralnosti.

Konfiguracija

Stereo raspored čija promena zahteva prekid/rekonstrukciju veze ili drugi diskretan stereo događaj; npr. R/S ili E/Z.

Konformacija / konformer

3D raspored dostupan rotacijama i fleksijom bez promene povezanosti; konformer je jedna takva geometrija. Kristalna konformacija i generisana low-energy konformacija imaju različit provenance.

Torzioni (diedarski) ugao

Orijentacija četiri uzastopna atoma. Periodičan je; razliku treba računati kružno, ne običnim oduzimanjem blizu $-180^\circ/180^\circ$.

Rotabilna veza

Algoritamski definisana veza oko koje je relevantna konformaciona rotacija. Amidi, prstenovi i terminalne veze se tretiraju različito po definiciji alata.

Koordinaciona hemija

Centralni atom / metalni centar

Atom, često metal, oko koga su ligandi uređeni u koordinacionoj jedinki. Jedan entry može imati više centara.

Ligand

Atom, jon ili molekulska grupa vezana za centralni atom; u ovom projektu obično organska komponenta koja preko jednog ili više donor-atoma donira jedan ili više elektronskih parova metalu u Lewisovom formalizmu.

Donorni atom

Konkretan ligandni atom koji je direktno koordinisan centralnom atomu, npr. iminski ili piridinski N. Prisustvo N u ligandu ne dokazuje da je taj N donor u konkretnoj strukturi.

Koordinaciona jedinka (coordination entity)

Centralni atom sa okolnim ligandima tretiranim kao celina. Nije isto što i ceo kristalni entry: counterioni i solventi mogu biti izvan jedinke.

Koordinacioni kompleks

Uobičajen naziv za coordination entity/jedinjenje koje je sadrži. U specifikaciji navedi da li porediš jedinku, neutralni kompleks, so ili punu kristalnu formu.

Koordinacioni broj (CN)

Broj direktno koordinisanih donor-atoma centralnom atomu prema eksplicitnom neighbor/bond modelu. Nije broj liganada: jedan tridentatni ligand daje tri donora.

Denticitet

Broj donor-atoma jednog liganda koji se istovremeno vezuju za isti centralni atom: mono-, bi-, tri- itd. Zapisuje se uz mapping, ne procenjuje iz imena liganda.

Helat

Prstenasta coordination arrangement nastala kada polidentatni ligand veže isti metal preko više donora.

Mostni ligand (bridging ligand)

Ligand koji povezuje dva ili više centara. Algoritam koji svaku komponentu dodeli tačno jednom metalu gubi ovu informaciju.

Haptičnost η^n

Broj susednih atoma delokalizovanog ligandnog segmenta koji zajedno koordiniraju metalu. Nije isto što i denticitet.

Koordinaciona geometrija

3D raspored donor-atoma oko centra, npr. linearna, tetraedarska, kvadratno-planarna, trigonalno-bipiramidalna ili oktaedarska. CN sam ne određuje geometriju.

Distortion measure / shape measure

Numeričko odstupanje realnog coordination polyhedron-a od idealne geometrije. Definicija, mapping i referentni ideal moraju pratiti vrednost.

Koordinacioni polimer / mreža

Periodična struktura u kojoj coordination veze šire jedinku u 1D, 2D ili 3D. „Izdvoji najveći molekul“ može biti besmisleno jer nema konačne diskretne jedinice bez presecanja mreže.

Metal-organic

Široka kategorija struktura sa metalom i organskim delom. Ne znači nužno organometalno u užem smislu sa direktnom metal–ugljenik vezom.

Ligandno polje

Model cepanja energija metalnih orbitala usled usmerenog okruženja liganada. U ovom kursu koristi se kvalitativno da bi se razumeli spin-zavisne distance, square-planar/tetrahedral grananje i elektronske distorzije; duboki multipletni/spektroskopski račun nije deo uvodnog nivoa kursa.

High-spin / low-spin Različiti načini popunjavanja split d -orbitala kada se nadmeću ligand-field splitting i pairing energija. Etiketa se ne izvodi samo iz coordination number-a ili jedne distance.

Jahn–Teller efekat Distorzija nelinearnog sistema koja uklanja elektronsku degeneraciju i može sniziti energiju. Pseudo-octahedral Cu(II), d^9 , često pokazuje aksijalnu elongaciju; isti geometrijski obrazac sam nije dokaz uzroka.

Kristal, ćelija i simetrija

Kristal

Čvrst materijal sa dugodometnim uređenjem koje daje diskretan difrakcioni obrazac. Realni kristali imaju defekte, termalno kretanje i mogući disorder.

Kristalna struktura

U operativnom scope-u ove knjige: konvencionalna 3D periodična malomolekulska struktura opisana rešetkom, motivom i simetrijom. Nije sinonim za jedan molekul niti za CIF fajl. Širi kristalografski pojam obuhvata i aperiodične kristale, pa ovu projektnu definiciju ne treba predstavljati kao univerzalnu.

Rešetka (lattice)

Matematički periodičan skup translaciono ekvivalentnih tačaka. Svaki rešetkasti vektor je celobrojna kombinacija vektora primitivnog bazisa; kod centriranog konvencionalnog bazisa njegove celobrojne kombinacije daju podrešetku, a centrirajući vektori daju preostale tačke. Atomi nisu „rešetka“; kristalna struktura nastaje vezivanjem motiva za rešetku.

Motiv / basis

Skup atoma/jedinki pridružen svakoj rešetkastoj tački da bi se izgradila struktura. Ne mešati sa basis vektorima ćelije.

Jedinična ćelija

Paralelepiped definisan vektorima **a**, **b**, **c** kojim se opisuje periodičnost rešetke. Kod primitivne ćelije njihove celobrojne translacije dosežu sve rešetkaste tačke; centrirana konvencionalna ćelija sadrži dodatne centrirajuće tačke. Nije jedinstven izbor; ista struktura može imati ekvivalentne ćelije/settings.

Parametri ćelije

Dužine a, b, c i uglovi α, β, γ . Zapremina za opšti slučaj potiče iz determinante cell matrix/metric tensor-a; slični parametri ne dokazuju isti packing.

Primitivna / konvencionalna ćelija

Primitivna ima jednu rešetkastu tačku po ćeliji; konvencionalna je standardno izabrana radi jasne simetrije i može biti centrirana.

Redukovana/standardizovana ćelija

Kanonskiji opis metrike dobijen definisanim algoritmom, koristan za candidate search. Rezultat zavisi od tolerancija i ne dokazuje strukturni identitet.

Kristalni sistem / Bravaisova rešetka

Sedam kristalnih sistema grupišu space groups po point-group simetriji. Sedam rešetkastih sistema razlikuju se u hexagonal familiji: koriste rhombohedral umesto trigonal kategorije. Četrnaest Bravaisovih tipova (aP – cF) klasifikuju translacione rešetke i centriranje; to nisu similarity score-evi. Trigonalni kristal može imati hP ili hR rešetku.

Frakciona koordinata

Koeficijenti (x, y, z) u osnovi ćelije: $\mathbf{r} = x\mathbf{a} + y\mathbf{b} + z\mathbf{c}$. Vrednosti koje se razlikuju za ceo broj predstavljaju periodično ekvivalentne položaje.

Kartezijanska koordinata

Koordinata u ortogonalnom 3D sistemu, tipično u ångströmima. Pretvaranje iz frakcionih zahteva punu cell matrix, ne samo množenje sa (a, b, c) kod neortogonalne ćelije.

Periodični granični uslovi (PBC)

Suprotne strane ćelije predstavljaju susedne kopije periodičnog prostora. Najkraći kontakt može prelaziti granicu ćelije.

Operacija simetrije

Transformacija koja ostavlja strukturu ekvivalentnom: translacija, rotacija, screw, refleksija/glide, inverzija i kombinacije.

Prostorna grupa (space group)

Grupa svih simetrijskih operacija periodične strukture. Postoji 230 tipova u 3D; oznaka poput $P2_1/c$ ne određuje hemijski identitet ni packing sama po sebi.

Setting / origin choice

Konvencija osa, baze i koordinatnog početka za isti space-group type. Ekvivalentni $P2_1/c$ i $P2_1/n$ zapisi mogu opisivati istu strukturu u drugom setting-u.

Asimetrična jedinica (ASU)

Minimalni nezavisni deo iz kog simetrijske operacije generišu ceo kristalni sadržaj. Nije nužno jedan ceo molekul niti cela ćelija.

Opšta / specijalna pozicija

Opšta pozicija nema dodatnu site simetriju i obično ima punu multiplicity; specijalna leži na elementu simetrije i ima manju multiplicity. To utiče na occupancy i broj atoma u ćeliji.

Multiplicity

Broj simetrijski ekvivalentnih mesta generisanih iz jednog atom site-a u ćeliji. Nije isto što i occupancy.

Z

Broj prijavljenih formula units u jediničnoj ćeliji. Zavisi od izabrane formule i ćelije; nije atomski broj.

Z' („Z prime“)

Broj formula units u ASU prema izabranoj hemijskoj formuli: $Z' = Z/m$, gde je m multiplicity opšte pozicije prostorne grupe za istu ćeliju. Važi i za specijalne pozicije, kada Z' može biti razlomak. Samo u jednostavnom molekulskom slučaju ovaj broj može se čitati kao broj celih nezavisnih molekula. Za polimere, disorder i višekomponentne forme posebno objasni izbor formule i ASU sadržaj. [IUCr definicija](#).

Kristalno pakovanje (packing)

Periodični način rasporeda i orijentacije molekula/komponenti. Isti molekul može imati različit packing; ista ćelija/space group nije dovoljan dokaz istog packing-a.

Kristalni habit

Spoljašnji oblik kristala uslovljen relativnim brzinama rasta lica. Različit habit ne mora značiti različitu unutrašnju kristalnu strukturu.

Mreža kontakata / interaction graph

Graf periodičnih suseda prema navedenim definicijama H-veza, koordinacije ili kontakta. Rezultat zavisi od cutoffs, uglova, H položaja i disorder-a.

Difrakcija, model i kvalitet

Rendgenska difrakcija

Elastično rasipanje rendgenskih talasa na elektronskoj gustini kristala. Meri se obrazac intenziteta; atomski model se rešava i refinira iz podataka.

Braggov zakon

Uslov konstruktivne difrakcije $2d \sin \theta = n\lambda$, gde je d razmak familije ravni, θ ugao, λ talasna dužina, a n red.

Recipročna rešetka

Matematički prostor u kome se periodične ravni i difrakcione refleksije prirodno opisuju. U konvenciji bez 2π , $\mathbf{g}_{hkl} = h\mathbf{a}^* + k\mathbf{b}^* + l\mathbf{c}^*$ i $d(hkl) = 1/||\mathbf{g}_{hkl}||$.

Millerovi indeksi (hkl)

Celobrojne oznake familija rešetkastih ravni/refleksija. Nisu atomske koordinate.

Refleksija

Jedna tačka/merenje intenzitet u difrakcionom skupu vezan za (hkl). Symmetry-equivalent merenja mogu se spojiti u jedinstvenu refleksiju.

Systematic absence / extinction Refleksija zabranjena translacionim delom space-group simetrije, npr. centriranjem, screw ili glide operacijom. Razlikuje se od dozvoljene, ali slabe/neopažene refleksije.

Simulirani / izmereni PXRD Simulirani pattern je deterministički derivat crystal model-a pod navedenim wavelength/profile settings-ima. Izmereni PXRD dolazi iz bulk uzorka i instrumenta; može podržati fazni identitet ili mešavinu, ali sam ne potvrđuje svaki SCXRD atom/refinement detalj.

Strukturni faktor F_{hkl}

Kompleksna amplituda izračunata kao zbir rasipanja svih atoma sa fazama određenim položajima. Intenzitet je približno proporcionalan $|F|^2$.

Fazni problem

Detektor meri intenzitete, ali ne direktno faze strukturnih faktora. Rešavanje strukture mora proceniti faze/model pre refiniranja.

Rešavanje strukture

Dobijanje početnog atomskog modela iz difrakcionih podataka i hemijskog znanja. Razlikuje se od kasnijeg refiniranja.

Refiniranje

Optimizacija parametara modela (položaji, displacement, occupancy...) da bi izračunati podaci bolje odgovarali opaženim, uz restraints/constraints i težine.

Least squares

Optimizacija zbira težinskih kvadrata ostataka. Mala vrednost ciljne funkcije ne garantuje da je model jedinstven ili hemijski ispravan.

R faktor

Konvencionalni ostatak zasnovan na razlikama opaženih i izračunatih amplituda. Mora se navesti skup refleksija, npr. all ili gt ; univerzalni quality cutoff nije validan.

wR

Težinski ostatak, često na F^2 . Zbog druge formule i težina obično nije direktno uporediv sa konvencionalnim R.

GoF / S

Goodness of fit: odnos težinskih ostataka prema broju stepeni slobode. Vrednost blizu 1 ima smisla samo uz realistične weights/uncertainties; nije sertifikat tačnosti.

R_{int}

Mera međusobnog slaganja symmetry-equivalent refleksija pre/pri spajanju. Govori o konzistentnosti merenja/obrade, ne direktno o potpunosti atomskog modela.

Completeness

Udeo očekivanih jedinstvenih refleksija izmerenih do određenog ugla/rezolucije prema definisanoj geometriji. Mora se navesti rezolucioni opseg.

Resolution / d_{min}

Najmanji razmak ravni obuhvaćen podacima; manje d_{min} znači višu prostornu rezoluciju. „Visok broj“ i „visoka rezolucija“ mogu jezički zbuniti.

Redundancy

Prosečan broj ponovljenih merenja iste/jednake refleksije. Viša redundancija može poboljšati procenu, ali nije zamena za kvalitet ili completeness.

Standardna neizvesnost (s.u.)

Neizvesnost izražena kao jedna standardna devijacija. $12.7138(3)$ znači 12.7138 ± 0.0003 u istoj jedinici, pod pretpostavkama procene.

Restraint

Meki dodatni cilj koji preferira hemijski razumno geometriju/displacement, ali dozvoljava odstupanje uz cenu. Broji se u objective-u.

Constraint

Tvrdo smanjenje slobode: parametar je fiksiran ili algebraski vezan za drugi. Ne mešati sa restraint-om.

Occupancy

Udeo populacije atomskog mesta u modelu, uz multiplicity i symmetry kontekst. Vrednost 0,5 može opisivati alternativu/disorder, ne „pola atoma u svakom kristalu“.

Disorder

Model više lokalnih položaja/orijentacija ili sastava koji se prosečno vide u kristalu. Alternative imaju povezane occupancy vrednosti; disorder nije automatski ni greška ni zanemarljiv.

ADP / U_{iso} / U_{ani} / B faktor

Atomic displacement parameter opisuje prosečnu raspodelu položaja usled termalnog kretanja i/ili statičkog nereda. Izotropni model je sfera, anizotropni elipsoid; konverzije $B \leftrightarrow U$ moraju biti eksplicitne.

Rezidualna elektronska gustina

Razlika opažene i modelovane gustine posle refiniranja. Pikovi/rupe mogu ukazati na propušten atom, apsorpciju, disorder ili druge efekte; tumače se prostorno i hemijski.

Apsorpciona korekcija

Korekcija za različito slabljenje rendgenskog zraka kroz kristal pri različitim orijentacijama. Posebno važna za jače apsorbujuće elemente/geometrije.

Twinning

Kristal/dataset koji sadrži dve ili više domena povezane određenom transformacijom, čiji se difrakcioni doprinosi preklapaju. Zahteva model twin law/fractions i utiče na quality metrics.

checkCIF / alert

IUCr validacioni servis i skup testova. Alert je strukturisan signal za proveru/objašnjenje, ne automatska presuda; odsustvo alert-a ne dokazuje hemijsku istinu.

CIF

Crystallographic Information **File** je tekstualni format sa data names, blokovima i loop tabelama. Ista skraćenica označava i Crystallographic Information **Framework**, širi okvir koji obuhvata rečnike i pravila razmene/validacije. Fajl može sadržati koordinatni model, eksperiment, strukturne faktore i ugrađene tekstualne blokove. [IUCr razjašnjenje](#).

Čvrste forme i termodinamika

Faza

Makroskopski homogena oblast sa ujednačenim fizičkim/hemijskim svojstvima. Jednofazni kristal i fizička mešavina dve faze nisu isto.

Čvrsta forma

Operativni krovni termin za određenu kristalnu ili amorfnu realizaciju supstance, uključujući polymorph, salt, solvate/hydrate ili cocrystal klasifikacije. Uvek navedi taksonomiju.

Polimorf

Jedna od različitih kristalnih struktura iste supstance/hemijskog sastava, uz definisanu terminološku konvenciju. Razlika u solventu ili proton transfer-u tipično nije „samo polimorf“.

Polimorfizam

Sposobnost supstance da postoji u više kristalnih formi. Jedan pronađen kristal ne dokazuje da drugih nema.

So

Jonska čvrsta forma sa suprotno naelektrisanim komponentama, često nastala proton transfer-om acid/base para. Položaj H i charge evidence mogu biti nejasni.

Solvat / hidrat

Kristal koji uključuje molekule rastvarača; hidrat je solvat sa vodom. Gubitak rastvarača može promeniti strukturu; solvat nije samo „nečistoća“.

Anhidrat

Forma bez kristalne vode. Ne znači da uzorak nikada nije bio izložen vodi ili da je jedina moguća forma.

Kokristal (co-crystal)

Jednofazni kristalni materijal sa dve ili više različitih komponenti u određenom odnosu, pod stručnom definicijom koja ga razlikuje od prostog solvata/soli. Granica salt–cocrystal može zahtevati dokaz protonacije.

Amorfno stanje

Čvrsto stanje bez dugodometnog kristalnog periodičnog uređenja. Nema jednu crystal cell/space group; lokalno uređenje ipak postoji.

Kristalni pseudopolimorf

Stariji/nejednoznačan izraz često korišćen za solvate/hydrates. Bolje je eksplicitno reći solvat/hidrat.

Termodinamička stabilnost

Niža odgovarajuća Gibbsova slobodna energija pri konkretnim (T, p) , sastavu i hemijskim potencijalima. Nije apsolutna etiketa forme za sve uslove.

Metastabilna forma

Lokalni minimum slobodne energije koji može dugo opstati zbog kinetičke barijere iako druga forma ima niži G . Nije automatski greška ili bezvredna forma.

Gibbsova slobodna energija

$G = H - TS$; pri konstantnim (T, p) , razlika ΔG određuje termodinamički smer/ravnotežu pod datim uslovima. Kristalni G nije samo izolovana molekulaska energija.

Entalpija / entropija

Entalpijski doprinos obuhvata energetiku/interakcije; entropijski doprinos broji dostupnost stanja i disorder/dinamiku. Stabilnost forme zavisi od oba i od temperature.

Energija rešetke

Energetska mera kohezije kristala prema definisanom referentnom stanju. Nije puna Gibbsova slobodna energija i ne uključuje automatski sve termalne/entropijske efekte.

Nukleacija

Nastanak kritičnog jezgra nove faze. Zavisna je od supersaturacije, interfejsa, nečistoća, površina, mešanja i vremena; kinetika može izabrati metastabilnu formu.

Rast kristala

Dodavanje jedinki postojećem jezgru/licu. Uslovi rasta utiču na habit, defekte, veličinu i koja forma preživi.

Supersaturacija

Stanje u kome koncentracija/hemijski potencijal prelazi ravnotežnu vrednost za određenu formu, dajući pokretačku silu za nukleaciju/rast. Vezana je za konkretnu formu i uslove.

Enantiotropija / monotropija

Enantiotropni polimorfi menjaju relativnu stabilnost na temperaturi tranzicije pre topljenja; kod monotropnih jedan je stabilniji kroz relevantan opseg. Eksperimentalna klasifikacija zahteva termalne/ravnotežne dokaze.

Rastvorljivost

Ravnotežna količina supstance koja se rastvara pri definisanim uslovima i specijaciji. Razlikuje se po formi i nije isto što i brzina rastvaranja.

Brzina rastvaranja (dissolution rate)

Kinetika prelaska materijala u rastvor; zavisi i od površine, habit-a, veličine čestica, mešanja i forme.

Talište / entalpija topljenja

Temperatura prelaza i toplotni efekat pod definisanim uslovima. Više talište samo po sebi ne daje univerzalni poredak stabilnosti bez pune termodinamičke analize.

Digitalni hemijski podaci i formati

Parser

Softver koji sintaksu fajla pretvara u strukturisan objekat. Uspešan parse znači da je nešto pročitano, ne da je hemija tačna.

Schema / data dictionary

Formalna definicija polja, tipova, jedinica, odnosa i dozvoljenih vrednosti. CIF rečnik daje semantiku data name-ova; proizvoljno SDF property ime nema automatski tu snagu.

MOL

MDL connection-table format za jedan molekulski zapis: atomi, veze i opcione koordinate/properties. Ne čuva periodičnost kristala.

MOL2

Tripos format sa atom/bond tipovima, substructure i opcionalnim charges. Opciona sekcija `CRYSTIN` može čuvati parametre ćelije i oznaku simetrije; to ne garantuje potpun periodični model niti očuvanje CIF occupancy/refinement konteksta. Tipovi poput `C.ar` ili `N.3` su dodela modela/izvoznika.

SDF

Structure Data File: niz MOL zapisa razdvojenih sa `$$$`, uz property polja. Zahteva eksplicitnu dataset schemu i missing/unit pravila.

SMILES

Linijski zapis molekulskog grafa. Isti graf ima više validnih SMILES; canonical SMILES zavisi od implementacije i ne čuva crystal cell/packing.

SMARTS

Jezik za strukturne obrasce/upite, sa wildcard i logičkim uslovima. SMARTS nije identifikator molekula.

InChI / InChIKey

Standardizovani IUPAC linijski identifikator i njegov sažeti hash-like ključ. Layers/policy su važni; ne kodiraju pun kristalni packing ili eksperimentalni entry.

CSD

Cambridge Structural Database: CCDC-ova kurirana, licencirana baza malih organskih i metal-organskih kristalnih struktura. Nije isto što i CCDC organizacija/portfolio.

CSD entry

Jedan bazni zapis o konkretnom strukturnom određivanju i metapodacima. Nije nužno jedinstven molekul, compound family ili čvrsta forma.

CCDC refcode

Identifikator CSD entry/family konvencije. Sličan prefiks može povezivati određivanja, ali sam string nije dovoljan ground truth za identitet forme.

ConQuest / .cqs

CCDC alat za strukturne i metadata upite; `.cqs` je binarni query/session objekat. Dostavljeni lokalni fajlovi sadrže i sačuvano stanje/rezultate, ali nisu obične prenosive result-liste. Naziv upita izražava nameru, dok stvarni atom/bond/filter constraints određuju semantiku.

Mercury / Mogul / CSD Python API

CCDC alati: vizuelizacija/analiza kristala; distribucije geometrije iz CSD-a; programski pristup funkcijama i podacima u granicama licence. „API“ ovde znači application programming interface, ne active pharmaceutical ingredient.

Hydrogen-bond propensity (HBP) Statistički model zasnovan na funkcionalnim grupama, fitting evidence-u i logističkoj regresiji za potencijalne donor–acceptor ishode. Individual propensity, observed H-veza, network grouping i coordination score su različiti output-i; nijedan sam nije polymorph probability ili lattice energy. HBP coordination score odnosi se na ostvarivanje H-veza oko donora/prihvatilaca, a ne na metalni koordinacioni broj iz koordinacione hemije; [lekcija 11A](#) razdvaja ta značenja.

API (active pharmaceutical ingredient)

Farmaceutski aktivna supstanca. U dokumentaciji uvek razjasni da li `API` znači aktivni sastojak ili programski interfejs.

Raw / canonical / derived

Raw je netaknut izvor/parsiran dokaz; canonical je kurirana task-specific verzija; derived su fingerprints, embeddings, izveštaji i modeli. Ne prepisivati jedan sloj drugim.

Normalizacija

Kontrolisana promena zapisa u dosledniji oblik, npr. jedinice ili whitespace. Mora se razlikovati od hemijske standardizacije koja menja reprezentaciju identiteta.

Standardizacija

Verziona pravila za components, charges, bonds, aromaticity, tautomers, coordinates i crystal setting. Nije neutralna; rezultat zavisi od zadatka.

Kanonski zapis

Deterministički izabrana reprezentacija unutar definisanog algoritma/verzije. „Kanonski“ ne znači univerzalno jedini istinit zapis.

Lossless / lossy transformacija

Lossless omogućava rekonstrukciju svih relevantnih informacija; lossy odbacuje ili sažima deo. CIF→SMILES je namerno lossy za crystal context.

Missing / unknown / not applicable

Nedostaje, nije poznato i nije primenljivo nisu nula. U CIF-u `?` i `.` imaju posebna značenja; u ML šemi moraju ostati odvojeni statusi.

Provenance / lineage

Provenance beleži poreklo, alat, osobu, vreme i okolnosti artefakta; lineage povezuje izvedeni rezultat sa tačnim ulazima i transformacijama.

Hash

Deterministički sažetak bajtova, npr. SHA-256. Detektuje promenu konkretnog fajla; ne potvrđuje naučnu istinu, vlasništvo ili licencu.

Representation version

Identifikator pravila/softvera koji su proizveli graf, fingerprint, ćeliju, embedding ili drugi prikaz. Bez njega se score-ovi ne smeju mešati.

Cheminformatika i sličnost

Molekulski graf

Graf čiji su čvorovi atomi, a ivice veze prema definisanom bond modelu. Ne sadrži automatski periodičnost, crystal packing ili eksperimentalni quality.

Atom/bond typing

Dodela hemijskih kategorija atomima/vezama radi pretrage ili modela. Kod aromatičnosti i metala može biti višeznačna; čuvaj alat, verziju i confidence.

Atom mapping

Eksplisitno uparivanje atoma između dve reprezentacije/reakcije. Mora prethoditi RMSD-u i objašnjenju lokalnih razlika.

Exact graph match

Izomorfizam grafova pod pravilima za element, bond order, charge, isotope i stereo. Exact zavisi od tog policy-ja.

Podstrukturna pretraga

Pita da li target sadrži query podgraf. Asimetrična je: mali query može biti u velikom target-u, ne obrnuto.

MCS

Maximum common substructure: najveći zajednički podgraf prema pravilima. Može imati više jednakih mapiranja i biti računski skup.

Deskriptor

Numerička ili kategorijska karakteristika, npr. masa, broj H-bond donora, koordinacioni broj ili cell volume. Svaki deskriptor ima definiciju i scope.

Fingerprint

Skup/vektor hemijskih feature-a, često binarni, napravljen za brzu pretragu. Kolizije i gubitak informacije su očekivani.

Morgan/ECFP fingerprint

Circular fingerprint koji iterativno kodira lokalna atomska okruženja do radius-a. Parametri, chirality, bit length/count mode i standardizacija menjaju rezultat.

Tanimoto koeficijent

Za binarne skupove $T = \frac{|A \cap B|}{|A| + |B| - |A \cap B|}$. Vrednost ima smisla samo uz identičnu fingerprint definiciju i task kontekst.

Embedding

Naučena ili projektovana kontinuirana vektorska reprezentacija. Blizina u embedding prostoru odražava cilj/podatke treninga; nije univerzalna hemijska istina.

RMSD

Korenska srednja kvadratna udaljenost mapiranih koordinata posle definisanog poravnanja. Bez mapping-a, coverage-a i symmetry/policy parametara može biti obmanjujuća.

Packing similarity

Poređenje periodičnih molekulskih okruženja, često preko klastera suseda i RMSD-a. Broj matched molecules, shell, tolerancije i component policy su deo rezultata.

Similarity profile

Verzisionisan paket definicija: objekti, standardizacija, metrike, parametri, težine, missing/abstention pravila i evidence schema.

Candidate generation / reranking

Prva faza brzo vraća širok kandidatni skup sa visokim recall-om; druga primenjuje skuplje, preciznije metode. Candidate recall je obavezna metrika.

ANN

Approximate nearest-neighbor pretraga: traži približne najbliže susede. Cilj je brži dohvat uz mogući gubitak suseda; na malom ili jako filtriranom skupu tačna pretraga može biti brža. Indeks i parametri moraju biti evaluirani nad istim korpusom i metrikom.

Coverage

Udeo objekta/podataka koji je zaista poređen ili ocenjen. Nizak RMSD na tri atoma može imati loš coverage.

Score / distance / probability

Score je vrednost određene funkcije; distance meri razdvojenost prema navedenoj definiciji; probability je verovatnoća imenovanog događaja. Model može dati probabilističku procenu koja je loše kalibrisana: tek provera kalibracije ispituje slaganje sa opaženim učestalostima. Sirov skor sličnosti nema automatski probabilističko značenje.

ML, evaluacija i privatnost

Feature / label / target

Feature je ulazna karakteristika; label je referentna oznaka; target je ono što model predviđa. Polje nastalo posle događaja ili iz ekspertske odluke ne sme slučajno u features.

Klasifikacija / regresija / rangiranje / retrieval

Klasifikacija bira kategoriju, regresija broj, rangiranje uređuje kandidate, retrieval pronalazi kandidate iz velike kolekcije. Zahtev određuje metrike.

Ground truth / referentna anotacija

Operacionalizovana ekspertska ili eksperimentalna odluka sa pravilima, evidence-om i confidence-om. Naziv fajla, ConQuest query ime ili model score nisu ground truth.

Train / validation / test skup

Train uči parametre; validation bira modele/thresholds; test se koristi tek za finalnu nepristrasnu procenu. Promena nakon gledanja testa čini ga delom razvoja.

Data leakage

Informacija nedostupna u realnoj primeni ili skoro duplikat prelazi iz test/ budućnosti u trening. U CSD-u su rizični redeterminations, ista compound family/publikacija i derivati istog entry-ja.

Random / scaffold / group / temporal split

Random deli zapise nasumično; scaffold grupiše hemijska jezgra; group čuva familije/izvore zajedno; temporal odvaja buduće podatke. Split se bira prema claim-u.

Baseline

Jednostavna transparentna metoda protiv koje se meri složeni model: formula filter, substructure, ECFP+Tanimoto, metal/donor pravilo, RMSD ili reduced-cell kandidat.

Ablation

Eksperiment uklanjanja jedne komponente sistema da bi se procenio njen doprinos, uz isti evaluation protokol.

Class imbalance

Velika razlika u učestalosti klasa. Accuracy može biti visoka predviđanjem većinske klase; koristi odgovarajuće precision/recall i PR metrike.

Precision / recall

Precision ($=TP/(TP+FP)$): koliko predviđenih pozitivnih je tačno. Recall ($=TP/(TP+FN)$): koliko stvarno pozitivnih je pronađeno.

F1

Harmonijska sredina precision-a i recall-a. Jedan F1 i dalje može sakriti različite threshold trade-offe i slice greške.

ROC-AUC / PR-AUC

Površine ispod ROC i precision–recall krivih kroz pragove. PR-AUC je često informativniji za retku pozitivnu klasu; nijedna ne zamenjuje operativni threshold.

Recall@k / precision@k

U retrieval-u, recall@k meri udeo relevantnih objekata pronađenih u prvih k , precision@k udeo relevantnih među prvih k . Oba zavise od potpunosti relevantnog seta.

MRR / MAP / nDCG

MRR naglašava rank prvog relevantnog rezultata; MAP prosečnu precision kroz relevantne pogodke; nDCG podržava graded relevance i jače vrednuje vrh rangiranja.

Calibration

Saglasnost predviđene verovatnoće sa empirijskom učestalošću: među slučajevima kojima model dodeljuje približno 0,9 očekuje se približno 90% pozitivnih ako je dobro kalibrisan u tom domenu. Model može davati loše kalibrisane verovatnosne procene; sirov skor sličnosti nema automatski ni tu probabilističku interpretaciju.

Brier score / calibration error

Brier meri kvadratnu grešku probabilističkih prognoza, uključujući nekalibrisane procene; nije čista mera kalibracije jer zavisi i od sposobnosti razlikovanja ishoda i raspodele podataka. Calibration error meri grupisano odstupanje procena od učestalosti. Navedi implementaciju/binning; [dokumentacija o kalibraciji](#) objašnjava zašto manji Brier ne garantuje bolju kalibraciju.

Uncertainty / evidence confidence

Uncertainty opisuje neizvesnost predikcije/parametra; evidence confidence pouzdanost ulaza i reprezentacije. Visok model score može imati nizak evidence confidence.

Abstention

Svesna odluka sistema da ne da claim kada nema potreban input, objekat je ambiguous/out-of-domain ili je rizik previsok.

Applicability domain / out-of-domain

Oblast hemijskog i podatkovnog prostora za koju je model evaluiran; out-of-domain slučaj nema isti dokaz performansi.

Domain shift / concept drift

Menja se raspodela ulaza/uslova ili veza feature–target tokom vremena, institucija ili CSD release-a. Monitoring mora pratiti slice i release verzije.

Hard positive / hard negative

Težak pozitivan je relevantan uprkos površinskoj razlici; težak negativan je nerelevantan uprkos velikoj površinskoj sličnosti, npr. isti ligand ali druga koordinaciona geometrija.

Invariance / metamorphic test

Invariance zahteva isti rezultat posle semantički neutralne transformacije; metamorphic test proverava poznat odnos između izlaza kada nema jednostavnog oracle-a.

p50 / p95 latencija

Medijana i 95. percentil vremena odziva. Prosek može sakriti spor dugi rep.

Federativno učenje (FL)

Učenje zajedničkog modela uz lokalno zadržavanje podataka i razmenu update-a prema protokolu. Ne znači automatski privatnost, dozvolu ili zaštitu IP-a.

FedAvg

Federated Averaging: agregacija lokalno treniranih model update-a težinski prema količini podataka, pod određenim pretpostavkama. Non-IID klijenti mogu otežati konvergenciju i pravednost.

Non-IID

Lokalni skupovi nisu nezavisno i isto distribuirani: različite laboratorije imaju različitu hemiju, instrumente, kuraciju i property protokole.

Secure aggregation

Kriptografski protokol kojim server uči agregat update-a bez uvida u pojedinačni update, pod modelom pretnji. Ne sprečava sve inferencije iz konačnog modela/agregata.

Differential privacy (DP)

Formalna granica promene raspodele objavljenog izlaza između susednih skupova koji se razlikuju za unapred definisanu zaštićenu jedinicu, npr. zapis ili učesnika, uz parametre ϵ , δ . Garancija zavisi od te definicije i kumulativnog obračuna privatnosti. Clipping gradijenata i odgovarajuće podešen šum čine jedan ML postupak, DP-SGD, a nisu sama definicija ili dovoljan dokaz DP-a; vidi [objašnjenje u lekciji 22](#).

Gradient/model leakage

Mogućnost rekonstrukcije ili inferencije o podacima iz gradients, update-a, modela ili izlaza. „Nismo poslali raw CIF“ nije dokaz bezbednosti.

Upravljanje, licence i FAIR

Metadata

Podaci o podacima: identitet, schema, units, source, uslovi, quality, licenca i veze. Metadata mogu biti dostupni i kada je sadržaj restricted.

Identifikator / verzija

Identifikator kaže koji je logički objekat; verzija koji tačno snapshot/representation. Filename nije dovoljan persistent ID.

Licenca / ugovor / policy

Licenca/ugovor pravno određuju dozvoljenu upotrebu; policy je njihova izvršiva tehnička interpretacija. Tehnička mogućnost pristupa nije dozvola.

Open data / public domain

Open data imaju dozvolu za pristup i ponovnu upotrebu pod navedenim uslovima; public domain je druga, šira pravna kategorija. Javno vidljivo nije automatski open.

FAIR

Findable, Accessible, Interoperable, Reusable. Accessible može zahtevati autentikaciju/autorizaciju; FAIR ne znači nužno open, free, public ili quality-certified.

Ontology / controlled vocabulary

Formalno definisani koncepti i relacije / dozvoljen skup termina. Sprečavaju da `solvent`, `coformer` i `counterion` postanu slobodni, nedosledni stringovi.

Claim ledger

Verzisionisan registar naučnih, tehničkih i licencnih tvrdnji: precizan claim, scope, izvor, lokalni test, confidence, datum provere, rok revalidacije i status.

Audit trail

Neizmenjiv ili kontrolisano verzionisan dnevnik događaja: pristup, transformacija, pregled, eksport, opoziv i brisanje.

Fail closed

Kada dozvola ili potreban dokaz nedostaju, operacija je blokirana. Suprotno, fail open bi pretpostavio dozvolu/uspeh.

Derivative

Artefakt izveden iz izvora: standardized record, fingerprint, embedding, indeks, model ili izveštaj. Nije automatski slobodan od licence izvora.

Karantin

Stanje u kome se raw evidence čuva, ali se sadržaj ne pušta u canonical indeks/trening/eksport dok se konflikt ne pregleda.

Termini koji se često pogrešno poistovete

Nije isto	Kratka razlika
CCDC / CSD	organizacija i portfolio / konkretna strukturna baza
entry / molekul	zapis jednog određivanja / hemijska jedinka
formula / graf	broj elemenata / povezanost atoma
graf / konformer	povezanost / jedan 3D raspored
molecule / crystal	konačna jedinka / periodični raspored
cell / packing	izbor translacione kutije / raspored sadržaja kroz periodični prostor
Z / Z'	formula units u ćeliji / nezavisni sadržaj ASU u jednostavnom slučaju
occupancy / multiplicity	populacija mesta / broj symmetry-equivalent mesta
formal charge / oxidation state / partial charge	Lewis knjigovodstvo / jonska formalizacija / metodom dodeljen neto naboj, obično necelobrojan
salt / cocrystal	jonske komponente/proton transfer / višekomponentna jednofazna forma po konvenciji
solvat / polymorph	promenjen sastav rastvaračem / drugi arrangement iste supstance
solubility / dissolution rate	ravnotežna količina / kinetika rastvaranja
R / wR / GoF	različite objective/statističke veličine
restraint / constraint	meko pravilo / tvrda algebrajska veza
missing / 0	nema poznate vrednosti / poznata nulta vrednost
score / probability / confidence	vrednost funkcije / verovatnoća događaja, uz zasebnu proveru kalibracije procene / pouzdanost dokaza
similar / same	task-specific blizina / identitet po eksplicitnoj definiciji
FAIR / open	upravljivost i ponovna upotreba / prava javnog pristupa-upotrebe
private repo / licence	kontrola pristupa hostu / pravna dozvola kopiranja i deljenja

Autoritativne tačke za proveru definicija

- IUPAC Gold Book — hemijska terminologija; posebno ligand, coordination entity, polymorph i standard uncertainty.

- [IUCr Online Dictionary of Crystallography](#) — kristalografija; posebno [unit cell](#), [asymmetric unit](#), [space group](#), [Bragg's law](#) i [refinement](#).
- [IUCr CIF dictionaries](#) — formalno značenje CIF data names.
- [OpenStax Chemistry 2e](#) — početničko objašnjenje atoma, veza, geometrije, interakcija, čvrstih struktura i termodinamike.
- [CCDC CSD Python API dokumentacija](#) — ponašanje CCDC alata i task-specific pojmovi; verziju i licencu proveravati iznova.

Opasne zablude

Ovo nije lista trivijalnih grešaka. Svaka zabluda ispod može napraviti naučno pogrešan label, nevalidan similarity score, curenje licence ili sistem koji deluje ubedljivo baš kada nema dokaz.

Čitaj poslednju kolonu kao **konceptualnu posledicu i ilustrativan način opovrgavanja zablude**. Ona ne propisuje buduća polja, fixture-e, UI ponašanje, gate-ove ili review proceduru; konkretan oblik eventualne realizacije određuje se kasnije.

Broj u prvoj koloni je identifikator zablude, ne redosled čitanja; redovi su grupisani po temi.

1. Identitet, sastav i hemijske veze

#	Zabluda	Šta je tačno	Konceptualna posledica / primer provere
1	„Ista molekulska formula znači isti molekul.“	Formula daje broj elemenata, ne povezanost. Etanol i dimetil-etar dele C_2H_6O , a različiti su konstitucioni izomeri.	Formula je jeftin filter, nikad exact graph label. Test: isti sastav/drugi graf mora biti hard negative.
2	„Isti molekul znači isti CSD entry.“	Entry predstavlja konkretno određivanje kristala; isti compound može imati više temperatura, redeterminations, polimorfa i solvata.	Deduplikacija mora imati odvojene entry, chemical entity, solid form i determination identitete.
3	„Isti SMILES znači isti kristal.“	Standardni SMILES opisuje molekulski graf, ne ćeliju, simetriju, packing, occupancy ili eksperiment.	SMILES exact-match ne sme biti packing/polymorph ground truth. Test: isti SMILES, dva dokazano različita packing-a.
4	„Različiti SMILES stringovi znače različite molekule.“	Isti graf ima mnogo validnih traversal zapisa; canonical SMILES zavisi od implementacije/verzije.	Pre string poređenja uradi parser + graph identity pod eksplicitnim charge/stereo/isotope policy-jem.
5	„Ime fajla je hemijski metadata.“	Filename je ljudska oznaka. <code>cu_n14_a.cif</code> nema Cu u formuli/atom sites; <code>Cu Kα</code> je izvor rendgenskog zračenja.	Element filter koristi strukturisana polja i cross-check, nikad substring imena. <code>cu</code> u imenu, bez Cu u formuli ili atomskim mestima, direktan je kontraprimer.
6	„Formula u CIF-u je nepogrešiva.“	Formula je prijavljena/izvedena stavka i može biti nesaglasna sa atom sites, occupancy, symmetry multiplicity ili Z .	Neslaganje formula sum/moiety, site composition, charge i density računa pokazuje internu nekonzistentnost; samo po sebi ne utvrđuje da je greška u sastavu.
7	„Formalni, oksidacioni i parcijalni naboj su isti broj.“	Formal charge je Lewis knjigovodstvo; oxidation state jonska formalizacija; partial charge zavisi od modela i obično nije ceo broj.	Formalni, oksidacioni i parcijalni naboj nisu zamenljive veličine; vrednost jedne ne određuje druge.
8	„Nula u MOL2 charge koloni dokazuje nepolarnost.“	<code>NO_CHARGES</code> /nule mogu značiti da parcijalni charge model nije dodeljen. Polarne veze i dipol i dalje mogu postojati.	<code>charge_model=none</code> je missing model, ne fizička nula. Ne koristiti kao feature bez provenance-a.
9	„Bond order u fajlu je direktno eksperimentalno meren.“	Difrakcija meri intenzitete; položaji/gustina se modeluju, a bond types se hemijski dodeljuju. Aromatic/unknown/metal bonds zavise od softvera.	Čuvaj originalni tip, perception alat/verziju i confidence. Testiraj razliku CIF/MOL/MOL2 prikaza istog uzorka.
10	„Uspešan valence check dokazuje tačnu hemiju.“	Više pogrešnih grafova može zadovoljiti lokalna pravila valence; metali, disorder i delokalizacija dodatno komplikuju model.	Valence je jedan signal. Potrebni su formula, geometrija, charge, component i stručni cross-check.
11	„Svaki N ili O je donor/prihvatalac.“	Protonacija, formalni naboj, rezonanca, amide-like delokalizacija i koordinacija menjaju raspoloživ lone pair.	Donor/acceptor etiketa je kontekstualna i verzionisana. DAP donor mapping proverava konkretne N atome.

#	Zabluda	Šta je tačno	Konceptualna posledica / primer provere
1 2	„Nedostajući H nije važan za similarity.“	H položaj određuje protonaciju, salt/cocrystal granicu, stereo, H-bond donor/acceptor uloge i interaction network. Rendgenski H često je modelovan.	Missing H daje uncertainty/ambiguous status; ne dodeljuj exact form identity bez dokaza.
1 3	„Neutralizacija, odvajanje soli i izbor tautomera su bezazlena normalizacija.“	Te transformacije mogu promeniti stvarni objekat, charge, donor set, komponentu i query odgovor.	Čuvaj raw/full crystal i task-specific parent prikaze paralelno; transformation log mora navesti pravilo.
1 4	„Najveći fragment je uvek aktivni ligand/parent.“	Counterion ili metalna mreža može biti veća; koordinacioni polimer nema jednostavan konačni „najveći molekul“.	Component role classification koristi hemiju i korisnički cilj. Uklanjanje ostalih komponenti menja identitet punog kristalnog sastava.

2. Metali i koordinaciona hemija

#	Zabluda	Šta je tačno	Konceptualna posledica / primer provere
1 5	„Ako entry sadrži metal i DAP motiv, DAP koordinira metal.“	Lokalni ConQuest 4M atom je nepovezan sa 18-atomski DAP query motivom; dokazano je samo da se metal nalazi negde u istom entry-ju.	Candidate label nije coordination ground truth. Potrebni su component assignment, metal-neighbor perception i donor mapping.
1 6	„Metal–ligand veza postoji ako je rastojanje ispod jednog globalnog cutoff-a.“	Tipične distance zavise od elemenata, oxidation/spin stanja, CN, geometrije, disorder-a i modela.	Neighbor model mora biti element/context-aware i verzionisan; blizina može vratiti ambiguous.
1 7	„Ako CIF/MOL nema nacrtanu metalnu vezu, koordinacije nema.“	Neki formati/izvoznici metal connectivity ostavljaju unknown ili je izvode iz geometrije. Odsustvo ivice može biti odsustvo anotacije.	Razdvoji explicit bond, inferred neighbor i expert-confirmed coordination; ne pretvaraj missing u false.
1 8	„Koordinacioni broj je broj liganada.“	CN broji direktne donor-atome; jedan tridentatni ligand doprinosi tri, a bridging ligand može vezati više centara.	CN, broj liganada, denticity i bridging su različiti deskriptori; isti CN može nastati iz različite raspodele donor-atoma po ligandima.
1 9	„Isti metal i isti CN znače istu geometriju.“	CN=4 može biti tetraedarski, kvadratno-planaran ili između; distortion nosi bitnu informaciju.	Poredi angles/shape measures uz metal/donor mapping. Hard negative: isti M/CN, druga geometrija.
2 0	„Oksidaciono stanje se čita iz elementa ili formalnog broja veza.“	Isti metal ima više oxidation states; covalency, charge i ligandi zahtevaju balans i stručni dokaz.	Ako evidence nije dovoljan, koristi unknown/ambiguous; ne imputiraj tipičnu vrednost kao činjenicu.
1 0 4	„Izduženi pseudo-octahedral Cu(II) automatski dokazuje Jahn–Teller efekat.“	Obrazac je kompatibilan sa d^9 efektom, ali ligandna nejednakost, strain, packing, disorder i model mogu dati sličnu geometriju.	Prijavi hipotezu uz oxidation state/ d^n , donor mapping, s.u., quality i alternativne uzroke.
2 1	„Coordination entity je isto što i ceo kristalni sastav.“	Counterions, solventi i cofomers mogu biti van koordinacione jedinice, a ipak su deo crystal form-a.	Zaključak zavisi od toga da li se poredi koordinaciona jedinica ili ceo kristalni sastav; ta dva scope-a nisu ekvivalentna.
2 2	„Metalni kompleksi se mogu standardizovati istim organskim sanitization pravilima.“	Organska valenca/aromatičnost pravila mogu pogrešno cepati koordinacione veze ili menjati charges.	Neuspešna organska sanitizacija može značiti neadekvatan model, ne nevalidnu hemiju; ista pravila mogu izbrisati koordinaciju ili promeniti naboje.

3. Kristal, simetrija i periodičnost

#	Zabluda	Šta je tačno	Konceptualna posledica / primer provere
2 3	„CIF je samo još jedan molekulski format.“	CIF može opisati ćeliju, space group, ASU, occupancy, eksperiment, refleksije i refinement. CIF→SMILES je bogata-to-siromašna projekcija.	Molekulska projekcija gubi informacije i ne može podupreti tvrdnje o ćeliji, simetriji, occupancy-ju ili packing-u.

#	Zabluda	Šta je tačno	Konceptualna posledica / primer provere
2 4	„Jedan CIF sadrži tačno jedan molekul.“	Može imati više data block-ova, components, nezavisnih molekula, disorder alternatives, solvent i periodičnu mrežu.	Identitet i poređenje zavise od izabranog data block-a i objekta; prvi molekul nema poseban naučni status.
2 5	„ASU je isto što i jedna ćelija ili jedan molekul.“	ASU je najmanji nezavisni deo iz kog simetrija generiše strukturu; može biti deo molekula ili više formula units.	Symmetry expansion mora prethoditi punom packing/contact računu. Čuvaj Z' uz ograničenja definicije.
2 6	„Svaki atom-site red je jedan pun atom u ćeliji.“	Site se širi kroz symmetry multiplicity i ponderiše occupancy; special positions menjaju broj kopija.	Sastav računaj iz elementa $\times$ multiplicity $\times$ occupancy, ne brojem redova.
2 7	„Occupancy i multiplicity su isto.“	Occupancy je populacija mesta; multiplicity broj symmetry-equivalent mesta.	Occupancy i multiplicity nezavisno ulaze u račun sastava i nisu zamenljivi.
2 8	„Frakcione koordinate su ångströmi.“	Frakcione koordinate su koeficijenti cell vectors; u neortogonalnoj ćeliji kartezijanska konverzija koristi punu matricu.	Distance račun koristi cell matrix + PBC. Testiraj monoklinični <code>cu_n14_a.cif</code> .
2 9	„Atomi na 0,99 i 0,01 su daleko.“	Periodični wrap može ih učiniti susedima preko granice ćelije.	Minimum-image/symmetry contact search; metamorphic test translacije za ceo lattice vector.
3 0	„Dve ćelije sa različitim parametrima moraju biti različiti kristali.“	Ista rešetka/struktura može biti zapisana drugom bazom, setting-om, origin-om, konvencionalnom ćelijom ili supercell-om.	Standardizuj/redukuj pre candidate poređenja i proveri invertibilnu transformaciju.
3 1	„Slična reduced cell dokazuje isto pakovanje.“	Metrika rešetke je samo candidate signal; sadržaj i orijentacije mogu biti drugačiji.	Packing proof zahteva mapirane periodične klastere, broj matched molecules, RMSD i parametre.
3 2	„Ista space group znači isti polimorf.“	Hiljade različitih struktura mogu deliti $P2_1/c$; space group je simetrijska kategorija.	Ne koristi space-group equality kao identity label; uključi composition, graph i packing.
3 3	„Različita space group automatski znači različit materijal.“	Ekvivalentni settings mogu imati različite simbole; phase transition, pseudosymmetry ili različit izbor mogu zahtevati ekspertizu.	Kanonizuj space-group type/setting, zadrži original i transformation evidence.
3 4	„ $Z = Z'$.“	Z broji formula units u ćeliji; $Z' = Z/m$, gde je m multiplicity opšte pozicije za istu ćeliju. Z' može biti razlomak i nije uvek broj celih nezavisnih molekula.	Njihova jednakost zahteva $m = 1$; specijalne pozicije ne ukidaju odnos, već menjaju tumačenje ASU sadržaja.
3 5	„Crystal packing je samo nearest-neighbor distance.“	Packing uključuje periodični 3D raspored, orijentacije, više shells i component roles.	Izveštaj navodi shell/cluster, mapping, tolerancije i coverage; jedan kontakt nije packing score.
3 6	„Spoljašnji oblik kristala identifikuje unutrašnju strukturu.“	Habit zavisi od relativnog rasta lica i uslova; ista struktura može imati različit habit, a sličan habit različite strukture.	Ne koristiti fotografiju/shape label kao polymorph ground truth bez difrakcionog dokaza.

4. Difrakcija i quality — nema magičnog semafora

#	Zabluda	Šta je tačno	Konceptualna posledica / primer provere
3 7	„ $R < 0,05$ znači dobar CIF; iznad toga odbaci.“	R zavisi od sastava, disorder/twinning-a, rezolucije, apsorpcije, skupa refleksija i modela. Nizak R može pratiti pogrešan/prefleksibilan model.	Quality je vektor dokaza; prag, ako postoji za claim, validira se po domenu i ostaje objašnjiv.
3 8	„ $R(\text{all})$, $R(\text{gt})$ i wR mogu direktno da se porede.“	Koriste različite skupove/formule/težine; wR je često na F^2 , R na amplitudama.	Svaka vrednost nosi CIF field i semantics; ne rangiraj modele mešanim kolonama.
3 9	„GoF=1 dokazuje tačnu strukturu.“	GoF blizu 1 govori da su weighted residuals saglasni sa pretpostavljenim uncertainties/weights; ne potvrđuje identitet, space group ili propušten solvent.	Pregledaj weights, residual density, geometriju, model i alerts. <code>cu_n14_a.cif</code> $S=1,095$ je dokaz samo u tom ograničenom smislu.

#	Zabluda	Šta je tačno	Konceptualna posledica / primer provere
40	„checkCIF alert znači da je struktura nevalidna.“	Alert označava anomaliju za pregled; opravdani izuzeci postoje i zahtevaju objašnjenje.	Čuvaj alert code/severity/response i review; ne briši zapis samo zbog boje.
41	„Bez checkCIF alert-a struktura je sigurno tačna.“	Automatizovani testovi ne znaju punu hemijsku nameru, uzorak, sintezu ili svaki model defect.	Automatska validacija + hemijski/kristalogrfski pregled + scope-specific acceptance.
42	„Disorder znači loši podaci koje treba odbaciti.“	Disorder može biti realna osobina ili najbolji prosečni model. Ignorisanje alternative menja sastav i kontakte.	Čuvaj alternatives/occupancy i quality confidence; samo claim koji zahteva jednoznačnu geometriju može abstain.
43	„Dve pozicije occupancy 0,5 su dva cela atoma.“	Često su alternativni položaji iste populacije. Pretvaranje u dva puna atoma duplira masu i stvara lažne kontakte.	Disorder-group-aware expansion i formula round-trip test.
44	„Occupancy 1 dokazuje odsustvo disorder-a.“	Samo pokazuje da u datom modelu mesto ima punu navedenu occupancy; ne isključuje nemodelovan nered ili druge sistematske probleme.	Formulacija izlaza mora biti „nema eksplicitno modelovanog disorder-a“, ne univerzalna negacija.
45	„H atomi su opaženi jednako pouzdano kao teži atomi.“	X-ray rasipanje prati elektrone; H je slab i često idealizovan/refiniran uz constraints.	H-bond/protonation claim nosi H provenance i uncertainty; neutron/X-ray i refinement model nisu isti dokaz.
46	„Broj u zagradi je tolerancija ili interval.“	12.7138(3) u CIF konvenciji znači s.u. 0,0003 poslednjih cifara, ne ±3 ili tri merenja.	Vrednost i s.u. čine povezanu mernu informaciju; razdvajanje menja značenje neizvesnosti.
47	„100 K kristalna geometrija je ista na sobnoj temperaturi.“	Čelija, ADP, konformacija, faza i disorder mogu zavistiti od temperature.	Temperature je deo identity/evidence i pair quality compatibility; ne spajaj uslove bez oznake.
48	„Jedan kvalitet score može bezbedno zameniti sva polja.“	R, resolution, completeness, s.u., residuals, restraints, disorder, twinning i temperatura odgovaraju na različita pitanja.	Čuvaj quality vector; learned score mora ostati rastavljiv, kalibrisan i bez rigidnog univerzalnog cutoff-a.
107	„Simulirani PXRD iz CIF-a potvrđuje taj CIF i bulk uzorak.“	Simulacija je derivat istog modela i zato kružni dokaz; nema informacije iz realnog bulk merenja.	Za fazni evidence koristi measured PXRD sa radiation/instrument/sample metadata i unapred definisanim poređenjem.

5. Čvrste forme, stabilnost i svojstva

#	Zabluda	Šta je tačno	Konceptualna posledica / primer provere
49	„Svaka različita čvrsta forma je polimorf.“	Salt, hydrate, drugi solvate i cocrystal menjaju component/charge/composition klasifikaciju; amorfno nije kristalni polymorph.	Solid-form relation je višekomponentna etiketa, ne jedno polymorph=true.
50	„Hidrat/solvat je nečist polimorf.“	Molekuli vode/rastvarača mogu biti stehiometrijski, strukturno ključni deo jednofaznog kristala.	Komponentu ne briši kao noise; parent i full-form poređenje prikazuju odvojeno.
51	„So i kokristal se uvek razlikuju samo formulom.“	Granica često zavisi od proton transfer-a i lokacije H; ista komponentna formula može biti ambiguous u slabom X-ray modelu.	Čuvaj protonation evidence, charge i terminološku verziju; dozvoli salt-cocrystal ambiguous.
52	„Najstabilnija forma prva kristališe.“	Nukleacija i rast su kinetički; metastabilna forma može nastati prva i opstati zbog barijere.	Model property/form selection mora uključiti uslove, proces i vreme, ne samo energy rank.
53	„Metastabilno znači pogrešno ili neupotrebljivo.“	Metastabilna faza je realan lokalni minimum i može imati korisna svojstva i dug vek.	Ne filtrirati label; zabeležiti uslove transformacije i storage rizik.
54	„Više talište uvek znači stabilniji polimorf.“	Stabilnost određuje Gibbsova energija i može se menjati temperaturom; melting/enthalpy odnosi zahtevaju punu termalnu analizu.	Ne praviti universal rank iz jednog melting point-a. Potrebni DSC/solubility/transition podaci i context.

#	Zabluda	Šta je tačno	Konceptualna posledica / primer prove
5 5	„Najniža energija izolovanog konformera daje najstabilniji kristal.“	Kristalna stabilnost uključuje intermolekulske interakcije, packing, entropy i uslove; molekul može platiti conformational strain radi boljeg packing-a.	Gas-phase/conformer feature je samo jedan signal; ne label za polymorph stability.
5 6	„Jedan uspešan screen dokazuje da druge forme ne postoje.“	Polymorph landscape zavisi od rastvarača, temperature, vlage, seeding-a, vremena i tehnike. Odsustvo dokaza nije dokaz odsustva.	Coverage protokola i negative claim scope moraju biti zapisani; sistem ne kaže „nema drugih formi“ bez granica.
1 0 5	„Mogul outlier ili 99. percentil znači visoku energiju/nestabilnost.“	To je neuobičajenost u konkretnoj query/filter/release populaciji, ne energetski račun.	Čuvaj referentni manifest/support/applicability; energiju i fazu testiraj odvojenim modelom/eksperimentom.
1 0 6	„HBP propensity 0,8 znači da je H-veza opažena ili da polimorf postoji.“	Propensity je output fitting/logistic modela za kandidatni par; observed status, grouping, coordination i realna faza su druga pitanja.	Prikaži output-e odvojeno sa evidence counts, uncertainty i applicability.
5 7	„Jedan difraktovani kristal predstavlja ceo bulk uzorak.“	Izabrani single crystal može biti manjinska faza; bulk phase purity zahteva odgovarajuće tehnike (npr. powder diffraction/thermal analysis).	Ne prenosi single-crystal identity automatski na batch property label.
5 8	„Rastvorljivost i brzina rastvaranja su isto.“	Prvo je ravnoteža, drugo kinetika zavisna od površine/habit-a/čestica i uslova.	Rastvorljivost i brzina rastvaranja su različita svojstva, a obe vrednosti zavise od jedinica i uslova merenja.
5 9	„Različiti habit znači drugi polimorf.“	Habit je spoljašnja morfologija; isti polymorph može rasti kao igla ili ploča.	Vizuelna klasifikacija nije crystal-form label bez strukturne potvrde.
6 0	„Crystal structure sama deterministički određuje property.“	Property zavisi i od defekata, veličine čestica, kompozicije, temperature, procesa i mernog protokola.	Structure–property ML label nosi conditions/provenance i uncertainty; razdvojiti causal claim od korelacije.

6. Formati, ingest i provenance

#	Zabluda	Šta je tačno	Konceptualna posledica / primer prove
6 1	„Konverzija CIF→SDF/SMILES samo menja ekstenziju.“	Odbacuju se cell, symmetry, packing, occupancy i quality, a components/bonds se biraju ili inferiraju.	Svaka konverzija ima loss matrix, source link i task scope; original se čuva.
6 2	„Ako parser nije prijavio grešku, zapis je validan.“	Sintaktički validan fajl može imati pogrešnu formulu, nesmislen graf, pogrešne units ili ozbiljne alerts.	Sintaktička ispravnost ne implicira hemijsku ili kristalografsku validnost, kvalitet dokaza ni dozvolu upotrebe.
1 0 8	„ <code>parser_ok</code> znači Curated.“	Sintaksno parsiranje i verzionisana automatska validacija nisu isto što i završena stručna/policy kuracija.	Parsiranje, automatska validacija, stručna kuracija i odobrenje za objavu jesu različiti nivoi potvrde; nijedan ne implicira sledeći.
6 3	„Canonical record je nova istina pa raw može da se obriše.“	Canonical je rezultat verzionisanih odluka i može se promeniti. Bez raw dokaza nema audit-a niti ponovnog parsiranja.	Immutable original + hash, raw parsed, canonical i derived slojevi ostaju povezani.
6 4	„Canonical SMILES je globalni persistent identifier.“	Canonicalization zavisi od toolkit-a, verzije, aromaticity, salt/tautomer/stereo policy-ja.	Za interni ID koristi stable source/version ID; SMILES čuvaj uz generator profil.
6 5	„Missing vrednost je isto što i nula.“	?, -, blank, parse failure, not measured i not applicable nose različita značenja.	Različiti razlozi odsustva podatka imaju različito značenje; nijedan nije fizička nula, a njihovo mešanje može pristrasiti model.
6 6	„Nepoznato znači negativno.“	Nema veze, nema H ili nema metal annotation može biti missing evidence, ne dokaz odsustva.	Ternary/multi-state labels: true/false/unknown/ambiguous/not-applicable.
6 7	„Hash potvrđuje da je sadržaj tačan.“	Hash potvrđuje identitet bajtova. Isti pogrešan ili licencno nedozvoljen fajl ima savršeno stabilan hash.	Hash kombinuj sa validation, source, licence i review statusom.

#	Zabluda	Šta je tačno	Konceptualna posledica / primer provere
6 8	„Ekstrahovan PDF tekst je ono što korisnik vidi.“	Embedded text layer može sadržati skriveni/stari sadržaj. U CCDC white paper-u strane 1–2 izvlače nevidljiv tekst o ultra-large GOLD docking-u.	Neslaganje text layer-a i rendera čini ekstrahovani sadržaj nepotvrđenim dokazom za naučne tvrdnje.
6 9	„Nevidljiv/stari PDF tekst treba obrisati bez traga.“	To bi uništilo dokaz incidenta i otežalo reprodukciju.	Raw evidence ostaje; canonical approved text ga isključuje uz datiranu odluku i parser/render verzije.
7 0	„Skriveni PDF tekst je samo dokumentni problem, nema veze sa hemijom.“	Pogrešan tekst može kontaminirati RAG, klasifikaciju teme, labels, deduplikaciju i provenance.	Hemijske tvrdnje izvedene iz dokumenta nasleđuju neizvesnost ekstrakcije; nevidljiv tekst nije isto što i opažen sadržaj.

7. Sličnost i ML evaluacija

#	Zabluda	Šta je tačno	Konceptualna posledica / primer provere
7 1	„Hemijska sličnost je objektivno jedan broj.“	Composition, graph, coordination, conformation, packing, interactions i property relevance su različiti claim-i.	Prikazuj component scores/evidence; combined score samo verzionisan i task-kalibrisan.
7 2	„Tanimoto 0,8 univerzalno znači veoma slično.“	Značenje zavisi od fingerprinta, radius-a, bit length-a, standardizacije, veličine i domena.	Score mora nositi representation profile; threshold se bira na validation set-u za konkretan task.
7 3	„2D fingerprint meri crystal packing.“	Fingerprint lokalnog grafa ne kodira cell/symmetry/periodično okruženje.	Koristi ga za candidate generation, zatim posebno packing poređenje. Hard test: isti graf/drugi polymorph.
7 4	„Nizak RMSD dokazuje slične strukture.“	RMSD može biti nizak na tri odabrana atoma, pogrešnom mapping-u ili mirror-u; zavisi od alignment policy-ja.	Navedi mapping, N , coverage, max deviation, symmetry/H/stereo i coordinate provenance.
7 5	„RMSD se može računati pre component/atom mapping-a.“	Bez uparivanja ne znaš koji atomi/komponente odgovaraju; ekvivalentni atomi daju više mapiranja.	Component mapping → atom mapping → alignment → RMSD, sa tie-breaker-om.
7 6	„not comparable je score 0.“	Nula je izračunata vrednost sa značenjem koje zavisi od mere: RMSD 0 označava poklapanje, Tanimoto 0 odsustvo zajedničkih bitova uz nepraznu uniju. Not comparable znači da poređenje nije definisano ili izvodljivo.	Nedefinisan rezultat nije ni nulta ni maksimalna udaljenost; zamena nulom pristrasuje rangiranje i agregate.
7 7	„Embedding udaljenost je hemijska istina.“	Embedding optimizuje cilj i bias trening podataka; može ignorisati metal, stereo ili packing.	Probe, hard-negative, out-of-domain i explanation testovi; transparentni baseline-i ostaju obavezni.
7 8	„Vector database je source of truth.“	Indeks je lossy/verzionisani derived cache i može biti zastareo.	Original/provenance žive drugde; svaki vektor ima source/version ID i može se reindeksirati.
7 9	„Brz ANN je dobar retrieval sistem.“	ANN može propustiti susede, a i tačni susedi po pogrešnoj reprezentaciji mogu biti hemijski nerelevantni.	Odvojeno meri ANN recall prema tačnoj pretrazi iste reprezentacije/metrike i candidate recall prema ekspertskoj relevantnosti, nad istim dozvoljenim korpusom/filterima i po podgrupama.
8 0	„Top-k susedi sadrže sve parove iznad praga.“	Ograničen top-k može izostaviti par iznad praga, naročito u gustom delu prostora.	Za pun all-pairs režim svaki par mora dobiti rezultat/status. Za garantovano nalaženje svih parova iznad praga potrebna je iscrpna pretraga ili dokazano konzervativna granica; visok empirijski recall sam nije takva garancija.

#	Zabluda	Šta je tačno	Konceptualna posledica / primer provere
8 1	„Više podataka automatski daje bolji model.“	Duplikati, pogrešne etikete, bias, missingness i licencne granice mogu pogoršati generalizaciju.	Data audit, family dedup, slice balans, label provenance i learning curves.
8 2	„Lokalni ConQuest rezultati reprezentuju ceo CSD.“	To je query-conditioned DAP subset bez uključenih standardnih quality/3D filtera; pun CSD nije dostupan.	Ne generalizuj globalne distribucije. Evaluation population i query snapshot moraju biti eksplicitni.
8 3	„Random record split je dovoljno pošten.“	Bliski refcodes, redeterminations, ista compound family ili publikacija mogu završiti na obe strane.	Group/scaffold/solid-form/time split prema claim-u, pre tuninga.
8 4	„Accuracy je dovoljna metrika.“	Kod retkih pozitivnih parova model sve negativno može imati visoku accuracy; retrieval zahteva ranking metrike.	Precision/recall/PR-AUC, recall@k/nDCG, calibration, coverage i slice analiza.
8 5	„Lepa heatmap ili klaster dokazuje naučnu validnost.“	Vizuelni obrazac može biti artefakt distance, linkage, scaling-a ili dataset bias-a.	Ground truth/rubrika, stability test, baseline i ekspertna analiza grupa pre claim-a.
8 6	„Ground truth je naziv query-ja ili database field.“	Naziv izražava nameru; query constraints mogu biti slabiji. Kurirana polja mogu imati scope i missingness.	Naziv upita ili polja nije ground truth; validna etiketa zahteva unapred definisan kriterijum vezan za dokaze.
8 7	„Ako dva eksperta ne slažu, većina daje objektivnu istinu.“	Neslaganje otkriva ambiguous definiciju ili nedovoljan dokaz.	Čuvaj individual labels/confidence/reason; adjudication i verzionisana rubrika.
8 8	„Score 0,9 znači 90% verovatnoću relevantnosti.“	Sirov similarity/logit nije kalibrisana probability.	Validation calibration, reliability analiza i jasno različita polja similarity, probability, evidence_confidence.
8 9	„Visok model confidence poništava loš input.“	Model može biti samouveren nad pogrešno percipiranim grafom ili out-of-domain metalom.	Input quality i model uncertainty su odvojeni; claim može abstain uprkos visokom score-u.
9 0	„Jedna ukupna metrika znači da sistem radi svuda.“	Prosek može sakriti neuspeh za metale, solvates, disorder, velike/fleksibilne molekule ili missing 3D.	Ukupan prosek ne implicira pouzdanost po podgrupama; neuspeh u relevantnom slice-u ograničava opšti claim.
9 1	„LLM može sam potvrditi hemijsku istinu iz teksta/CIF-a.“	LLM može korisno objašnjavati, ali može halucinirati, pogrešno parsirati i nema eksperimentalni oracle.	LLM izlaz nije nezavisan dokaz hemijske istine; zaključak ostaje ograničen primarnim podacima i proverljivim metodama.

8. Federativno učenje, privatnost i licence

#	Zabluda	Šta je tačno	Konceptualna posledica / primer provere
9 2	„Federativno učenje garantuje privatnost jer raw fajlovi ne napuštaju instituciju.“	Gradients/update-i i konačni model mogu odavati informacije; lokalni logovi i coordinator su deo threat model-a.	Secure aggregation/DP gde odgovara, leakage testovi, minimalni outputs i pravno odobren protokol.

#	Zabluda	Šta je tačno	Konceptualna posledica / primer provere
9 3	„Secure aggregation rešava svaku privatnost.“	Skriva pojedinačne update-e od servera pod pretpostavkama, ali ne rešava malicious clients, final-model inference, endpoint security ili licencu.	Threat model po akteru i artefaktu; kombinuj kontrole, ne naziv tehnologije.
9 4	„Differential privacy je besplatna i automatska.“	Potrebni su clipping, noise, ϵ , δ , composition accounting i utility trade-off; pogrešna implementacija nema garanciju.	Privatnost budget i scientific utility se prijavljuju zajedno.
9 5	„Embedding/model nije raw CIF, pa se slobodno objavljuje.“	Može biti licencno izvedeni materijal, memorisati detalje ili omogućiti rekonstrukciju/inference.	Ugovorna analiza, derivative registry, leakage/reconstruction test i pisano odobrenje kada je potrebno.
9 6	„CSD je akademska baza pa su raw podaci open.“	CSD Portfolio i njegovi data files/subsets su licencirani proprietary sadržaj po javnim CCDC uslovima.	Akademska dostupnost ne daje pravo na redistribuciju; dozvoljeni obim upotrebe određuje konkretna licenca.
9 7	„Private GitHub repo rešava CSD licencu.“	Private kontroliše vidljivost, ali i dalje kopira podatke trećem hostu, backup-ima, naložima i lokacijama.	Proveri dozvoljenu lokaciju/korisnike; bez odobrenja licensed data-plane ostaje odvojen.
9 8	„Ako nešto mogu preuzeti preko API-ja, smem da ga keširam i delim.“	Tehnički access, processing, retention, redistribution i publication su odvojena prava.	Dozvola za pristup ne implicira dozvolu za obradu, čuvanje, izvedene artefakte ili redistribuciju; svako pravo je zasebno.
9 9	„Citiranje zamenjuje dozvolu.“	Citiranje priznaje izvor; ne daje pravo kopiranja/redistribucije ili treninga.	I citation i licence compliance su potrebni; proveri obavezni CCDC citation tekst.
1 0 0	„FAIR znači open, besplatno i bez logina.“	FAIR Accessible može koristiti authentication/authorization; cilj je pronalaženje, standardan pristup, interoperabilnost i ponovna upotreba pod uslovima.	Kontrolisan ili ograničen pristup nije suprotan FAIR principu.
1 0 1	„Open fajl je automatski FAIR.“	Bez stabilnog ID-a, metadata, semantike, provenance-a i licence javni dump može biti slabo reusable.	Otvorenost nije ni nužan ni dovoljan uslov za FAIR; ponovna upotrebljivost zavisi i od stabilnog ID-a, metapodataka, semantike, provenance-a i licence.
1 0 2	„FAIR je potvrda naučnog kvaliteta.“	FAIR opisuje upravljanje/pristup/semantiku; ne garantuje tačan crystal model, property ili unbiased labels.	FAIR status sam po sebi ne potvrđuje naučnu validnost, bezbednost ni licencnu usklađenost; svaka od tih tvrdnji zahteva odgovarajući dokaz.
1 0 3	„Brisanje raw fajla briše njegov uticaj.“	Cache, fingerprints, embeddings, modeli, pair reports i backup-i mogu ostati derivative.	Brisanje izvora ne uklanja informaciju već kodiranu u izvedenim artefaktima; njihov preostali uticaj mora se proceniti zasebno.

Brzi test za novu tvrdnju

Ako rečenica sadrži „**uvek**“, „**nikad**“, „**isti**“, „**tačan**“, „**stabilan**“, „**privatan**“ ili „**sličan**“, postavi šest pitanja:

1. Koji tačno objekat i scope?
2. Pod kojim hemijskim, temperaturnim i eksperimentalnim uslovima?
3. Da li je informacija izmerena, prijavljena, izvedena ili modelovana?
4. Koja definicija, algoritam, verzija i prag?
5. Koja neizvesnost, missingness i domen važenja?
6. Koja dozvola važi za ulaz i svaki derivative?

Ako odgovor nedostaje, ublaži claim ili vrati `unknown/ambiguous/not assessed`.

Mini-vežbe sa odgovorima

1. Visok 2D score, bez ćelije

Query i pogodak imaju Tanimoto 0,91, ali target nema cell/symmetry. Da li sistem sme da napiše „isti packing“?

Odgovor

Ne. Može prijaviti 2D similarity uz pun fingerprint profil. Packing grana vraća `missing-input`; 2D graf ne meri periodični raspored.

2. Metal u rezultatu

ConQuest query nalazi DAP motiv i nepovezan `4M`. Da li je label `DAP_tridentate_complex=true`?

Odgovor

Ne. To je kandidat koji sadrži motiv i neki metal. Potrebni su component assignment, tri konkretna donor N mapping-a, metal-neighbor/geometry dokaz i pravilo za ambiguous slučajeve.

3. Dobar R i ozbiljan alert

CIF ima nizak R, ali checkCIF upozorava na moguću propuštenu simetriju. Koji signal pobeđuje?

Odgovor

Nijedan sam. Pregledaj alert, alternative space-group model, residuals, refinement i hemijsku razumnost. Quality je skup dokaza; nizak R ne poništava strukturnu hipotezu koju alert dovodi u pitanje.

4. Skrивene dve rečenice u PDF-u

Embedded extractor nalazi temu koju render ne prikazuje. Da li je brisanje tih rečenica dovoljno?

Odgovor

Ne. Sačuvaj raw tekst kao provenance evidence, označi stranice i konflikt, potvrdi render/OCR, isključi ga iz approved indeksa i zapiši alat/verziju/QA odluku.

5. Model iz CSD-derived podataka

Weights ne sadrže lako čitljiv CIF. Da li mogu u javni repo?

Odgovor

To se ne može zaključiti iz formata weights-a. Proveri konkretni ugovor i CCDC uslove za derived artifacts, svrhu/distribuciju, mogućnost memorisanja ili rekonstrukcije i potrebno pisano odobrenje.

Gde proveriti detalje

- hemijski identitet i veze: [poglavlja 1–4](#);
- koordinaciona hemija: [poglavlje 5](#);

- interakcije, ćelija i kvalitet: interakcije, ćelija, difrakcija;
- forme, referentne raspodele i stabilnost: čvrste forme, Mogul/HBP;
- konverzija, standardizacija i lifecycle: formati, standardizacija, lifecycle stanja;
- reprezentacije i score: reprezentacije, sličnost;
- evaluacija, licence i FAIR: evaluacija, licence i provenance.

Izvori i metod validacije

Poslednji sadržajni pregled: 2026-09-05. Lokalni nalazi ponovo su provereni nad dostavljenim fajlovima, a primarni izvori za naučne korekcije i ključne dinamičke tvrdnje otvoreni tokom pregleda. Ovo nije tvrdnja da je svaki bibliografski link ili svaka softverska mogućnost lokalno reprodukovana; za to su potrebni odgovarajući runtime, podaci i dozvole.

Pregled obuhvata svih 36 hemijskih i 15 ML/AI Markdown stranica, uključujući rečnik, zablude, vežbe, rešenja i planove učenja. Lokalna provera koristi svih 15 izvornih artefakata iz 2CDC, Gemmi 0.7.5 za CIF, nezavisno čitanje MOL2/SD/SMI zapisa i statičku inspekciju CQS-a bez izvršavanja pickle sadržaja. Svih 22 strana white paper-a provereno je i vizuelno. Brojčani agregati lokalnih pretraga, N14 i CAPHEK kontrolni računi potvrđeni su; opravdane dopune odnose se na značenje skorova i kalibracije, zavisnost parova u evaluaciji, poreklo H geometrije, HBP terminologiju i početničke međukorake. To nije benchmark predloženih modela niti potvrda njihovog rada nad punim CSD-om.

Dinamičke i licencne tvrdnje moraju ponovo da se proveru

CCDC licenca, Conditions of Use, portfolio/proizvodi, API ponašanje, dokumentacija i broj CSD zapisa mogu se promeniti. Proveri ih **pre svakog izdanja, deployment-a, novog načina obrade, deljenja ili objavljivanja**, a ne samo na datum ove stranice. Merodavan je ugovor konkretne institucije i pisano tumačenje vlasnika podataka; ova knjiga nije pravni savet.

Ova strana ima dve uloge:

- 1. propisuje kako jedna tvrdnja postaje dovoljno proverena za kurs, kod, proizvod ili disertaciju;
- 2. daje organizovan registar primarnih i autoritativnih izvora korišćenih kroz kurs.

Hijerarhija nije „jedan sajt je uvek najbolji“

Autoritet zavisi od vrste tvrdnje. IUPAC je pravi izvor za hemijski termin, ali nije izvor za ponašanje CSD Python API-ja. CCDC dokumentacija je pravi izvor za sopstveni proizvod, ali vendor white paper nije dovoljan dokaz univerzalnog naučnog mehanizma.

Vrsta tvrdnje	Prvi izbor	Drugi dokaz	Šta nije dovoljno
hemijska nomenklatura/definicija	važeća IUPAC preporuka ili Gold Book termin sa verzijom	stručni originalni/review rad za kontekst	blog, search snippet, LLM odgovor
kristalografska definicija/CIF polje	IUCr dictionary, International Tables ili CIF dictionary	originalni metodološki rad/IUCr vodič	softverski tooltip bez verzije
naučni metod ili empirijski rezultat	originalni peer-reviewed rad i njegov tačan scope	nezavisna replikacija/review; lokalni benchmark	vendor claim ili citiranje samo apstrakta
CCDC funkcija/proizvod	zvanična CCDC dokumentacija tačne release/API verzije	reprodukcioni test u licenciranom okruženju	pretpostavka na osnovu imena funkcije
licenca/dozvoljena upotreba	potpisani ugovor institucije + važeći zvanični CCDC uslovi	pisana odluka CCDC-a/data owner-a i interni pravni review	private repo, tehnička dostupnost ili citat
broj/obim CSD-a	datirani CCDC statistics snapshot	query manifest za stvarno korišćen release	hardkodovana brojka bez datuma
lokalni fajl/upit	netaknut fajl + hash + deterministička inspekcija	nezavisna alatka/render i stručni review	filename ili opis pošiljaoca

Vrsta tvrdnje	Prvi izbor	Drugi dokaz	Šta nije dovoljno
uvodna hemija	autoritativni udžbenik kao OpenStax	IUPAC/IUCr izvor kada termin ulazi u šemu	popularni sažetak kao jedini dokaz
FAIR/provenance	originalni FAIR rad + W3C PROV standard	implementacioni profil i audit test	slogan „open by default“

Praktična hijerarhija dokaza

1. **Normativni izvor:** standard, rečnik ili važeći ugovor određuje značenje/pravilo.
2. **Primarni naučni izvor:** originalni rad određuje metod, dataset i empirijski rezultat u svom scope-u.
3. **Reprodukcioni dokaz:** kod/test nad tačno navedenim verzijama pokazuje šta naš sistem radi.
4. **Lokalni dokaz:** hashirani ulaz i audit trag potvrđuju šta postoji u konkretnom artefaktu.
5. **Sinteza:** review/udžbenik povezuje teme, ali se kritičan claim vraća na nivoe 1–4.
6. **Orijentir:** blog, prezentacija, search rezultat ili LLM mogu pomoći da se izvor pronađe; nisu kraj validacije.

Dve vrste „primarnog izvora“

Za tvrdnju „šta piše u `cu_n14_a.cif`“ primaran je lokalni fajl. Za tvrdnju „šta je occupancy“ primaran je IUCr rečnik. Lokalni primer ne postaje univerzalna definicija, a rečnik ne potvrđuje da je konkretan fajl ispravno refiniran.

Protokol validacije tvrdnje

Korak 1 — napiši atomaran claim

Loše:

CSD je kvalitetna baza i naš similarity radi dobro.

Dobro:

U CCDC snapshot-u datiranom 1. januar 2026. prijavljeno je 1.431.347 CSD struktura; ta brojka opisuje taj snapshot, ne budući release.

Hipotetički primer dobre forme tvrdnje (broj nije rezultat ovog projekta):

Kada bi validirani held-out compound-family test skupa `eval-v1` pokazao 97,2%, tvrdnja bi glasila: candidate generator vraća 97,2% ekspertski relevantnih DAP analoga u prvih 100 kandidata, uz fingerprint profil `ecfp-v3` i navedeni interval neizvesnosti.

Jedan ledger red treba da sadrži jednu proverljivu tvrdnju. Spoj „i zato“ često skriva nedokazanu inferenciju.

Korak 2 — klasifikuj promenljivost i rizik

Klasa	Primer	Tipični review trigger
normative-stable	definicija Braggovog zakona, CIF data name	nova verzija standarda/rečnika ili godišnji audit

Klasa	Primer	Tipični review trigger
scientific-scoped	rezultat konkretnog peer-reviewed rada	novi dokaz, replikacija, promenjen projektni scope
local-forensic	2.038 lokalna metal-filterovana rezultata	promena bilo kog fajla/hash-a ili parsera
empirical-system	recall@100 modela v1	novi model, dataset, split, feature ili threshold
dynamic-statistic	broj CSD struktura 1.1.2026.	svaki novi CSD snapshot/release
product-behavior	API metoda/field podržani u eksplicitno navedenom release-u	upgrade API-ja, licence ili platforme
licence-legal	redistribucija CSD-derived podataka	svaki release/deployment/partner/purpose/ugovor
interpretive	nevidljivi, tematski nepodudarni embedded PDF tekst; „zaostali sloj/šablon“ je samo mogući uzrok	novi PDF forensic dokaz; uzrok jasno označiti kao inference

Korak 3 — pronađi izvor odgovarajuće vrste

- za termin: idi na IUPAC/IUCr definiciju, ne na sekundarni članak;
- za metod: pronađi originalni rad, ne samo kasniju implementaciju;
- za alat: otvori zvaničnu dokumentaciju i zabeleži verziju;
- za licencu: pročitaj aktuelni tekst i konkretni institucijski ugovor;
- za lokalni artefakt: izračunaj hash i sačuvaj reproduktivnu komandu/test;
- za broj: zabeleži `as_of` datum, release i direktan snapshot.

Korak 4 — proveriti šta izvor zaista podržava

Zapiši:

- tačnu sekciju, tabelu, CIF data name, stranu ili DOI;
- populaciju, uslove, dataset i ograničenja;
- da li je tekst definicija, opažanje, preporuka ili vendor opis;
- da li naš zaključak stoji direktno u izvoru ili je **inferencija**;
- moguću kontradikciju ili noviji izvor.

Naslov i apstrakt nisu dovoljni za numerički ili metodološki claim. DOI potvrđuje identitet rada, ne da naš sistem reprodukuje rezultat.

Korak 5 — reprodukuji lokalno, gde je primenljivo

Za CIF:

1. schema-aware parse;
2. nezavisna provera ključnih data names;
3. formula/site/ Z /density cross-check;
4. symmetry/PBC i round-trip test;
5. checkCIF uz lokalnu politiku poverljivosti;
6. stručni pregled alerts/hemije.

Za PDF:

1. original + hash + broj strana;

2. embedded text po strani;
3. render relevantnih/svih strana;
4. OCR/visible-text poređenje kada treba;
5. conflict log i human QA odluka.

Za ML:

1. immutable dataset/split manifest;
2. transparentni baseline;
3. leakage/family audit;
4. held-out metrike i intervali;
5. slice, calibration, abstention i invariance testovi;
6. model/feature/environment verzije.

Korak 6 — review i životni ciklus

- **draft**: claim postoji, dokaz nije kompletan;
- **verified**: izvor i lokalni test pokrivaju ceo navedeni scope;
- **qualified**: tačan samo uz eksplicitno ograničenje;
- **disputed**: izvori/stručnjaci se ne slažu;
- **superseded**: novija definicija/verzija ga je zamenila;
- **blocked**: nedostaje dozvola ili ključni dokaz; ne ide u proizvod/publikaciju.

Confidence (high/medium/low) nikad ne zamenjuje status ni dokaz.

Claim ledger: potrebne kategorije dokaza

Format nije propisan, ali svaki proverljiv zapis treba da odgovori na sledeće:

Kategorija	Značenje
claim_id	stabilan interni ID, npr. CLM-CIF-0042
claim_text	atomarna, proverljiva rečenica bez skrivene generalizacije
claim_class	jedna od klasa iznad
scope	objekat, populacija, uslovi, verzija i izuzeci
source_id	DOI/URL/ugovor/local SHA-256 manifest
support_location	strana, sekcija, tabela, data name ili test ID
support_type	direct, derived, inference, expert-judgement
local_evidence	test/report/artifact verzija koja reprodukuje claim
counterevidence	poznati konflikt ili none-found-as-of-date
status	draft/verified/qualified/disputed/superseded/blocked
confidence	high/medium/low sa razlogom
verified_by	osoba/uloga; za critical claim poželjna dva reviewera
verified_on	datum provere
revalidate_on	datum ili event trigger
supersedes	prethodni claim/version ID, ako postoji

Ovo su evidencione kategorije, ne buduća YAML schema, baza ili review workflow. Ista informacija može živeti u tabeli, registru ili drugom odobrenom formatu.

Primeri claim ledger-a za 2CDC

ID	Sažeta tvrdnja	Dokaz i scope	Status/revalidacija
CLM-LOCAL-CIF-001	cu_n14_a.cif navodi C25 H20 N3 O2 P; Cu nije u formula/site elementima.	lokalni CIF, formula fields + atom-site loop; filename i Cu K α nisu sastav	verified; ponovi ako se hash/parser promeni
CLM-LOCAL-CIF-002	isti CIF navodi R(all)=0,0347, wR(ref)=0,0838 i GoF=1,095.	direktna CIF polja; bez claim-a da jedan broj „dokazuje kvalitet“	verified/qualified; ponovi na promeni fajla
CLM-LOCAL-QUERY-003	lokalni search2 je podskup search1 sa 2.038/2.110 refcodes; query 4M nije povezan sa DAP motivom.	hashirani eksporti + set diff + .cqs constraints + ConQuest guide; važi samo za dostavljene fajlove	verified/qualified; novi query/export zahteva novi ledger red
CLM-PDF-004	embedded extraction sa strana 1–2 CCDC white paper-a vraća nevidljivi, tematski nepodudarni tekst o ultra-large GOLD docking-u koji render ne pokazuje.	originalni PDF, SHA-256 3A4D2597158505C0B4956BB967B7DFA294FF7E88 04AB29450444C9157D23C612; page extraction + render svih 22 strana	verified kao lokalni konflikt; „zaostali sloj/šablon“ ostaje samo inference
CLM-IUCR-005	R i wR imaju različite definicije i ne smeju se tretirati kao ista skala.	IUCr CIF dictionary/statistical descriptors	verified; proveriti dictionary verziju godišnje
CLM-CSD-006	CCDC snapshot 1.1.2026 navodi 1.431.347 struktura.	datirani official statistics PDF	verified; obavezno promeni/revalidiraj na sledećem release-u
CLM-LIC-007	javni Conditions of Use ograničava redistribuciju CSD komponenti i derived software/data bez odgovarajućeg odobrenja.	važeći CCDC Conditions of Use; konkretan institucijski ugovor ima prednost	qualified; legal review pre svakog načina deljenja/objave
CLM-FAIR-008	FAIR Accessible ne zahteva anonimn/open pristup; A1.2 dopušta authentication/authorization kada su potrebni.	originalni FAIR principi	verified; FAIR nije quality ili licence grant
CLM-GSK-009	u Kalash et al. analiziranom skupu GSK i CSD Drug Subset se podudaraju u nekim crystal descriptors, ali ne u diversity solid-form space.	originalni rad D1CE00665G; ne generalizovati na svaku proprietary bazu	qualified; novi dataset/studija zahteva nov claim
CLM-ML-010	federativno učenje ne daje samo po sebi punu privatnost.	FedAvg definiše decentralized update obrazac; secure aggregation i leakage radovi pokazuju dodatni threat model	verified kao bezbednosno ograničenje; revalidirati protokol/implementaciju

Pravila citiranja u kursu, kodu i disertaciji

- U tekstu navedi **tačan claim uz izvor**, ne listu URL-ova na kraju bez veze.
- Za definiciju navedi verziju rečnika kada je dostupna; IUPAC Gold Book se aktivno ažurira.
- Za DOI rad navedi autore, naslov, časopis/godinu i DOI u bibliografiji disertacije.
- Za software/API rezultat navedi CCDC release/API verziju, licence boundary i parametre.
- Za CSD statistiku uvek navedi **as of** datum.
- Za lokalni fajl navedi filename samo radi čitljivosti; identitet zasnivaj na hash-u i manifestu.
- Direktna citat koristi samo kada je formulacija normativno važna; inače sažmi svojim rečima i ne kopiraj duge odlomke.

- White paper je izvor ciljeva i primera; svaki naučni claim iz njega proveriti u standardu ili originalnom radu koji citira.
- Claim u disertaciji koji zavisi od našeg modela mora imati zamrznut dataset/split/model/test manifest, ne samo Git commit.

Autoritativni izvori: IUPAC

IUPAC izvori određuju hemijsku nomenklaturu i preporučene definicije. Online Gold Book termin navodi sopstveni DOI/status; verziju termina treba zabeležiti u ledger-u.

Opšti jezik i koordinaciona hemija

Izvor	Za šta se koristi u kursu
IUPAC Gold Book — početna strana	centralni indeks hemijske terminologije
IUPAC Periodic Table	važeći simboli, imena i standardni periodni sistem
Ligands, L03518	značenje liganda u koordinacionoj hemiji
Coordination entity, C01330	centralni atom + ligands kao jedinka
Crystal field, CT06770	razdvajanje crystal-field i ligand-field pojma
Ligand-field splitting, L03517	termin za cepanje orbitalnih energetske nivoa
High-/low-spin, LT06788	precizna razlika načina popunjavanja split <i>d</i> -orbitala
Jahn–Teller effect, J03361	veza elektronske degeneracije i strukturne distorzije
Unit cell, U06562	hemijsko-terminološka definicija ćelije; IUCr ostaje detaljniji kristalografski izvor
Standard uncertainty, S05928	s.u. kao jedna standardna devijacija

Interakcije i čvrste forme

Izvor	Za šta se koristi
IUPAC preporuka: definition of the hydrogen bond	kriterijumi i terminologija H-veze
IUPAC preporuka: definition of the halogen bond	kriterijumi i terminologija halogene veze
Polymorph, 15225	osnovna definicija polimorfa u pharmaceuticals kontekstu
Crystal polymorph, 14219	crystalline phase terminologija, naročito napomene za polimere
Solvate, 15234	solvat
Hydrate, 15195	hidrat

Autoritativni izvori: IUCr

Rečnik kristalografije

Izvor	Uloga
IUCr Online Dictionary	ulaz u standardizovane kristalografske pojmove
Crystal structure	kristalna struktura naspram molekula/rešetke
Unit cell	ćelija i njena translaciona uloga
Asymmetric unit	minimalni nezavisni deo space-group prostora

Izvor	Uloga
Z and Z'	definicija $Z' = Z/m$, uključujući razlomljene vrednosti na specijalnim pozicijama; numeričke primere proveriti nezavisno
Space group	grupa operacija periodične simetrije
Clegg 2019: Some reflections on symmetry: pitfalls of automation and some illustrative examples	razlika Sohncke grupa, hiralnosti i prisustva enantiomera u kristalu
Lattice system	razlika lattice-system i crystal-system klasifikacije
Miller indices	značenje (hkl) ravni/refleksije
Reciprocal lattice	operativni real-space/reciprocal-space most
Bragg's law	$2d \sin \theta = n\lambda$ i difrakcioni uslov
Refinement	razlika structure solution/refinement i cilj optimizacije
Statistical descriptors	residuals, uncertainty i tumačenje statistike
Co-crystal	kristalografska definicija kokristala i terminološki opseg
Crystallographic Information Framework	priroda CIF standarda

CIF, validacija i učenje simetrije

Izvor	Uloga
IUCr CIF dictionaries	autoritativna semantika data names; zabeležiti dictionary verziju
Core CIF dictionary browser	direktna provera polja iz <code>cu_n14_a.cif</code>
IUCr CIF guide	praktična sintaksa/data-block/loop osnova
checkCIF	strukturisana validacija CIF-a; za poverljive podatke prethodno proveriti policy slanja
checkCIF FAQ	alerts i Validation Response tumačenje
PLAT076 primer	occupancy/site multiplicity zamka
Teaching pamphlet 2	početnička mapa sistema i 14 Bravaisovih rešetki
IUCr Bravais nomenklatura	standardne oznake $aP - cF$ i trigonal/rhombohedral nijansa
Teaching pamphlet 9	matrice, translacije i transformacije
Teaching pamphlet 10	metric tensor i ćelijska geometrija
Teaching pamphlet 21	crystal packing
Powder CIF dictionary	measured/calculated powder data, radiation, instrument i profile metadata

Autoritativni izvori: CCDC/CSD

Ovi linkovi su autoritativni za CCDC proizvode i njihove javne uslove, ali su **dinamički**. U produkcionom claim-u navedi datum pristupa, CSD Software/API release i stvarni ugovor.

Baza, statistika, citiranje i licenca

Izvor	Uloga i ograničenje
CCDC Conditions of Use za CSD Portfolio/API	javna licencna granica; konkretan ugovor/pisano odobrenje su merodavni
CCDC Standard Licence Agreement stranica	zvanični ulaz u standardni ugovor; proveriti trenutno izdanje i institucijski dodatak
How does licensing work for the CSD Portfolio?	aktuelni produktni/licencni kontekst; nije zamena za ugovor

Izvor	Uloga i ograničenje
CSD Entry Summary Statistics — 1 January 2026	datirani broj 1.431.347 struktura i drugi snapshot pokazatelji; ne hardkodovati kao trajne
How should I reference the CSD?	trenutno preporučena opšta CSD referenca; proveriti pre publikacije
Groom et al. 2016: The Cambridge Structural Database	peer-reviewed opis CSD-a i preporučena naučna referenca
Taylor & Wood 2019: A Million Crystal Structures	pregled razvoja i naučne ponovne upotrebe CSD znanja

CSD Python API i ConQuest ponašanje

Izvor	Uloga
CSD Python API dokumentacija	release notes, podržane funkcije i verzije
Reading/writing molecules and crystals	razlika molekulskog i crystal I/O modela
Search philosophy	vrste CSD pretrage
Substructure searching	query graph i constraints
Similarity searching	CCDC similarity behavior/parameters
Reduced-cell searching	lattice candidate search i tolerancije
Molecular geometry analysis	CSD-based bond/angle/torsion distribucije i standardizacija
Crystal objects, packing i contacts	symmetry expansion i crystal-level funkcije
Packing similarity	CCDC implementation parameters/results; vezati na tačnu verziju
Hydrogen-bond propensities	fitting evidence, logistic model, propensities, uncertainty i grouping/coordination output
Disorder	CCDC representation/obrada disorder-a
Descriptors	definicije dostupnih descriptor objekata
ConQuest User Guide	semantika 4M i query UI; sačuvati verziju uz .cqs manifest

Dokumentacija ne dokazuje lokalnu licencu

To što API stranica opisuje funkciju ne znači da je funkcija dostupna u vašem product tier-u, da imate CSD data access ili da rezultat smete eksportovati. Capability test i permission test su odvojeni.

Originalni i peer-reviewed radovi korišćeni u kursu

Kristalne interakcije i packing

Rad	Zašto je ovde
Etter, MacDonald & Bernstein 1990: Graph-set analysis of hydrogen-bond patterns in organic crystals	originalna graph-set sistematika za H-bond motive
Bernstein et al. 1995: Patterns in Hydrogen Bonding: Functionality and Graph Set Analysis in Crystals	proširenje/praktična primena graph-set jezika
Galek et al. 2007: Knowledge-based model of hydrogen-bonding propensity	primarni HBP metod; statistički output nije energetski ili polymorph oracle
Allen & Bruno 2010: Bond lengths in organic and metal-organic compounds revisited: X—H bond lengths from neutron diffraction data	referentne internuklearne X—H dužine i potreba da se navede normalizacija H geometrije
Chisholm & Motherwell 2005: COMPACK	originalni pristup za prepoznavanje crystal-structure/packing sličnosti

Cheminformatika i reprezentacije

Rad	Zašto je ovde
Rogers & Hahn 2010: Extended-Connectivity Fingerprints	primarni ECFP/circular fingerprint metod; implementation parametri i dalje moraju biti navedeni
Groom et al. 2016: The Cambridge Structural Database	sadržaj, kuracija i uloga CSD-a
Taylor & Wood 2019: A Million Crystal Structures	širok pregled strukturnog znanja izvedenog iz CSD-a

Čvrste forme i relevantnost proprietary podataka

Rad	Zašto je ovde i granica claim-a
Aitipamula et al. 2012: Polymorphs, Salts, and Cocrystals — What's in a Name?	stručna terminološka rasprava; regulatorna klasifikacija se dodatno proverava u aktuelnom FDA/EMA kontekstu
Bryant et al. 2019: The CSD Drug Subset	scope approved-drug crystal subset-a i poređenje hemijskog prostora; broj zapisa je istorijski rezultat tog rada
Xin et al. 2019: Solvate Prediction for Pharmaceutical Organic Molecules with Machine Learning	primer CSD-derived supervised ML za solvate propensity; ne preneti objavljeni performance van njihovog skupa
Kalash et al. 2021: First global analysis of the GSK database of small molecule crystal structures	direktan dokaz da public/proprietary skupovi mogu pokriti različit solid-form prostor; zaključak je scoped na analizirane baze
FDA Guidance: Regulatory Classification of Pharmaceutical Co-Crystals	zvanični regulatorni kontekst; nije univerzalna hemijska definicija i mora se revalidirati

FAIR, provenance i federativna privatnost

Izvor/rad	Zašto je ovde
Wilkinson et al. 2016: FAIR Guiding Principles	originalni FAIR principi; A1.2 pokazuje da Accessible može uključiti auth/authz
W3C PROV-O Recommendation	formalni model entity–activity–agent provenance relacija
McMahan et al. 2017: Communication-Efficient Learning of Deep Networks from Decentralized Data	primarni FedAvg/federated-learning obrazac
Bonawitz et al. 2017: Practical Secure Aggregation for Privacy-Preserving Machine Learning	secure aggregation kao dodatna kontrola, pod navedenim threat model-om
Zhu, Liu & Han 2019: Deep Leakage from Gradients	konkretn dokaz da gradient/update razmena može otkriti input informacije

OpenStax: početnički most do standarda

OpenStax Chemistry 2e je autoritativan, otvoreno dostupan udžbenički uvod. Koristi se za intuiciju i osnovne primere; kada pojam ulazi u produkcionu šemu, definicija se proverava u IUPAC/IUCr izvoru.

Tema kursa	Direktna OpenStax strana
atomska struktura, izotopi i simboli	2.3 Atomic Structure and Symbolism
hemijske formule	2.4 Chemical Formulas
jonska i molekulska jedinjenja	2.6 Ionic and Molecular Compounds
Lewisovi simboli i veze	7.3 Lewis Symbols and Structures
formalni naboj i rezonanca	7.4 Formal Charges and Resonance
VSEPR, 3D geometrija i polaritet	7.6 Molecular Structure and Polarity

Tema kursa	Direktna OpenStax strana
intermolekulske sile	10.1 Intermolecular Forces
rešetke i kristalne čvrste supstance	10.6 Lattice Structures in Crystalline Solids
Brønsted–Lowry acid/base	14.1 Brønsted–Lowry Acids and Bases
Lewis acid/base i kompleksi	15.2 Lewis Acids and Bases
Gibbsova slobodna energija	16.4 Free Energy
funkcionalne grupe	OpenStax Organic Chemistry 3.1

Dodatni standardi i referentna dokumentacija

Ovi izvori su korisni za implementaciju, ali se njihova software/version semantika mora zamrznuti u manifestu:

- [Daylight SMILES theory](#) — originalna teorija SMILES/SMARTS jezika;
- [RDKit Getting Started](#) — konkretna open-source implementacija fingerprints/descriptors; ne pretpostavljati kompatibilnost verzija;
- [Open Babel format overview](#) — format conversion mogućnosti; uspešna konverzija nije dokaz očuvanja značenja;
- [spglib symmetry dataset](#) — standardization/symmetry output polja i verzije;
- [MIT OCW 3.091 Solid-State Chemistry](#) — dodatni edukativni most za rešetke i čvrsto stanje;
- [GO FAIR Foundation: FAIR principi](#) — F1, A1.2 i A2 povezuju trajni identitet, kontrolisan pristup i dostupnost metapodataka; normativni claim vraćaj na originalni FAIR rad.

Lokalni artefakti: šta mogu, a šta ne mogu da dokažu

Artefakt	Validan lokalni dokaz	Nije validna generalizacija
CCDC_white_paper_sharpen.pdf	teme/problemi koje vendor white paper naglašava; 22 strane; konflikt nevidljivog, tematski nepodudarnog embedded teksta i rendera	univerzalna tačnost svakog marketinškog/naučnog claim-a; svaki cited rad se proverava zasebno
dve funkcionalnost i.txt	trenutni opis željena dva proizvoda	završni requirements, scientific definitions ili acceptance thresholds
cu_n14_a.cif	konkretna formula, ćelija, P_{21}/c , 100 K, refinement fields i ugrađeni blokovi	globalna distribucija CSD-a ili univerzalni quality prag
N14.mol / N14.mol2	kako dva izvoza kodiraju atoms/bonds/types/charges za ovaj primer	koji format je „uvek tačniji“
search1/search2 izvozi i .cqs	lokalni refcode skupovi, njihov set odnos i stvarni constraints	unbiased uzorak celog CSD-a ili dokaz DAP–metal koordinacije

Svaki lokalni claim mora navesti hash konkretnog izvora. Ako fajl ne sme u repo, manifest može čuvati hash, originalno ime, owner/licence status, bez samog sadržaja.

Šta ne prihvatamo kao finalni dokaz

- search-engine summary bez otvaranja izvora;
- Wikipedia ili blog kao jedini izvor kritične definicije;
- LLM odgovor, uključujući ovu knjigu, bez claim ledger dokaza;
- naslov rada bez čitanja metoda/scope-a;

- screenshot bez URL-a, datuma i verzije;
- vendor feature lista bez reproduktionog testa;
- filename ili naziv ConQuest query-ja kao hemijska etiketa;
- korelacija kao uzročni claim;
- jedan globalni prosek bez relevantnih slices;
- `private`, `academic` ili `FAIR` kao zamena za licencu.

Kada dokaz može da zastari

Promena/događaj	Koji deo tvrdnje može izgubiti važenje
novi CSD/API release	statistike, product behavior, query rezultat i representation kontekst
novi partner, lokacija ili svrha	ugovor, dozvoljene operacije, primaoci, retention i derivati
nova publikacija/disertaciona tvrdnja	scope, DOI metadata, dataset/model snapshot, novija literatura i limitations
nova IUPAC/IUCr/regulatorna verzija	terminologija, standard i regulatorni kontekst
incident ili promenjen source hash	svi povezani downstream nalazi i zaključci

Tačan raspored, odgovorne uloge i procedure održavanja nisu deo plana učenja.

Završna kontrolna lista izvora

- ☐ Svaka kritična rečenica ima `claim_id`.
- ☐ Izvor je odgovarajućeg tipa za tvrdnju.
- ☐ Pročitana je podržavajuća sekcija, ne samo snippet/apstrakt.
- ☐ Direktan dokaz i naša inferencija su odvojeni.
- ☐ Scope, uslovi, dataset, verzije i izuzeci su zapisani.
- ☐ Lokalni artefakt ima hash i reprodukcioni test.
- ☐ Dinamična brojka ima `as_of` datum.
- ☐ Software ponašanje ima verziju i capability test.
- ☐ Licencni claim ima ugovor/review trigger i fail-closed status.
- ☐ Kontradiktoran ili noviji dokaz je zabeležen.
- ☐ Datum provere je `2026-08-22` ili noviji.
- ☐ U publikaciji nema tvrdnje šire od dokaza.

Kada sva polja postoje, „verovali smo izvoru“ postaje proverljiv lanac: **claim** → **autoritativni izvor** → **lokalni dokaz** → **review** → **verzija** → **revalidacija**.